

基于单目场景的车辆三维目标检测方法综述

唐心瑶^{1, 2}, 王伟³

(1. 华南理工大学 电子与信息学院, 广东 广州 510640; 2. 广电运通集团股份有限公司, 广东 广州 510663;
3. 长安大学 信息工程学院, 陕西 西安 710018)

摘 要:近年来, 车辆三维目标检测在自动驾驶等智能交通领域备受关注。相较于二维检测, 三维检测可精确估计目标在三维空间中的位置、尺寸与姿态等信息。因单目相机具备成本低、数据处理效率高等优势, 在实际应用中占据主导地位。文章聚焦单目场景下的三维目标检测方法, 系统梳理其发展脉络。首先, 依据先验信息来源, 将检测方法分为基于几何信息、二维目标检测与几何信息约束、三维特征估计三类, 并分别剖析了每类方法中代表性算法的核心思想及其优缺点。其次, 介绍领域内常用的公共数据集与评价指标, 并在 KITTI 数据集上对典型算法的实验结果进行量化对比。最后, 结合当前研究现状, 剖析该领域现存的主要问题, 并展望未来发展趋势。

关键词: 智能交通; 单目相机; 三维目标检测; 深度学习
中图分类号: TP391.4 **文献标识码:** A **文章编号:** 2096-4706 (2025) 09-0016-10

Survey of Vehicle 3D Object Detection Methods Based on Monocular Scene

TANG Xinyao^{1,2}, WANG Wei³

(1.School of Electronic and Information Engineering, South China University of Technology, Guangzhou 510640, China;
2.GRG Banking Equipment Co., Ltd., Guangzhou 510663, China;
3.School of Information Engineering, Chang'an University, Xi'an 710018, China)

Abstract: In recent years, vehicle 3D Object Detection has attracted much attention in the field of intelligent transportation such as autonomous driving. Compared with 2D detection, 3D detection can accurately estimate the position, size and attitude of the target in 3D space. Because of the advantages of low cost and high data processing efficiency, monocular camera plays a leading role in practical applications. This paper focuses on the 3D Object Detection method in monocular scenes and systematically sorts out its development context. Firstly, according to the source of prior information, the detection methods are divided into three categories based on geometric information, 2D Object Detection and geometric information constraints, and 3D feature estimation. The core ideas, advantages and disadvantages of representative algorithms in each category are analyzed. Secondly, the common data sets and evaluation indexes commonly used in the field are introduced, and the experimental results of typical algorithms are quantitatively compared on the KITTI dataset. Finally, combined with the current research status, the main existing problems in this field are analyzed, and the future development trend is prospected.

Keywords: intelligent transportation; monocular camera; 3D Object Detection; Deep Learning

0 引 言

目前, 计算机视觉领域的三大任务包括图像分类、目标检测和图像语义分割。目标检测作为计算机视觉领域的基本问题, 旨在找出图像中特定类别的目标, 并确定目标在图像中的位置和尺寸。目标检测是解决分割、跟踪等更高层次视觉任务的基础, 在自动驾驶^[1-3]、增强现实^[4-5]等领域有广泛应用, 具有重要的研究意义和实用价值。

在实际应用中, 相较于二维目标检测获取图像层面的信息, 获取目标在三维空间中的位置等信息具有更为重要的意义。在自动驾驶领域, 车辆三维目标检测已成为研究热点。通过估计目标的三维位置, 自动驾驶车辆可以确定自身与周围物体的位置关系, 从而准确规划路径, 避免碰撞。当前车辆三维目标检测最常用的传感器包括激光雷达^[6-9]和以双目相机^[10-12]、RGB-D 深度相机^[13-18]为代表的立体视觉系统。这类传感器能够直接且准确地获取车辆目标在三维空间的位置信息, 但它们通常价格昂贵, 且对使用环境有较高要求。相比之下, 普通单目 RGB 相机^[19-22]价格低廉、部署简单, 数据处理速度快, 更适用于车辆所处的室外大尺度场景。然而, 由于单目相机本身的成像机制

收稿日期: 2024-01-04
基金项目: 陕西省自然科学基金基础研究计划项目
(2023-JC-YB-600)

限制,仅凭一幅图像无法恢复目标的三维位置。但对于特定类型目标,通过利用强先验信息作为约束,结合深度学习和射影几何知识,可以完成车辆三维目标检测任务。这也使得单目三维目标检测成为研究热点。

如图1所示,单目场景下车辆三维目标检测的基本目标为:给定一幅RGB图像,首先从中找出所有车辆目标,然后计算出图1中第二行3D包围框的8个顶点或能够表示第三行3D线框的若干特征点在图像中的坐标。接着,根据计算结果在原始图像中绘制车辆的3D包围框或3D线框,这分别被称为车辆三维目标检测和车辆三维形状检测。在3D包围框或3D线框的基础上,可进一步求解车辆目标的3D位置、尺寸和姿态等信息。




图1 单目场景车辆三维目标检测示意图

图2为当前单目场景下常用的车辆三维目标检测方法,主要可分为三大类:

- 1) 基于几何信息的方法^[23-26],这类方法又可分为基于CAD模型的方法^[23-25]和基于消失点的方法^[26]。
- 2) 基于深度学习二维目标检测和几何信息约束的方法^[27-36]。近年来,随着深度学习技术的不断成熟,卷积神经网络已成为二维目标检测中最常用的方法,其准确度高于传统混合高斯背景建模(GMM)等方法。因此,在车辆三维目标检测中,借鉴深度学习二维目标检测的思想或利用二维目标检测的结果,并结合多视图几何的理论知识,可以同时提高车辆三维目标检测的准确度和效率。然而,二维目标检测提供的约束信息有限,可能会带来二义性问题。
- 3) 基于深度学习三维特征估计的方法^[37-43]。该类方法借助三维特征(如车辆关键点),结合重投影等方法,直接回归出车辆目标3D包围框的8个顶点在图像中的投影坐标,无须依赖二维目标检测的结果,能在一定程度上避免二义性问题,并提高检测准确率。




图2 单目场景车辆三维目标检测方法分类

1 单目场景车辆三维目标检测

1.1 基于几何信息的方法

早期在深度学习技术未成熟时,研究人员大都通过提取图像中的几何信息来完成三维目标检测,几何信息通常包括CAD模型和消失点等,这些信息通过图像处理算法在场景中易于提取,且提取效率较高。

1.1.1 基于CAD模型的方法

由于特征点方法的缺陷,另一类思路是使用已知的CAD模型^[23-25]来描述车身结构,以提高算法准确度。文献[25]首先在已有CAD车辆模型库的基础上,通过主成分分析(PCA)的方法简化模型,得到粗3D线框模型如图3所示,用于描述同类车辆的几何不变性。接着,通过2D-3D结构和特征点匹配,确定车辆的最佳3D线框。虽然该类方法能够在一定程度上提高准确度,但算法的计算量较大,并且由于车辆种类复杂,CAD车辆模型库通常无法涵盖所有车辆。




图3 车辆CAD模型示意图

1.1.2 基于消失点的方法

为了提高算法效率,2014年,Dubská等^[26]提出了一种完全基于自标定的车辆三维目标检测方法。该方法既不受视角的限制,也不需要先验模型信息,仅需一段交通场景的监控视频。通过视频中的运动车流获取交通场景中三个互相正交的消失点,即可完成车辆三维目标的检测以及车辆速度和尺寸的测量,如图4所示。实验结果表明,该方法具有较好的实时性,但消失点的求取需要视频中大量车辆,且检测结果对相机标定结果具有较大的依赖性。




图4 基于消失点的方法实例图

为了进一步提高车辆三维目标检测的准确率和效率,随着深度学习目标检测技术的发展,通过构建卷积神经网络的方法直接回归出3D包围框,或在二维

目标检测的基础上结合几何信息回归出 3D 包围框,已成为目前车辆三维目标检测方法的主流。因此,本文针对该类方法作详细阐述。

1.2 基于深度学习二维目标检测和几何信息约束的方法

近年来,随着深度学习卷积神经网络技术的不断发展,涌现出一批优秀的二维目标检测网络,如 YOLO^[27]、CenterNet^[28]、SSD^[29]等。许多研究人员将二维目标检测中的 Region Proposal 思想直接应用于车辆三维目标检测,并取得了一些成果^[30-31],其中比较有代表性的为文献[31]的工作。2016年,Chen等^[31]将深度学习二维目标检测滑动窗口的思想引入到车辆三维目标检测中,首先在 3D 空间中生成一系列候选框,利用相机标定结果将其投影至图像平面,然后结合车辆轮廓、地平面约束和 2D 图像分割等复杂的先验信息,进一步推断出单目图像中存在车辆目标的区域和 3D 包围框,最后通过非极大值抑制挑选出最佳 3D 包围框。该方法可以直接生成候选框,原理简单,但 3D 空间的搜索范围比 2D 空间大得多,且结合了较多复杂的先验信息,大大降低了算法的运行效率。

受深度学习二维目标检测的启发,目前大多数车辆三维目标检测算法仍基于二维目标检测的结果。首先,通过卷积神经网络预测出目标的位置、尺寸和朝向等信息,为了提升算法效率,摒弃了直接在 3D 空间中生成候选框的方法,改用构建 2D-3D 空间几何约束(通常是 3D 包围框与 2D 包围框紧密贴合)的方法,以求解最佳 3D 包围框。

2017年,Mousavian等^[32]在二维目标检测的基础上,设计了一种使用 MultiBin discrete continuous 形式损失函数的网络,从裁剪图像的特征中分别回归出 3D 包围框的朝向和尺寸,将车辆三维目标检测结果投影至图像平面,构建 2D-3D 包围框紧密贴合的约束,从而恢复出准确的 3D 包围框,完成 3D 目标检测和位姿估计的任务。这种方法能在一定程度上提高算法效率,但对二维目标检测结果的依赖性较大,且仅从 2D 包围框中提取约束信息,仅能提取 4 组约束,容易产生二义性问题如图 5 所示。



图5 基于二维目标检测的 3D 包围框二义性问题示意图

为了避免二义性问题,Chabot等^[33]提出一个 Deep MANTA 的多任务网络,且预先定义了与车辆

形状相对应的模板,用于同时完成车辆三维目标检测和车辆三维形状检测的任务。算法处理过程可分为两阶段:第一阶段,使用 Region Proposal Network (RPN 网络)推断出一系列候选框,再经过 ROI Pooling 层和卷积层,得到最后的二维目标检测结果、车辆类型、位置、可见性和车辆与模板的相似度;第二阶段,根据车辆与模板的相似度,选择最合适的 3D 形状模板,与二维目标检测结果进行匹配,得到最后的检测结果。实验结果表明,该方法有效规避了二义性问题,但由于算法的 two-stage 特性,算法效率一般。

2018年,Yang等^[34]提出一种 CubeSLAM 的方法。首先,通过现有的 YOLO 目标检测网络完成二维目标检测;在此基础上,通过提取车身边缘直线段检测车辆目标的三个相互正交的消失点,以此消失点结果作为计算车辆目标 3D 包围框的依据。该方法不需要任何先验信息,且无须在 3D 全局空间搜索,因此效率较高,但对消失点的结果依赖较大。

2019年,He等^[35]提出一种 Mono3D++ 网络。在 SSD^[29]和 stacked hourglass 网络结构的基础上,分别设计出两个网络完成二维目标检测和 14 个能够表示车辆形状的 2D 特征点检测的任务。结合深度图、地平面和形状结构先验信息,构建 Mono3D++ 网络损失函数,推断出车辆的 3D 位姿和形状信息。实验结果表明,该方法能同时完成车辆三维目标检测、三维形状检测和 3D 位姿识别的任务,在算法效率和准确度上与文献[32-33]相比都有一定程度的提升。

由于单目图像固有的成像机制导致的深度缺失问题,仅依靠几何约束仍然无法获得精确的 3D 表示。因此,考虑通过单目图像恢复图像深度信息,以更好地进行 3D 信息表示,从而完成更加精确的 3D 包围框预测。然而,这种方法对深度估计的结果依赖较大。

Manhardt等^[36]提出了一种 ROI-10D 网络,使用 ResNet-FPN 结构进行 2D 目标检测和单目深度估计。随后,他们提出了一种 RoI lifting 过程,即在回归 3D 包围框之前,将 2D 目标检测所得的 RoI 区域在 ResNet-FPN 和深度网络的特征层上进行提取,再结合车辆形状 CAD 模型学习 3D 目标检测和位姿。Ding等^[37]提出了一个 single-stage 的 3D 检测器,其输入为原始 RGB 图像和使用深度估计网络预测所得深度图像。该检测器使用 ResNet-50 作为 backbone,分为两个分支,分别对两路输入提取特征,并在深度指导滤波模块将两路特征进行融合。最后,输入部分借鉴了目标检测中的 Anchor 机制,预测出 2D 包围框、3D 包围框、3D 尺寸、旋转角等信息的偏移量,再通过 NMS 和解码得到最终结果。该方法融合了单目图

像深度信息，在 KITTI 数据集上取得了 7 项第一。

1.3 基于深度学习三维特征估计的方法

为了避免仅从二维目标检测的包围框中提取信息构建约束产生二义性，并进一步提高算法的准确率和效率，研究人员尝试了一些新的思路。目前最新的单目场景车辆三维目标检测方法更关注 3D 信息的直接提取，也称为三维特征估计，即通过深度学习网络直接提取 2D 图像中能够用于 3D 任务的特征或关键点等信息，完成 3D 包围框的回归。

基于深度学习三维特征估计的方法早期在三维位姿估计的任务上使用较多。2017 年，Rad 等^[38]提出了一种 BB8 位姿估计网络，其基本思路是将实例分割后的裁剪 2D 图像送入第二层网络，预测出目标的 3D 包围框的 8 个顶点在 2D 图像平面上的投影。同年，Wadim 等^[39]提出的 SSD-6D 网络与 BB8 网络有类似的思路，在 SSD 网络的基础上，同时预测出 2D 包围框和粗略的车辆目标朝向。在使用深度学习网络获取三维特征后，这两种方法都需要对车辆目标经过进一步的位姿调整，以提升位姿估计的精确度。当场景中需要被检测的车辆目标数量增加时，算法处理时间会呈线性增长。结合前两种三维特征，Bugra 等^[40]提出了 YOLO-6D，在 YOLO 网络结构的基础上，直接预测出车辆目标 3D 包围框的 8 个顶点在 2D 图像平面上的投影和方向，然后使用 PnP 的方法估计车辆目标的 6D 位姿（包括 3D 位置和方向）。

2018 年，Ishan 等^[41]借鉴了这种三维特征提取的思想，提出了一种端到端的检测器，能够直接预测出车辆目标底部平面中心点在 2D 图像中的投影点坐标。通过建立的查找表，将该投影点坐标转换到 3D 空间中，实现车辆三维目标检测和 3D 位置估计。该方法不依赖二维目标检测的结果，在一定程度上提高了算法的效率。

Li 等^[42]提出了一种能够修正 3D 包围框的 GS3D 网络，包含两个子网络：2D+O 子网络和 3D 子网络。其中，2D+O 子网络在 Faster RCNN 网络框架的基础上，加入了一个车辆朝向预测分支，用于同时求解二

维目标检测和车辆方向的结果。在此基础上结合相机标定的结果，生成粗略的 3D 包围框（guidance）。3D 子网络用于提取 guidance 的可见面三维特征信息，完成 3D 包围框的修正，以得到更为精确的检测结果。

虽然算法的运行效率在逐渐提高，但是仍无法达到实时的需求。2019 年，Li 等^[43]首先提出了一种 RTM3D 的实时三维目标检测网络，图 6 为 RTM3D 方法的整体流程图。将车辆三维目标检测中的顶点检测看作关键点检测问题，无须借助二维目标检测结果。该网络分别基于 ResNet-18 和 DLA-34 网络构建，采用 pyramids 机制适应多尺度目标，可直接预测出 3D 包围框的 8 个顶点和 1 个中心点在 2D 图像中投影的坐标。然后，通过最小化重投影误差，可求解出目标尺寸、位置、方向角等未知参数，从而进一步求取 3D 包围框信息。实验结果表明，该方法对于截断和遮挡的情况也能准确检测，并且检测帧率（FPS）最高可达 30 帧/秒，具有较好的实时性。




图 6 所提方法 RTM3D 的整体流程图

2020 年，Ivan 等^[44]提出了一种端到端的基于关键点的 3D 目标检测和定位网络，将 Mask R-CNN 中的 FPN Resnet-101 作为 backbone，共包含 3 个分支：2D 目标检测子网络、2D 关键点回归子网络、三维尺寸回归子网络。与文献[33]一样，也使用了 3D CAD 模型，但对每个模型只标注了 14 个关键点，并且在几何推理模块将 2D-3D 空间联系起来，从而实现网络的端到端训练。

表 1 总结了单目场景下的车辆三维目标检测的代表性方法，并给出了具体的特点描述信息。

表 1 单目场景车辆三维目标检测代表性方法总结

文献方法	年份	可识别信息	先验信息	关键技术	数据集	是否受视角限制
Zia ^[25]	2013	3D 包围框、车辆形状	/	CAD 模型匹配	3D Object Classes, EPFL Multiview cars	是
Dubská ^[26]	2014	3D 包围框、车辆尺寸、行驶速度	/	相机标定	BrnoCompSpeed	否
Mono3D ^[31]	2016	3D 包围框	分割图像、地平面	3D 空间搜索	KITTI	是
Deep3DBox ^[32]	2017	3D 包围框、车辆位姿	/	几何约束	Pascal 3D+	否
DeepMANTA ^[33]	2017	3D 包围框、车辆形状、车辆位姿	/	几何约束	KITTI	否
CubeSLAM ^[34]	2018	3D 包围框	/	几何约束	KITTI, SUN RGBD	否

(续表)

文献方法	年份	可识别信息	先验信息	关键技术	数据集	是否受视角限制
Mono3D++ ^[35]	2019	车辆形状、车辆位姿	深度图、地平面、CAD 模型	几何约束	KITTI	否
ROI-10D ^[36]	2019	3D 包围框、车辆形状	深度图、CAD 模型	几何约束	KITTI	否
Depth-Guided ^[37]	2020	3D 包围框、车辆尺寸、偏航角	深度图	Anchor 机制	KITTI	否
Ishan ^[41]	2018	3D 包围框	/	三维特征点估计	KITTI	否
GS3D ^[42]	2019	3D 包围框	/	三维特征点估计	KITTI	否
RTM3D ^[43]	2020	3D 包围框	/	三维特征点估计	KITTI	否
Ivan ^[44]	2020	3D 包围框、车辆位置	CAD 模型	三维特征点估计	KITTI	否

2 数据集和算法性能评价

在进行单目场景车辆三维目标检测实验时，需要对各类方法进行详细、准确的评估，因此需要标准权威的数据集和统一的性能评价指标。本章对一些常用的公开数据集作了简明介绍和对比，列举了一些车辆三维目标检测中常用的性能评价指标，并在常用数据集上对实验结果进行了对比分析。

2.1 数据集

2.1.1 KITTI 数据集

图 7 为 KITTI 数据集示意图。KITTI 数据集^[45]由德国卡尔斯鲁厄理工学院和丰田美国技术研究院联合创办，是目前国际上最大的自动驾驶场景下的计算机视觉算法评测数据集。该数据集用于评测立体图像（stereo）、光流（optical flow）、视觉测距（visual odometry）、3D 物体检测（object detection）、3D 跟踪（tracking）和语义分割等计算机视觉技术在车载环境下的性能。KITTI 包含市区、乡村和高速公路等场景采集的真实图像数据，每张图像中多达 15 辆车和 30 个行人，还有不同程度的遮挡与截断。整个数据集由 389 对立体图像和光流图、39.2 km 的视觉测距序列以及超过 200K 带有 3D 标注物体的图像组成。对于 3D 物体检测，label 可细分为 8 个类别，包括 car、van、truck、pedestrian、pedestrian（sitting）、cyclist、tram 和 misc。根据截断、遮挡和目标大小的不同，可将检测任务分为简单、中等、困难三个级别。




图 7 KITTI 数据集示意图

2.1.2 Pascal 3D+ 数据集

图 8 为 Pascal 3D+ 数据集示意图。PASCAL 3D+ 数据集^[46]由斯坦福大学于 2014 年发布，是一个 3D 物体检测和姿态识别数据集，包含 PASCAL VOC 2012 中的 12 个类别物体的 3D 标注，平均每个类别

中有 3 000 个实例。



图 8 Pascal 3D+ 数据集示意图

2.1.3 ApolloScape 数据集

图 9 为 ApolloScape 数据集示意图。ApolloScape^[47]是百度 Apollo 自动驾驶开放平台的一个专题项目，它代表了目前行业内环境最复杂、标注最精准、数据量最大的三维自动驾驶数据集。ApolloScape 提供的数据量比 Cityscapes、KITTI 等同类数据集大 10 倍以上，包括感知、仿真场景、路网数据等数十万帧逐像素语义分割标注的高分辨率图像数据，以及与其对应的逐像素语义标注、稠密点云、立体图像、立体全景图像，并进一步涵盖了更复杂的环境、天气和交通状况等。



图 9 ApolloScape 数据集示意图

2.1.4 Waymo Open Dataset

图 10 为 Waymo Open Dataset 数据集示意图。

Waymo 数据集^[48]包含 3 000 段驾驶记录，总时长为 16.7 小时，平均每段时长约为 20 秒。整个数据集共有 60 万帧图像，包含约 2 500 万个 3D 边界框和 2 200 万个 2D 边界框。此外，该数据集涵盖了汽车、行人、自行车等 4 个类别的对象，并包含了不同的天气条件、采集时间和地点，在数据多样性方面有很大的提升。




图 10 Waymo Open Dataset 数据集示意图

2.1.5 nuScenes 数据集

图 11 为 nuScenes 数据集示意图。nuScenes 数据

集^[49]是自动驾驶公司 nuTonomy 建立的大规模自动驾驶数据集，该数据集包含了普通单目相机、激光雷达和雷达三种传感器采集的数据。数据集由 1 000 个场景组成，每个场景视频长度为 20 秒，其中包含 40 个手工标注的关键帧（key frames），标注信息涵盖目标的大小、范围、类别和可见程度。此外，该数据集还记录了车辆的运动轨迹，可用于实现更加智慧的识别算法和感知融合算法。




图 11 nuScenes 数据集示意图

表 2 总结了车辆三维目标检测常用公开数据集并给出了特点对比。

表 2 车辆三维目标检测数据集简介

数据集	年份	采集场景	采集方式	种类	数据总量	训练集	测试集
KITTI ^[45]	2012	城市道路、住宅区、校园	车载摄像机 / 激光雷达	8	80K	7 481	7 518
Pascal 3D+ ^[46]	2014	自然环境	普通 RGB 相机	12	20K	N/A	N/A
ApolloScape ^[47]	2018	城市	激光雷达	27	200K	17 062	1 973
Waymo ^[48]	2019	城市、郊区	车载摄像机 / 激光雷达	4	12M	N/A	N/A
nuScenes ^[49]	2019	城市	车载摄像机 / 激光雷达 / 雷达	23	1.4M	N/A	N/A

2.2 性能评价指标

目标检测中，常用的性能评价指标主要包括准确率（Accuracy）、召回率（Recall）、精确率（Precision）、平均精度（Average Precision, AP）、平均精度均值（Mean Average Precision, mAP）、交并比（Intersection over Union, IoU）、帧率（Frame Per Second, FPS）等，在单目三维目标检测中，通常使用 Recall 和 AP 这两个指标来衡量算法性能，具体定义及计算公式如下：

1) 召回率（R）。召回率又称为查全率，用于计算所有实际为正样本的样本中，被正确识别出来的正样本的比例。具体计算方法如式（1）：

$$R=\frac{TP}{TP+FN}$$
 (1)

2) 精确率（P）。精确率又称为查准率，用于计算所有被识别为正样本的样本中，实际为正样本的比例，具体计算方法如式（2）：

$$P=\frac{TP}{TP+FP}$$
 (2)

其中，TP（True Positive）表示实际为正样本识别为正样本，FN（False Negative）表示实际为正样本识别为负样本，FP（False Positive）表示实际为负样本识别为正样本。

3) 交并比。交并比用于确定包围框的预测结果（DetectionResult）与标注的真实值（GroundTruth）之间的重合程度，示意图如图 12 所示，具体计算方式如式（3）：

$$IoU=\frac{DetectionResult \cap GroundTruth}{DetectionResult \cup GroundTruth}$$
 (3)




图 12 交并比示意图

4) 平均精度和平均精度均值。这两个指标是目标检测算法中最为重要的一组指标。如图 13 所示，当 IoU 选取某一固定阈值时，可画出对应的 P-R 曲线。针对某一特定类别，在固定的 IoU 阈值下，平均精度即为在不同召回率下对应精度的均值，即 P-R 曲线与两坐标轴围起来的面积。平均精度均值是针对多个类别而言的一个性能指标，即对每个类别在某一固定阈值下的 AP 再求平均值。通常来说，AP 和 mAP 的值越高，表示算法的精度越高。

在车辆三维目标检测中，通常也采用 KITTI 数据集定义的平均精度 AP_{2D} 和 AP_{3D}。AP_{2D} 与前面所述

计算 AP 的方法一致, IoU 由车辆目标 3D 包围框的 8 个顶点在图像中投影所得 2D 包围框与 2D 真实值计算得到。AP_{3D} 中的 IoU 由世界坐标系中的车辆目标 3D 包围框与 3D 真实值计算得到。




图 13 某一阈值下的 P-R 曲线示意图

5) 帧率。除了检测准确度,某些应用场景对目标检测算法的实时性也有要求,实时性体现在检测速度上,即帧率,具体定义为每秒可以处理的图片数量或处理一张图片所需的时间。每秒处理的图片数量越多,或处理一张图片所需的时间越少,就表示算法的

实时性越好。

2.3 算法实验结果分析

由于 KITTI 数据集在车辆三维目标检测领域具有较为完备的数据量和算法评价体系,因此大多数算法的实验选择在此数据集上进行。表 3 选取并总结了本文前述一些代表性算法在 KITTI 数据集上的实验结果。从表中可以看出,各类算法在二维目标检测上效果较好,在 IoU 设置为 0.7 时,多数算法也能达到 90% 的准确率。由于所需先验信息和约束较为复杂,单目场景下的车辆三维目标检测算法运行时间普遍较长。各类算法在三维目标检测的结果参差不齐,与二维目标检测结果相比下降较多。在简单级别、IoU 设置为 0.5 的条件下,目前大多数算法也无法达到 50% 的准确率,在困难级别下只能达到 20% 左右。

总体来说,单目相机由于其固有的丢失深度信息的成像机制,使得三维目标检测的精度受到很大限制。目前,算法大多采用复杂先验信息构建约束的方式来求解 3D 包围框,这也在一定程度上限制了算法的运行效率。

表 3 KITTI 数据集车辆三维目标检测实验结果对比

文献方法	运行时间 /s	IoU	AP _{2D} /%			AP _{3D} /%		
			简单	中等	困难	简单	中等	困难
Mono3D ^[31]	4.2	0.5	/	/	/	25.19	18.20	15.52
		0.7	92.33	88.66	78.96	2.53	2.31	2.31
Deep3DBox ^[32]	/	0.5	/	/	/	27.04	20.55	15.88
		0.7	92.98	89.04	77.17	5.85	4.10	3.84
DeepMANTA ^[33]	2	0.5	97.45	91.47	81.79	/	/	/
		0.7	/	/	/	/	/	/
Mono3D++ ^[35]	0.6	0.5	/	/	/	42.00	29.80	24.20
		0.7	/	/	/	10.60	7.90	5.70
ROI-10D ^[36]	/	0.5	/	/	/	36.25	23.00	22.06
		0.7	89.04	88.39	78.77	7.79	5.16	3.95
GS3D ^[42]	2.3	0.5	/	90.02	/	32.15	29.89	26.19
		0.7	/	/	/	13.46	10.97	10.38
RTM3D ^[43]	0.035	0.5	/	/	/	54.36	41.90	35.84
		0.7	/	90.41	/	20.77	16.86	16.63
Ivan ^[44]	/	0.5	/	/	/	50.82	31.28	20.21
		0.7	/	/	/	13.96	7.37	4.54

3 存在的问题及发展趋势

3.1 存在的问题

当前基于单目场景的车辆三维目标检测方法已取得较大的进展,但是仍然存在以下几方面问题:

1) 大部分单目三维目标检测结果易受到车辆之间互相遮挡、截断和环境光照的影响,算法在复杂环境中的鲁棒性表现一般,部分算法还会受到场景视角

的限制,并且需要依赖较多复杂的先验信息,如车辆轮廓、语义分割等,导致算法运行效率和通用性均受到较大制约。

2) 目前的三维目标检测数据集存在难以用通用格式读取的情况,且每种数据集的数据采集方式、坐标系定义、包含的数据类型和评价指标都有较大区别,导致数据预处理和完整的三维目标检测网络训练需要

消耗大量时间和资源。

3) 单个深度学习网络在单目三维目标检测中,通常只具备单一的功能,无法同时完成多种任务。

3.2 发展趋势

自动驾驶是智能交通领域内的热点研究方向。随着城市交通数据量的不断增加,准确、快速的车辆三维目标检测对于自动驾驶车辆的路径规划至关重要。现将单目场景车辆三维目标检测方法的发展趋势总结如下:

1) 构建高效的单目三维目标检测网络。实时性在自动驾驶决策中起着非常关键的作用。针对当前单目三维目标检测网络检测速度慢的问题,需要合理设计网络内部结构以及选择合适的先验信息,以达到实时性的要求。

2) 开发多功能多信息融合算法。当前单目三维目标检测方法大都停留在某一类特定方法的应用,如特征提取、几何约束构建等,具有一定的局限性。针对这一问题,未来可以考虑使用其他类型的约束,搭建多功能网络框架,进一步提高算法的准确率。

3) 建立多样完备的三维目标检测数据集。深度学习模型性能与数据量大小有很大关系。针对当前数据量不足和数据表示形式不统一的问题,需要考虑引入非监督学习预训练模型,并进一步采集除自动驾驶以外其他应用场景的数据,建立统一完善的数据表示机制,以方便研究人员更好地训练和测试模型。

4 结论

单目场景下的车辆三维目标检测目前在自动驾驶等智能交通领域是热点问题,具有非常广阔的研究空间。本文针对单目场景车辆三维目标检测方法的研究现状进行了梳理,首先将检测方法分为三大类,详细阐述了每一类中包含的代表性方法及其优缺点,然后对常用的公开数据集和算法性能评价指标做了简要介绍,并在KITTI数据集上对代表性算法的实验结果进行了对比分析,最后对单目场景下车辆三维目标检测目前存在的不足和发展趋势进行了总结。

参考文献:

- [1] ASEEM B, OMID H J, SIVA K M, et al. Bounding Boxes, Segmentations and Object Coordinates: How Important is Recognition for 3D Scene Flow Estimation in Autonomous Driving Scenarios? [C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 2593-2602.
- [2] MA X Z, WANG Z H, LI H J, et al. Accurate Monocular 3D Object Detection Via Color-Embedded 3D Reconstruction for Autonomous Driving [C]//2019 IEEE /CVF International Conference on Computer Vision (ICCV). Seoul: IEEE, 2019: 6850-6859.
- [3] 曹培. 面向自动驾驶的双传感器信息融合目标检测及姿态估计 [D]. 哈尔滨: 哈尔滨工业大学, 2019.
- [4] ZHANG H R, CAO Q X. Texture-Less Object Detection and 6D Pose Estimation in RGB-D Images [J]. Robotics and Autonomous Systems, 2017, 95: 64-79.
- [5] DAVID J T, NASSIR N, FEDERICO T. 6D Object Pose Estimation with Depth Images: A Seamless Approach for Robotic Interaction and Augmented Reality [J/OL]. arXiv:1709.01459 [cs.CV]. [2024-12-18]. <https://arxiv.org/abs/1709.01459>.
- [6] JORGE B, CARLOS G, FRANCISCO M M, et al. Birdnet: A 3D Object Detection Framework from LiDAR Information [C]//2018 21st International Conference on Intelligent Transportation Systems (ITSC). Maui: IEEE, 2018: 3517-3523.
- [7] LI B, ZHANG T L, XIA T. Vehicle Detection from 3D Lidar Using Fully Convolutional Network [J/OL]. arXiv:1608.07916 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/1608.07916>.
- [8] SHI S S, WANG X G, LI H S. Pointcnn: 3D Object Proposal Generation and Detection from Point Cloud [C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 770-779.
- [9] ZHOU Y, ONCEL T. Stereo Imagery: End-to-end Learning for Point Cloud Based 3D Object Detection [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 4490-4499.
- [10] GUPTA S, GIRSHICK R, ARBELÁEZ P, et al. Learning Rich Features from RGB-D Images for Object Detection and Segmentation [J]. CoRR, 2014: 345-360.
- [11] CHEN X Z, KAUSTAV K, ZHU Y K, et al. 3D Object Proposals Using Stereo Imagery for Accurate Object Class Detection [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2018, 40 (5): 1259-1272.
- [12] XU B, CHEN Z Z. Multi-Level Fusion Based 3D Object Detection from Monocular Images [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 2345-2353.
- [13] QI C R, YI L, SU H, et al. PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space [J/OL]. arXiv:1706.02413 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/1706.02413>.
- [14] CHEN X Z, MA H M, WAN J, et al. Multi-View 3D Object Detection Network for Autonomous Driving [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017: 6526-6534.
- [15] QI C R, LIU W, WU C X, et al. Frustum PointNets for 3D Object Detection from RGB-D Data [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 918-927.
- [16] CHU H, MA W C, KAUSTAV K, et al. Surfconv: Bridging 3D and 2D Convolution for RGBD Images [C]//2018 IEEE Conference on Computer Vision and Pattern Recognition.

Salt Lake City: IEEE, 2018: 3002-3011.

[17] QIN Z Y, WANG J L, LU Y. Triangulation Learning Network: From Monocular to Stereo 3D Object Detection [C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 7607-7615.

[18] LI P L, CHEN X Z, SHEN S J. Stereo R-CNN Based 3D Object Detection for Autonomous Driving [C]//2019 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 7636-7644.

[19] HU H N, CAI Q Z, WANG D Q, et al. Joint Monocular 3D Vehicle Detection and Tracking [C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul: IEEE, 2019: 5389-5398.

[20] QIN Z Y, WANG J L, LU Y. Monogrnnet: A Geometric Reasoning Network for Monocular 3D Object Localization [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33: 8851-8858.

[21] THOMAS R, ALEX K, ROBERTO C. Orthographic Feature Transform for Monocular 3D Object Detection [J/OL]. arXiv:1811.08188 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/1811.08188>.

[22] KU J, PON A D, WASLANDER S L. Monocular 3D Object Detection Leveraging Accurate Proposals and Shape Reconstruction [C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 11859-11868.

[23] XIANG Y, CHOI W G, LIN Y Q, et al. Subcategory Aware Convolutional Neural Networks for Object Proposals and Detection [C]//2017 IEEE Winter Conference on Applications of Computer Vision (WACV). Santa Rosa: IEEE, 2017: 924-933.

[24] LI C, ZIA M Z, TRAN Q H, et al. Deep Supervision with Shape Concepts for Occlusion-Aware 3D Object Parsing [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017: 388-397.

[25] ZIA M Z, MICHAEL S, BERNT S, et al. Detailed 3D Representations for Object Recognition and Modeling [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2013, 35 (11): 2608-2623.

[26] DUBSKÁ M, HEROUT A, SOCHOR J. Automatic Camera Calibration for Traffic Understanding [EB/OL]. [2024-12-19]. <https://www.bmva-archive.org.uk/bmvc/2014/papers/paper013/index.html>.

[27] ultralytics. YOLOv5 [EB/OL]. [2024-12-19]. <https://github.com/ultralytics/yolov5>.

[28] ZHOU X Y, WANG D Q, KRHENBHL P. Objects as Points [J/OL]. arXiv:1904.07850 [cs.CV]. [2024-12-20]. <https://arxiv.org/abs/1904.07850>.

[29] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single Shot MultiBox Detector [J/OL]. arXiv:1512.02325 [cs.CV]. [2024-12-20]. <https://arxiv.org/abs/1512.02325>.

[30] LIU L J, LU J W, XU C J, et al. Deep Fitting Degree Scoring Network for Monocular 3D Object Detection [C]//2019 IEEE Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 1057-1066.

[31] CHEN X Z, KAUSTAV K, ZHANG Z Y, et al. Monocular 3D Object Detection for Autonomous Driving [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 2147-2156.

[32] MOUSAVIAN A, ANGUELOV D, FLYNN J, et al. 3D Bounding Box Estimation Using Deep Learning and Geometry [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017: 5632-5640.

[33] CHABOT F, CHAOUCH M, RABARISOA J, et al. Deep MANTA: A Coarse-to-Fine Many-Task Network for Joint 2D and 3D Vehicle Analysis from Monocular Image [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 1827-1836.

[34] YANG S C, SCHERER S. CubeSLAM: Monocular 3-D Object SLAM [J]. IEEE Transactions on Robotics, 2019, 35 (4): 925-938.

[35] HE T, SOATTO S. Mono3D++: Monocular 3D Vehicle Detection with Two-Scale 3D Hypotheses and Task Priors [J/OL]. arXiv:1901.03446 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/1901.03446>.

[36] MANHARDT F, KEHL W, GAIDON A. ROI-10D: Monocular Lifting of 2D Detection to 6D Pose and Metric Shape [C]//2019 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 2064-2073.

[37] DING M Y, HUO Y Q, YI H W, et al. Learning Depth-Guided Convolutions for Monocular 3D Object Detection [C]//2020 IEEE Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2020: 11669-11678.

[38] M RAD, VINCENT L. BB8: A Scalable, Accurate, Robust to Partial Occlusion Method for Predicting the 3D Poses of Challenging Objects without Using Depth [C]//2017 IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 3848-3856.

[39] WADIM K, FABIAN M, FEDERICO T, et al. SSD-6D: Making RGB-Based 3D Detection and 6D Pose Estimation Great Again [C]//2017 IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 1530-1538.

[40] BUGRA T, SUDIPTA N S, PASCAL F. Real-Time Seamless Single Shot 6D Object Pose Prediction [C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 292-301.

[41] ISHAN G, AKSHAY R, MOHAN T. 3D Bounding Boxes for Road Vehicles: A One-Stage, Localization Prioritized Approach Using Single Monocular Images [EB/OL]. [2024-12-19]. https://openaccess.thecvf.com/content_eccv_2018_workshops/w29/html/Gupta_3D_Bounding_Boxes_for_Road_Vehicles_A_One-Stage_Localization_Prioritized_ECCVW_2018_paper.html.

(下转 31 页)

精度和召回率,并降低了错误分类的概率,这为马铃薯品质检测和分类提供了一种新的有效方法。

参考文献:

- [1] 崔永伟,杜聪慧,李树君.中国马铃薯种薯产业发展分析与展望[J].农业展望,2020,16(1):71-76.
- [2] 张玉胜,刘洋,高明杰,等.中国马铃薯产品国际竞争力比较分析[J].农业展望,2020,16(9):101-106.
- [3] 姜宏,于永波,章翔峰,等.马铃薯外部品质分级方法综述[J].科学技术与工程,2022,22(14):5519-5527.
- [4] 刘浩,贺福强,李荣隆,等.基于机器视觉的马铃薯自动分级与缺陷检测系统设计[J].农机化研究,2022,44(1):73-78.
- [5] 杨嘉鹏,董荣.机器学习在智慧农业中的应用[J].农业工程,2024,14(7):15-21.
- [6] 唐振三,袁剑龙,康亮河,等.基于图像特征识别的马铃薯薯皮粗糙度分级研究[J].中国农业科学,2023,56(22):4428-4440.
- [7] 贺雨晴,何永宁,经波,等.基于灰度共生矩阵的甘蔗保护区作物种类监测方法[J].智能城市,2021,7(11):

12-13.

[8] 纪娜,何国荣.基于灰度识别的猕猴桃形状疤痕图像纹理特征提取方法[J].自动化与仪器仪表,2019(1):159-162.

[9] 张金敏,杨添玺.基于 LBP 与 SVM 的马铃薯芽眼识别[J].山东农业大学学报:自然科学版,2020,51(4):744-748.

[10] 杨颖,文小玲,章秀华.基于方向梯度直方图和局部二值模式混合特征的水稻病虫害识别方法研究[J].河南农业大学学报,2021,55(6):1089-1096.

[11] 刘立,丰洪才,黄清.基于 Sobel-LBP 的农技知识视频关键帧提取优化算法[J].湖北农业科学,2022,61(20):172-178.

[12] 陈德强.基于改进 KNN 算法的图像分类研究[D].贵阳:贵州民族大学,2020.

作者简介:刘帅(2003—),男,汉族,甘肃环县人,本科在读,研究方向:数据挖掘、机器视觉;康亮河(1987—),女,汉族,甘肃会宁人,讲师,硕士,研究方向:人工智能算法研究。

(上接 24 页)

[42] LI B Y, OUYANG W L, SHENG L, et al. GS3D: An EFFicient 3D Object Detection Framework for Autonomous Driving [C]//2019 IEEE Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 1019-1028.

[43] LI P X, ZHAO H C, LIU P F, et al. RTM3D: Real-Time Monocular 3D Detection from Object Keypoints for Autonomous Driving [J/OL]. arXiv:2001.03343 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/2001.03343v1>.

[44] IVAN B, ALEXEY A, EVGENY B, et al. Monocular 3D Object Detection via Geometric Reasoning on Keypoints [J/OL]. arXiv:1905.05618 [cs.CV]. [2024-12-19]. <https://arxiv.org/abs/1905.05618>.

[45] ANDREAS G, PHILIP L, RAQUEL U. Are we Ready for Autonomous Driving? The KITTI Vision Benchmark Suite [C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. Providence: IEEE, 2012: 3354-3361.

[46] XIANG Y, ROOZBEH M, SILVIO S. Beyond

PASCAL: A Benchmark for 3D Object Detection in the Wild [C]//IEEE Winter Conference on Applications of Computer Vision. Steamboat Springs: IEEE, 2014: 75-82.

[47] HUANG X Y, WANG P, CHENG X J, et al. The ApolloScape Open Dataset for Autonomous Driving and Its Application [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 42(10): 2702-2719.

[48] SUN P, HENRIK K, XERXES D, et al. Scalability in Perception for Autonomous Driving: Waymo Open Dataset [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2020: 2443-2451.

[49] CAESAR H, BANKITI V, LANG A H, et al. NuScenes: A Multimodal Dataset for Autonomous Driving [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2020: 11618-11628.

作者简介:唐心瑶(1996—),女,汉族,江苏苏州人,算法工程师,博士,研究方向:计算机视觉、智能交通。