



计算机应用与软件

Computer Applications and Software

ISSN 1000-386X, CN 31-1260/TP

《计算机应用与软件》网络首发论文

题目：基于单目相机的深度辅助 3D 目标检测算法
作者：柳凡, 佟维妍, 高成, 温悠悠
收稿日期：2025-01-24
网络首发日期：2025-04-21
引用格式：柳凡, 佟维妍, 高成, 温悠悠. 基于单目相机的深度辅助 3D 目标检测算法 [J/OL]. 计算机应用与软件. <https://link.cnki.net/urlid/31.1260.tp.20250421.1213.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于单目相机的深度辅助 3D 目标检测算法

柳凡 佟维妍* 高成 温悠悠

(沈阳工业大学化工过程自动化学院 辽宁 辽阳 111003)

摘要 针对在单目图像上进行 3D 目标检测时由于缺乏深度信息导致检测性能不理想这一问题,提出了一种基于 Transformer 架构的 3D 目标检测算法 MonoDAB。将 DAB-DETR 图像检测算法的动态锚框的预测方式由中心点和宽高信息的形式改为 3D 中心点和到边框距离的形式,使 2D 目标检测精度达到了 94.14%,相较于原算法提升了 3.08%。在改进版的 IDAB-DETR 的基础上增加提出的深度感知模块,通过深度真值进行监督指导以提高 3D 目标检测的性能。实验结果表明,该算法在 KITTI 测试集上对汽车类别简单任务的 3D 检测精度达到 20.10%,在验证集上进一步提升到 25.42%,同时,将模型的检测时间缩短至 22ms。该算法在 KITTI 数据集和构建的场景数据集上均展现出了良好的性能。

关键词 3D 目标检测 Transformer IDAB-DETR MonoDAB 深度感知模块

中图分类号 TP391 文献标志码 A

DEPTH-ASSISTED 3D OBJECT DETECTION ALGORITHM BASED ON MONOCULAR CAMERA

Liu Fan Tong Weiyan* Gao Cheng Wen Youyou

(College of Chemical Process Automation, Shenyang University of Technology, Liaoyang 111003, Liaoning, China)

Abstract In order to solve the problem that the detection performance is unsatisfactory due to the lack of depth information when performing 3D object detection on monocular images, a 3D object detection algorithm based on Transformer architecture MonoDAB was proposed. The dynamic anchor box prediction method of the DAB-DETR image detection algorithm is modified from the format of center point and width-height information to the format of 3D center point and distance to the bounding box, achieving a 2D object detection accuracy of 94.14%, which is an improvement of 3.08% compared to the original algorithm. On the basis of the improved version of IDAB-DETR, the proposed depth perception module is added, and the performance of 3D object detection is improved by supervising and guiding the depth truth value. Experimental results show that the 3D detection accuracy of the algorithm for simple tasks of automobile categories on the KITTI test set reaches 20.10%, which is further improved to 25.42% on the verification set, and the detection time of the model is shortened to 22ms. The proposed algorithm has shown good performance on both the KITTI dataset and the constructed scene dataset.

Keywords 3D object detection Transformer IDAB-DETR MonoDAB Depth perception module

0 引言

矿山和港口现场环境恶劣,不适合长久作业。使用自动驾驶矿卡,不仅可以提高作业效率还能节省劳动力开支^[1]。自动驾驶的核心是环境感知,环境感知即对周围的事物进行 3D 目标检测。近年来,基于单目相机的 3D 目标检测技术^[2-4]已经取得了显著的进展,使得仅用单目相机实现 3D 目标检测成为可能。2018 年,

MultiFusion 算法^[5]引入一个辅助性的深度估计网络,将其以辅助特征通道的形式融合到单目图像的数据特征图中,进而提高检测的鲁棒性和准确度。2020 年, Ding 等提出了 D4LCN 算法^[6],构建了一种新的深度引导局部动态卷积网络,卷积核通过深度映射计算生成,并在单个图像样本的每个像素和通道上进行局部应用。此方法可动态地自适应学习相应的感受野,进而实现对不同场景和深度信息的更佳适应。2021 年,文献^[7]提出了 DDMP-3D 算法,引入了一种深度约束动

态消息传播网络, 该网络利用 3D 检测和深度特征提取, 成功实现了多尺度深度信息与图像上下文的整合。然而, 这些直接采用预训练深度估计器的方法, 不仅会带来额外的计算成本, 而且由于深度先验的不准确检测性能往往不理想。为了解决这一问题, 提出了一种新的 3D 目标检测算法 MonoDAB。此算法在改进的 IDAB-DETR 的基础上增加一种新的深度感知模块, 从而有效的提升了单目图像中 3D 目标检测的性能。

1 改进的 IDAB-DETR 目标检测算法

1.1 改进的 IDAB-DETR 算法

IDAB-DETR 图像目标检测算法是基于 DAB-DETR^[8]进行改进的。DAB-DETR 算法将锚框的坐标 (x,y,w,h) 当作解码器的查询(Q), 利用锚框的中心点来池化周围的特征, 利用锚框的大小来调整交叉注意力图, 实现锚框坐标逐层动态更新, 从而使查询以级联的方式逐层执行软 ROI 池化, 极大地加快了模型的收敛速度。

受到 FCOS 检测算法中预测锚点到检测框四条边距离进行锚点回归的启发, 将直接学习动态锚框的计算方式由中心点与宽高形式改为投影的 3D 中心点 $O:(x_{3d}, y_{3d})$ 和到四条边距离 (l, r, t, b) 的形式, 如图 1 所示。




图 1 2D 检测框图

训练过程中, 学习到的特征中心 $O':(x'_{3d}, y'_{3d})$ 与标签的几何中心 $O:(x_{3d}, y_{3d})$ 存在偏差, 当特征中心发生偏移而宽高的尺寸不变时, 导致此时的锚框整体发生偏移, 如图 2(a)所示, 偏移后的 w' 等于 w , h' 等于 h 。使用 $(x_{3d}, y_{3d}, l, r, t, b)$ 的锚框预测方式, 可以在训练过程中自适应的调节特征中心 o' 到四条边框的距离, 从而快速准确地框住目标, 如图 2(b)所示。




图 2 改进后的检测框对比图

此预测方法加快了图像检测的收敛速度, 提高目

标的定位和检测的精确性以及降低冗余度。

给定一张图像, 先通过 CNN 提取图像空间特征, 然后使用 transformer 编码器细化特征, 再将位置查询(Acnchor Boxes)和内容查询(Decoder Embeddings)送入解码器, 以探测与锚框对应且与内容查询具有相似模式的对象。双重查询被逐层更新, 以逐渐接近目标真实对象。最终解码器层的输出用于预测带有标签和框的对象, 然后使用二分图匹配来计算 IDAB-DETR 的损失。改进版 IDAB-DETR 解码器的结构图, 如图 3 所示。




图 3 改进后的 IDAB-DETR 解码器

直接学习锚框可以导出位置查询。每个解码器层有两个注意力模块, 包括一个自注意力模块(Multi-Head Self-Attention)和一个交叉注意力模块(Multi-Head Cross-Attention), 分别用于查询更新和特征探测。每个模块都需要查询(Q)、键(K)和值(V)来执行基于注意力的值聚合, 但这些三元组的输入各不相同。其中, 记第 q 个锚框为 $A_q=(x_q, y_q, l_q, r_q, t_q, b_q)$, $A_q=(x_q, y_q, l_q, r_q, t_q, b_q)$, 内容查询为 $C_q \in \mathbb{R}^D$, 位置查询为 $P_q \in \mathbb{R}^D$, P_q 如式(1)所示。

$$P_q = \text{MLP}(\text{PE}(A_q)) \quad (1)$$

因为 $A_q=(x_q, y_q, l_q, r_q, t_q, b_q)$ 是六元数, 在这里重载 PE 的运算符, 如式(2)所示。

$$\begin{aligned} \text{PE}(A_q) &= \text{PE}(x_q, y_q, l_q, r_q, t_q, b_q) \\ &= \text{Cat}(\text{PE}(x_q), \text{PE}(y_q), \text{PE}(l_q), \text{PE}(r_q), \text{PE}(t_q), \text{PE}(b_q)) \end{aligned} \quad (2)$$

1.2 结果分析

通过在 KITTI 数据集上对汽车(Car)类别的检测精度来确定算法的性能, 采用 AP_{40} (AP_{40} : 去掉 0 处的召回位置利用 40 个召回位置)进行 AP 计算。

$R_{40}=\{1/40,2/40,3/40,\dots\}$ 检测指标。其中 Car 类别的 IoU 阈值设定为 0.7。将测试集的检测结果上传至官网后会返回 2D 目标检测精度(AP_{2D})。改进前后的算法关于 Car 类别的 2D 目标检测精度,如表 1 所示。

表 1 KITTI 测试集上汽车类别 2D 目标检测精度

算法	$AP_{2D}@IoU=0.7$		
	Easy	Mod	Hard
DAB-DETR	91.06	73.55	63.82
IDAB-DETR	94.14	86.12	76.25

算法 2D 目标检测的 PR 曲线如图 4 所示。




图 4 2D 目标检测 PR 曲线图

由表 1 和图 4 可看出,改进版 IDAB-DETR 目标检测算法可以有效的提升图像检测的精度。2D 目标检测精度在 Car 类别的简单任务上由原 91.06%提升至 94.14%,增加了 3.08%,在中等难度任务上能达到 86.12%,在高难度任务上能达到 76.25%,算法在每种难度的任务上的检测精度都比改进前的算法有所提升。

2 本文算法




图 5 MonoDAB 算法整体结构图

2.2 深度感知模块

深度感知模块与依赖于预训练的深度估计器的方法^[10-12]相比,减少了额外的计算负担,能显著提高模型的检测速度,能够更好的适应不同的应用场景。深度感知模块由深度特征增强模块(DFE)、深度

在改进版的 IDAB-DETR 图像目标检测算法的基础上增加深度感知模块,提出了一种基于单目相机的深度辅助 3D 单目检测算法 MonoDAB。此算法可以从全局感受野对于每个查询去提取特征,实现对场景级的空间有更好的全局理解,而非局限于中心点周围的局部特征。实现只使用单目相机完成 3D 目标的检测识别与定位功能。

2.1 MonoDAB 算法架构

MonoDAB 网络架构由特征提取模块、编码与解码器模块以及检测头模块组成。采用 Resnet50 作为主干提取网络(Backbone)提取图像特征,并将提取的特征输入 Transformer^[9]编码器进行编码细化。同时将提取的特征输入深度特征增强模块(Depth-Aware Feature Enhancement Module, DFE)学习并增强深度特征,并使用深度标签对深度信息进行辅助监督。深度特征位置编码模块(Depth positional encoding, DPE)对深度特征进行位置编码并将深度位置提示信息注入 Transformer。

编码与解码器模块采用 Transformer 编码与解码特征融合网络对图像与深度特征进行融合,此网络中的深度引导的解码模块(Depth-guided Decoder)具有深度交叉注意力模块,可以进行相互查询和查询场景深度特征的交互。最后使用检测头去预测 3D 边框、2D 边框、深度、分类、距离和角度。网络整体架构如图 5 所示。

位置编码模块(DPE)和深度引导解码模块组成。在基线模型 MonoDETR^[13]的深度特征提取模块的基础上进行改进, MonoDETR 的深度预测器结构简单,深度信息的生成和利用相对显式,直接从输入图像中预测深度图,然后将深度图编码为深度嵌入,与视

觉特征融合。这种方法在复杂场景下,深度预测的准确性会下降,从而对整体性能产生不利影响。故将其改进为提出的深度感知模块隐式地学习深度特征和全局利用深度信息,以提高模型的性能和泛化能力,对深度信息进行更好的学习。提出的 DFE 模块以端到端方式学习深度感知特征,以避免从现成的深度估计器获得不准确的深度先验和高计算成本。DPE 模块将每个像素的深度位置提示嵌入到 transformer 中,以增强模型对深度的感知能力。

2.2.1 深度特征增强模块

深度特征增强模块由初始深度特征学习、深度原型表示学习和深度原型特征增强三部分组成。

为了生成深度感知特征,利用一个辅助的深度估计任务,并将其视为一个序列分类问题。如图 6(a)所示,给定主干网络输出的输入特征 $F \in \mathbb{R}^{C \times H \times W}$, 采用两层卷积来预测离散化深度箱的置信度 $D \in \mathbb{R}^{D \times H \times W}$, 其中 D 表示深度类别的数量。为了将连续空间中的深度真值离散化为离散化区间,采用线性递增离散化 (LID) 来制定深度箱。通过这种方式,中间特征图 $X \in \mathbb{R}^{C \times H \times W}$ 可被视为初始深度特征。




图6 深度特征增强模块图

为了进一步增强深度表示的能力,通过引入相应深度类别的中心表示来增强每个像素的特征。每个深度类别的特征中心(视为深度原型)可以通过聚合属于特定类别的每个像素的深度感知特征来计算。实际操作中,首先对预测的深度图 D 应用分组卷积,以合并相邻的深度类别,将类别数量从 D 减少到 $D'=D/r$, 其中 r 为比例因子。这有助于共享相似的深度线索并减少计算量。

深度原型的表示 F_d 通过收集所有像素的特征 X' 并按其属于深度类别 d 的概率进行加权来生成,如式(3)所示。

$$F_d = \sum_{i \in I} \tilde{P}_{di} X'_i, d = \{1, \dots, D'\} \quad (3)$$

其中, X'_i 表示 X' 中第 i 个像素的特征, $I \in \mathbb{R}^{H \times W}$ 是特征图中的像素集合, $\tilde{P}_{di}$ 是归一化后属于第 d 个深度原型的概率。通过这种方式 F_d 可以表达每个深度类别的全局上下文信息,如图 6(b)所示。

基于深度原型表示重构新的深度特征,这使得每

个像素能够从全局视角理解深度类别的表示。重构的特征 F' 的计算方式,如式(4)所示。

$$F' = \sum_{d=1}^{D'} \tilde{P}_{di} F_d \quad (4)$$

通过将初始深度感知特征 X 和重构的特征 F' 进行拼接,并通过一个简单的 1×1 卷积层得到增强后的深度特征,如图 6(c)所示。

2.2.2 深度位置编码模块

传统的位置编码一般是根据像素的位置用正弦函数或者学习的方式来生成,但深度信息要比像素间的关系更有利于机器理解 3D 世界信息,所以使用了深度位置编码模块将每个像素的位置信息嵌入到 Transformer 中,如图 7 所示。




图7 深度位置编码模块图

通过可学习的嵌入为每个深度区间构建深度类别编码 $E_d = [e_1, \dots, e_D] \in \mathbb{R}^{D \times C}$ 。依据每个像素点预测的深度类别 D 的 argmax 值,可以从 E_d 中查找到初始的位置编码 $P \in \mathbb{R}^{H \times W \times C}$ 。为了进一步从邻近的像素点表示位置信息,对 P 应用核大小为 3×3 的卷积层 G 得到最终编码,记作深度位置编码。在 Transformer 中,应用线性注意力来取代普通的自注意,能获得更高的推理速度。

2.2.3 深度引导解码模块

深度感知模块放入深度引导解码器,如图 8 所示。




图8 深度引导解码器模块

聚合来自编码器的图像与深度特征,使用一组可学习的查询 $q \in \mathbb{R}^{N \times C}$ 来检测 3D 目标, N 代表输入图像中预定义的最大检测目标的数量, C 代表每个查询

对应的特征向量的维度。共使用了三个解码块, 每个解码块按顺序由深度交叉注意层 (Depth Cross-Attention)、查询间自注意力层 (Inter-Query Self-Attention)、视觉交叉注意层 (Visual Cross-Attention) 和 FFN (Feed Forward Network) 组成。

2.3 损失函数

将损失分为两组。第一组目标分类、2D 框, 都与图像有关。第二组深度、3D 框和方向角, 都与目标的 3D 空间属性有关。将两组损失分别求和, 记为 L_{2D} 和 L_{3D} 。

经过查询和标签匹配后, 从 N 个查询中得到 N_{gt} 对有效对, 其中 N_{gt} 表示目标标签的个数。训练图像的总损失, 如式(5)所示。

$$L_{overall} = \frac{1}{N_{gt}} \sum_{n=1}^{N_{gt}} (L_{2D} + L_{3D}) + L_{dmap} \quad (5)$$

L_{dmap} 表示深度特征图的损失。

对于二分匹配, 仅通过 L_{2D} 组计算每个查询标签对的匹配代价, 如式(6)所示。

$$L_{2D} = \lambda_1 L_{class} + \lambda_2 L_{xy3D} + \lambda_3 L_{lrb} + \lambda_4 L_{GloU} \quad (6)$$

其中 λ_{1-4} 分别设为 2、10、5 和 2。对于最终损失中的 L_{3D} , 不设权重简单地将其进行相加, 如式(7)所示。

$$L_{3D} = L_{size3D} + L_{orien} + L_{depth} \quad (7)$$

表 2 KITTI 测试集上 Car 类别的检测性能

算法	Extra date	Time(ms)	$AP_{3D}@IoU=0.7$			$AP_{BEV}@IoU=0.7$		
			Easy	Mod	Hard	Easy	Mod	Hard
D4LCN	Depth	200	16.65	11.72	9.51	22.51	16.02	12.55
IAFA ^[15]		-	17.81	12.01	10.61	25.88	17.88	15.35
MonoDLE ^[16]		40	17.23	12.26	10.29	24.79	18.89	16.00
MonoRCNN ^[17]		70	18.36	12.65	10.03	25.48	18.11	14.10
MonoDAB	None	22	20.10	13.94	11.52	28.11	19.40	16.33
Improvement			+1.74	+1.29	+0.91	+2.23	+0.51	+0.33

表中共有五列。其中, 算法列出了参与对比的算法名称。Extra date 表示各方法是否使用其他数据。Times 表示各方法检测一张图像的运行时间, 以毫秒 (ms) 为单位。最后两列表示 $IoU=0.7$ 时算法的 AP_{3D} 与 AP_{BEV} 。加粗的字体代表本算法在 KITTI 上的检测精度, Improvement 指的是本算法相对于次优算法的改进大小。可见, MonoDAB 取得了比较好的性能, 优于流行的方法, 包括附加输入是深度时的方法。在 Easy、Moderate 和 Hard 水平下 AP_{3D} 分别优于次优的+1.74%、+1.29%、+0.91%, AP_{BEV} 分别优于次优的+2.23%、+0.51%、+0.33%。这表明所提出的深度感知模块是有效的。而且从 Time 数据可看出, 模型的检测速度有了显著的提升, 检测时间缩短到 22ms, 能满足自动驾驶目

3 实验与分析

3.1 实验配置

本算法的修改、训练和推理均在配置为 Intel Core i7-13700KF CPU 和 NVIDIA RTX4090(24G) 的 Ubuntu20.04 的电脑上进行。代码的开发与编写基于 Pytorch1.91 深度学习框架。训练数据集的 Batch_size 为 8, 训练周期为 195。使用 Adamw 优化器可以自适应的调整学习率, 初始学习率设置为 1.0×10^{-4} , 权重衰减的动量设置为 1.0×10^{-4} , 学习率调整策略采用余弦函数, 其中 Decay_rate 为 0.1。在 KITTI 数据集上进行了算法的训练与评测。

3.2 实验结果

本文在 KITTI 数据集上对 Car(汽车)类别^[14]进行了检测精度评估, 采用 AP_{40} 作为主要性能指标。其中 Car、Pedestrian(行人)和 Cyclist(骑行者)类别的 IoU 阈值分别设定为 0.7、0.5 和 0.5。MonoDAB 算法在 KITTI 测试集 Car 类别的检测性能与其他 3D 单目检测方法的对比, 如表 2 所示。

标检测的实时检测需求。

MonoDAB 算法在 KITTI 验证集 Car 类别的检测性能与其他方法的对比结果, 如表 3 所示。Easy、Mod 和 Hard 分别代表简单、中等和困难三种检测难度级别, 难度越大代表图像中目标被遮挡或截断的部分越大, 小目标越多, 检测难度就越高。在 $IoU=0.7$ 时, AP_{3D} 和 AP_{BEV} 与其他次优的算法相比, 分别实现了 +2.66/+4.02/+2.6 和 +2.36/+2.0/+3.01 的不错的提升, 证明了基于 Transformer 架构的特征融合算法比纯卷积结构更有优势。

表 3 KITTI 验证集上 Car 类别的检测性能

算法	$AP_{3D}@IoU=0.7$			$AP_{BEV}@IoU=0.7$		
	Easy	Mod	Hard	Easy	Mod	Hard
MonoRCNN	16.61	13.19	10.65	25.29	19.22	15.30

IAFA	18.95	14.96	14.84	22.75	19.60	19.21
MonoDLE	17.45	13.66	11.68	24.97	19.33	17.01
GUPNet ^[18]	22.76	16.46	13.72	31.07	22.94	19.75
MonoDAB	25.42	20.48	17.44	33.43	24.94	22.76
Improvement	+2.66	+4.02	+2.6	+2.36	+2.0	+3.01

MonoDAB算法在KITTI测试集Pedestrian/类别的检测性能与其他方法的对比，如表4所示。

表 4 KITTI 测试集中 Pedestrian/Cyclist 类别的检测性能

算法	Pedestrian, AP _{3D}			Cyclist, AP _{3D}		
	Easy	Mod	Hard	Easy	Mod	Hard
D4LCN	4.55	3.42	2.83	2.45	1.67	1.36
MonoDLE	9.64	6.55	5.44	4.59	2.66	2.45
MonoDAB	14.51	9.31	7.70	6.79	3.80	3.35
Improvement	+2.66	+4.02	+2.6	+2.36	+2.0	+3.01

Pedestrian和Cyclist这两个类别与Car类别相比，形状更小也更不规则，对应的所占像素就越小，导致的识别的难度更大。并且，在训练集中，这两个样本所包含的训练样本比汽车少很多，所以对于网络来说，检测的准确度更具有挑战性，相应的，检测性能相比于汽车Car类别要低。但与其他单目3D目标检测算法的AP_{3D}指标相比，本文提出的MonoDAB算法检测性能更好，有较强的泛化能力。

3.3 消融实验

本文对MonoDAB进行了全面的消融研究，以验证提出的每个单独的组件的有效性。如表5所示，实验(1)是本文在Monodetr上修改的基线。实验(2)、(3)分别是添加改进的锚框模块(A)、深度感知模块(B)，相比于基线，实验(2)和(3)都有一定幅度的提升，说明这两个模块都是有效的。实验(4)应用了所有设计的模块，在不同检测级别的性能实现了大幅度的提升。

表 5 不同组件在 KITTI 测试集上的检测性能

实验	(A)	(B)	Car, AP _{3D}		
			Easy	Mod	Hard
(1)			16.6	11.08	9.5
(2)	√		17.35	11.41	9.74
(3)		√	18.62	12.74	11.10
(4)	√	√	20.10	13.94	11.52

为了验证深度感知模块中各个组成部分的有效性，分别对以下三个模块：(a)深度特征增强模块、(b)深度特征增强模块和(c)深度引导解码模块进行了性能评估，如表6所示。这三个模块在car简单级别的任务上分别为模型的性能提供了+1.17/+0.56/+0.29的增益。结果表明，每个模块都对模型性能有显著的提升作用，且所有模块协同工作。

表 6 深度感知模块的有效性

实验	(a)	(b)	(c)	Car, AP _{3D}		
				Easy	Mod	Hard
基线				16.6	11.08	9.5

是否添加组件	√			17.77	12.54	10.79
	√	√		18.33	12.61	10.92
	√	√	√	18.62	12.74	11.10

3.4 检测结果可视化

为了更好地展示所提出的方法的有效性，将该算法的检测速度以及在公共数据集和创建的港口和矿山场景数据集上的检测效果进行了可视化。

(1)检测速度可视化

MonoDAB 算法的 3D 目标检测速度如图 9 所示，从图中的模型处理时间可知，模型的检测时间缩短到 22ms，检测速度得到了很大的提升，能够满足自动驾驶的实时性需求。




图 9 模型检测速度

(2)图像检测效果可视化

在公共数据集图像的检测效果，如图 10 所示。



(a) 行人检测效果图



(b) 车辆检测效果图

图 10 图像检测效果图

从图中可以看出算法在图像上有很好的 3D 目标检测效果。检测结果还对目标的分类、概率、方向和深度信息进行了可视化。

(3)视频效果可视化

在公共数据集视频上的检测效果，如图 11 所示。从图中可看出，算法在视频上的 3D 目标检测也能达到很好的效果，能够实时的检测出视频中出现的车辆和行人等目标，并且能准确的框住目标。



(a) 行人检测效果图




(b) 车辆检测效果图


图 11 视频检测效果图

(4) 场景数据集检测效果可视化

矿山和港口场景数据集的检测效果, 如下图 12 所示。



(a) 港口场景检测效果图



(b) 矿山场景检测效果图

图 12 实地场景检测效果图

图中右上角展示了算法在场景数据图像上的检测效果。为了更清晰地展示检测效果, 将检测结果在点云中进行了展示。从图中可以看出, 单目目标检的 3D 框可以准确地框住表示物体的点云。

4 结 语

深入研究了在矿山和港口场景下, 基于单目相机的 3D 目标检测, 提出了深度辅助 3D 目标检测算法 MonoDAB。在 DAB-DETR 算法的基础上加入深度感知模块, 采用标注的深度标签对深度特征进行监督, 通过深度感知模块对深度特征进行增强引导。基于 Transformer 结构使得特征的提取不再局限于相邻的视觉特征, 而是全局集成上下文线索和深度特征。实验表明, 在 KITTI 测试集上关于汽车的检测性能在简单难度上达到 20.10%, 在验证集上, 简单难度达到

25.42%。模型的检测时间缩短到 22ms。算法的检测速度与精度得到了一定的提升, 能满足实际应用场景的需求。

参考文献

- [1] 陈善有, 郭洋, 田斌, 等. 国内外露天矿山无人驾驶研究现状分析与发展前景[J]. 现代矿业, 2023, 39(12): 12-16.
- [2] 徐谦. 面向复杂环境自动驾驶的视觉环境感知研究[D]. 长春: 吉林大学, 2023.
- [3] 梁振明, 黄影平, 宋卓恒, 等. 自动驾驶中基于深度学习的 3D 目标检测方法综述[J/OL]. 上海理工大学学报, 1-17[2024-04-10]. <https://doi.org/10.13255/j.cnki.jusst.20231101004>.
- [4] 王子牛. 基于单目的自动驾驶三维目标检测系统研究[D]. 北京: 北京交通大学, 2022.
- [5] Xu B, Chen Z. Multi-level fusion based 3d object detection from monocular images[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, 2018:2345-2353.
- [6] Ding M, Huo Y, Yi H, et al. Learning depth-guided convolutions for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on computer vision and pattern recognition workshops, 2020:1000-1001.
- [7] Wang L, Du L, Ye X, et al. Depth-conditioned dynamic message propagation for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:454-463.
- [8] Liu S, Li F, Zhang H, et al. Dab-detr: Dynamic anchor boxes are better queries for detr[EB]. arxiv preprint arxiv:2201.12329, 2022.
- [9] 李丽芬, 黄如. 引入Transformer的道路小目标检测[J]. 计算机工程与设计, 2024, 45(1): 95-101.
- [10] Liu Y, Shao Z, Hoffmann N. Global attention mechanism: Retain information to enhance channel-spatial interactions[EB]. arxiv preprint arxiv:2112.05561, 2021.
- [11] Wang Y, Fathi A, Kundu A, et al. Pillar-based object detection for autonomous driving[C]//Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XXII 16: Springer, 2020:18-34.
- [12] Liu Z, Cheng J, Fan J, et al. Multi-modal fusion based on depth adaptive mechanism for 3D object detection[J]. IEEE Transactions on Multimedia, 2023, 327:1-11.
- [13] Zhang R, Qiu H, Wang T, et al. Monodetr: Depth-guided transformer for monocular 3d object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision.

- 2023: 9155-9166.
- [14] 杨咏嘉, 钟良琪, 闫胜业. 基于点云的自动驾驶下三维目标检测[J]. 计算机工程与设计, 2024, 45(4): 1093-1099.
- [15] Zhou D, Song X, Dai Y, et al. Iafa: Instance-aware feature aggregation for 3d object detection from a single image[C]//Proceedings of the Asian Conference on Computer Vision. 2020.
- [16] Ma X, Zhang Y, Xu D, et al. Delving into localization errors for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021:4721-4730.
- [17] Shi X, Ye Q, Chen X, et al. Geometry-based distance decomposition for monocular 3d object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021:15172-15181.
- [18] Lu Y, Ma X, Yang L, et al. Gupnet++: geometry uncertainty propagation network for monocular 3D object detection[EB]. arxiv preprint arxiv:2310.15624, 2023.