

中国公路学报
China Journal of Highway and Transport
ISSN 1001-7372,CN 61-1313/U

《中国公路学报》网络首发论文

题目：基于深度引导的自动驾驶端到端单目 3D 目标检测方法
作者：贺宜，凌志颖，邱志军，张鸣
收稿日期：2025-06-30
网络首发日期：2026-01-13
引用格式：贺宜，凌志颖，邱志军，张鸣. 基于深度引导的自动驾驶端到端单目 3D 目标检测方法[J/OL]. 中国公路学报.
<https://link.cnki.net/urlid/61.1313.U.20260112.1913.026>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于深度引导的自动驾驶端到端 单目 3D 目标检测方法

贺宜^{1,2*}, 凌志颖^{1,2}, 邱志军^{1,2}, 张鸣³

- (1. 武汉理工大学智能交通系统研究中心, 湖北 武汉 430063;
2. 交通信息与安全教育部工程研究中心, 湖北 武汉 430063;
3. 湖北三江航天万山特种车辆有限公司, 湖北 孝感 432009)

摘要：为了解决单目 3D 目标检测因缺乏真实的深度信息，尤其在远距离目标深度估计方面面临精度瓶颈的问题。针对现有方法在目标中心定位与深度估计中的不足，本文提出一种融合深度引导与几何约束的单目 3D 目标检测方法，MonoDGNet (Monocular Depth and Geometry Network)。该模型在 DETR 结构基础上引入前景深度图预测模块与专用深度编码器，用于提取具备全局上下文感知能力的深度嵌入特征，增强对场景结构的理解。同时，提出一种基于门控机制的三维解码器，自适应调节深度特征对每个查询的引导强度，提升目标几何信息建模能力。为了提高检测精度与收敛速度，设计轻量级二维解码器辅助目标查询初始化，并集成高效目标分割模块，优化 Transformer 输入特征。进一步地，本文在损失函数中引入透视不变的几何误差修正机制，该机制属于自监督损失函数的关键组成，通过融合几何深度与回归深度有效降低深度预测误差。本方法针对自动驾驶端到端感知场景，实现单目 RGB 图像到 3D 检测结果的直接映射。实验结果表明，MonoDGNet 在没有额外数据的情况下，在 KITTI 数据集上相较于当前最优性能(SOTA)的模型，于 Easy、Moderate 与 Hard 下精度分别提升了+1.38、+1.76、+1.71，展现出优越的性能和良好的实时性，为 3D 目标检测技术发展提供了新的思路与方法支持。

关键词：自动驾驶；MonoDGNet；深度学习；端到端感知；单目视觉；3D 目标检测

MonoDGNet: An End-to-End Monocular 3D Object Detection for Autonomous Driving with Depth Guidance

HE Yi^{1,2*}, LING Zhiying^{1,2}, QIU Zhijun^{1,2}, ZHANG Ming³

- (1. Research Center for Intelligent Transportation Systems, Wuhan University of Technology, Hubei, Wuhan 430063;
2. Engineering Research Center of Transportation Information and Safety, Ministry of Education, Hubei, Wuhan 430063;
3. Hubei Sanjiang Aerospace Wanshan Special Vehicle Co., Ltd., Hubei, Xiaogan 432009)

Abstract: Abstract To address the accuracy bottleneck in monocular 3D object detection caused by the lack of explicit depth information, particularly for distant objects, this paper proposes MonoDGNet, an end-to-end framework that incorporates depth guidance and geometric constraints. The proposed method introduces a foreground depth prediction module and a dedicated depth encoder to extract globally-aware depth embeddings, enhancing scene depth understanding. A novel gating mechanism is employed in the 3D decoder to dynamically adjust the influence of depth features for each query, enabling adaptive depth-guided feature fusion. Additionally, a lightweight 2D decoder and an efficient segmentation module are designed to provide accurate query initialization and enrich semantic representations. A perspective-invariant geometric projection correction is incorporated into the loss function. This mechanism is a key component of the self-supervised loss function and effectively reduces the depth prediction error by

integrating geometric depth and regression depth.. MonoDGNet is aimed at the end-to-end perception scenario of autonomous driving, achieving direct mapping from monocular RGB images to 3D detection results. Experimental results on the KITTI dataset demonstrate that MonoDGNet achieves +1.38%, +1.76%, and +1.71% improvements in 3D Average Precision (AP) across the easy, moderate, and hard levels, respectively, without relying on external data. The proposed approach offers a promising solution for cost-effective, real-time monocular 3D object detection in autonomous driving scenarios.

Keywords: autonomous driving; MonoDGNet; deep learning; end to end perception; monocular; 3D object detection

Received 2025-06-30

中图分类号: U471.15

文献标志码: A

0 引言

在自动驾驶领域, 3D 目标检测作为环境理解与决策规划的核心技术, 直接决定了智能系统的安全性和可靠性^[1,2]。与基于激光雷达和多视角图像的 3D 目标检测方法相比, 单目 3D 目标检测仅依赖单目图像数据, 由于深度估计的不确定性, 不可避免地面临语义歧义、遮挡误判和目标定位失准等难题, 导致其检测精度显著低于其他方法。目前的单目检测方法主要应用在 2D 检测方面, 如 YOLOv8^[3], SSD^[4], RT-DETR^[5]等模型在 2D 目标检测领域展现出极高的成熟度。而在 3D 目标检测领域, 基于激光雷达的 PointPillars^[6], VoxelNeXt^[7], DSVT^[8]等模型凭借精确的距离测量能力, 相较于单目 3D 检测模型存在着天然的优势。尽管存在性能差距, 单目目标检测凭借其低成本(硬件成本仅为激光雷达的 1/12)、低功耗及易部署等优势, 在终端设备的轻量化的需求下, 展现出独特的应用价值。此外, 随着边缘计算芯片算力的提升和轻量化神经网络的发展, 单目 3D 目标检测方案已能在满足实时性要求(如 30FPS 处理速度)的前提下, 逐步缩小与多传感器方案的性能差距。这种性能与成本的平衡追求, 使得单目 3D 目标检测技术发展为学术界和工业界近年来的重点研究内容, 在智能交通、服务机器人等领域展现出广阔的应用前景。

精准的深度估计是实现精确的单目 3D 目标检测的最大挑战^[9,10]。单目相机仅能获取二维平面图像, 缺乏直接的深度感知能力, 无法像激光雷达那样通过主动发射信号获取场景的三维距离信息。在单目成像过程中, 三维空间中的不同物体可能在二维图像上投影到相同位置, 导致深度信息丢失, 形成尺度歧义问题。Lu 等^[11]通过基于边界框和目标尺寸高度的投影公式计算几何深度, 此方法存在多重缺陷。首先, 该方法依赖于目标尺寸的先验假设, 当遇到非标准尺寸物体, 如改装车辆、异形货物运输车辆时, 尺寸先验与实际目标存在偏差, 会导致深度计算产生系统性误差; 其次, 基于边界框的投影计算仅利用了目标的局部视觉特征, 难以捕捉场景中物体间的相对位置关系, 在复杂交通场景下, 当目标存在严重遮挡或重叠时, 边界框的完整性遭到破坏, 进而导致深度估计失效; 最后, 此类方法缺乏对场景全局几何结构的感知, 在远距离目标检测时, 由于图像分辨率降低、纹理信息模糊, 仅通过边界框和尺寸高度的投影公式, 无法有效处理尺度歧义问题, 严重影响检测结果的准确性和可靠性。Yan 等^[12]提出一种利用投影公式计算几何深度, 并引入了深度学习模型预测的场景深度信息, 并通过自适应加权融合策略的方法。有效缓解了因尺寸先验偏差、局部特征依赖和全局结构感知不足导致的性能瓶颈。但如果多个预测深度聚集在地面真值深度的同一侧, 该策略仍难以纠正深度误差。

Chong^[13]和 Hong^[14]等提出一种基于蒸馏的方法的单目 3D 目标检测模型, 该方法以激光雷达数据训练高性能教师模型, 通过构建包含空间几何约束的蒸馏损失函数, 引导仅输入单目图像的学生模型学习教师模型的空间特征表示。然而, 这种方法依赖额外的激光雷达数据进行训

练。Ranasinghe 等^[15]提出了一种基于反向扩散过程来估计 3D 边界框和方向的方法。但其多步迭代推理机制导致计算复杂度极高，难以满足自动驾驶等场景的实时性要求。

得益于 Transformer^[16]架构强大的全局特征建模能力，基于 DETR (Detection Transformer)^[17]的模型通过多头注意力机制聚合跨区域信息，能够有效解决传统方法仅依赖局部特征的局限性。近年来，基于 DETR 的模型在计算机视觉领域取得了巨大成功：在 2D 检测^[5,17,18]、多视图^[19-21]和多模态 3D 检测^[22]等方面都表现出了卓越的性能。MonoDETR^[23]是第一个基于 DETR 的端到端单目 3D 目标检测模型，是一种最先进的方法，性能超越了以往所有的单目 3D 目标检测模型，并且在不同的光照条件下均表现出更高精度和鲁棒性。然而，MonoDETR 仍然表现出一定的局限性：解码器的查询初始化过程缺乏明确的语义指导，导致目标的特征提取效率受限；简单的深度估计网络难以应对复杂场景下的深度变化；由于深度估计存在固有的不确定性，深度交叉注意力模块在融合信息时无法自适应的筛选可靠的深度线索，干扰目标特征的准确提取；未充分考虑检测目标的几何深度约束，影响 3D 定位的准确性。

为有效解决上述问题，本文提出一种基于融合深度引导与几何约束的 DETR 架构的单目 3D 目标检测方法——MonoDGNet (Mono Depth and Geometry Net)。该方法在 MonoDETR 基础上进行了以下创新：首先，通过多尺度特征提取网络获取多尺度图像特征，并引入语义分割分支对目标与背景特征进行显式区分，提升特征表示的语义纯度；其次，将 MonoDETR 的深度引导解码器解耦为独立的 2D 视觉解码器与 3D 深度解码器，其中 2D 解码器专注于目标检测与查询向量的语义初始化，3D 解码器则通过引入自适应门控机制，使深度交叉注意力模块能够根据特征置信度动态筛选可靠深度线索；最后，设计几何约束优化模块，前景深度图预测模块与深度编码器先输出初步深度预测结果，再与相机投影几何关系融合，通过计算透视不变的几何误差，最终构建自监督损失函数，其核心为透视不变的几何误差修正。MonoDGNet 通过结构解耦与信息融合的协同优化，在保持轻量化网络架构的同时，实现了检测精度的提升。实验结果表明，在没有额外数据的情况下，MonoDGNet 在 KITTI 数据集^[24]上达到了单目 3D 目标检测的当前最优性能(SOTA)。

1 单目视觉三维目标检测方法设计

1.1 算法整体框架

MonoDGNet 采用编码器-解码器结构，如图 1 所示。MonoDGNet 是一个端到端的目标检测模型，仅以单目图像作为输入，即可在不需要后处理的情况下完成三维目标检测结果的输出。




图 1 MonoDGNet 网络框架

Fig. 1 MonoDGNet Network Framwork

此算法基于编码器—解码器的端到端架构，采用模块化和并行化设计理念。共可分为四个模块，分别为：图像输入与多尺度特征融合模块、双分支编码模块、双分支解码模块以及基于几何约束的结果融合模块。

具体而言：网络以单目 RGB 图像 $I \in \mathbb{R}^{H \times W \times 3}$ (H, W 分别为图像的高宽) 作为输入，首先通过主干网络，如 ResNet50^[25]，提取不同层级的多尺度特征图 $F_i \in \mathbb{R}^{\frac{H}{2^{i+3}} \times \frac{W}{2^{i+3}} \times C}$ ， $i = 0, 1, 2, 3$ ， C 为通道数。随后，利用特征金字塔网络(FPN)融合多尺度特征，输出具有丰富语义信息的 $F_1 \sim F_3$ 多级特征。通过引入轻量级区域分割头模块，预测目标区域概率，实现前景和背景的有效区分，进而增强前景视觉特征 F_V 。同时，轻量级深度估计模块生成深度估计图及对应的深度特征 F_D 。增强的后的视觉特征与深度特征分别被馈送到两个并行的 Transformer 编码器中进行特征编码。编码后的特征作为双分支解码模块的输入，该模块由二维检测解码器和三维检测解码器组成。其中，二维检测解码器输入图像特征，通过解码输出二维查询信息，为三维检测解码器提供高质量的初始查询信息。三维检测解码器基于交叉注意力机制设计，同时接收视觉编码器和深度编码器的输出，通过跨模态特征交互，从视觉特征和深度特征中提取目标的几何和空间信息。特别地，在 3D 检测解码器中引入可学习的门控机制，对每个查询动态控制深度信息的引导强度，并采用门控高斯线性单元 (Gated Gaussian Linear Unit, GEGLU)^[26] 激活函数提高非线性表达能力与网络训练稳定性。最终，通过二维与三维检测头分别输出投影平面与三维空间中的目标检测结果。为进一步提升深度估计的准确性，模型设计了透视不变的几何误差修正模块，引入几何深度与回归深度的加权融合策略作为深度监督。

1.2 模块设计

1.2.1 多尺度特征融合模块




图 2 多尺度特征融合模块

Fig. 2 Multi-scale Feature Fusion Module

为解决多尺度目标检测性能失衡的问题，本文构建了多尺度特征融合模块作为特征提取网络。详细结构如图 2 所示，该模块主要由特征主干网络、特征金字塔网络和区域分割头等三个部分构成。

在特征提取环节，使用 ResNet50 作为主干网络，通过下采样操作，提取多个尺度的视觉特征 $F_0 \sim F_3$ ，特征尺度分别为输入图像 I 的 $1/8$ 、 $1/16$ 、 $1/32$ 、 $1/64$ 。不同尺度的特征蕴含着丰富且互补的语义信息，小尺度特征能够捕捉目标的细节纹理，大尺度特征有助于把握目标的整体轮廓与语义信息。然后通过特征金字塔网络对不同层级、不同尺度的特征进行特征聚合，通过其自上而下和横向连接的方式，提高模型对目标特征的提取和表征能力。在区域分割头的构建上，本文借鉴 U-Net^[27] 的结构，打造了一个轻量级网络。其核心作用在于有效区分图像前景和背景特征。为进一步增强特征的表达能力，在区域分割头中引入了卷积块注意力模块^[28]

(Convolutional Block Attention Module, CBAM) 模块对每个尺度的特征进行注意力加权。

CBAM 由通道注意力模块和空间注意力模块两部分组成，二者可以顺序堆叠使用，共同对输入特征图进行优化，具体计算如式(1)(2)：

$$\begin{cases} F'_i = M_c(F_i) \otimes F_i, \\ F''_i = M_s(F'_i) \otimes F'_i, \end{cases} \quad i = 0, 1, 2, 3 \quad (1)$$

$$\begin{cases} M_c(F) = \sigma(W_1(\text{AvgPool}(F)) + W_2(\text{MaxPool}(F))) \\ M_s(F) = \sigma(f^{7 \times 7}([\text{AvgPool}_c(F); \text{MaxPool}_c(F)])) \end{cases} \quad (2)$$

其中， F_i 表示不同尺度的特征， M_c 表示通道注意力模块， M_s 表示空间注意力模块， $\otimes$ 表示逐元素相乘， σ 表示 sigmoid 激活函数， $\text{AvgPool}(\cdot)$ 和 $\text{MaxPool}(\cdot)$ 分别表示平均池化层和最大池化层。经过 CBAM 模块处理后，特征图在通道和空间维度上都得到了优化，更能突出目标的关键信息。对于区域分割头，本文最后使用 sigmoid 函数实现语义分割。通过将预测的目标概率与原始特征相乘，有效的增强了前景特征并且抑制了背景噪声。




图 3 深度估计模块

Fig. 3 Depth Predictor Module




图 4 DSC 模块和 LGFI 模块

Fig. 4 DSC Module And LGFI Module

1.2.2 双分支编码模块

双分支编码模块是 MonoDGNet 实现跨模态特征解耦与增强的核心组件，由深度估计、深度编码器和视觉编码器三个部分组成，旨在分别对深度信息与视觉语义进行精细化编码，为后续双分支解码提供高质量特征输入。本文尝试了多种先进的轻量化单目深度估计模型。最终通过精简 Lite-Mono^[29]模型，在没有增加过多计算量的同时，提高的检测精度。而其他很多模型甚至会导致精度下降包括 Lite-Mono^[29]，MonoDepth-V2^[30]，and ZoeDepth^[31]等，对比效果如表 1。本文认为，这一结果可能是平衡网络训练的结果，本文的主要目的是检测，而不是深度估计。过大的深度估计网络可能会破坏网络训练过程，从而导致检测精度下降。精简的 Lite-Mono^[28]模型如图 3 所示，其核心包括连续扩展卷积（Consecutive Dilated Convolutions，CDC）模块与局部全局特征交互（Local-Global Features Interaction，LGFI）模块的精简版本。

为了轻量化 Lite-Mono，本文对其核心 CDC 模块和 LGFI 模块进行了改动，如图 4 所示，与原文中的 CDC 模块不同的是，深度可分离卷积（Depthwise Separable Convolution，DSC）模块将其中的扩张卷积层替换为了深度可分离卷积层，以减少计算量和参数量，提升计算效率。与 DSC 模块相似，为了轻量化，精简的 LGFI 模块不包括逐点相乘层，仅保留多头注意力与残差结构，降低计算复杂度。

通过深度估计模块输出深度特征，首先将这些特征统一采样到 $1/16$ 维度大小，随后利用一个 1×1 卷积融合多尺度特征，以融合后的特征为基础，展开深度离散化处理。




图 5 深度离散化策略

Fig. 5 Deep Discretization Methods

本文采取如图 5 中的线性递增的离散化(LID)策略^[32]，将深度离散化为 $k+1$ 个区间，其中前 k 个区间表示前景深度，最后一个区间表示背景。本文选择的深度空间离散化方式为 LID（线

性递增离散化），因为可以利用更宽的间隔来抑制更远对象的较大深度估计误差。本文将前景深度限制在 $[d_{min}, d_{max}]$ 范围内，并将第一个区间的长度和 LID 的区间深度差设置为 δ 。然后将深度标签 d 分类到第 k 个区间中，如下式：

$$\begin{cases} k = \left\lfloor -0.5 + 0.5 \sqrt{1 + \frac{8(d - d_{min})}{\delta}} \right\rfloor \\ \delta = \frac{2(d_{max} - d_{min})}{k(k+1)} \end{cases} \quad (3)$$

通过关注对象的深度值，该网络能够更精准地捕捉前景空间结构及对象间的深度关系，为后续的深度编码器生成信息丰富的深度特征。

深度编码器采用多头自注意力机制，对离散化后的深度特征进行全局上下文建模，通过跨空间位置的注意力交互，捕捉场景中无体检的相对深度关系，生成包含几何结构信息的深度嵌入。

在视觉编码器中，本文为了减少计算量开销，提高推理速度，基于 RT-DETR^[5]所提出的混合编码器架构，设计轻量化视觉编码器以适应单目图像的多尺度语义提取需求，结构如图 6 所示：




图 6 混合视觉编码器

Fig. 6 Hybird Visual Encoder

与原始的 RT-DETR 提出的混合编码器相比，本文的混合编码器在 Fusion 模块上表现了差异。可以灵活的由下面公式表示：

$$\begin{aligned} Q, K, V &= \text{Linear}(\text{Flatten}(F_3)) \\ F_3 &= \text{Reshape}(\text{Attn}(Q, K, V)) \\ \text{Output} &= \text{CCFM}(\{F_1, F_2, F_3\}) \end{aligned} \quad (4)$$

其中 Flatten 表示展平操作，Linear 表示线性连接，Attn 表示多头自注意力，Reshape 表示将特征恢复到与输入 F_3 相同的形状。

该模块通过结构优化与功能解耦，为双分支解码模块提供了语义明确、几何一致的跨模态特征，是 MonoDGNet 实现高精度单目 3D 检测的关键基础。

1.2.3 双分支解码模块

本文将 MonoDETR 中的深度引导的解码器模块解耦为二维检测解码器和三维检测解码器。使用二维解码器获取初始化查询，二维查询可以获取空间位置、形状和类别信息，从而减少深度不确定性。随后，将这些二维查询作为三维检测解码器的初始查询，与视觉和深度特征进行交互。这样可以确保每个编码器能够专注于自己的特定人物，并在训练过程中稳定收敛。

二维检测解码器：本文使用一组可以学习的目标查询 $q \in \mathbb{R}^{N \times C}$ 作为输入，依次通过多层堆叠的自注意力层、多尺度可变形的交叉注意力层（MSDeform Attn^[18]）和前馈（FFN）网络，输出二维查询。其中 N 表示单个图像中预设的最大目标数量。

$$q_{2d} = \text{FFN}(\text{MSAttn}(F, \text{Attn}(q))) \quad (5)$$

其中，MSAttn 表示多尺度可变形的交叉注意力， F 表示二维编码器和深度特征的融合输入。三维检测解码器可以利用这些二维查询先验来更快的聚焦在复杂场景中的目标区域。

三维检测解码器：为了更有效地融合深度特征与图像特征，本文在三维检测解码器中引入了门控深度交叉注意力模块（Gate Depth Cross Attention Module, GDCA），如图 7 所示，初始化的二维目标查询 $q_{2d} \in \mathbb{R}^{N \times C}$ 与深度嵌入作为模块输入。由于不同类型的输入数据具有显著的分布差异，直接进行融合可能导致信息干扰或噪声传播。因此，提出了一种基于门控机制的动态融合方法，用于自适应控制深度特征在交叉注意力中的引导权重，从而实现更鲁棒的特征融合。




图 7 三维检测编码器和门控深度交叉注意力模块

Fig. 7 3D Detection Decoder and Gate Depth Cross Attention Module

具体而言，门控模块会对当前查询和深度嵌入进行联合建模，生成一组融合权重以调节深度信息对每个查询的影响程度。与传统硬性融合方式不同，门控机制具备可学习与动态响应能力，能够根据不同输入特征自适应分配融合比例，从而避免信息冗余或误导。

此外，本文还引入了门控指数线性单元（GEGLU）^[26]作为激活函数，一种结合了 GELU 激活函数的非线性特性与 GLU 的门控机制，其定义如下：

$$\text{GEGLU}(x) = \text{GELU}(x_1) \boxtimes \text{Linear}(x_2) \quad (6)$$

其中 x_1 , x_2 分别为输入特征的两个线性变换分支， $\boxtimes$ 表示逐元素相乘。GELU 激活函数用于捕捉非线性变化趋势，而线性分支则保留输入特征的线性信息。相比传统的 GLU，GEGLU 结合

了非线性激活与门控机制，能够更好地平衡特征的线性表达与非线性投影能力，从而提升模型表达能力与训练稳定性。在多尺度注意力融合过程中，GEGLU 有效缓解了深度引导带来的训练不稳定问题，进一步提高了网络的收敛速度和检测精度。

1.2.4 基于几何约束的结果融合模块

二维检测头基于二维查询输出 2D 检测结果，具体包括目标类别、投影中心坐标及二维尺寸等信息；三维检测头则通过三维查询生成 3D 检测结果，涵盖目标三维尺寸、深度值及目标航向角等参数。然而在三维目标检测任务中，仅通过三维检测头回归获得的深度值通常是存在不确定性。尤其在远距离或遮挡严重的场景中，为减轻深度的不确定性，本文引入了透视投影公式作为几何约束。具体而言，通过预设车辆高度信息 H ，以及二维尺寸计算，得出几何深度 D_{geo} ，计算公式如下：


$$D_{geo} = \frac{f \times H}{h_{2d}} \quad (7)$$


图 8 透视投影公式及误差

Fig. 8 Perspective Projection Formula And Errors

图 8 中， f 为相机焦距， h_{2d} 为目标在二维图像中的高度。与回归深度 D_r 相比， D_{geo} 具有透视不变性，空间不确定性较小。为充分利用两种深度信息的优势，本文采用注意力引导的方式，对回归深度和几何深度进行自适应融合，具体公式如下：

$$\begin{aligned} F_{attn} &= \text{ChanAttn}(\text{SpatAttn}(F)) \\ D_f &= F_{attn} \square D_{geo} + (1 - F_{attn}) \square D_r \end{aligned} \quad (8)$$

其中，ChanAttn 和 SpatAttn 分别表示通道注意力和空间注意力，使得网络能够自动判断在不同条件下应更加依赖哪一类深度信息，实现自适应融合。

1.3 损失函数设计

训练损失由四个部分组成：区域分割损失 L_{region} ，深度损失 L_D ，二维损失 L_{2d} 和三维损失 L_{3d} 。 L_{2d} 包含目标类别，投影中心点和边界框的损失； L_{3d} 包括航向角，三维尺寸和中心深度的损失。本文用 $\lambda_1 \sim \lambda_6$ 表示这些损失的权重，MonoDGNet 的总损失公式如下：

$$L_{region} = \sum_{i=0}^4 \left(1 - \frac{2 \cdot \sum_{j=1}^{N_i} p_j \cdot g_j}{\sum_{j=1}^{N_i} p_j + \sum_{j=1}^{N_i} g_j} \right), \quad i = 0, 1, 2, 3 \quad (9)$$

$$L_D = \frac{1}{N} \sum_{i=1}^N \|D_f^i - D_{gt}^i\|_1 + \lambda \|W - 0.5\|_2^2 \quad (10)$$

$$L = L_{2D} + L_{3D} + \lambda_7 L_D + \lambda_8 L_{region} \quad (11)$$

其中, p_j 表示第 j 个像素的预测概率, g_j 表示地面该像素的真值标签, N_i 表示第 i 个特征图 F_i 中的像素总数, D_f 表示预测深度, W 为可学习的融合权重, 作为一个正则化约束。

2 网络训练

2.1 数据集准备

本文选择 KITTI 公开数据集^[24]验证所提出的 MonoDGNet 模型。KITTI 数据集包括 7481 张训练图像和 7518 张测试图像, 并依据检测难度划分为三个难度级别 (easy, moderate, hard), 目标类别包括 Car、Cyclist 和 Pedestrian 等。考虑常用的数据划分策略, 将 KITTI 数据集中 7481 张的训练图片划分为 3712 张图像作为训练集, 3769 张图像作为验证集, 7518 张测试图像作为测试集。

2.2 数据预处理

除了常规的数据增强方式外, 本文进一步引进了 MixUp3D^[33]数据增强技术, 以提升模型的泛化能力。该技术基于传统的 MixUp 数据增强思想并针对 3D 数据特性进行改进, 在保持几何一致性的前提下, 将两张图像及其对应标签按比例混合, 生成具有物理一致性和语义合理性的合成样本, 缓解了 3D 检测中的过拟合问题, 并避免了图像模糊伪影的出现。

具体来说, 对于训练集中的图像 I_1 和 I_2 及其对应的标签 Y_1 和 Y_2 , 只要其图像的焦距相同, 就可以生成新的数据样本, 具体计算如下式:

$$\begin{aligned} I &= \lambda I_1 + (1 - \lambda) I_2 \\ Y &= Y_1 + Y_2 \end{aligned} \quad (12)$$

其中 λ 为混合比例因子, I 和 Y 表示生成的新的数据样本所对应的图像及标签, 可以在不引入新的噪声的情况下丰富训练样本, 有效缓解过拟合问题, 提高模型的鲁棒性。在本文的实验中, 训练过程中每张图片有 50% 的随机概率采取 MixUp3D 数据增强技术, λ 为固定设置的 0.5。 $\lambda = 0.5$ 使两张图像对损失贡献相等, 避免任一标签被过度稀释, 保证 3D 几何与语义约束对称, 并且固定单值无需额外随机数采样, 简化训练流程。

2.3 网络训练参数配置

本文算法基于 Ubuntu20.04 系统与 Pytorch 2.0.0 深度学习框架。实验硬件平台为搭载 Intel i9-14900K CPU 处理器, 128GB 内存, Nvidia RTX4090 24GB 的高性能工作站。

在超参数设置方面, 将批尺寸设置为 8, 默认学习率设置为 0.0002, MonoDGNet 共训练 250 个批次。损失函数中各项权重系数 $\lambda_1 \sim \lambda_8$ 分别设置为 {5, 2, 10, 1, 1, 1, 1, 1}。

优化器采用带权重衰减的 AdamW^[34], 权重衰减因子设置为 0.0002。LID 策略的 k 值设置为 80, 将 kitti 的前景深度限制在 [0.001, 60]m 范围内。使用 warmup 的预热学习率策略, 初始学习率设置为 0.00001, 随后在接下来的 5 个批次内, 采用 cosine 退火策略将学习率提升至默认学习率, 以提升模型稳定性与收敛效果。并采用阶梯式学习率调整策略, 分别在第 85、125、165 及 225 批次时, 将学习率调整至前一批次的 0.5 倍。MonoDGP 网络训练过程损失、学习率及精度变化如图 9 所示, MonoDETR 网络训练过程损失、学习率及精度变化如图 10 所示。




图 9 MonoDGNet 训练过程

Fig. 9 MonoDGNet Training Process




图 10 MonoDETR 训练过程

Fig. 10 MonoDETR Training Process

通过 ADF 检验表明，MonoDGNet 模型的训练过程具有统计显著性 ($P < 0.001$)，表现为平稳时间序列，而基线模型呈现非平稳特征。同时，改进模型在收敛后的标准差相比基线模型降低了 11.0%，变异系数降低了 16.1%，证明了训练稳定性的显著提升。

3 网络评估

3.1 评估指标

本文的主要以 3D 边界框和鸟瞰图的平均精度 (AP) 指标进行评估，即 AP_{3D} 和 AP_{BEV} ，在 KITTI 中 AP 有两种计算方式，分别为基于 11 个召回点位置的计算的平均精度 $AP|_{R10}$ 和基于 40 个召回点位置计算的平均精度 $AP|_{R40}$ 。

本研究采用 $AP|_{R40}$ 作为评价指标，并且设定在 IoU 达到 0.7 时才会被判定为正确预测。最终，基于 $AP|_{R40}^{70}$ 对网络检测效果展开分析与验证，以确保评估的准确性与可靠性。

3.2 检测精度分析

为了验证所提出模型的优越性能，本文展示了 MonoDGNet 在 KITTI 验证集和测试集上的定量评估结果。如表 2 所示，研究对近年来先进的单目三维目标检测方法进行了比较。在未使用额外数据的情况下，MonoDGNet 模型全面超越基准模型 MonoDETR，在各项指标上均取得最优表现。

于测试集而言，与现有优秀方法相比，在三个难度级别下，MonoDGNet 模型的 AP_{3D} 和 AP_{BEV} ，相较于精度排名第二的模型，分别提升了 1.38、1.76、1.71 以及 1.14、1.62、1.61。在验证集的三个难度级别下， AP_{3D} 较精度排名第二的模型分别提高了 1.20、1.86、2.49。除 Car 类别外，本文还报告了 MonoDGNet 以及基线模型在 Pedestrian 以及 Cyclist 类别上的检测效

果，由于基线模型 MonoDETR 未公开其在测试集上 Pedestrian 以及 Cyclist 类别的检测结果，因此，此结果均为在 KITTI 验证集评估指标，结果如表 3 所示。

值得注意的是，为优化模型性能，本文运用早停策略筛选验证集上的最优结果。具体而言，在训练过程中持续监测验证集指标，一旦指标不再提升便停止训练，选定此时的模型参数作为最佳配置。对于测试集，采用最后一个批次的模型权重进行推理，并将检测结果提交至 KITTI 官网。

鉴于 DETR 模型存在训练不稳定的特性，本文对 MonoDGNet 模型进行了 5 次独立训练。在评估时，选取 5 次训练结果中 Mod.难度下的中位数作为最终检测结果。同时，为了展示 GEGLU 激活函数对训练不稳定问题的改善效果，通过 5 次独立训练，选取 Mod.难度的检测结果的中位数，并计算方差作为对比。结果如表 4 所示。后续开展的消融实验也遵循相同的评估方式，确保实验结果的可靠性与一致性。

表 1 不同深度估计模块的影响
Table 1 The Impact of Different Depth Estimation Modules

深度估计模块	Mod.精度 (%)	参数量 Params. (Million)
Foreground Depth	20.61	-
Lite-Mono	21.89	+2.9
MonoDepth-V2	20.73	+14.3
ZoeDepth	20.37	+112
精简 Lite-Mono	22.47	+2.0

3.3 消融实验

为验证本文所提出 MonoDGNet 的有效性与其严谨性，在 KITTI 验证集上针对是否使用 MixUp3D 数据增强策略以及模型中提出的多尺度特征融合模块、双分支编码模块、双分支解码模块和基于几何约束的结果融合模块开展消融实验。以批尺寸为 1，在 RTX4090 上测试了推理时间。实验以 AP3D 和推理时间为主要评估指标，结果如表 5 所示。

与基线网络相比，三级难度下的 AP_{3D} 分别提升了 3.48%，2.25%和 2.32%，且实时性损失不明显。并且可视化了结果融合模块对远距离目标的效果提升以及展示了模型在不同距离区间下的检测精度，如图 11、表 6。经过统计，KITTI 数据集中超过 50%的车辆距离在 25m 以内，超过 75%车辆的距离在 40m 以内，所以将距离区间划分 0-20m，20-40m，40m+。通过消融实验验证了 MonoDGNet 中使用的每种模块的有效性。

表 2 KITTI 测试集和验证集上的检测结果
Table 2 Detection Results on the KITTI Test Set and Validation Set

模型	额外数据	测试集, AP _{3D} (%)			测试集, AP _{BEV} (%)			验证集, AP _{3D} (%)		
		Easy	Mod.	Hard	Easy	Mod.	Hard	Easy	Mod.	Hard
DDMP-3D ^[35]	深度	19.71	12.78	9.80	28.08	17.89	13.44	-	-	-
MonoDistill ^[13]		22.97	16.03	13.60	31.87	22.59	19.72	24.31	18.47	15.76
MonoPGC ^[36]		24.68	<u>17.17</u>	14.14	32.50	23.14	20.03	25.67	18.63	15.65
OPA-3D ^[37]		24.60	17.05	14.25	33.54	22.53	19.22	24.97	19.40	16.59
SMOKE ^[38]	无	14.03	9.76	7.84	20.83	14.49	12.75	14.76	12.85	11.50
GUPNet ^[11]		20.11	14.20	11.77	-	-	-	22.76	16.46	13.72
MonoCon ^[39]		22.50	16.46	13.95	31.12	22.10	19.00	26.33	19.01	15.98
MonoDETR ^[23]		25.00	16.47	13.58	33.60	22.11	18.60	<u>28.84</u>	<u>20.61</u>	16.38
MonoCD ^[12]		<u>25.53</u>	16.59	<u>14.53</u>	33.41	22.81	19.57	26.45	19.37	16.38
FD3D ^[40]		25.38	17.12	14.50	<u>34.20</u>	<u>23.72</u>	<u>20.76</u>	28.22	20.23	<u>17.04</u>

MonoDGNet	无	26.91	18.93	16.24	35.34	25.34	22.37	30.04	22.47	19.53
提升	-	+1.38	+1.76	+1.71	+1.14	+1.62	+1.61	+1.20	+1.86	+2.49

表 3 KITTI 验证集上 Pedestrian 和 Cyclist 的检测结果

Table 3 Detection Results of Pedestrian and Cyclist on the KITTI Validation Set

模型	验证集,AP _{3D} (%)					
	Easy	行人 Mod.	Hard	Easy	自行车 Mod.	Hard
MonoDETR	13.04	7.89	6.38	4.28	2.32	1.95
MonoDGNet	15.62	9.73	8.15	5.48	2.97	2.65
提升	+2.62	+1.84	+1.77	+1.20	+0.65	+0.70

表 4 5 次训练结果精度及方差

Table 4 Accuracy and Variance after 5 Training

次数	1	2	3	4	5
Mod.精度(GELU) (%)	22.60	21.91	22.51	21.07	21.18
Mod.精度(GEGLU) (%)	21.89	22.47	22.06	22.51	22.82
方差(GELU)			0.51		
方差(GEGLU)			0.37		

表 5 消融实验

Table 5 The Ablation Study

Mixup3D	多尺度特征 提取模块	双分支编 码模块	双分支解码 模块	结果融 合模块	验证集 AP _{3D} (%)			推理时间 (ms)
					Easy	Mod.	Hard	
-	-	-	-	-	26.56	20.22	17.21	17
✓	-	-	-	-	28.17	20.79	17.25	17
✓	✓	-	-	-	28.76	20.92	18.23	18
✓	✓	✓	-	-	29.18	21.04	18.34	21
✓	✓	✓	MSDeform Attn	-	29.34	21.13	18.76	24
✓	✓	✓	GDCA	-	29.83	21.63	19.21	21
✓	✓	✓	✓	✓	30.04	22.47	19.53	22
		提升			3.48	2.25	2.32	-

表 6 不同距离区间的检测精度

Table 6 Detection Accuracy at Different Distance Ranges

模型	0-20m(Mod.) (%)	20-40m(Mod.) (%)	40m+(Mod.) (%)
MonoDETR	48.85	23.62	0.58
MonoDGNet	53.61	25.03	0.86
提升	+4.67	+1.41	+0.28




图 11 回归深度对比几何深度

Fig. 11 Regression Depth V.S. Geometric Depth

3.4 可视化

如图 12 和图 13 所示, 本文分别展示了基线网络 MonoDETR 与所提出算法 MonoDGNet 在 KITTI 测试集上的推理结果可视化, 以及在 BEV 视角下的推理结果可视化。在 BEV 视角下, 绿色为 GT 目标, 蓝色为预测目标。从可视化结果中可以看出, MonoDGNet 在检测性能上相较于 MonoDETR 有显著优势。具体来说, MonoDGNet 在复杂场景下的三维目标检测更加准确, 能够更精确地捕捉到目标的轮廓和位置信息, 在处理遮挡、截断等挑战性问题时也表现出更强的鲁棒性, 并且 MonoDGNet 在深度上与真实结果更为贴合, 体现了模型在深度估计上的高精度。同时, 为验证模型在低亮度环境下的适应性, 本文对 KITTI 验证集数据进行低亮度预处理, 未针对低亮度数据额外训练, 并展示了 MonoDGNet 的推理结果, 如图 14。实验表明, 即便在光照不足的场景中, MonoDGNet 仍能保持良好的检测精度, 进一步证明了其环境适应性。这些可视化结果进一步验证了 MonoDGNet 在单目 3D 目标检测任务中的优越性。

4 结 语

本文提出了一种融合深度引导与几何约束的单目三维目标检测方法——MonoDGNet, 在满足实时性前提下显著提升了检测精度与鲁棒性。主要贡献体现在以下几个方面:

(1) 构建了基于模块化、并行化编码器-解码器架构的端到端检测框架, 仅依赖单目 RGB 图像即可实现高精度三维目标检测;

(2) 针对单目图像中不同距离目标的成像尺度差异显著问题, 本文提出了多尺度特征融合模块, 通过特征金字塔优化等方式实现对多尺度目标的精细化检测, 同时引入轻量级的区域分割头网络, 实现图像前景和背景特征有效分离;

(3) 针对基线网络解码器在查询初始化时缺乏有效性的问题, 本文提出了双分支解码模块。利用二维检测解码器为三维检测解码器提供高质量的查询初始化, 有效促进了解码器的训练收敛速度, 从而提升了整体检测精度。同时, 设计了一种基于门控机制的深度引导融合方法, 可自适应调节深度特征的引导权重, 实现更加鲁棒的跨模态特征融合;

(4) 针对单目图像天然缺乏深度信息的问题, 通过引入相机透视投影公式生成几何深度, 自适应融合回归深度和几何深度, 提升了模型对空间结构的感知能力, 进一步提高了 3D 检测的性能;

(5) 在 KITTI 公开数据集上的测试结果表明, 相较于基线网络, MonoDGNet 在三种难度的 AP3D 分别提升了+3.48%, 2.25%和 2.32%, 与当前精度排名第二的模型相比, 分别提升了

+1.38、+1.76、+1.71。同时，在检测速度方面，本文方法在没有经过优化处理的情况下，能够满足实时性处理需求。

未来工作将聚焦于进一步提升模型的泛化能力和部署效率，探索在多场景、多任务条件下的适应性，推动单目三维检测在真实自动驾驶系统中的落地应用。




图 12 推理结果可视化

Fig. 12 Visualization of Inference Results




图 13 KITTI 数据集 BEV 可视化结果

Fig. 13 Visualization Results of KITTI Dataset from the BEV



图 14 低亮度情况下可视化结果

Fig. 14 Visualization Results Under Low Brightness Conditions

参考文献:

References:

- [1] CUI Y D, CHEN R, CHU W B, et al. Deep learning for image and point cloud fusion in autonomous driving: a review[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(2): 722-739.
- [2] 任柯燕, 谷美颖, 袁正谦, 等. 自动驾驶 3D 目标检测研究综述[J]. 控制与决策, 2023, 38(4): 865-889.
REN Ke-yan, GU Mei-ying, YUAN Zheng-qian, et al. A survey on 3D object detection for autonomous driving[J]. Control and Decision, 2023, 38(4): 865-889.
- [3] VARGHESE R, SAMBATH M. YOLOv8: A novel object detection algorithm with enhanced performance and robustness[C]//IEEE. 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). Tamil Nadu, India: IEEE, 2024: 1-6.
- [4] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot MultiBox detector[C]//LEIBE B, MATAS J, SEBE N, et al. Computer Vision - ECCV 2016. Cham: Springer International Publishing, 2016: 21-37.
- [5] ZHAO Y, LV W, XU S, et al. DETRs beat YOLOs on real-time object detection[C]//IEEE. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 16965-16974.
- [6] LANG A H, VORA S, CAESAR H, et al. PointPillars: Fast encoders for object detection from point clouds[C]//IEEE. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach: IEEE, 2019: 12697-12705.
- [7] CHEN Y, LIU J, ZHANG X, et al. VoxelNeXt: Fully sparse VoxelNet for 3D object detection and tracking[C]//IEEE. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 21674-21683.
- [8] WANG H Y, SHI C, SHI S S, et al. DSVT: Dynamic sparse voxel transformer with rotated sets[C]//IEEE. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 13520-13529.
- [9] 霍威乐, 荆涛, 任爽. 面向自动驾驶的三维目标检测综述[J]. 计算机科学, 2023, 50(7): 107-118.
HUO Wei-le, JING Tao, REN Shuang. Review of 3D object detection for autonomous driving[J]. Computer Science, 2023, 50(7): 107-118.
- [10] MA X, OUYANG W, SIMONELLI A, et al. 3D object detection from images for autonomous driving: a survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(5): 3537-3556.
- [11] LU Y, MA X, YANG L, et al. Geometry uncertainty projection network for monocular 3D object detection[C]//IEEE. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: IEEE, 2021: 3111-3121.
- [12] YAN L F, YAN P, XIONG S Z, et al. MonoCD: Monocular 3D object detection with complementary depths[C]//IEEE. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 10248-10257.
- [13] CHONG Z, MA X, ZHANG H, et al. MonoDistill: Learning spatial features for monocular 3D object detection[J/OL]. (2022-01-26)[2025-03-24]. <http://arxiv.org/abs/2201.10830>.
- [14] HONG Y, DAI H, DING Y. Cross-modality knowledge distillation network for monocular 3D object detection[C]// AVIDAN S, BROSTOW G, MARIA FARINELLA G, et al. Computer Vision - ECCV 2022. Tel Aviv, Israel: Springer, 2022: 87-104.
- [15] RANASINGHE Y, HEGDE D, PATEL V M. MonoDiff: Monocular 3D object detection and pose estimation with diffusion models[C]//IEEE. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 10659-10670.
- [16] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//ACM. Proceedings of the 31st International Conference on Neural Information Processing Systems. California: ACM, 2017: 6000-6010.
- [17] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//VEDALDI A, BISCHOF H, BROX T, et al. Computer Vision - ECCV 2020. Cham: Springer International Publishing, 2020: 213-229.

- [18] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable transformers for end-to-end object detection[J/OL]. (2020-10-08)[2023-11-24]. <https://arxiv.org/abs/2010.04159>.
- [19] LI Z, WANG W, LI H, et al. BEVFormer: Learning bird's-eye-view representation from LiDAR-camera *via* spatiotemporal transformers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(3): 2020-2036.
- [20] YANG C, CHEN Y, TIAN H, et al. BEVFormer v2: Adapting modern image backbones to bird's-eye-view recognition *via* perspective supervision[C]//IEEE. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 17830-17839.
- [21] WANG Y, GUIZILINI V C, ZHANG T, et al. DETR3D: 3D object detection from multi-view images *via* 3D-to-2D queries[C]//ALEKSANDRA F, DAVID H, GERHARD N. Proceedings of the 5th Conference on Robot Learning(CoRL). Auckland, New Zealand: PMLR, 2022: 180-191.
- [22] LIANG T, XIE H, YU K, et al. BEVFusion: A simple and robust LiDAR-camera fusion framework[J]. Advances in Neural Information Processing Systems, 2022, 35: 10421-10434.
- [23] ZHANG R R, QIU H, WANG T, et al. MonoDETR: Depth-guided transformer for monocular 3D object detection[C]//IEEE. 2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 9155-9166.
- [24] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the KITTI vision benchmark suite[C]//IEEE. 2012 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2012: 3354-3361.
- [25] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//IEEE. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: IEEE, 2016: 770-778.
- [26] SHAZEER N. GLU variants improve transformer[J/OL].(2020-02-12)[2025-05-25]. <https://arxiv.org/abs/2002.05202>.
- [27] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241.
- [28] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//FERRARI V, HEBERT M, SMINCHISCU C, et al. Computer Vision - ECCV 2018. Munich, Germany: Springer International Publishing, 2018: 3-19.
- [29] ZHANG N, NEX F, VOSSelman G, et al. Lite-Mono: A lightweight CNN and transformer architecture for self-supervised monocular depth estimation[C]//IEEE. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 18537-18546.
- [30] GODARD C, MAC AODHA O, FIRMAN M, et al. Digging into self-supervised monocular depth estimation[C]//IEEE. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 3827-3837.
- [31] BHAT S F, BIRKL R, WOFK D, et al. ZoeDepth: Zero-shot transfer by combining relative and metric depth[J/OL]. (2023-03-23)[2025-03-24]. <http://arxiv.org/abs/2302.12288>.
- [32] READING C, HARAKEH A, CHAE J, et al. Categorical depth distribution network for monocular 3D object detection[C]//IEEE. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 8551-8560.
- [33] LI Z, JIA J, SHI Y. MonoLSS: Learnable sample selection for monocular 3D detection[J/OL]. (2024-05-22)[2025-03-12]. <http://arxiv.org/abs/2312.14474>.
- [34] LOSHCILOV I, HUTTER F. Decoupled weight decay regularization[J/OL]. (2018-02-14)[2025-05-27] <https://arxiv.org/abs/1711.05101>.
- [35] WANG L, DU L, YE X, et al. Depth-conditioned dynamic message propagation for monocular 3D object detection[C]//IEEE. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 454-463.
- [36] WU Z, GAN Y, WANG L, et al. MonoPGC: Monocular 3D object detection with pixel geometry contexts[C]//IEEE. 2023 IEEE International Conference on Robotics and Automation (ICRA). London, United Kingdom: IEEE, 2023: 4842-4849.
- [37] SU Y Z, DI Y, ZHAI G Y, et al. OPA-3D: Occlusion-aware pixel-wise aggregation for monocular 3D object detection[J]. IEEE Robotics and Automation Letters, 2023, 8(3): 1327-1334.
- [38] LIU Z C, WU Z Z, TOTH R. SMOKE: Single-stage monocular 3D object detection via keypoint

- estimation[C]//IEEE. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Seattle, WA, USA: IEEE, 2020: 4289-4298.
- [39] LIU X P, XUE N, WU T F. Learning auxiliary monocular contexts helps monocular 3D object detection[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Vancouver, BC, Canada: AAAI Press, 2022, 36(2): 1810-1818.
- [40] WU Z Z, GAN Y Z, WU Y Z, et al. FD3D: Exploiting foreground depth map for feature-supervised monocular 3D object detection[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Vancouver, BC, Canada: AAAI Press, 2024, 38(6): 6189-6197.

