

天津理工大学学报
Journal of Tianjin University of Technology
ISSN 1673-095X, CN 12-1374/N

《天津理工大学学报》网络首发论文

题目：基于特征信息强化的单目三维目标检测模型
作者：张续坤，温显斌
收稿日期：2023-12-28
网络首发日期：2024-12-17
引用格式：张续坤，温显斌. 基于特征信息强化的单目三维目标检测模型[J/OL]. 天津理工大学学报. <https://link.cnki.net/urlid/12.1374.N.20241216.1739.046>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于特征信息强化的单目三维目标检测模型*

张续坤^{1, 2, 3}, 温显斌^{1, 2, 3*}

- (1. 天津理工大学 计算机科学与工程学院, 天津 300384;
2. 天津理工大学 计算机视觉与系统教育部重点实验室, 天津 300384;
3. 天津理工大学 天津市智能计算与软件新技术重点实验室, 天津 300384)

摘要:近年来, 基于深度学习的单目图像三维目标检测由于数据来源简单、成本低等优点, 被广泛应用于自动驾驶、战场感知等领域。但由于单目图像中深度信息的匮乏, 导致现阶段模型性能较低。为此, 本文提出了一种新的单目三维目标检测 Transformer 模型 DM-Transformer (Depth-aware Monocular Transformer)。该模型以 ResNet50 为骨干网络对单目图像提取视觉特征; 通过交叉注意力机制构造深度信息表现模块, 并将深度感知解码器输出的视觉信息和深度信息作为输入进行融合学习, 使模型学习物体局部的深度信息以及物体之间的特征联系; 最后基于融合了深度和视觉特征进行三维物体检测, 并在公共目标检测数据集 KITTI 3D 上验证了该模型的性能, 与当前单目三维目标检测模型相比, 有效提高了三维物体检测精确度。

关键词:深度学习; 单目三维目标检测; Transformer; 深度可分离卷积

中图分类号: TP391.4 **文献标识码:** A

Monocular three dimensions detection model based on enhanced features
informationZHANG Xukun^{1, 2, 3}, WEN Xianbin^{1, 2, 3*}

- (1. School of Computer Science and Engineering, Tianjin University of Technology,
Tianjin 300384, China;
2. Key Laboratory of Computer Vision and System, Ministry of Education,
Tianjin University of Technology, Tianjin 300384, China
3. Tianjin Key Laboratory of Intelligence Computing and Novel Software Technology,
Tianjin University of Technology, Tianjin 300384, China)

Abstract: In recent years, monocular 3D object detection based on deep learning has been widely applied in fields such as autonomous driving and battlefield perception due to its advantages of simple data sources and low cost. However, the performance of existing models is relatively low due to the lack of depth information in monocular images. To address this issue, this paper proposes a novel monocular 3D object detection Transformer model named DM-Transformer (Depth-aware Monocular Transformer). This model utilizes ResNet50 as the feature backbone to extract visual features from monocular images. Then Explicit Depth Module is constructed to fuse and learn the visual and the depth information output from the depth-aware decoder. This enables the model to learn the local depth information around objects and the feature relationships between objects. Finally, based on the fused depth and visual features, 3D object detection is performed, and the performance of the proposed method is evaluated on the publicly available KITTI 3D database. Compared to other methods, the proposed DM-Transformer model effectively improves the accuracy of 3D object

detection.

Key words: deep learning; monocular 3D object detection; transformer; depthwise separable convolution

当前,自动驾驶和智能机器人技术正飞速发展,对三维物体的检测需求愈发迫切。由于现实环境的复杂性,三维物体检测则更具挑战性。三维物体检测主要分为激光雷达点云数据检测、双目(多目)视觉图像检测,及单目视觉图像检测等。基于单目视觉的三维物体检测因其缺乏深度信息,检测难度较高,并且其模型的检测性能也受到模型无法有效提取图像中深度信息的限制。

近年来国内外诸多研究人员针对单目三维目标检测问题进行了深入研究,并提出诸多方法。XU 等^[1]提出了 MF3D 模型,使用了当时深度预测中的 SOTA (State Of The Art)模型 MonoDepth^[2]进行深度预测,随后将得到的深度信息不断与主分支中的视觉特征进行融合,从而辅助完成物体三维边界框参数的预测。在 2020 年,DING 等^[3]提出了 D4LCN (depth-guided dynamic depthwise dilated LCN)网络,构建了一个有深度信息图引导的特征提取网络,通过让模型分离出多个提取器以关注不同层次的图像信息,该模型使用了 MobileNets^[4]中的通道卷积,并且通过使用空洞卷积来使模型获得更大的感受野,从而使模型在多个层次中学习物体间的深度关联信息。之后在 2021 年,CHEN 等^[5]结合不确定性理论提出了 MonoRUn,先通过传统 2D 物体检测网络检测出特种图中的 ROI 区域,在其之后增加额外类似的 3D 学习分支,使模型能学习到稠密的物体坐标,建立二维空间到三维空间的几何一致性,此方法通过 2D 边界框中深度预测的不确定性差异来直接学习得到实例分割的掩膜,再通过隐向量表征的方法得到物体的 3D 坐标,此方法利用真值的位姿信息辅助重投影过程而不是直接学习位姿,并通过设计的 KL-Loss 实现自监督的坐标预测学习。但以上方法由于以卷积神经网络为基础构建,因此对物体局部特征的把握能力优越,但对整张图像中的全局特征表达规律的学习能力不佳,而三维目标识别对于物体之间的特征形态关联有着更高的要求,因此成为限制单目三维目标检测方法发展的主要问题。

随着 Transformer^[6]架构模型在目标检测领域展现了强大的能力,被许多学者注意到,Transformer 被证

明有强大的全局特征学习能力,其对于单目三维目标检测方法来说也至关重要,因此对于该领域有着极大的潜力。ViT (Vision Transformer)^[7]的出现将 Transformer 的应用拓展到计算机视觉领域。但是在很长一段时期内此类模型都需要例如非极大值抑制^[8]之类笨重的预处理方法,为了解决这个问题,目标检测 Transformer (DEtection TRansformer, DETR)^[9]模型的出现成为了首个端到端的物体检测模型,模型产生的预测结果会经过匈牙利匹配算法进行优化,不需要额外的人工工作,然而,由于四倍的注意力计算复杂度,DETR 模型需要 500 轮次才能完全训练,因此 Deformable DETR^[10]解决了这个问题,设计了一种稀疏的可变形的注意力机制,并且仅仅使用了 50 轮训练就取得了更好的成绩,使得计算规模和收敛轮次大大减小,并且小物体检测能力得到大幅提升,让 Deformable DETR 成为更加优秀的目标检测模型。虽然 Transformer 架构模型对于全局特征表达具有强大的学习能力,但缺乏将物体局部特征规律与图像全局特征表达相结合的能力进而导致模型表现欠佳。

对这些问题,本文以 MonoDETR^[11]模型为基础,提出了一种针对深度信息进行强化的 3D 目标探测模型 DM-Transformer,它包含一个深度预测模块,一个深度感知 Transformer 模块,一个深度信息表现模块 (explicit depth module, EDM) 以及探测头。其中深度预测模块先对图像进行初步的深度分类,深度感知 Transformer 模块对图像的视觉和深度特征进行交叉注意力计算,EDM 模块利用局部和全局特征对图像中的深度特征信息进行提取。能为深度感知 Transformer 提供更丰富的深度信息,解决了单目图像中 3D 信息匮乏的问题。最后通过探测头对物体的三维特征进行预测。

1 特征信息强化的单目三维目标检测模型

1.1 网络的整体结构

为了更好地对图像中的物体之间的深度关系进行学习, 本文以 Transformer 模型为基础进行单目 3D 目标检测任务, 同时为了加强模型对图像中深度信息的获取能力, 采用了以深度卷积和 MLP 为基础的 EDM 模块对模型在学习过程中的深度信息进行提取。DM-Transformer 的整体架构如图 3.3 所示。首先, 受到了贾岩松等^[12]的启发, 以 ResNet50^[13]为骨干网络对单目图像提取视觉特征; 其次, 一方面将视觉特征通过视觉编码器进行视觉编码学习, 同时另一方面将视觉特征输入深度预测模块, 通过深度离散化方法实现深度信息的预测和学习, 得到初步的深度特征, 并通过深度编码器, 与视觉编码器同时进行学习, 为后续的视觉深度信息交互做准备; 然后深度引导解码器将深度编码器输出的深度特征与随机生成的物体查询进行深度信息融合和信息交互, 同时, 为了解决交互过程中深度信息获取不足问题, 本文设计了深度信息表现模块, 深度卷积模块和通道 MLP 模块对物体局部的深度信息进行学习, 再使用残差网络在与视觉信息进行融合后进行残差链接, 通过深度卷积模块对物体局部特征分布进行把握以及通道 MLP 模块对物体间和全局特征分布规律进行学习, 以达到将物体局部和物体之间以及全局特征表现相融合的效果, 帮助模型对图像中的三维信息进行学习, 从而提高三维目标识别的准确率; 最后, 基于融合了深度和视觉特征进行三维物体检测。




图 1 DM-Transformer 网络结构

Fig.1 Network structure of DM-Transformer

1.2 深度预测模块

为了给深度编码器提供初步的深度特征信息, 本文使用了 MonoDETR 中的深度预测模块, 使用

ResNet-50^[13]作为特征提取网络, 之后将提取后的特征分别输入深度预测模块和视觉编码器。特征提取骨干网络得到的特征图大小分别为原图尺寸的 1/8, 1/16 以及 1/32。将三张尺度不同的特征图通过最近邻采样法^[14]都缩放到原图的十六分之一大小, 之后将三张特征图进行元素加法操作, 得到跨尺度特征, 再将得到的跨尺度特征经过两个连续的 3×3 卷积网络, 得到包含深度信息的特征图 f_d , 为了生成更加丰富的深度信息, 本文在 f_d 之上预测一个额外的前景深度特征图 D_{fg} 。具体是在 f_d 上通过 1×1 卷积得到 D_{fg} , 其中 $D_{fg} \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times (k+1)}$, k 为人为设置的深度阈值数量, 将深度信息进行线性增长离散化, 分为 k 个前景深度区间, 深度越小的物体包含较多的特征信息, 深度信息预测越精确, 因此区间范围越小, 距离摄像头越远包含的信息越少, 深度预测越困难, 因此区间范围越大, 区间范围随着距离摄像头距离增加而增加。通过以上方法, 物体 d 所在的深度区间 k 的计算公式如下:

$$k = \left\lceil -0.5 + 0.5 \sqrt{\frac{8 \times (d - d_{min})}{\delta}} \right\rceil \quad (1)$$

其中

$$\delta = \frac{2 \times (d_{max} - d_{min})}{k(k+1)} \quad (2)$$

其中 d_{max} 和 d_{min} 分别对应人为规定的深度最大区间和深度最小区间。对于预测出的背景区域将其分类为第 $k+1$ 类。通过以上方法得到了 D_{fg} , 并将其输入深度编码器中进行深度编码。同时使用 Focal Loss^[15]方法对深度特征图 D_{fg} 进行监督, 损失使用 L_{dmap} 来表示。深度预测模块具体结构及参数如图 2 所示。




图 2 深度预测模块结构图

Fig.2 The structure of Depth Predictor Module

1.3 视觉和深度编码器

本文方法中的视觉和深度编码器沿用了 MonoDETR 中的视觉和深度编码器结构, 如图 3 所示。

将视觉和深度特征图分别输入视觉和深度编码器中，两个编码器均由自注意力层和前馈神经网络组成，在视觉编码器中模型采用可变形注意力算法对视觉特征图进行学习和编码，能够大幅降低计算成本以及更好学习物体局部的视觉特征分布，最后输出视觉特征图 f_V^e 。而在深度编码器中使用的全局自注意力算法能够让深度特征图更好地为模型提供全局深度特征，最后输出深度特征图 f_D^e ，另外深度和视觉特征的分别处理也能让他们更好的学习到自身的特征分布。




图 3 深度解码器 (a) 和视觉解码器 (b) 模块结构

Fig.3 Structure of depth encoder(a) and visual encoder(b)

1.4 深度感知解码器

根据输入的深度特征图 f_D^e 和视觉特征图 f_V^e ，本文使用一系列可学习的物体查询表示 $q \in \mathbb{R}^{N \times C}$ ，通过深度感知解码器来对三维目标进行检测，其中 N 代表人为限制的最大物体数量，每一个编码器中都包含一个深度交叉注意力层，一个查询自注意力层，一个视觉交叉注意力层和一个前馈神经网络，其中物体查询首先通过深度交叉注意力层在深度特征图 f_D^e 中学习有效的深度信息，首先通过线性变化将物体查询和深度编码转换为查询，键和值，其变换过程如公式所示：

$$Q_q = \text{Linear}(q), K_D, V_D = \text{Linear}(f_D^e) \quad (3)$$

其中， $Q_q \in \mathbb{R}^{N \times C}$ ， $K_D, V_D \in \mathbb{R}^{N \times \frac{HW}{16^2}}$ ，接着通过交叉注意力算法计算查询和深度信息交互的注意力权重图 $A_D \in \mathbb{R}^{N \times \frac{HW}{16^2}}$ ，之后通过聚合 A_D 得到的权重与查询进行线性变换得到了具有深度信息的查询 q' ，过程如公式所示：

$$A_D = \text{SoftMax}(Q_q K_D^T / \sqrt{C}) \quad (4)$$

此深度交叉注意力层帮助物体查询从图片特征中学习深度信息。因此物体查询能够更好的理解场景信息以及物体之间的几何关系，以此来帮助深度信息的估算。

1.5 深度信息表现模块




图 4 深度信息表现模块结构

Fig. 4 Structure of Explicit Depth Module

在深度感知解码器的深度交叉注意力层和查询自注意力层中，模型通过深度特征图与物体查询的注意力运算，以及查询间的注意力运算使模型对图像中各个物体所对应的深度信息特征以及物体间相互的深度关系进行感知，而在接下来的视觉深度交叉注意力层中，由于得到的深度信息与视觉信息进行交叉全局注意力运算，使一部分物体对应的深度信息在计算过程中被忽视，因此本模型在深度感知解码器的深度交叉注意力和自注意力计算后加入了深度信息表现模块，以此对模型在这两部分所得到的深度信息进行提取和优化。此模块结构如图 4 所示。此模块由两部分组成，一个深度卷积模块以及一个通道 MLP 模块，受到陈思等^[16]的启发，使用了深度可分离卷积进行计算，其中深度卷积模块输出的特征再进入通道 MLP 模块进行计算，从深度交叉注意力或自注意力层输出的特征通过分组后进行组归一化，然后进入深度卷积层进行计算。与传统卷积操作不同，相对于传统卷积层，深度卷积能够提升特征的代表性以及减少计算开销。之后进行通道分割以及 drop path 计算，以及特征进行残差链接，公式如下：

$$\hat{X}_{in} = DConv(GN(X_{in})) + X_{in} \quad (5)$$

对于通道 MLP 部分，从深度卷积模块输出的特征首先进行分组归一化，之后输入通道 MLP 层进行计算，与传统的 MLP 相比，通道 MLP 不仅仅可以高效的降低计算开销，还能够帮助模型进一步增强

对图像全局深度特征分布的理解, 与深度卷积模块得到的物体局部特征信息一同增强模型对图像中深度信息的理解能力。之后通过通道分割和 **drop path** 计算后进行残差链接, 公式如下:

$$MLP(X_{in}) = CMLP(GN(\hat{X}_{in})) + \hat{X}_{in} \quad (6)$$

通过深度信息表现模块对深度交叉注意力层和查询自注意力层所得到的深度特征进行提取和学习, 再输入深度感知解码器的输出中, 模型可以更好地提取图像中的深度信息, 从而提高模型的深度预测效果。

1.6 损失计算

通过深度感知解码器后, 通过一系列以 MLP 为基础的检测头对图像中物体三维特征进行预测, 在训练过程中使用匈牙利算法对无序的物体查询匹配, 求得距离最小的真值。

本文使用了 MonoDETR^[12]中的损失计算公式, 在检测头中, 每一个查询都将被预测六个参数, 分别是物体类别、2D 尺寸 (l, r, t, b)、3D 投影中心 (x_{3D}, y_{3D})、深度 (d_{reg})、3D 尺寸 (h_{3D}, w_{3D}, l_{3D}) 以及偏转角度 α , 其中 l, r, t, b 代表物体 2D 预测框的四边相对于物体 3D 投影中心 (x_{3D}, y_{3D}) 的距离, 两个参数都针对图像尺寸进行归一化处理。为了对物体最终的深度信息 d_{pred} 进行估计, 文中使用三个预测值进行综合: 检测头预测出的 d_{reg} , 通过预测的 2D 和 3D 尺寸进行变换的 d_{geo} 以及通过深度特征图 D_{fg} 得到的 x_{3D}, y_{3D} , 具体的计算公式如下:

$$d_{geo} = f \frac{h_{3D}}{t+b}$$

$$d_{pred} = (d_{reg} + d_{geo} + d_{map}(x_{3D}, y_{3D})) / 3 \quad (8)$$

其中, h_{3D} 和 $t+b$ 代表预测的 3D 以及 2D 的物体高度, f 代表相机的焦距。

为了正确匹配查询以及其对应的真值, 每个查询都将被计算其损失并使用匈牙利算法进行匹配。将每个查询对应的六个参数分为两组, 第一组中包含物体类别、2D 尺寸以及 3D 投影中心, 因为这些参数大都与物体的 2D 特征相关联, 第二组包含物体的深度信息、3D 尺寸以及偏转角度这些与物体 3D 特征相关联的参数, 分别被命名为 L_{2D} 和 L_{3D} 。由于物体的 3D 信息大部分情况下都不及 2D 信息准确, 尤其是当训练刚开始时, 混乱的 3D 信息也会影响查询和真值的匹

配, 因此本文仅仅使用 L_{2D} 来为查询和真值进行匹配。当全部匹配完成后, 从中选出 N_{gt} 个有效的配对, N_{gt} 代表真值的数量, 然后对整体的损失进行计算, 公式如下:

$$L_{overall} = \frac{1}{N_{gt}} \cdot \sum_{n=1}^{N_{gt}} (L_{2D} + L_{3D}) + L_{dmap} \quad (9)$$

其中, L_{dmap} 代表对 D_{fg} 进行深度类别监督得到的损失。

2 实验数据集

KITTI 是当前自动驾驶领域最重要的数据集之一, 能够用于评测立体图像、光流、视觉测距、3D 物体检测等计算机视觉技术在车载环境下的性能。KITTI 包含市区、乡村和高速公路等场景采集的真实图像数据, 每张图像中最多达 15 辆车和 30 个行人, 还有各种程度的遮挡与截断。3D 目标检测数据集由 7481 个训练图像和 7518 个测试图像以及相应的点云数据组成, 包括总共 80256 个标记对象。

该数据集中与三维目标检测领域相关的评价指标共有两种, 分别为 3D 精确度以及 BEV 精确度, 分别表示检测框在 3D 视图下以及 BEV 视图下的平均精确率, 在以上两种指标下又分为三种难度标准, 分别为简单、中等和困难, 根据标注框是否被遮挡、遮挡程度和框的高度进行定义, 具体在简单标准下最小的边界框高度为 40 像素, 最大的遮挡级别为完全可见, 最大截断程度为 15%; 中等标准下最小的边界框高度为 25 像素, 最大遮挡级别为部分遮挡, 最大截断程度为 30%; 困难标准下最小边界框高度为 25 像素, 最大遮挡级别为难以看到, 最大截断程度为 50%。通过对物体不同程度的遮挡以及控制边界框的大小, 能够在一定程度上模拟不同真实环境下的可视情况, 从而验证模型的泛化能力。

3 实验结果与分析

3.1 实验参数设置

本文将 KITTI 3D 数据集的训练集分为训练子集和验证集, 其中训练子集包含 3712 张图像, 验证集包含 3769 张图像。对于模型的实现细节, 本文沿用 MonoDETR^[12]文中所给出的实验细节, 采用 ResNet-50 作为骨干网络。对于深度感知 Transformer 部分,

将注意力头的数量设置为 8, 将物体查询的数量设置为 50。文中通道数以及前馈网络和以 MLP 为基础的检测头隐藏层维度设置为 256。对于前景深度图, 最小深度和最大深度分别设置为 0m 和 60m, 同时深度区间的数量设置为 80。本模型在单张 NVIDIA GeForce RTX3090 上运行, batchsize 设置为 16, 训练 195 个轮次, 模型整体学习率设置为 2×10^{-4} 。

3.2 对比实验结果

表 1 DM-Transformer 在 BEV 精度指标下的对比实验结果

Tab. 1 Experimental results of different levels of difficulties on KITTI in DM-Transformer

模型	精确度, BEV 精度		
	简单	中等	困难
Kinematic3D ^[17]	-	-	-
MonoRUn ^[3]	-	-	-
CaDDN ^[18]	-	-	-
MonoDTR ^[19]	33.33	25.35	21.68
AutoShape ^[20]	-	-	-
SMOKE ^[21]	19.99	15.61	15.28
MonoPair ^[22]	24.12	18.17	15.76
MonoDLE ^[23]	24.97	19.33	17.01
MonoRCNN ^[24]	25.29	19.22	15.30
GUPNet ^[25]	31.07	22.94	19.75
IAFA ^[26]	22.75	19.60	19.21
MonoDETR ^[12]	37.86	26.95	22.80
DM-Transformer	39.49	27.23	23.18

表 1 给出采用深度感知 Transformer 和 EDM 模块的 DM-Transformer 在 KITTI 官方汽车类型检测的 BEV 精度指标。通过视觉编码器和深度编码器, 以及深度视觉解码器的结构, 模型能够将图像中的视觉信息以及对应的深度信息进行融合, 同时视觉信息也可以在一定程度上对深度信息的预测提供帮助, 最后通过 EDM 模块对深度信息进行提取和学习, 使模型更好地聚焦深度信息与视觉信息中的关系, 从而帮助模型提高检测结果。对比次优模型, BEV 精度 的三个困难等级分别有 1.63%, 0.28%, 0.38% 的领先。

表 2 DM-Transformer 在 3D 精度下的对比实验结果

Tab.2 Experimental results of different levels of difficulties on KITTI in DM-Transformer

模型	精确度, 3D 精度
----	------------

	简单	中等	困难
Kinematic3D ^[17]	19.76	14.10	10.47
MonoRUn ^[3]	20.02	14.65	12.61
CaDDN ^[18]	23.57	16.31	13.84
MonoDTR ^[19]	24.52	18.57	15.51
AutoShape ^[20]	20.09	14.65	12.07
SMOKE ^[21]	14.76	12.85	11.50
MonoPair ^[22]	16.28	12.30	10.42
MonoDLE ^[23]	17.45	13.66	11.68
MonoRCNN ^[24]	16.61	13.19	10.65
GUPNet ^[25]	22.76	16.46	13.72
IAFA ^[26]	18.95	14.96	14.84
MonoDETR ^[12]	28.84	20.61	16.38
DM-Transformer	30.12	21.84	19.21

如表 2 所示, 本文提出的方法在 KITTI 3D 模型检测的 3D 精度指标下也达到了最高的实验结果, 通过 EDM 模块对深度视觉编码器中深度信息的提取和强化, 再通过残差链接的方式与其输出的视觉深度特征相加, 能够使模型更好的对图像中的深度信息进行聚焦, 从而帮助模型在对于 3D 目标检测中的 3 维深度信息进行更好的预测。对比次优模型, 3D 精度的三个难度标准分别有 1.28%, 1.23%, 2.83% 的领先。

3.3 消融实验结果

本模型采用的深度信息表现模块使得模型对于深度信息的学习更加准确, 以及效率更高, 若去掉该模块会使得模型的表现和学习效率下降。具体表现如表 3 所示:

表 3 EDM 模块及其分支在 3D 精度指标下的消融实验

Tab.3 Effectiveness of the different part of our EDM module

设置	精确度, 3D 精度			时间(时: 分)
	简单	中等	困难	
w/o EDM	25.44	18.35	15.31	12:27
w/o CMLP	27.24	18.91	16.62	14:48
w/o DConv	26.70	18.48	16.04	14:20
(Ours)	30.12	21.84	19.21	13:35


表 4 EDM 模块及其分支在 BEV 精度指标下的消融实验**Tab.4 Effectiveness of the different part of our EDM module**

设置	精确度, BEV 精度			时间(时: 分)
	简单	中等	困难	
w/o EDM	35.14	24.25	20.92	12:27
w/o CMLP	37.28	26.08	22.26	14:48
w/o DConv	35.89	24.33	21.52	14:20
(Ours)	39.48	27.22	24.18	13:35

表 3 显示 EDM 模块能够对深度感知解码器得到的深度信息进行提取和优化, 并且能够帮助模型从图像中获取更多的深度信息, 其中通道 MLP 模块不仅能够学习深度特征的全局分布规律, 还能有效地减少模型的计算时间, 提高模型收敛效率, 深度卷积模块能够帮助模型对图像中局部物体的深度特征信息进行学习, 从而加强模型的深度信息检测能力。如表 3 所示, w/o EDM 代表去除整个 EDM 模块, w/o CMLP 代表去除 EDM 模块中的通道 MLP 部分, w/o DConv 代表去除 EDM 模块中的深度卷积部分, 可以看出在原有模型的基础上, 去除整个 EDM 模块后模型的 3D 精度在三个难度条件下分别降低了 4.68%, 3.49%, 3.90%, BEV 精度在三个难度条件下分别降低了 4.34%, 2.97% 和 3.26%, 而模型整体的训练时间也由原本的 12 小时 27 分钟增加到 14 小时 48 分钟, 增加了 2 小时 21 分钟, 增加了 19% 的训练时间, 证明 EDM 模块对于模型在精度和学习效率的表现上都有提升的效果。接下来去除通道 MLP 部分后模型的训练时间对比本文模型增加了 1 小时 53 分钟, 而 3D 精度相比本文模型在三个难度条件下降低了 2.88%、2.93%、2.59%, BEV 精度相比本文模型在三个难度条件下也有 2.20%、1.14% 和 1.92% 的降低, 可以看出通道 MLP 模块通过不同维度特征交互融合帮助模型降低了计算成本, 进而降低了模型的训练时间, 对于模型学习时间的降低起到了关键作用, 对于模型精确度效果相比之下提升不高。接下来去除深度卷积部分后, 模型的 3D 精度对比本文模型在三个难度条件下分别降低了 3.42%, 3.36%, 3.17%, 模型的 BEV 精度对比本文模型在三个难度条件下分别有 3.59%, 2.89%, 和 2.66% 的降低, 而模型的训练时间增加相比本文模型降低并不明显, 由此可

以看出深度卷积部分通过对局部深度信息进行提取和学习对于模型对深度信息的学习有明显的提升效果。

本文方法与去除 EDM 模块后方法的损失变化如图 5 所示, 从图中可以得出由于 EDM 模块将图像全局深度特征分布以及物体局部深度信息聚合, 从而帮助模型获得更好的稳定性以及更低的检测损失, 再次验证了本文所提出方法在单目三维目标检测中的优秀性能。

**图 5 本文方法的损失变化折线图****Fig.5 Loss result of DM-Transformer**

4 结论

文中提出基于深度信息强化的单目 3D 目标检测 Transformer 模型 DM-Transformer, 这种方法与之前的以 Transformer 架构模型为基础的单目 3D 目标检测模型相比更加注重单目图像中物体局部深度信息, 以及物体间的深度关联的获取和强化, 深度显示模块将深度感知解码器中的深度信息进行提取, 通过深度卷积模块对图像中物体局部特征进行提取和通道 MLP 模块对图像的全局深度特征分布进行优化, 从而加强模型对图像中物体局部深度信息以及物体间深度关联的把握, 提高模型的检测精度。

参考文献

- [1] XU B, CHEN Z. Multi-level fusion based 3D object detection from monocular images[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New

- York: IEEE, 2018: 2345-2353.
- [2] CLEMENT G, OISIN M A, GABRIEL J B. Unsupervised monocular depth estimation with left-right consistency[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017: 6602-6611.
- [3] DING M, HUO Y, YI H, et al. Learning depth-guided convolutions for monocular 3D object detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. New York: IEEE, 2020: 1000-1001.
- [4] ANDREW G H, ZHU M, CHEN B. MobileNetV2: Inverted Residuals and Linear Bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City, UT, USA: CVPR, 2018: 4510-4520.
- [5] CHEN H, HUANG Y, TIAN W, et al. MonoRUn: monocular 3D object detection by reconstruction and uncertainty propagation[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: CVPR, 2021: 10379-10388.
- [6] ASHISH V, NOAM S, NIKI P, et al. Attention is all you need[C]//NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, California, USA: NIPS, 2017: 6000-6010.
- [7] ALEXEY D, LUCAS B, ALEXANDER K, et al. An image is worth 16x16 words: transformers for image recognition at scale[C]//The Ninth International Conference on Learning Representations Oral. Vienna, Austria: ICLR, 2021: 1909-1930.
- [8] ALEXANDER N, LUC V G. Efficient non-maximum suppression[C]//18th International Conference on Pattern Recognition (ICPR'06). NW Washington, DC, USA: ICPR, 2006: 850-855.
- [9] NICOLAS C, FRANCISCO M, GABRIEL S, et al. End-to-end object detection with transformers[C]//2020 European Conference on Computer Vision (ECCV). Glasgow, UK: ECCV, 2020: 213-229.
- [10] ZHU X, SU W, LUL, et al. Deformable DETR: deformable transformers for end-to-end object detection[C]//The Ninth International Conference on Learning Representations Oral. Vienna, Austria: ICLR, 2021: 1041-1057.
- [11] ZHANG R, QIU H, WANG T, et al. MonoDETR: Depth-guided transformer for monocular 3D object detection [C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: CVPR, 2023: 4002-4011.
- [12] 贾岩松, 温显斌. 面向姿势多样性问题的行人重识别方法. 天津理工大学学报, 2023, 39 (4): 46-52.
- [13] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA: CVPR, 2015: 770-778.
- [14] OLIVER R, CAO H. Nearest neighbor value interpolation[J]//International Journal of Advanced Computer Science and Applications, 2012, 3 (4): 25-30.
- [15] LIN T-Y, PRIYAG, ROSS G, et al. Focal loss for dense object detection[C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: ICCV, 2017: 2999-3007.
- [16] 陈思, 王怀彬, 柳爽. 轻量级卷积神经网络架构在入侵检测上的应用[J]. 天津理工大学学报, 2020, 36 (5): 20-25.
- [17] GARRICK B, GERARD P, LIU X, et al. Kinematic 3D object detection in monocular video[C]//2020 European Conference on Computer Vision (ECCV). Glasgow, UK: ECCV, 2020: 135-152.
- [18] CODY R, ALI H, JULIA C, et al. Categorical depth distribution network for monocular 3D object detection[C]//Proceeding of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: CVPR, 2021: 8551-8560.
- [19] HUANG K C, WU T H, SU H T, et al. MonoDTR: monocular 3D object detection with depth-aware transformer[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern

- Recognition (CVPR). New Orleans, LA, USA: CVPR, 2022: 4002-4011.
- [20] LIU Z, ZHOU D, LU F, et al. AutoShape: real-time shape-aware monocular 3D object detection[C]//Proceeding of the IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: ICCV, 2021: 15641-15650.
- [21] LIU Z, WU Z, ROLAND T. SMOKE: single-stage monocular 3D object detection via keypoint estimation[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Seattle, WA, USA: CVPRW, 2020: 4289-4298.
- [22] CHEN Y, TAI L, SUN K, et al. MonoPair: Monocular 3D object detection using pairwise spatial relationships[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: CVPR, 2020: 12090-12099.
- [23] MAX, ZHANG Y, XUD, et al. Delving into localization errors for monocular 3D object detection[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: CVPR, 2021: 4719-4728.
- [24] SHI X, YE Q, CHEN X, et al. Geometry-based distance decomposition for monocular 3D object detection[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2021: 15152-15161.
- [25] LU Y, MAX, YANG L, et al. Geometry uncertainty projection network for monocular 3D object detection[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2021: 3091-3101.
- [26] ZHOU D, SONG X, DAI Y, et al. IAFA: Instance-aware feature aggregation for 3D object detection from a single image[C]//2020 Asian Conference on Computer Vision (ACCV). Kyoto, Japan: ACCV, 2020: 417-435.

作者简介: 张续坤(1997—), 男, 硕士研究生, 研究方向:

计算机视觉。E-mail: thefakeaaron@163.com

温显斌(通信作者)(1966—), 男, 教授, 博士, 研究方

向: 计算机视觉。E-mail: xbwen@tjut.edu.cn