

多尺度金字塔特征融合网络的单目 3D 目标检测*

李 健 王永归 张在成

(陕西科技大学电子信息与人工智能学院 西安 710016)

摘 要 目标尺度差异性大是单目 3D 目标检测面临的重要挑战,通常解决目标尺度差异性大的方法是多尺度特征融合。然而,目前大多数多尺度特征融合方法使用单一尺度上下采样的金字塔网络融合不同尺度特征,忽略了特征图中噪声影响与特征融合的不平滑现象,并未充分利用多尺度特征图中的特征信息。针对上述问题,论文提出了一种多尺度金字塔特征融合网络,该网络由改进的 DLA_34 与多尺度金字塔网络构成,能够实现多尺度特征的平滑与充分融合,同时减少噪声对后续特征融合的影响。在 KITTI 开源数据集上的实验结果表明:与其他基于多尺度融合的方法相比,论文所提出的方法在简单、中等与困难检测级别下的 3D 检测与 BEV 检测平均精度均达到最优。

关键词 多尺度;金字塔网络;特征融合;3D 目标检测

中图分类号 TP391.41 **DOI:** 10. 3969/j. issn. 1672-9722. 2026. 03. 018

Monocular 3D Object Detection Based on Multi-Scale Pyramid Feature Fusion Network

LI Jian WANG Yonggui ZHANG Zaicheng

(School of Electronic Information and Artificial Intelligence, Shaanxi University of Science & Technology, Xi'an 710016)

Abstract The large difference in target scale is an important challenge for monocular 3D target detection. Usually, the method to solve the large difference in target scale is multi-scale feature fusion. However, most of the current multi-scale feature fusion methods use a single-scale up-sampling pyramid network to fuse features of different scales, ignore the effect of noise in the feature map and the unsmooth phenomenon of feature fusion, and do not make full use of the feature information in the multi-scale feature map. In response to the above problems, this paper proposes a multi-scale pyramid feature fusion network, which is composed of an improved DLA_34 and a multi-scale pyramid network, which can achieve smooth and full fusion of multi-scale features, while reducing the impact of noise on subsequent feature fusion. The experimental results on the KITTI public dataset show that compared with other methods based on multi-scale fusion, the method proposed in this paper achieves the best average accuracy of 3D detection and BEV detection at the simple, medium and difficult detection levels.

Key Words multi-scale, pyramid network, feature fusion, 3D object detection

Class Number TP391.41

1 引言

3D 目标检测旨在图像中识别与定位对应目标,是计算机视觉的关键任务之一,已广泛应用于自动驾驶与室内物体检测等领域中。目前,检测精度最高的 3D 目标检测方法,主要依赖于 LiDAR 激光点云数据提供精确的目标深度信息,但是 LiDAR

设备价格十分昂贵,数据采集过程中对环境要求极高。相比较基于 LiDAR 的检测方法,单目相机具有成本低、易于携带与安装,并且对于使用环境要求较低等特点,因此单目相机已广泛应用于许多计算机视觉相关领域中。但是在单目 3D 目标检测领域,仅从单张 RGB 图像中识别与定位不同尺度的目标是一个重大挑战。

* 收稿日期:2025 年 9 月 16 日,修回日期:2025 年 10 月 24 日

基金项目: 国家土建结构预制装配化工程技术研究中心沈祖炎专项基金(编号:2019CPCCE-K02);国家自然科学基金项目(编号:61871260)资助。

作者简介: 李健,男,博士,教授,研究方向:深度学习、图像处理、智能建造等。王永归,男,硕士,研究方向:深度学习、图像处理、无人驾驶技术。张在成,男,硕士,研究方向:深度学习与神经立体渲染等。

多任务监督与多尺度特征融合是解决单目图像中检测不同尺度大小目标的有效方法,能够极大地提升单目 3D 目标检测的性能。多任务监督的方法需要利用额外的注释数据与独立的神经网络进行训练,这将使得网络复杂度变大,并且在训练过程中会消耗大量的计算资源。目前,大多数多尺度特征融合方法采用单一的上下采样对不同尺度的特征图进行各分辨率特征加权求和。例如 CenterNet^[1]通过特征金字塔^[2](Feature Pyramid Network, FPN)自下而上的提取图像特征并进行横向连接,对不同尺度的特征信息进行融合。Li 等^[3]建立了一种针对 3D 目标检测的关键点金字塔特征网络,首先通过 2 倍上采样与 4 倍上采样使得特征图大小一致,其次对于上采样后的特征图进行各分辨率特征加权求和,最终实现多尺度特征融合。但是 CenterNet 采用的特征金字塔网络(FPN)并不适用于 3D 检测中关键点检测,FPN 会导致相邻的关键点出现重叠现象,虽然关键点特征金字塔网络解决了

上述重叠现象,但是依旧存在着特征金字塔网络中只是单纯地叠加各个尺度特征图的问题,因此并未真正达到多尺度特征融合的效果。

针对上述问题,本文提出了一种新的多尺度金字塔特征融合网络,能够充分地融合不同尺度的特征信息,在主干网络中添加了缓冲模块能够有效解决上采样过程中由于尺度跳跃太大,导致各层的特征融合不平滑的问题。如图 1 所示,本文所构建的单目 3D 目标检测整体网络框架主要分为三个部分。首先,以单目 RGB 图像作为输入通过主干网络提取不同尺度的特征图;其次,将不同尺度的特征图通过多尺度特征金字塔网络进行特征融合;最后,利用 3D 检测头预测关键点位置并筛选出对应目标置信度最高的 8 个 3D 包围框的顶点与 1 个 3D 中心点。通过 3D 目标检测 KITTI 数据集的评估与验证,本文所提出方法的检测速度达到实时要求,并且检测精度优于其他基于多尺度特征融合的 3D 目标检测方法。




图 1 3D 目标检测整体网络框架

2 相关工作

单目 3D 目标检测:单目 3D 目标检测方法按照训练数据分为三个类型:多任务检测、双阶段检测与单阶段检测。

多任务检测是利用图像分割、车辆形状先验或者伪点云数据建立多任务特征融合模块,为检测头提供候选 3D 包围框。Wang 等^[4]在 Pseudo-LiDAR 中利用单目图像获取深度信息,结合原图像与深度信息得到伪点云数据,最后用伪点云数据代替点云数据进行 3D 目标检测。Ding 等^[5]在 D4LCN 中提出了一种新的局部卷积网络(LCN),通过单目图像与深度图分别进行特征提取任务,之后结合两个任务的特征图预测对应目标的 3D 位置信息。多任务的方法需要利用额外的注释数据与独立的神经网络

进行训练,这将使得网络框架复杂度变大,并且在训练过程中会消耗大量时间与资源。

双阶段检测是通过 2D 包围框的几何约束恢复 3D 包围框中的八个顶点与 3D 中心点,如 Li 等^[6]在 GS3D 中提出了双阶段的单目 3D 目标检测,首先利用 Faster R-CNN^[7]检测目标的 2D 包围框,在 2D 包围框的基础上利用先验知识投影 3D 包围框的各个顶点。Brazil 等^[8]利用 3D 包围框投影在 2D 包围框的几何关系,建立了一个具有共享 2D 和 3D 检测空间的独立单目 3D 区域提议网络(M3D-RPN)。由于 3D 包围框过于依赖 2D 包围框导致了 3D 检测的精度上限取决于 2D 检测的精度,并且 3D 检测的误差包含了 2D 检测与 3D 检测的两种误差。为了解决 2D 检测的误差过大现象,大多数双阶段检测方法提高 2D 检测的精度以保证 3D 检测预测的准确

性,但是这种方法限制了3D检测速度的上限。

考虑到双阶段方法的检测速度问题,基于单阶段的3D目标检测方法开始被研究,如Zhou等^[1]在CenterNet提出了利用FPN直接预测目标的中心点和尺寸。受CenterNet的启发,Li等^[3,9]在RTM3D与KM3D中将3D目标检测中预测3D包围框转换为预测3D关键点,3D关键点包含了3D包围框的8个顶点与2个3D中心点。Liu等^[10]提出了一种SMOKE的新型3D目标检测方法,该方法通过将单个关键点估计与回归的3D变量相结合来预测每个检测到的目标的3D边界框。单阶段检测方法直接从图像中预测目标3D位置,不受2D包围框误差的影响,使得检测精度更高与检测速度更快。

多尺度特征融合网络:单尺度的神经网络对于目标尺度相差过大导致模型精度降低,随着卷积网络不断提取特征,浅层特征分辨率高与空间细节信息丰富,深层特征感受野大、语义信息丰富,但是缺乏空间细节信息。在目标检测任务中目标尺度不同,大多数检测方法采用了多尺度机制进行特征提取,例如,YOLOv3^[11]中利用上采样与通道数相加进行多尺度特征融合预测目标位置信息。雷帮军等^[12]提出了一种基于多尺度特征融合增强网络模型,可以实现高精度的目标检测。Qin等^[13]借鉴特征金字塔网络提出了上下文增强模块(Context Enhancement Module, CEM),利用局部和全局特征增强网络特征表达能力。Zhao等^[14]在M2det中提出了一种多层次多尺度特征融合的金字塔网络,使用浅层特征辅助目标检测任务。Zhou等^[1]结合特征金字塔网络,设计了一种不需要锚框的检测方法直接预测目标位置的检测方法,但是距离相近的关键点经过FPN提取特征会出现互相重叠现象。Li等^[3]

设计了一种关键点特征提取网络(KFPN),利用上采样机制将不同尺度的特征图调整为同一尺度进行特征融合。

与上述多尺度特征提取网络相比,本文提出的是一种多尺度金字塔特征融合网络,能够对不同尺度的特征图进行多次平滑的特征融合,并且引入了注意力机制能够在特征融合过程中提取关键信息。这种多尺度金字塔特征融合网络能够对各个尺度的特征信息进行充分融合,并且避免了无用特征信息对于特征融合的影响。

3 3D目标检测模型

本文利用金字塔网络与注意力机制构建了一种达到实时检测的单目3D目标检测网络模型,如图1所示,该模型包含主干网络、多尺度金字塔网络与一系列的检测头。主干网络进行跨尺度的提取特征,多尺度金字塔网络利用采样机制与注意力机制融合不同尺度的特征信息,最终由检测头预测目标3D位置的各个信息。

3.1 主干网络

主干网络由DLA_34^[15]网络改进生成,DLA_34是一种利用树结构融合浅层次与深层次的特征图,并保留不同尺度的特征信息的网络。本文在DLA_34^[15]网络的基础上添加了注意力机制与融合模块构成了新的主干网络,如图2所示,输入一张RGB图像 $I \in \mathbb{R}^{W \times H \times 3}$, I 经过一个 7×7 卷积层生成特征图 $f^1 \in \mathbb{R}^{W \times H \times 16}$, f^1 经过Attention Layer生成 $f^2 \in \mathbb{R}^{W \times H \times 16}$,其中Attention Layer由空间与通道注意力层组成。 f^2 通过六次两倍降采样层与 1×1 卷积层生成不同尺度的特征图,经过六次降采样层后,通道数分别为16、32、64、128、256和512。




图2 主干网络

主干网络由左向右的方向融合了不同层的特征图,但是跨尺度特征融合存在不平滑的现象。因此,本文构建了一种缓冲模块Buffer Module,能够

更加合理地进行不同尺度的特征融合,可以在原始层之间生成各种合成层,从而将特征图缩放到1.5倍、0.75倍与0.5倍大小。如图3所示,该模块包含

了两个输入,首先进行1.5倍上采样与0.75倍下采样,然后逐像素的求和,最终通过 1×1 的卷积层生成0.5倍大小的特征图。




图3 缓冲模块

如图4所示,以无预训练权重的ResNet18网络为例,图(a)为原图像,图(b)为ResNet18网络在提取特征过程中的热力图可视化结果,图(c)为加入缓冲模块后的热力图可视化结果。对比图(b)的可视化结果,图(c)中包含更多目标的重要特征信息。



图4 热力图可视化

3.2 多尺度金字塔网络

物体的3D包围框由9个关键点构成,由于关键点的大小一致,传统的特征金字塔并不适用于关键点检测,而关键点特征金字塔网络(KFPN)虽然




图6 上采样模块

3.3 损失函数

多尺度金字塔特征融合网络包含了多个检测头,其中各检测头对应的损失函数分别为主中心点损失函数 L_m ,关键点损失函数 L_k ,三维尺度损失函数 L_d ,目标朝向损失函数 L_o 与置信度损失函数 L_{conf} 。

其中主中心损失 L_m 如式(1)所示,使用焦点损失^[16](focal Loss)预测目标的2D中心点位置, $\hat{p}$ 为真实中心点的高斯核值, p 为预测中心点的高斯核值, α 与 β 的值分别为2与4。

$$L_m = -\frac{1}{N} \sum \begin{cases} (1-\hat{p})^\alpha \log(\hat{p}) & \text{if } p=1 \\ (1-p)^\beta (\hat{p})^\alpha \log(1-\hat{p}) & \text{otherwise} \end{cases} \quad (1)$$

可以检测空间中的关键点,但KFPN在上采样过程中会丢失特征信息。因此,本文提出了一种新的方法,多尺度金字塔网络,如图5所示,通过上采样模块(Upsample)使不同尺度的特征图扩展为相同尺度,随后将相同大小的特征图进行像素求和,最终利用反卷积操作融合特征图预测目标的关键点位置。




图5 多尺度金字塔网络

其中上采样模块如图6所示,首先利用空间注意力机制生成具有显著特征的特征图 $f \in \mathbb{R}^{0.5W \times 0.5H \times C}$, f 经过 3×3 的可变形卷积(Deformconv)改变特征通道数生成 $f' \in \mathbb{R}^{0.5W \times 0.5H \times O}$, f' 经过2倍反卷积(Deconv)生成 $f'' \in \mathbb{R}^{W \times H \times O}$,最终 f'' 经过通道注意力机制生成具有通道权重的特征图 $f''' \in \mathbb{R}^{W \times H \times O}$ 。

关键点损失 L_k 如式(2)所示,引用了一种动态调整对象惩罚系数的深度引导 L_1 损失^[9],用来预测对应目标八个顶点与一个3D中心点的位置。其中 j 为对应目标索引标号, i 为关键点索引标号, kp 为预测关键点位置信息, $\widehat{kp}$ 为真实关键点位置信息。 $g(Z)$ 如式(2)所示代表 L_k 中的动态惩罚系数, Z 为预测深度值, ∂ 与 α 分别为0.01与5。

$$L_k = \frac{1}{N} \sum_j \sum_i g(Z_j) \|kp_j^i - \widehat{kp}_j^i\|_1 \quad (2)$$

$$g(Z) = \begin{cases} \partial Z & \text{if } Z < \alpha \\ \log_{10}(Z+1-\alpha) + \partial \alpha & \text{if } Z \geq \alpha \end{cases} \quad (3)$$

维度损失 L_d 与置信度损失函数 L_{conf} 分别为

L_1 损失和 L_2 损失如式(4)~(5)所示, dp 与 cp 为预测的维度与置信度值,其中 $\widehat{dp}$ 与 $\widehat{cp}$ 为真实标签。

$$L_d = \|dp_i - \widehat{dp}_i\|_1 \quad (4)$$

$$L_{conf} = \|cp_i - \widehat{cp}_i\|_2 \quad (5)$$

目标朝向的损失 L_o 如式(6)所示,采用多框损失函数^[17](Multi-Bin Loss), L_o 由 L_{conf} 与 L_{loc} 加权求和得到,其中 L_{conf} 如式(7)所示, L_{loc} 代表预测角度与地面真实角度之间的损失, n_{θ^*} 图像中3D包围框数目, θ^* 为目标真实角度值, c_i 为目标 i 的3D包围框中心角度, $\Delta\theta_i$ 为中心角度的变化大小。

$$L_o = L_{conf} + w \times L_{loc} \quad (6)$$

$$L_{loc} = -\frac{1}{n_{\theta^*}} \sum \cos(\theta^* - c_i - \Delta\theta_i) \quad (7)$$

如式(8)所示总损失函数为

$$L = L_m + L_k + L_d + L_o + L_{conf} \quad (8)$$

4 实验与结果分析

4.1 数据集

为了验证本文方法的有效性,本文在KITTI数据集上训练和测试网络模型,KITTI是国际上最大的3D目标检测算法评测数据集。数据集中包含了大量已标注过的点云、双目与单目图像,本文选用

的单目图像数据集分别包含左眼与右眼各7 481张图像,图像尺寸大小为384*1 280,其中包含训练集3 712张图像,验证集7 481张图像与测试集3 769张图像。

4.2 实验设置

本文提出的单目3D目标检测方法基于Pytorch框架实现,在Ubuntu16环境下使用显存为16 GB的Tesla V100 GPU进行训练与测试。在训练过程中输入图像尺寸为384*1 280, Batch Size设置为8,使用Adam优化器进行优化,初始学习率设置为0.000 1,训练300个epoch,在第100个与200个epoch时学习率分别降低十倍。

4.3 结果分析

定性分析:图7展示了利用不同检测方法分别预测目标3D位置并生成对应鸟瞰图的可视化结果,其中绿色椭圆范围为漏检部分,黄色箭头所指为错检部分。相较于本文方法的可视化结果,CenterNet的方法在图(b)中出现错检现象,在图(a)、图(b)与图(c)中均出现漏检现象。RTM3D的方法在图(b)与图(c)中出现错检现象,在图(c)中出现漏检现象。KM3D的方法在图(c)中出现漏检与错检现象。通过可视化结果对比,可以说明本文提出的方法能够更加精确地对车辆与行人进行3D目标检测。



图7 检测结果可视化对比

定量分析:为了更加客观地验证本文所提出方法的检测性能,本文使用KITTI数据集官方提供的评价指标平均精度(AP)与其他基于多尺度特征融合网络的3D目标检测方法进行比较。表1展示了在IoU>0.7情况下,分别对比简单、中等与困难三种检测难度下的不同检测方法生成三维包围框的平均精度AP与检测时间。通过对比结果说明本文所提出的方法在简单、中等与困难检测级别下3D包围框的平均精度相较于精度第二的方法分别提高了1.85%、4.05%和4.71%,并且达到实时检测效果。

表1 3D包围框平均精度AP(%)对比

方法	简单	中等	困难	时间/s
CenterNet ^[1]	0.60	0.66	0.77	0.03
RTM3D ^[3]	14.41	10.34	8.77	0.05
KM3D ^[9]	16.73	11.45	9.92	0.03
本文	18.58	15.50	14.63	0.05

表2展示了在IoU>0.7情况下,分别对比简单、中等与困难三种检测难度下的不同检测方法生成鸟瞰图的平均精度AP与检测时间。如表2所示,本文方法生成的鸟瞰图在简单、中等与困难检测级别下AP达到最优,相较于精度第二的方法分别提高了1.42%、4.06%和3.32%。

表2 鸟瞰图平均精度AP(%)对比

方法	简单	中等	困难	时间/s
CenterNet ^[1]	3.46	3.31	3.21	0.03
RTM3D ^[3]	19.17	14.20	11.99	0.05
KM3D ^[9]	23.44	16.20	14.47	0.03
本文	24.86	20.26	17.79	0.05

由实验分析,本文提出基于多尺度金字塔特征融合网络的3D目标检测方法能够在实时检测的前提下,在简单、中等与困难检测级别下平均精度均达到最优。

4.4 消融实验

为了验证注意力机制、缓冲模块与多尺度金字塔网络在单目3D目标检测中的有效性,本文以DLA_34网络加金字塔特征网络的3D目标检测算法为基准方法,在KITTI数据集上中等检测难度下进行的消融实验结果如表3所示。基准方法DLA_34网络加金字塔特征网络在KITTI数据集上3D检测的平均精度(AP)为11.45%。在DLA_34网络的基础上,分别加入注意力机制与缓冲模块,AP分别从11.45%提升至12.04%与12.21%,分别提升0.59%与0.76%。在基准方法中将金字塔特征网络替换为多尺度金字塔网络,AP从11.45%提升至

14.61%,提升3.16%。在DLA_34网络基础上加入注意力机制与缓冲模块,同时将金字塔特征网络替换为多尺度金字塔网络,AP从11.45%提升至15.50%,提升4.05%。

表3 消融实验结果

注意力机制	缓冲模块	多尺度金字塔网络	AP
			11.45
√			12.04
	√		12.21
		√	14.61
√	√	√	15.50

实验结果证明,本文提出的注意力机制、缓冲模块与多尺度金字塔网络能够有效地提升单目3D目标检测的检测精度。其中注意力机制能够有效地减少噪声对后续特征融合的影响,缓冲模块与多尺度金字塔网络能够实现多尺度特征的平滑与充分融合。

5 结语

针对单目3D目标检测中存在的目标尺度差异性大与多尺度特征融合不平滑的问题,本文提出了一种多尺度特征融合金字塔网络。该网络包括主干网络和多尺度金字塔网络:其中,主干网络提取不同尺度特征信息,利用缓冲模块整合不同尺度的浅层特征与深层特征信息,解决了特征融合不平滑的问题;多尺度金字塔网络通过多次上采样特征充分融合不同尺度特征信息,并且在上采样过程中利用注意力机制减少无用信息对后续特征融合的干扰。最后,在KITTI数据集的实验结果表明,与之前其他基于多尺度特征融合的单目3D目标检测方法相比,本文方法在简单、中等与困难检测级别下3D包围框与BEV的平均精度均达到最优。

参考文献

[1] Zhou X, Wang D, Krähenbühl P. Objects as points[J]. ArXiv Preprint ArXiv:1904.07850, 2019.

[2] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2117–2125.

[3] Li P, Zhao H, Liu P, et al. Rtm3d: Real-time monocular 3d detection from object keypoints for autonomous driving [C]//European Conference on Computer Vision. Springer, Cham, 2020: 644–660.

(下转第817页)

144-146, 150.

YANG Yan, ZHANG Hong, HE Miao, et al. A Method of Mechanical 3D Model Retrieval with Fusion of Distance Feature [J]. Machinery Design & Manufacture, 2020(8): 144-146, 150.

[18] 张开兴, 黄瑞, 刘贤喜. 基于距离-夹角形状分布的三

维 CAD 模型检索算法 [J]. 农业机械学报, 2014, 45(4): 316-321.

ZHANG Kaixing, HUANG Rui, LIU Xianxi. 3-D CAD Model Retrieval Algorithm Based on Distance and Angle Distributions [J]. Transactions of the Chinese Society for Agricultural Machinery, 2014, 45(4): 316-321.

(上接第 691 页)

[4] Wang Y, Chao W L, Garg D, et al. Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 8445-8453.

[5] Ding M, Huo Y, Yi H, et al. Learning depth-guided convolutions for monocular 3d object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020: 1000-1001.

[6] Li B, Ouyang W, Sheng L, et al. Gs3d: An efficient 3d object detection framework for autonomous driving [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 1019-1028.

[7] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks [C]//Advances in Neural Information Processing Systems, 2015: 91-99.

[8] Brazil G, Liu X. M3d-rpn: Monocular 3d region proposal network for object detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 9287-9296.

[9] Li P, Zhao H. Monocular 3d detection with geometric constraint embedding and semi-supervised training [J]. IEEE Robotics and Automation Letters, 2021, 6(3): 5565-5572.

[10] Liu Z, Wu Z, R Tóth. SMOKE: Single-Stage Monocular 3D Object Detection via Keypoint Estimation [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020: 996-997.

[11] Redmon J, Farhadi A. Yolov3: An incremental improvement [J]. ArXiv Preprint ArXiv: 1804.02767, 2018.

[12] 雷帮军, 耿红彬, 吴正平. 基于自适应校准和多分支注意力的遥感目标检测 [J]. 电子测量技术, 2022, 45(22): 106-111.

LEI Bangjun, GENG Hongbin, WU Zhengping. Remote sensing target detection based on adaptive calibration and multi-branch attention [J]. Electronic Measurement Technology, 2022, 45(22): 106-111.

[13] Qin Z, Li Z, Zhang Z, et al. ThunderNet: Towards real-time generic object detection on mobile devices [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 6718-6727.

[14] Zhao Q, Sheng T, Wang Y, et al. M2det: A single-shot object detector based on multi-level feature pyramid network [C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 9259-9266.

[15] Yu F, Wang D, Shelhamer E, et al. Deep layer aggregation [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2403-2412.

[16] Law H, Deng J. Cornernet: Detecting objects as paired keypoints [C]//Proceedings of the European Conference on Computer Vision (ECCV), 2018: 734-750.

[17] Mousavian A, Anguelov D, Flynn J, et al. 3d bounding box estimation using deep learning and geometry [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 7074-7082.