



工程科学学报
Chinese Journal of Engineering
ISSN 2095-9389, CN 10-1297/TF

《工程科学学报》网络首发论文

题目: 融合动态 Bins 和深度不确定性的智能车辆单目 3D 目标检测
作者: 于承峰, 王鹏伟, 孙宾宾, 高松, 张玉桦, 杨凡, 张泽恒
收稿日期: 2026-01-13
网络首发日期: 2026-05-09
引用格式: 于承峰, 王鹏伟, 孙宾宾, 高松, 张玉桦, 杨凡, 张泽恒. 融合动态 Bins 和深度不确定性的智能车辆单目 3D 目标检测[J/OL]. 工程科学学报.
<https://link.cnki.net/urlid/10.1297.TF.20260509.1509.001>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

融合动态 Bins 和深度不确定性的智能车辆单目 3D 目标检测

于承峰^{1,2)}, 王鹏伟^{1,2)}✉, 孙宾宾^{1,2,3)}✉, 高松^{1,2)}, 张玉桦^{1,2)}, 杨凡^{1,2)},
张泽恒^{1,2)}

1) 山东理工大学交通与车辆工程学院, 淄博 255000 2) 山东省新能源车辆集成设计与智能化重点实验室, 淄博 255000 3) 现代农业装备研究院, 淄博 255000

*通信作者 王鹏伟, E-mail: wpwk16@163.com; 孙宾宾, E-mail: sunbin_sdut@126.com

摘要 针对目前自动驾驶单目三维(3D)目标检测中, 主干网络多尺度信息捕获能力不足, 3D 深度预测误差较大和 Transformer 深度信息编码能力有限导致的目标识别精度低等问题, 提出了一种面向自动驾驶车辆的单目 3D 目标检测算法 MonoDBDU。首先, 提出了一种双向注意力门控特征融合模块, 并结合 ResNeSt50 网络(BAGFF-ResNeSt50)作为 MonoDBDU 框架的主干提取网络, 解决了多尺度信息捕获能力不足的问题。其次, 设计了一种融合深度不确定性的动态 Bins 深度预测器, 解决了因深度预测和 Bins 分布引起的 3D 深度预测误差较大的问题。最后, 提出了一种融合深度不确定性的轻量化 Transformer(DU-Transformer), 通过引入 Swin transformer 中的移位多头自注意力机制, 减少了模型的参数量, 同时对深度不确定性进行显式建模, 解决了深度信息编码能力有限的问题。仿真实验验证, MonoDBDU 在 KITTI 数据集 IOU=0.7 时, Hard 测试值在 AP_{3D} 指标相较于 MonoLSS 提升了 0.57 个百分点, AP_{BEV} 指标相较于 MonoDETR 提升了 1.17 个百分点, 在 Waymo 数据集 IOU=0.7 时, Hard 测试值在 AP_{3D} 和 AP_{BEV} 指标相较于 MonoLSS 分别对应提升幅度达到 1.09 和 1.80 个百分点。实车实验验证, 本文提出的 MonoDBDU 在 BEV 视角投影的 mAP 指标为 23.6%, 具有良好的实用性和有效性。

关键词 自动驾驶; MonoDBDU; 3D 目标检测; 动态 Bins; 深度不确定性

中图分类号 TP391.41

DOI: 10.13374/j.issn.2095-9389.2026.01.13.004

Monocular 3D target detection for intelligent vehicles based on dynamic Bins and deep uncertainty

YU Chengyi^{1,2)}, WANG Pengwei^{1,2)}✉, SUN Binbin^{1,2,3)}✉, GAO Song^{1,2)}, ZHANG Yuhua^{1,2)}, YANG Fan^{1,2)}, ZHANG Zeheng^{1,2)}

1) School of Transportation and Vehicle Engineering, Shandong University of Technology, Zibo 255000, China

2) Key Laboratory of Integrated Design and Intelligence of New Energy Vehicles in Shandong Province, Zibo 255000, China

3) Modern Agricultural Equipment Research Institute in Shandong Province, Zibo 255000, China

*✉ Corresponding author, WANG Pengwei, E-mail: wpwk16@163.com; SUN Binbin, E-mail: sunbin_sdut@126.com

Abstract Monocular 3D object detection is a critical perception task in autonomous driving systems, offering advantages in cost efficiency and ease of deployment compared to multi-camera or LiDAR-based solutions. However, existing monocular 3D object detection methods suffer from low target recognition accuracy due to three key challenges: the insufficient multiscale information capture capability of backbone networks, large errors in 3D depth prediction, and limited depth information encoding ability of transformers. To address these issues comprehensively, this study proposes a novel monocular 3D object detection algorithm, namely MonoDBDU, for autonomous driving vehicles. First, a bidirectional attention gated

收稿日期: 2026-01-13

基金项目: 国家自然科学基金资助项目(52102465, 52475269); 山东省自然科学基金资助项目(ZR2024ME179, ZR2022MF230); 山东重大科技创新工程项目(2023CXGC010111); 山东省青年基金资助项目(ZR2021QF039); 山东省中小企业创新能力提升工程项目(2022TSGC2277)

网络首发时间: 2026-05-09 18:32:53 网络首发地址: <https://link.cnki.net/urlid/10.1297.TF.20260509.1509.001>

feature fusion (BAGFF) module is introduced to overcome the limitations of traditional backbone networks in capturing multiscale features—including inadequate feature fusion, severe interference from redundant features, and unreasonable weight allocation among different scale features—which lead to poor feature representation capability in multiscale targets. This module is deeply integrated with the ResNeSt50 network to construct a BAGFF-ResNeSt50 backbone feature extraction network, which serves as the core feature extraction unit of MonoDBDU. The powerful feature extraction capability of ResNeSt50 (endowed by its split-attention mechanism) and the superior multiscale feature fusion performance of the BAGFF module are fully leveraged. The integration overcomes the issues of insufficient multiscale information capture in traditional backbones and provides high-quality multiscale feature inputs for subsequent 3D depth prediction and feature encoding. Second, to overcome the limitations of conventional depth prediction methods, where fixed bins distribution fails to adapt to the dynamic changes of depth information in complex autonomous driving scenarios and uncertainty factors are ignored in the depth prediction process, a dynamic bins depth predictor with depth uncertainty (DBDU) is designed. The dynamic bins generation unit adaptively adjusts the number, interval range, and distribution density of depth bins based on the statistical information of multiscale features from input images, realizing precise allocation of bins resources according to the depth distribution characteristics of different scenes. The depth uncertainty modeling unit explicitly models the uncertainty in depth prediction through probabilistic modeling methods, outputting depth prediction values and corresponding uncertainty coefficients that quantify the reliability of depth prediction results, providing uncertainty guidance for subsequent feature encoding and target regression and improving the accuracy and robustness of monocular 3D depth prediction. Finally, to address the limitations of traditional transformers with fixed-size multihead self-attention—such as high parameter volume, heavy computational complexity, and limited depth information encoding ability—a lightweight depth uncertainty transformer (DU-Transformer) is proposed as the core feature encoding module of MonoDBDU. Dividing feature maps into nonoverlapping windows and performing attention interaction between adjacent windows reduces the computational load and parameter volume of self-attention significantly. Meanwhile, a depth uncertainty modeling branch is introduced to enhance the encoding weight of high-reliability depth features and suppress the interference of low-reliability ones through attention mechanisms, achieving precise fusion of depth information and semantic features. In extensive simulation experiments, On the KITTI dataset with an IOU (Intersection over union) threshold of 0.7, MonoDBDU achieves an improvement of 0.57 percentage points in 3D average precision (AP_{3D}) over MonoLSS and 1.17 percentage points in BEV (bird's eye view) average precision (AP_{BEV}) over MonoDETR for the hard test subset. On the Waymo open dataset under the same IOU threshold of 0.7, the proposed MonoDBDU outperforms MonoLSS by 1.09 and 1.80 percentage points in AP_{3D} and AP_{BEV} on the hard subset, respectively. In real-world vehicle experiments, MonoDBDU achieved an mAP of 23.6% in BEV perspective projection, highlighting its favorable practicality and effectiveness in real-world autonomous driving scenarios.

Key words autonomous driving; MonoDBDU; 3D object detection; dynamic Bins; deep uncertainty

在自动驾驶领域, 车辆是否能够精确感知环境是保证安全行驶的前提^[1], 其中视觉感知更是在场景语义理解、突发风险响应和场景决策等方面发挥着重要作用^[2], 尤其是三维(3D)目标检测技术不仅是环境感知系统的重要组成部分, 而且一直以来是自动驾驶和智能车辆等相关领域的研究热点^[3], 3D目标检测的主要任务是从各项传感器数据中精准识别目标类别, 输出目标在三维空间中的位置、尺寸和朝向角等关键参数^[4]。在3D目标检测技术的众多研究方向中, 单目3D目标检测因只依赖单目相机即可实现3D目标信息的感知, 具备硬件成本低、部署难度小等独特优势, 成为该领域极具研究价值和应用潜力的分支方向。

单目3D目标检测的发展历程大致可以分为传统方法探索、深度学习奠基、多视角融合突破和开放场景泛化四个阶段。在传统方法中, Mousavian等^[5]提出了Deep-3D-Box方法, 首次通过二维(2D)检测框与3D检测框的投影约束构建方程组, 结合卷积神经网络(CNN)预测目标尺寸和朝向, 进而求解3D中心位置。Hedau等^[6]通过单目图像估计深度, 结合2D检测结果求解目标3D位置信息, 开创了深度估计结合几何推理的经典范式。但传统方法高度依赖手工设计特征和强先验假设, 泛化能力和多尺度信息捕获能力有限, 且几何约束易受到图像噪声和相机标定误差的影响, 鲁棒性有待提高。

随着深度学习和端到端模式的兴起, 研究人员直接利用CNN学习从2D图像到3D参数的映射, 减少对人工先验的依赖。Weng等^[7]首次提出单阶段3D目标检测框架Mono3D, 通过生成大量3D候选框并投影到2D图像空间进行评分, 实现了端到端的训练。Zhou等^[8]提出了CenterNet框架, 在2D目标检测的基础上, 通过关键点检测来定位目标中心, 结合深度估计和尺寸回归实现3D目标检测, 其高效轻量设计为实时应用奠定了基础。之后, Wang等^[9]提出Pseudo-LiDAR, 将单目检测的深度结

果转换为伪点云，直接复用基于激光雷达的 3D 检测框架。但以上方法的深度估计精度不足，从而容易导致 3D 定位误差较大，并且 Anchor 设计仍存在锚框匹配不准确的问题，影响小目标的检测性能。

多视角融合为单目 3D 目标检测提供了切实可行的路线，将图像特征转换为鸟瞰视角（BEV, Bird eye view）的形式来表示，进而实现多视角融合来提升 3D 检测精度，其主要得益于基于编码和解码的 DETR (Detection transformer)^[10]的提出，其中具有代表性的算法有 Li 等^[11]提出的 BEVFormer，利用可学习的 BEV 查询生成特征，结合时空 Transformer 处理多帧图像，在 3D 目标检测中表现优异。Zhang 等^[12]提出了 MonoDETR，基于 Transformer 架构，通过渲染传输预测深度图，实现端到端的单目 3D 目标检测。但使用多视角融合处理 3D 目标检测，容易受数据对齐误差的影响，3D 目标检测精度容易受到预测的深度图影响。

随着自动驾驶技术和开放场景大模型的发展，对 3D 目标检测模型适应开放场景复杂性、动态性和不确定性的需求增加。Yang 等^[13]首次提出了端到端的开集单目 3D 目标检测框架 3D-MOOD，通过规范图像空间（Canonical image space, CIS）和几何感知查询（Geometry aware, GA），在未知类别和跨域场景中显著超越基线方法。Li 等^[14]提出了一种统一的模型架构 Uni-MODE，支持多模态输入和跨场景泛化，但在开放集检测中性能仍稍逊于 3D-MOOD。以上模型具有更加复杂的网络结构，计算量大幅度增加，难以满足自动驾驶实时性要求。

综上所述，自单目 3D 目标检测诞生以来，多尺度信息捕获能力有限导致的鲁棒性不足，深度预测中固定的区间（Bins）分配和深度不确定性传递导致的 3D 定位误差大和深度信息编码能力有限导致的复杂环境适应能力较弱等问题一直存在，针对以上问题，结合自动驾驶实时性需求，本文提出了一种面向自动驾驶车辆基于 Transformer 端到端的单目 3D 目标检测框架：融合动态 Bins 和深度不确定性的单目 3D 目标检测（Dynamic bins depth uncertainty monocular 3D object detection, MonoDBDU）。其结构大致包括主干网络、深度预测器、改进的 Transformer 结构和回归头四部分。

1 MonoDBDU 算法

1.1 算法总体框架

本文所提的 MonoDBDU 算法，是一种基于 Transformer 端到端训练的单阶段 3D 目标检测算法，主要由四部分组成：主干网络（BAG-ResNeSt50）、深度预测器（DBDU-Depth Predictor）、改进的 Transformer 结构（DU-Transformer）以及用于回归任务的回归头。MonoDBDU 算法的整体结构如图 1 所示。




图 1 MonoDBDU 总体结构图
Fig.1 Structure diagram of MonoDBDU

MonoDBDU 算法的流程如下：在特征提取阶段，采用 BAGFF-ResNeSt50 作为主干网络，经过主

干网络后输出四层特征图 $[F_1^{H/4,W/4}, F_2^{H/8,W/8}, F_3^{H/16,W/16}, F_4^{H/32,W/32}]$, F 表示每一层输出的特征图, H 代表特征图的高度, W 表示特征图的宽度。其次, 在深度预测阶段, 采用了 DBDU-Depth 预测器, 输出深度特征和深度不确定性特征。在 DU-Transfomer 编码阶段, 对网路提取到的特征图、深度特征和深度不确定性特征进行编码。在解码阶段, 采用融合深度不确定性引导机制的解码器 (Uncertainty depth-guided decoder) 进行解码。在参数回归阶段, 回归头将 3D 目标检测所需要的 2D 边界框、3D 坐标中心、3D 尺寸、航向角、深度值等参数, 结合相机内参, 将这些参数转化为真实世界下的 3D 目标属性, 从而实现对 3D 目标的检测任务, 具体创新在以下章节展开。

1.2 BAGFF-ResNeSt50

现有基于 Transformer 的单目 3D 目标检测算法的特征融合多集中于检测头阶段, 主干网络输出的原始特征质量不足, 容易导致后期融合效果受限。针对单目 3D 目标检测的场景痛点, 提出双向注意力门控+分组注意力的主干网络设计范式, 既保留了主干网络对细微特征的敏感优势, 又通过双向融合和动态加权来解决遮挡和干扰场景下的特征提取难题, 同时兼顾精度与实时性。在特征提取阶段, 采用 ResneSt50^[15]作为 Baseline。其分组注意力机制和通道注意力机制可以为深度预测网络提供更高质量的特征输入, 且在相同时间成本下检测精度优于 EfficientNet^[16]、ResNeXt^[17]和 SENet^[18]等系列特征提取网络, 具体结构如图 2 所示。




图 2 BAGFF 结构图(k 表示卷积核大小, c 表示通道数)

Fig.2 BAGFF structure diagram (k represents the size of convolution kernel and c represents the number of channels)

首先, 为了使得在融合过程中提高信息处理效率、强化关键特征, 本文引入了注意力门控的思想, 提出了适合双向特征融合的注意力门控模块, 具体如式 (1) 所示。

$$\begin{cases} N^* = \text{Conv}_{1 \times 1}(\text{Upsample}(N)) \\ M^* = \text{Conv}_{1 \times 1}(M) \\ O_{AG} = \text{Sigmoid}(\text{Conv}_{1 \times 1}(\text{Relu}(M^* + N^*))) \otimes M \end{cases} \quad (1)$$

其中, M^* 表示经过卷积后的低层特征 M , N^* 表示经过上采样和卷积之后的高层特征 N , O_{AG} 表示融合深层特征线索的低层特征图 M , $\otimes$ 表示对应元素相乘。

进一步的, F_4' 中的特征经过上采样与 ResNeSt50 网络中通道压缩后的 F_3 特征经过注意力门控单元后输出 F_3' , 并且同理可得 F_2' , 具体如 (2) 式所示。

$$\begin{cases} F_3' = \text{AG}(\text{Conv}_{1 \times 1}(F_3), \text{Upsample}(F_4')) \\ F_2' = \text{AG}(\text{Conv}_{1 \times 1}(F_2), \text{Upsample}(F_3')) \end{cases} \quad (2)$$

其中, $F_3 \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 1024}$ 、 $F_2 \in \mathbf{R}^{\frac{H}{8} \times \frac{W}{8} \times 512}$ 分别表示原 ResNeSt50 网络第三层和第二层输出的特征图, $\text{Conv}_{1 \times 1}$ 表示 1×1 卷积, Upsample 表示上采样。 $F_3' \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 、 $F_2' \in \mathbf{R}^{\frac{H}{8} \times \frac{W}{8} \times 256}$ 分别表示改进网络的第三层和第二层的输出, AG 表示注意力门控模块。

最后, 低层特征图通过注意力门控单元向高层特征进行融合, ResNeSt50 中 $F_1 \in \mathbf{R}^{\frac{H}{4} \times \frac{W}{4} \times 256}$ 和 F_3 先经过注意力门控模块得到高层语义引导的浅层特征, 再与经过上采样的 F_2' 和通道压缩后的 F_1 进行融合, 具体如式 (3) 所示。

$$F_1' = (\text{Conv}_{1 \times 1}(F_1) + \text{Upsample}(F_2') + G) / 3 \quad (3)$$

其中, $F_1' \in \mathbf{R}^{\frac{H}{4} \times \frac{W}{4} \times 256}$ 表示改进的 ResNeSt50 第一层输出的特征图, G 表示融合高层语义引导的 F_1 特征。

综上所述 BAGFF-ResNeSt50 通过 1×1 卷积将 F_1' 、 F_2' 、 F_3' 、 F_4' 层级特征通道统一为 256, 同时保持特征图的空间维度适配, 为 DBDU-Depth 预测器和 DU-Transformer 提供通道统一、质量稳定的输入特征, 极大的提高了 ResNeSt50 网络应对复杂动态环境的性能, 减少后续模块的适配成本, 间接提升整体模型的推理效率。

1.3 DBDU-Depth 预测器

近年来, 研究人员提出将连续深度回归问题转化为离散区间的分类问题, 即把整个深度范围划分为 N 个离散的区间 (Bins), 网络只需预测目标深度属于每个 Bin 的概率, 再通过概率加权各 Bin 的中心值得到连续深度估计值。但固定 Bins 的离散化方案存在固有缺陷, 且未考虑深度预测的不确定性, 导致深度估计误差仍无法有效降低, 难以满足高精度感知需求。本文提出融合深度不确定性的动态 Bins 深度预测器 (DBDU-Depth predictor), 通过动态调整 Bins 的中心位置和宽度, 让深度区间划分适配不同场景的深度分布特性, 解决固定 Bins 的场景适应性较弱和深度分辨率失衡的问题, 并且通过对深度预测的不确定性显式建模, 将不确定性特征融入深度特征提取与概率加权过程, 同时设计损失函数对不确定性进行约束, 为后续的 Transformer 深度信息编码和 3D 目标参数回归提供可靠的深度特征支撑, 具体结构如图 3 所示。




图3 DBDU-depth predictor 结构图
Fig.3 DBDU-depth predictor structure diagram

1.3.1 深度不确定性融合

首先，从主干网络输出的特征图 F_2' 、 F_3' 和 F_4' 先进行特征融合，融合过程如式（4）所示。

$$\begin{cases} J = (Y + F_3' + I) / 3 \\ Y = \text{Downsample}(F_2') \\ I = \text{Upsample}(F_4') \end{cases} \quad (4)$$

其中， $J \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示融合后的特征图， $Y \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示下采样后的 F_2' 特征，Downsample 表示下采样， $I \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示上采样后的 F_4' 特征。

特征图 J 分别进入深度不确定性估计模块和深度特征提取模块，深度不确定性估计模块具体过程如式（5）所示。

$$\begin{cases} \xi = (\text{SiLu}(\text{GroupNorm}(\text{Conv}_{3 \times 3}(J))))_{\times 2} \\ f = \text{Sigmoid}(\text{Conv}_{1 \times 1}(\xi)) \end{cases} \quad (5)$$

其中， ξ 表示经过卷积、组归一化、激活函数后提取的特征。 $\times 2$ 表示 J 经过两次特征提取操作。 $f \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示 ξ 经过卷积模块之后通过 Sigmoid 激活函数转换成的不确定性概率图。

进一步的，为了能够实现对深度不确定性的稳定训练，本文借鉴了平均绝对误差损失函数的思想设计了深度不确定性损失函数，深度不确定性损失由两个方面组成：（1）损失函数惩罚误差大但不确定性低的情况；（2）损失函数惩罚不确定性被无意义放大的情况。具体如式（6）所示。

$$L_{ud} = \frac{1}{N} \sum_{i=1}^N \left(\frac{|d_i^{\text{predict}} - d_i^{\text{target}}|}{\phi_i + \epsilon} + \lg(\phi_i + \epsilon) \right) \quad (6)$$

其中， L_{ud} 表示总体的不确定性损失， ϕ_i 表示网络输出的深度不确定性概率值， d_i^{predict} 表示网络预

测的深度值, d_i^{target} 表示深度的真实值, $\varepsilon = 1 \times 10^{-6}$, 防止分母为零和对数输入为负。

同时, 经过融合的特征 $\mathbf{J}$ 也会通过深度特征提取模块进一步提取特征, 其处理过程如式 (7) 所示。

$$\zeta = (\text{ReLu}(\text{GroupNorm}(\text{Conv}_{3 \times 3}(\mathbf{J}))))_{\times 2} \quad (7)$$

其中 $\zeta \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示经过深度特征提取之后的特征图。 $\times 2$ 表示 $\mathbf{J}$ 经过两次特征提取操作。

再次, 为了减小深度预测误差, 将深度特征提取之后的特征与不确定性估计模块相乘得到融合了深度不确定性的深度特征。具体过程如式 (8) 所示。

$$\mathbf{v} = \mathbf{f} \otimes \zeta \quad (8)$$

其中, $\mathbf{v}$ 表示融合了不确定性概率的深度特征。

最后, 在后处理阶段 $\mathbf{v}$ 经过分类之后得到深度逻辑值, 再通过 Softmax 函数转化成概率, 并与对应的 Bin 中心深度相乘得到最终的预测深度, 具体过程如式 (9) 所示。

$$\begin{cases} \mathbf{H} = \text{Softmax}(\text{Classifier}(\mathbf{v})) \\ \boldsymbol{\rho} = \mathbf{H} \times \mathbf{D}_{\text{center}} \end{cases} \quad (9)$$

其中, $\mathbf{H}$ 表示特征属于 Bins 区间的概率, $\mathbf{D}_{\text{center}}$ 表示 Bins 中心深度。此处的 $\mathbf{D}_{\text{center}}$ 使用了动态 Bins。 $\boldsymbol{\rho}$ 表示模型预测出的深度值。

1.3.2 动态 Bins 深度预测

如果在设计动态 Bins 时, 直接使用网络预测 Bins 的中心和宽度不仅会加大网络参数, 而且会使得训练更加复杂, 实时性难以保证。因此, 本研究提出了可学习的 Bins 中心和宽度, 将 Bins 中心和宽度设为可学习参数, 通过损失函数对其进行更新, 具体如下所示。

首先, 初始化 Bins 的中心深度和宽度为均匀分布, 具体如式 (10) 所示

$$\begin{cases} D_i = d_{\min} + i \times (d_{\max} - d_{\min}) / (N - 1) \\ W_i = (d_{\max} - d_{\min}) / N \end{cases} \quad (10)$$

其中, $i \in [0, 1 \dots N - 1]$, N 表示 Bins 的数量, D_i 表示每一个 Bins 中心的深度, $d_{\min}$ 、 $d_{\max}$ 分别表示深度的最小值和最大值。 W_i 表示每一个 Bins 的宽度。

其次, 计算每一个 Bin 区间的边界序列, 返回所有左边界和最后一个右边界, 形成连续的深度区间, 具体的过程如式 (11)

$$\begin{cases} D_i^n = \text{Max}(d_{\min}, \text{Min}(D_i^{n-1}, d_{\max})) \\ W_i^n = \text{softplus}(W_i^{n-1}) + o \\ L_i^n = D_i^n - W_i^n / 2 \\ R_i^n = D_i^n + W_i^n / 2 \\ \mathbf{E} = [L_0^n, L_1^n, \dots, L_{N-1}^n, R_{N-1}^n] \end{cases} \quad (11)$$

其中, 第 1 行表示对中心点进行约束, 确保所有中心点都在有效的范围之内, D_i^n 表示第 i 个 Bin 中心第 n 次更新时的深度值, Max 表示取最大值, Min 表示取最小值。第 2 行表示对宽度进行正定, 避免无效的负宽度, W_i^n 表示第 i 个 Bin 中心第 n 次更新时的宽度值。 softplus 表示对宽度进行正定, 使其为正数。 $o = 1 \times 10^{-4}$, 防止宽度为 0。第 3、4 行中 L_i^n 、 R_i^n 分别表示获取 i 个 Bin 中心第 n 次更新时的左边界和右边界值。第 5 行中 $\mathbf{E}$ 表示返回的所有左边界和最后一个右边界, 得到所有 Bins 形成的连续深度区间。

最后, 将动态 Bins 预测融入深度预测中, 如式 (10) 所示, 至此模型可以使用主任务中的损失函数对 Bins 进行更新。但为了防止在训练过程中 Bins 区间交叉造成深度预测混乱得分现象, 在主任务损失函数 L_{depth} 的基础上增加了 Bins 有序性约束, 具体损失函数如式 (12) 所示。

$$L_t = L_{\text{depth}} + \sum_{i=0}^{N-2} \max(0, D_i - D_{i+1})^2 \quad (12)$$

其中, L_t 表示总损失, L_{depth} 表示主任务的深度预测损失, D_i 、 D_{i+1} 分别表示第 i 、 $i+1$ 个 bin 的中心深度值。

1.4 DU-Transformer 模块

在单目 3D 目标检测中传统 Transformer 的编码和解码结构基于通用视觉任务设计, 其注意力机制仅在 2D 像素空间内计算特征相似度, 未将深度预测的不确定性结果作为核心引导信息融入特征交互过程, 这种固有局限性在面向复杂动态场景下, 深度预测的不确定性会急剧升高, 预测值中包含大量噪声, 进而导致 3D 检测框的中心坐标、尺寸回归精度下降。本文提出了 DU-Transformer 将深度不确定性作为显式引导信息, 与深度预测值共同融入 Transformer 的注意力计算与特征解码过程, 构建了双引导机制, 并且通过简化注意力头数和优化特征通道维度以及设计紧凑的编码解码结构, 在保留核心表达能力的前提下, 大幅降低参数量与计算开销, 其具体结构如图 4 所示。




图 4 DU-Transformer 结构图
Fig.4 DU-Transformer structure diagram

首先, 为了能减少模型的参数量, 提升模型的运行速度, 本文引入了 Swin transformer 中的移位多头自注意力机制 (SW-MSA), 以满足实时性的要求, 考虑到特征的维度为 $\mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$, 本文选择的窗口大小为 4×4 , 偏移量为 2。为了能够实现对深度不确定性信息显式编码, 增加了不确定性编码层 (Uncertainty encoder), Uncertainty encoder 具体过程表达如式 (13) 所示。

$$\begin{cases} U_1 = \text{SW-MSAttn}_{4 \times 4}^2(U) \\ U_2 = \text{FFN}(U_1) \\ U_3 = \text{LayerNormal}(U_2) \end{cases} \quad (13)$$

其中, $U \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 表示提取到的不确定性特征, $\text{SW-MSAttn}_{4 \times 4}^2$ 表示窗口大小为 4, 偏移量为 2 的 SW-MSA 注意力机制, FFN 函数表示前馈神经网络, LayerNormal 表示对 U_2 进行层归一化,

$$U_3 \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}.$$

其次, 在解码器中融入不确定性, 加权交叉注意力机制中的 Value 特征具体步骤如下: (1) 将编码器输出的 Memory 向量通过线性变换得到 K 向量和 V 向量。(2) 将编码器中输出的不确定性特征 $U_3 \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 通过 Sigmoid 函数转换为概率。(3) 将生成的 $U_p \in \mathbf{R}^{\frac{H}{16} \times \frac{W}{16} \times 256}$ 展平和向量 V 相乘, 具体的公式如式 (14) 所示。

$$\begin{cases} \mathbf{K}, \mathbf{V} = \text{Linear}(\mathbf{M}_e) \\ \mathbf{U}_p = \text{sigmoid}(\mathbf{U}_3) \\ \mathbf{V}_{\text{new}} = \mathbf{U}_p^e \otimes \mathbf{V} \end{cases} \quad (14)$$

其中, $\mathbf{M}_e$ 表示编码器输出的 Memory 向量, $\mathbf{U}_p$ 表示转换为概率的不确定性特征, $\mathbf{U}_p^e \in \mathbf{R}^{\frac{H \times W}{16^2} \times 256}$ 表示展平后的 $\mathbf{U}_p$, $\mathbf{V}_{\text{new}}$ 表示加权后的 $\mathbf{V}$ 向量。

最后, 增强查询向量 $\mathbf{Q}$ 对可靠区域敏感度的实现具体有以下步骤: (1) 利用查询参考点, 通过双线性插值从 $\mathbf{U}_3 \in \mathbf{R}^{\frac{H \times W}{16^2} \times 256}$ 的空间特征图中得到参考点 $(x_q, y_q) \in \mathbf{R}^{N \times 2}, q=1, 2, \dots, N$ 周围四个像素的加权不确定性特征值, 将其作为 $\mathbf{Q}$ 向量中每个元素对应的不确定性, 从而实现将 $\mathbf{U}_3$ 投影到 $\mathbf{Q} \in \mathbf{R}^{N \times C}$ 的维度的目的, 投影后的矩阵如式 (15) 所示。

$$\mathbf{U}_{\text{map}} = \begin{bmatrix} d_{1,1} & d_{1,2} & \dots & d_{1,C} \\ d_{2,1} & d_{2,2} & \dots & d_{2,C} \\ \vdots & \vdots & & \vdots \\ d_{N,1} & d_{N,2} & \dots & d_{N,C} \end{bmatrix} \quad (15)$$

其中, $\mathbf{U}_{\text{map}} \in \mathbf{R}^{N \times C}$ 表示投影后的矩阵, $d_{m,n}$ 表示 $\mathbf{Q}$ 向量中每个元素对应的不确定性特征值, N 、 C 分别表示投影后矩阵的行数和列数, $d_{m,n}$ 的计算如式 (16) 所示。

$$d_{m,n} = \sum_{(j,i) \in \{(j_n, i_n), (j_n, i'_n), (j'_n, i_n), (j'_n, i'_n)\}} \mathbf{U}_3(j, i, m) \cdot w_q(j, i) \quad (16)$$

其中, (j_n, i_n) 、 (j_n, i'_n) 、 (j'_n, i_n) 、 (j'_n, i'_n) 分别表示采样的参考点周围四个像素坐标。 $w_q(j, i)$ 表示四个像素点的权重值, $\mathbf{U}_3(j, i, m)$ 表示在 $\mathbf{U}_3$ 空间中对应的通道数为 m , 坐标为 (j, i) 像素对应的不确定性特征值。权重 $w_q(j, i)$ 计算如式 (17) 所示。

$$w_q(j, i) = \begin{cases} (1-a_q)(1-b_q)(j, i) = (j_n, i_n) \\ a_q(1-b_q)(j, i) = (j_n, i'_n) \\ (1-a_q)b_q(j, i) = (j'_n, i_n) \\ a_q b_q(j, i) = (j'_n, i'_n) \\ 0, \text{ Other pixels} \end{cases} \quad (17)$$

其中, $a_q \in (0, 1)$ 和 $b_q \in (0, 1)$ 表示第 q 个查询参考点到邻域像素 X 轴和 Y 轴方向的距离, 且四个权重和为 1。

(2) 将投影后的 $\mathbf{U}_3$ 不确定性特征和向量 $\mathbf{Q}$ 融合, 具体的公式如式 (18) 所示。

$$\mathbf{Q}_{\text{new}} = \mathbf{U}_{\text{map}} + \mathbf{Q} \quad (18)$$

其中, $\mathbf{U}_{\text{map}} \in \mathbf{R}^{N \times C}$ 表示投影后的 $\mathbf{U}_3$ 特征, $\mathbf{Q}_{\text{new}}$ 表示融合不确定性特征后的 $\mathbf{Q}$ 。

综上所述, 通过对不确定性特征进行编码、权重化以及增强查询向量 $\mathbf{Q}$ 对可靠区域的敏感的方式实现了对 Value 特征的放缩和 $\mathbf{Q}$ 特征的增强, 进而弱化了高不确定性区域对注意力输出的影响。

2 实验验证及分析

为了更加全面的检验 MonoDBDU 算法在自动驾驶 3D 目标检测任务中的有效性与实用性, 本文采用了仿真验证结合实车验证的实验设计思路。其中, 仿真实验聚焦于算法的精度指标与泛化性能验证, 实车实验则聚焦于算法的工程实用性验证, 通过上述仿真实验与实车实验的协同验证 MonoDBDU 模型的有效性与实际应用价值。

2.1 实验准备

2.1.1 实验数据集

仿真实验中使用的开放数据集有 KITTI^[19]和 Waymo^[20], KITTI 数据集是自动驾驶领域最基本的数据集之一, 提供了遮挡、截断和难度等级等场景和属性。场景相对典型, 干扰因素可控, 能精准验证算法的核心能力。Waymo 数据集相比于 KITTI 具有更大的数据量, 是目前规模最大、标注最精细、场景最复杂的自动驾驶公开数据集, 对验证模型的泛化性能和鲁棒性具有重要意义。

2.1.2 实验配置

本文采用 Windows11 操作系统, 搭载 Intel(R) Core(TM) Ultra 9-275HX, 主频为 2.7 GHz。显卡为 NVIDIA GeForce RTX 5090 Laptop GPU, 内存为 64 GB, 训练时的学习率为 0.0002, 训练轮数为 195, 批次大小为 16, Bins 初始值为 90。用到的评价指标是 3D 平均精度 (3D average precision, AP_{3D}) 和鸟瞰图平均检测精度 AP_{BEV} (BEV average precision, AP_{BEV}) 其计算公式如式 (19) 所示。

$$\begin{cases} P_{\text{interp}}(r) = \text{Max}_{\tilde{r} \geq r} P(\tilde{r}) \\ \text{AP} = \frac{1}{N} \sum_{r \in [0,1]} P_{\text{interp}}(r) \end{cases} \quad (19)$$

其中, $P_{\text{interp}}(r)$ 表示插值后的精度, N 表示取 $P_{\text{interp}}(r)$ 点的个数, r 表示模型检测出的真实正样本占全部真实正样本的比例即召回率, $\tilde{r}$ 代表所有大于等于 r 的召回率取值, 用于在插值时查找最大精确率, 避免局部波动。

2.2 MonoDBDU 算法仿真实验

2.2.1 对比实验

为了能够充分验证 MonoDBDU 在自动驾驶场景中的有效性和实用性, 本文在 KITTI 数据集上与单目 3D 目标检测领域技术先进的 (SOTA, state of the art) 算法在交并比 (IOU, intersection over union) 为 0.7、0.5 时的 3D 平均检测精度 AP_{3D} 和鸟瞰图平均检测精度 AP_{BEV} 以及运行时间进行综合性了分析, IOU=0.7 时的对比结果具体如表 1 所示。

表1 IOU=0.7时, MonoDBDU算法与SOTA算法对比

Table 1 Comparison between MonoDBDU algorithm and SOTA algorithm on KITTI dataset when IOU=0.7

Methods	AP _{3D} (IOU=0.7) /%			AP _{BEV} (IOU=0.7) /%			Time/ms	Parameters/10 ⁶
	Easy	Mod.	Hard	Easy	Mod.	Hard		
MonoCon ^[21]	22.50	16.46	13.95	31.12	22.10	19.00	25.8	22.3
MonoFlex ^[22]	23.64	17.51	14.83				35.0	41.2
MonoDETR ^[12]	28.84	20.61	12.38	37.86	26.95	22.80	43.0	47.4
MonoDTR ^[23]	23.81	15.90	13.21	32.55	21.50	18.25	41.2	48.6
GUPNet ^[24]	20.11	14.20	11.77				34.0	38.7
MonoDLE ^[25]	17.45	13.66	11.68	24.97	19.33	17.01	40.0	43.0
MonoLSS ^[26]	26.11	19.15	16.94	34.89	25.95	22.59	35.0	38.7
MonoATT ^[27]	23.65	15.92	12.99	32.08	21.44	17.85	43.0	39.2
This work	29.37	21.26	17.51	38.62	27.68	23.97	31.7	37.2

由表 1 可知, 本文所提出的算法检测精度最高, AP_{3D} 指标在 Easy 和 Mod.测试值上与算法 MonoDETR 相比分别提高了 0.53 和 0.65 个百分点, Hard 测试值与 MonoLSS 相比提高了 0.57 个百分点。AP_{BEV} 指标在 Easy、Mod.和 Hard 测试值上与 MonoDETR 算法相比提高了 0.76、0.73 和 1.17 个百分点。在运行速度上处于同类算法中上水平。MonoDBDU 在难度等级为 Hard 时, 提升更加明显, 说明其在复杂环境下鲁棒性和目标检测能力强。与相近时间成本的算法 MonoFlex 在 AP_{3D} 上提升了 5.73、3.75 和 2.68 个百分点, 凸显了本文算法的优越性。综上所述, 通过 IOU=0.7 时的 AP_{3D} 和 AP_{BEV} 指标对比, 充分说明了本文所提算法在自动驾驶领域的有效性。当 IOU=0.5 时的对比结果如表 2 所示。

表2 IOU=0.5时, MonoDBDU算法与SOTA算法对比

Table 2 Comparison between MonoDBDU algorithm and SOTA algorithm on KITTI dataset when IOU=0.5

Methods	AP _{3D} (IOU=0.5) /%			AP _{BEV} (IOU=0.5) /%		
	Easy	Mod.	Hard	Easy	Mod.	Hard
MonoFlex	60.70	46.65	39.91	66.26	49.30	44.42
MonoDETR	68.86	48.92	43.57	72.30	53.10	46.62
MonoDTR	64.03	47.32	42.20	69.04	52.47	42.90
GUPNet	57.62	42.33	37.59	61.78	47.06	40.88
MonoDLE	55.41	43.42	37.81	60.73	46.87	41.89
MonoLSS	67.19	46.51	43.28	70.94	52.16	42.77
MonoATT	64.53	44.25	40.73	69.81	51.38	42.02
This work	71.06	47.86	45.34	72.41	54.19	47.56

由表 2 可知, MonoDBDU 在检测精度上, 除 AP_{3D} 指标在 Mod.测试值不是最高, 其他情况 AP_{3D} 和 AP_{BEV} 值最高。综合表 1、2 数据可知, 本文提出的算法不仅在 IOU=0.7 时处于前列, 而且在 IOU=0.5 时也有较大的提升, 具有较强的鲁棒性和 3D 目标检测能力。图 5 展示了 MonoDBDU 和 MonoCon 算法 3D 目标检测的可视化对比效果。




图 5 MonoDBDU 和 MonoCon 模型可视化对比图。(a)视角遮挡场景; (b)小目标场景; (c)车辆密集场景

Fig.5 Visual comparison between MonoDBDU and MonoCon models: (a) viewpoint occlusion scenarios; (b) small object scenarios; (c) dense vehicle scenarios

由图 5 可知, 绿色和蓝色实线方框分别代表 MonoDBDU 和 MonoCon 算法的检测结果, 红色虚线圆框所示为不同算法间的检测差异。在图 5 (a)、(b) 中 MonoDBDU 算法在视角遮挡和小目标的场景下相比于 MonoCon 在目标识别的准确度和鲁棒性有较大的提升, 体现了本文 BAGFF-ResNeSt50 在特征融合和全局特征关联上的优越性。由图 5 (c) 可知, 在车辆分布密集区域, MonoDBDU 检测能力优于 MonoCon 算法, 在密集区域 MonoDBDU 会根据特征量的多少分配密集的 Bins 区间, 并且与 DU-Transformer 结合, 从而使得识别精准有效。证明本文所提算法 MonoDBDU 在自动驾驶领域的有效性。为了说明本文算法在不同数据集上的泛化性能, 在 Waymo 数据集上与 CaDDN 和 MonoCon 等算法在 IOU=0.7 和 IOU=0.5 时的 AP_{3D} 和 AP_{BEV} 指标进行了对比, 具体数据如表 3、4 所示。

表3 IOU=0.7时, MonoDBDU算法与SOTA算法在Waymo数据集上的对比

Table 3 Comparison of MonoDBDU algorithm and SOTA algorithm on Waymo dataset when IOU=0.7

Methods	AP _{3D} (IOU=0.7) /%			AP _{BEV} (IOU=0.7) /%		
	Easy	Mod.	Hard	Easy	Mod.	Hard
CaDDN ^[28]	26.87	19.96	17.15	35.72	26.60	23.68
MonoDETR	31.52	24.87	21.09	40.26	32.15	28.73
MonoLSS	34.28	27.55	23.82	43.16	35.42	31.29
MonoATT	28.63	21.95	18.74	37.42	29.38	25.65
This work	34.37	28.14	24.91	44.01	36.57	33.09

由表 3 可知, Waymo 数据集中 MonoDBDU 算法的 AP_{3D} 和 AP_{BEV} 指标在 Easy、Mod.和 Hard 测试值相比于 MonoLSS 算法分别提高了 0.09、0.59 和 1.09 个百分点和 0.85、1.15 和 1.80 个百分点, 充分证明了 MonoDBDU 算法有着较好的泛化性和鲁棒性。

表4 IOU=0.5时, MonoDBDU算法与SOTA算法在Waymo数据集上的对比

Table 4 Comparison of MonoDBDU algorithm and SOTA algorithm on Waymo dataset when IOU=0.5

Methods	AP _{3D} (IOU=0.5)			AP _{BEV} (IOU=0.5)		
	Easy	Mod.	Hard	Easy	Mod.	Hard
CaDDN	61.48	54.33		67.29	57.09	
MonoCon	64.24	56.17		69.77	59.64	
MonoATT	69.27	60.12	52.61	72.09	63.71	58.92
This work	71.37	62.08	53.87	71.13	65.41	60.01

由表 4 可知, Waymo 数据集中 MonoDBDU 算法在 IOU=0.5 时 AP_{3D} 指标在 Easy、Mod.和 Hard 测试值上相比于算法 MonoATT 提高了 2.10、1.96 和 1.26 个百分点, AP_{BEV} 指标在 Mod.和 Hard 测试值上相比于 MonoATT 分别提高了 1.70 和 1.09 个百分点, 证明了 MonoDBDU 算法有着较好的泛化性能。

2.2.2 消融实验

为了进一步验证 MonoDBDU 算法中 BAGFF 模块、DBDU 模块和 DU-Transformer 模块对算法的提升作用, 本文在 KITTI 数据集上依次对以上三个模块进行了验证, 具体数据如表 5 所示。

表5 IOU=0.7时, MonoDBDU算法在KITTI数据集上的消融实验

Table 5 Ablation experiment of MonoDBDU algorithm on KITTI dataset with IOU=0.7

BAGFFDBDUDU-Transformer	AP _{3D} (IOU=0.7) /%			AP _{BEV} (IOU=0.7) /%		
	Easy	Mod.	Hard	Easy	Mod.	Hard
	24.29	16.70	13.72	33.82	23.67	19.51
√	25.87	18.62	16.06	35.32	23.95	21.86
√	25.84	17.26	15.17	34.18	24.26	20.17
√	28.93	19.52	17.02	37.63	25.06	23.11
√	25.33	16.84	14.38	34.07	24.37	20.58
√	29.37	21.26	17.51	38.62	27.68	23.97

由表 5 可知, 在 KITTI 数据集上进行的泛化实验证明 BAGFF 模块、DBDU 模块和 DU-Transformer 模块对模型具有显著的提升。AP_{3D} 指标在 Easy、Mod.和 Hard 测试值上与未添加任何模块的原始模型相比分别提高 5.08、4.56 和 3.79 个百分点, AP_{BEV} 指标分别提高了 4.80、4.01 和 4.46 个百分点, 进一步证明了本文提出的 BAGFF 模块、DBDU 模块和 DU-Transformer 模块的有效性。

本文在 SW-MSA 中设置的窗口大小为 4, 偏移量为 2, 为了说明超参数设置的合理性, 在 KITTI 数据集上对 DU-Transformer 进行了窗口大小和偏移量的消融实验, 具体实验结果如表 6 所示。

表6 DU-Transformer模块超参数消融实验

Table 6 Super parametric ablation experiment of DU-transformer module

Window size	Shift size	AP _{3D} (IOU=0.7) /%			AP _{BEV} (IOU=0.7) /%		
		Easy	Mod.	Hard	Easy	Mod.	Hard
7×7	3×3	29.16	20.97	16.82	38.15	26.74	22.43
4×4	2×2	29.37	21.26	17.51	38.62	27.68	23.97
12×12	6×6	28.71	20.46	16.13	37.88	26.67	21.64

由表 6 中的数据可知, 当窗口大小为 4×4, 偏移量为 2×2 时 MonoDBDU 算法在 KITTI 数据集上 AP_{3D} 和 AP_{BEV} 指标分别为[29.37%, 21.26%, 17.51%]和[38.62%, 27.68%, 23.97%], 相比于窗口大小为 7×7, 偏移量为 3×3 的模型 AP_{3D} 提高了 0.21、0.29 和 0.69 个百分点, AP_{BEV} 指标提高了 0.47、0.94 和 1.54 个百分点。与窗口大小为 12×12, 偏移量为 6×6 的模型相比 AP_{3D} 指标提高了 0.66、0.80 和 1.38 个百分点 AP_{BEV} 指标提高了 0.74、1.01 和 2.33 个百分点, 证明本文在 DU-Transformer 模块中选择窗口大小为 4, 偏移量为 2 的合理性。

2.2.3 可视化分析

为了直观地表现出 BAGFF 模块的作用, 将其与原始的 ResNeSt50 网络在特征提取和特征关注度上进行对比, 对其生成的特征进行热力化展示, 具体如图 6 所示。




图 6 ResNeSt50 和 BAGFF-ResNeSt50 热力图对比. (a)小目标场景; (b)车辆密集场景热; (c)视角遮挡场景

Fig.6 Comparison of ResNeSt50 and BAGFF ResNeSt50 heatmaps: (a) small object scenarios; (b) dense vehicle scenarios; (c) viewpoint occlusion scenarios

由图 6 可知, 红色虚线圆框代表两种不同算法之间具体的检测差异, 由图 6 (a) 可知, 红色虚线圆框标出的地方, 特征的热度更高, 说明在自动驾驶场景下小目标的特征提取上 BAGFF-ResNeSt50 优于 ResNeSt50。通过图 6 (b) 可知, 红色框标出的地方, 在具有大量树木和车辆干扰情况下, 基准模型被明显干扰, 而 BAGFF-ResNeSt50 通过双向特征流仍然保持较好的识别能力。由图 6 (c) 可知在红色框标注的视角遮挡处, ResNeSt50 对特征的关注度较小, 而 BAGFF-ResNeSt50 可以通过全局的特征关联精准关注到遮挡处的相关特征。

为了直观地表现添加了 DBDU 模块的深度预测器的优越性, 与不添加 DBDU 模块的深度预测器进行了对比, 具体如图 7 所示。




图 7 深度预测器有无 DBDU 模块对比图. (a)车辆密集场景; (b)小目标场景; (c)视角遮挡场景

Fig.7 Comparison of deep predictors with and without DBDU modules: (a) dense vehicle scenarios; (b) small object scenarios; (c) viewpoint occlusion scenarios

由图 7 可知, 红色虚线圆框代表两种不同算法之间具体的检测差异, 通过对有 DBDU 模块的深度预测和无 DBDU 模块的深度预测器进行对比可以看出, 添加了 DBDU 模块的深度预测器通过融合深度不确定性和动态划分的 bins, 对深度的预测和感知能力有了较为明显的提升, 证明 DBDU 模块在深度预测方面的优越性和有效性。

为了能够对添加了 DBDU 模块的深度预测器与基础深度预测器进行定量分析, 将 KITTI 数据集的测试集分成 6 组分别对比了每组在均匀分布初始化和高斯分布初始化下的 AbsRel 指标, 结果如图 8 所示。




图8 深度预测器有无 DBDU 模块均匀分布和高斯分布初始化下 AbsRel 指标对比
Fig.8 Comparison of deep predictors with and without DBDU Modules on AbsRel index

由图 8 中的曲线对比可知, 添加了 DBDU 模块的深度预测器 AbsRel 指标显著低于基础预测器, 模型在均匀分布初始化和高斯分布初始化下, AbsRel 指标变动较小, 因此模型对不同初始化状态的敏感程度较小, 具有较强的稳定性和鲁棒性。

2.3 实车实验

2.3.1 实验准备

为了进一步说明 MonoDBDU 算法的实用性, 本文采用自动驾驶车辆作为实验平台, 通过 ROS 系统实现各种传感器信息的交互。实验主要用到锐尔威视摄像头和高性能工控机, 将 MonoDBDU 算法通过编写 ROS 包结点的形式实现 3D 目标检测, 具体实验平台如图 9 所示。



图9 实验平台
Fig.9 Experimental platform

2.3.2 可视化分析

为了能更好地展示实车实验效果, 选取了动态场景、小目标场景和多目标遮挡场景进行可视化展示, 如图 10 所示。




图 10 实车实验结果可视化. (a) 动态场景; (b) 小目标场景; (c) 多目标遮挡场景

Fig.10 Visualization of real vehicle experiment results: (a) dynamic scenarios; (b) small object scenarios; (c) multi-object occlusion scenarios

由图 10 所示, 其中红色虚线圆框表示自动驾驶车辆激光雷达扫描到的目标车辆, 绿色实线方框表示 MonoDBDU 检测到的目标车辆。本文将其实分成三组, 在图 10 (a) 中, 车辆正处动态转弯的过程, 车身发生的动态旋转会对单目 3D 目标检测算法造成较大的干扰, 但本文算法成功地检测到该目标, 并且检测框方向与车辆基本一致。在图 10 (b) 中, 车辆与实验车辆距离较远, 而且因为透视投影关系小目标物体会对单目 3D 目标检测造成极大困难, 但本文算法较为准确地识别到 3D 目标。通过图 10 (c) 可以看出在目标层层遮挡以及远处小目标有较好的识别效果, 但处于目标复杂、数量较多的路况下, 视频帧更新略有延时, 实车实验验证了本文所提算法的有效性。

为了能够验证本文所提算法的性能, 将实车实验检测到的 3D 目标框投影到 BEV 平面中的平均精度均值(mAP, Mean average precision)指标进行了分析, 具体结果如图 11 所示。




图 11 实车实验 mAP 指标对比

Fig.11 Comparison of map indexes in real vehicle experiment

由图 11 可知, 在 BEV 视角下的本文所提出算法的 mAP 为 23.6%, 与同基于 Transformer 的算法 MonoATT 和 MonoLSS 相比分别提高了 1.9 和 1.5 个百分点, 相比于仅使用深度引导机制的

MonoDETR 提高了 2.7 个百分点, 通过实车实验可以看出, 本文提出的 MonoDBDU 模型具有良好的实用性和鲁棒性。

3 结论

针对现有自动驾驶车辆单目 3D 目标检测算法多尺度信息捕捉能力较弱、3D 深度预测误差较大以及骨干网络深度信息编码能力有限问题, 本文提出了一种适用于自动驾驶车辆的单目 3D 目标检测算法 (MonoDBDU)。首先, 设计了 BAGFF-ResNeSt50 主干提取网络, 解决了多尺度信息捕获能力不足的问题。其次, 提出了一种融合深度不确定性的动态 Bins 深度预测器, 解决了 3D 深度预测误差较大的问题。最后, 提出 DU-Transformer 结构强化了模型对深度信息的编码能力, 综合仿真实验和实车实验验证结果, 与当前主流同类算法相比, MonoDBDU 算法具有较为显著的性能提升。在 KITTI 数据集 (IOU=0.7, Hard 难度) 上, AP_{3D} 指标相较于 MonoLSS 提升了 0.57 个百分点, AP_{BEV} 指标相较于 MonoDETR 提升了 1.17 个百分点, 在 Waymo 数据集 (IOU=0.7, Hard 难度) 上, AP_{3D} 和 AP_{BEV} 指标相较于 MonoLSS 分别对应提升幅度达到 1.09 和 1.80 个百分点, 具有较强的泛化能力和鲁棒性。但在实车实验中发现, 在面临检测目标数量较多的拥挤道路场景时, 视频帧更新略有延迟。因此, 未来的研究工作将聚焦于在保留 MonoDBDU 算法检测精度的前提下对其进行轻量化设计, 使其能更好地适应自动驾驶的实时性要求和复杂场景需求。

参考文献

- [1] Ma Z G, Li Z, Liang Y P. Overview and prospect of communication-sensing-computing integration for autonomous driving in the Internet of vehicles. *Chin J Eng*, 2023, 45(1): 137
(马忠贵, 李卓, 梁彦鹏. 自动驾驶车联网中通感算融合研究综述与展望. 工程科学学报, 2023, 45(1): 137)
- [2] Liu J Y, Li X Y, Wang Z R, et al. PromptFusion: Harmonized semantic prompt learning for infrared and visible image fusion. *IEEE/CAA J Autom Sin*, 2025, 12(3): 502
- [3] Li Y J, Li X P, Zhang W G. Survey on vision-based 3D object detection methods. *Comput Eng Appl*, 2020, 56(1): 11
(李宇杰, 李煊鹏, 张为公. 基于视觉的三维目标检测算法研究综述. 计算机工程与应用, 2020, 56(1): 11)
- [4] Wu Y T, Li Q, Sun W W, et al. Overview of object detection methods based on LiDAR point cloud under adverse weather conditions. *Chin J Eng*, 2025, 47(5): 1081
(武雨田, 李擎, 孙文蔚, 等. 复杂天气下车载激光点云目标检测方法综述. 工程科学学报, 2025, 47(5): 1081)
- [5] Mousavian A, Anguelov D, Flynn J, et al. 3D bounding box estimation using deep learning and geometry//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, 2017: 5632
- [6] Hedau V, Hoiem D, Forsyth D. Recovering the spatial layout of cluttered rooms//2009 IEEE 12th International Conference on Computer Vision. Kyoto, 2009: 1849
- [7] Weng X S, Kitani K. Monocular 3D object detection with pseudo-LiDAR point cloud//2019 IEEE/CVF International Conference on Computer Vision Workshop (ICCVW). Seoul, 2019: 857
- [8] Zhou X Y, Wang D Q, Krähenbühl P. Objects as points[J/OL]. *arXiv* (2019-04-16)[2026-01-13]. <https://arxiv.org/abs/1904.07850>
- [9] Wang Y, Chao W L, Garg D, et al. Pseudo-LiDAR from visual depth estimation: Bridging the gap in 3D object detection for autonomous driving//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, 2020: 8437
- [10] Carion N, Carion N, Massa F, et al. End-to-end object detection with transformers//Computer Vision—ECCV 2020. Glasgow, 2020: 213
- [11] Li Z Q, Li Z Q, Wang W H, et al. BEVFormer: Learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers//Computer Vision—ECCV 2022. Tel Aviv, 2022: 1
- [12] Zhang R R, Qiu H, Wang T, et al. MonoDETR: Depth-guided transformer for monocular 3D object detection//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, 2023: 9121
- [13] Yang Y H, Piccinelli L, Segu M, et al. 3D-MOOD: Lifting 2D to 3D for monocular open-set object detection[J/OL]. *arXiv* (2025-07-31)[2026-01-13]. <https://arxiv.org/abs/2507.23567>
- [14] Li Z L, Xu X G, Lim S, et al. UniMODE: Unified monocular 3D object detection//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, 2024: 16561
- [15] Zhang H, Wu C R, Zhang Z Y, et al. ResNeSt: Split-attention networks//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). New Orleans, 2022: 2735
- [16] Tan M X, Le Q V. EfficientNet: Rethinking model scaling for convolutional neural networks[J/OL]. *arXiv* (2019-05-25) [2026-01-13]. <https://arxiv.org/abs/1905.11946>
- [17] Xie S N, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, 2017: 5987
- [18] Hu J, Shen L, Albanie S, et al. Squeeze-and-excitation networks. *IEEE Trans Pattern Anal Mach Intell*, 2020, 42(8): 2011
- [19] Geiger A, Lenz P, Urtasun R. Are we ready for autonomous driving? The KITTI vision benchmark suite//2012 IEEE Conference on Computer Vision and Pattern Recognition. Providence, 2012: 3354
- [20] Sun P, Kretzschmar H, Dotiwalla X, et al. Scalability in perception for autonomous driving: Waymo open dataset//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, 2020: 2443
- [21] Liu X P, Xue N, Wu T F. Learning auxiliary monocular contexts helps monocular 3D object detection. *Proc AAAI Conf Artif Intell*, 2022, 36(2): 1810
- [22] Zhang Y P, Lu J W, Zhou J. Objects are different: Flexible monocular 3D object detection//2021 IEEE/CVF Conference on Computer Vision

- and Pattern Recognition (CVPR). Nashville, 2021: 3288
- [23] Li Y Y, Li Y Y, Chen Y T, et al. Densely constrained depth estimator for monocular 3D object detection//*Computer Vision—ECCV 2022*. Tel Aviv, 2022: 718
- [24] Wang L N, Yu C H, Salián S, et al. Searching the deployable convolution neural networks for GPUs//*2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New Orleans, 2022: 12217
- [25] Ma X Z, Zhang Y M, Xu D, et al. Delving into localization errors for monocular 3D object detection//*2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Nashville, 2021: 4719
- [26] Li Z J, Jia J R, Shi Y F. MonoLSS: Learnable sample selection for monocular 3D detection//*2024 International Conference on 3D Vision (3DV)*. Davos, 2024: 1125
- [27] Zhou Y S, Zhu H Z, Liu Q, et al. MonoATT: Online monocular 3D object detection with adaptive token transformer//*2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Vancouver, 2023: 17493
- [28] Reading C, Harakeh A, Chae J L, et al. Categorical depth distribution network for monocular 3D object detection//*2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Nashville, 2021: 8551