

◎图形图像处理◎

基于Contextual Transformer的自动驾驶单目3D目标检测

库向阳, 颜唯佳, 董立红

西安科技大学 计算机科学与技术学院, 西安 710054

摘要:针对当前单目3D目标检测中存在的漏检和多尺度目标检测效果不佳的问题,提出了一种基于Contextual Transformer的自动驾驶单目3D目标检测算法(CM-RTM3D)。在ResNet-50网络中引入Contextual Transformer (CoT),构建ResNet-Transformer架构以提取特征。设计多尺度空间感知模块(MSP),通过尺度空间响应操作改善浅层特征的丢失情况,嵌入沿水平和竖直两个空间方向的坐标注意力机制(CA),使用softmax函数生成各尺度的重要性软权重。在偏移损失中采用Huber损失函数代替L1损失函数。实验结果表明:在KITTI自动驾驶数据集上,相较于RTM3D算法,该算法在简单、中等、困难三个难度级别下, AP_{3D} 分别提升了4.84、3.82、5.36个百分点, AP_{BEV} 分别提升了4.75、6.26、3.56个百分点。

关键词:自动驾驶;单目3D目标检测;Contextual Transformer;多尺度感知;坐标注意力机制

文献标志码:A **中图分类号:**TP391 **doi:**10.3778/j.issn.1002-8331.2307-0084

Monocular 3D Object Detection for Autonomous Driving Based on Contextual Transformer

SHE Xiangyang, YAN Weijia, DONG Lihong

College of Computer Science and Technology, Xi'an University of Science and Technology, Xi'an 710054, China

Abstract: Aiming at the current problems of leakage and poor multi-scale target detection in monocular 3D object detection, a monocular 3D object detection algorithm for autonomous driving based on Contextual Transformer (CM-RTM3D) is proposed. Firstly, Contextual Transformer (CoT) is introduced into the ResNet-50 network to construct the ResNet-Transformer architecture for feature extraction. Secondly, the multi-scale spatial perception (MSP) module is designed to improve the loss of shallow features through scale-space response operations, embedding the coordinate attention mechanism (CA) along both horizontal and vertical spatial directions, and generating soft weights of importance at each scale using the softmax function. Finally, the Huber loss function is used instead of the L_1 loss function in the offset loss. The experimental results show that, compared with the RTM3D algorithm on the KITTI autopilot dataset, the algorithm in this paper improves AP_{3D} by 4.84, 3.82, and 5.36 percentage points, and AP_{BEV} by 4.75, 6.26, and 3.56 percentage points, respectively, at the three difficulty levels of easy, medium, and difficult.

Key words: autonomous driving; monocular 3D object detection; Contextual Transformer; multi-scale perception; coordinate attention mechanism

2D目标检测的准确率已经超越了人眼辨别能力,但仅能提供目标在图像平面的位置信息,缺乏对3D空间特性的描述,无法满足自动驾驶等领域的特定需求。而3D目标检测在感知目标的同时,能够进一步预测物体在3D空间中的坐标位置、尺寸、偏航角度等关键信

息,因此在自动驾驶等辅助系统的研究中具有更为重要的价值。基于单目视觉的3D目标检测方法通过单摄像机获取的2D图像来预测物体的三维几何信息,具有成本低、易于推广等优势,目前已成为自动驾驶领域的研究热点。根据是否借助额外信息,基于单目视觉的3D

基金项目:陕西省自然科学基金项目(2019JLM-11);陕西省科技计划(2021JQ-576);陕西省教育厅项目(19JK0526)。

作者简介:库向阳(1968—),男,博士后,教授,主要研究方向为数据挖掘与智能信息处理、人工智能与模式识别;颜唯佳(1999—),通信作者,女,硕士研究生,主要研究方向为模式识别、机器学习和智能信息处理, E-mail: 972679930@qq.com;董立红(1968—),女,博士,主要研究方向为智能信息处理技术、计算机监测与控制技术。

收稿日期:2023-07-07 **修回日期:**2023-10-16 **文章编号:**1002-8331(2024)19-0178-12

目标检测可分为三类:(1)基于深度估计的方法;(2)基于伪 Lidar 点云的方法;(3)基于 RGB 图像的方法。

基于深度估计的方法融合深度信息和图像特征信息,计算目标的三维位置和姿态,从而实现目标检测和定位。Reading 等人^[1]将图像转化为视锥特征,通过相机校准实现立方体特征的转换,并使用深度估计特征网络完成 BEV 视角的检测,生成高质量 BEV 图。Ding 等人^[2]提出了一种深度引导的局部卷积网络,使用深度图从单目图像中学习局部动态深度扩展核,得到了更准确的 3D 表示。Lu 等人^[3]提出了一种几何不确定性投影网络,通过几何投影方法实现深度估计,为每个深度提供可靠的置信度,解决了推理和训练阶段中误差放大带来的影响。该类方法不需要额外的深度传感器,但预训练模型的泛化能力差,存在深度估计误差较大的问题。

基于伪 Lidar 点云的方法通过获取高精度的三维点云数据来实现对三维场景的目标检测,并将点云数据与图像信息进行融合完成 3D 目标检测任务。Ku 等人^[4]构建了一种对物体掩膜和形状特征进行重建的学习方法,对点云预测、点云投影后的匹配度、深度信息三方面进行联合监督学习,大大降低了回归 3D 边界框的难度。该类方法能够提高检测的稳定性,但需要依赖额外的标注,不适用于计算资源有限的使用场景。

基于 RGB 图像的方法通过借助几何先验和不确定性理论等信息,对 RGB 图像进行特征提取,直接预测目标的 3D 参数。Li 等人^[5]通过提取 RGB 图像的表面特征来解决边界模糊问题,同时解决了 MonoPair^[6]中利用配对约束建立相邻目标之间距离关系的局限性。Chabot 等人^[7]提出了一种 RGB 图像与 2D-3D 车辆检测相结合的多任务网络,利用车辆的特征点对 3D 车辆信息进行编码,实现了对目标的精确姿态估计和三维车辆定位。Li 等人^[8]通过预测物体的 3D 边界框在 RGB 图像上的 9 个投影关键点,利用 2D-3D 的投影关系估计 3D 边界框的位置、方向和尺度信息,同时顾及实际应用的时效性。Ma 等人^[9]在 CenterNet^[10]的基础上,引入不确定性理论对 RGB 图像上的目标进行预测,改善了总体预测精度。Zhang 等人^[11]考虑到 RGB 图像中目标的截断属性,使用边缘特征解耦了截断目标和正常目标,同时将高度比与不确定性理论相结合,构建了一种集成学习方法来预测物体的中心位置。Liu 等人^[12]提出了一种端到端的关键点检测网络,在 RGB 图像上预测 3D 边界框中心点的投影点,利用相机参数进一步推断 3D 边界框的位置,有效整合了 3D 参数。该类方法仅通过 RGB 图像获取检测框,尽管在定位能力方面存在一定的限制,但不依赖额外信息、避免使用多种传感器和复杂的数据处理,因此在实际应用中具有更大的技术优势。

虽然现有的 3D 目标检测方法从信息融合、数据辅助和边框回归等方面进行了优化,但仍然存在以下两个问题:(1)传统的卷积神经网络(CNN)作为特征提取器

存在感受野较小的不足,导致道路上被截断或遮挡的目标容易发生漏检现象。(2)鉴于车辆行驶情况的复杂性和目标尺度的多样性,现有方法往往没有充分考虑行驶道路上的空间相关性,难以学习多尺度目标的精细特征,从而导致检测效果不佳。Contextual Transformer^[13]利用近邻 keys 之间的上下文信息指导自注意力学习,实现上下文感知,从而帮助模型更好地理解序列中不同位置之间的关系,扩大了感受野,避免特征丢失的现象,在图像识别、目标检测等任务中,均取得了很好的效果。Coordinate Attention^[14]专注于学习输入张量中不同坐标位置的重要性,以提高模型对精细特征的学习能力。相较于传统的注意力机制,Coordinate Attention 不仅考虑特征通道之间的相互作用,还考虑了不同坐标之间的相关性,实现了在一个空间方向上捕获长距离依赖性,同时在另一个空间方向上保留位置信息,能够有效处理复杂的图像特征,从而获得更好的性能表现。

针对车辆被遮挡、截断导致的漏检以及多尺度目标检测精度不佳的问题,本文提出了一种基于 Contextual Transformer 的自动驾驶单目 3D 目标检测算法(Contextual Transformer and multi-scale spatial perception-real-time monocular 3D detection from object keypoints for autonomous driving, CM-RTM3D)。首先,将 Contextual Transformer(CoT)引入 ResNet-50 网络^[15]中,构建 ResNet-Transformer 架构提取特征,扩大了网络感受野;其次,设计了一个多尺度空间感知模块(multi-scale spatial perception module, MSP),以增强对多尺度特征的学习能力,为了充分利用有效特征,克服小尺度目标特征丢失的问题,通过尺度空间响应操作增加浅层特征的检测范围,将 CA 模块通过坐标信息嵌入和坐标注意力生成两个步骤嵌入 MSP,并通过 softmax 函数生成各尺度的重要性软权重,进而融合得到自注意力学习增强的特征图;最后,在偏移损失中采用 Huber 损失函数,提高了对遮挡等异常情况的敏感度。在 KITTI 自动驾驶数据集^[16]上的实验结果证明:本文算法能够有效降低漏检率,提升多尺度目标的检测精度。

1 相关理论与技术

1.1 Contextual Transformer

Contextual Transformer 结构如图 1 所示。首先,对输入 Key 进行 $k \times k$ 卷积得到局部上下文 K^1 。其次,将局部上下文 K^1 与输入 Query 连接,依次输入两个连续的 1×1 卷积 C_1 、 C_2 中,获得动态注意力矩阵 B 。再次,对 Value 进行 1×1 卷积操作后,与矩阵 B 进行自注意力计算,得到全局上下文 K^2 。最后,将局部上下文 K^1 与全局上下文 K^2 进行融合,得到输出结果 Y 。

1.2 RTM3D 单目 3D 目标检测算法

实时单目三维目标检测(real-time monocular 3D detection from object keypoints for autonomous driving,




图1 Contextual Transformer 结构

Fig.1 Contextual Transformer structure

RTM3D)通过2D和3D的几何关系预测目标的尺寸、位置和朝向,其算法流程如图2所示。实现过程如下:(1)将待测RGB图像输入到关键点检测网络,对目标的八个顶点和一个中心点进行预测,得到目标在图像空间中的九个关键点;(2)利用几何约束将3D边界框的估计问题描述为最小化能量函数问题;(3)求解最小化能量函数问题,对预测的关键点进行修正,得到最终检测结果。




图2 RTM3D 算法流程

Fig.2 RTM3D algorithm flow

1.3 CA 模块

CA模块作为一种新型移动网络注意力机制,其结构如图3所示。实现过程如下:(1)将输入特征图 X 沿水平和垂直方向进行平均池化,得到两个方向上的特征图 I_h, I_w ;(2)对 I_h, I_w 进行特征融合,通过卷积运算进行特征变换,并进行归一化和非线性函数运算,生成包含空间信息的过程特征图 t ;(3)沿空间维度将过程特征图 t 分离为两个特征向量 t_h, t_w ;(4)通过卷积运算和Sigmoid函数生成两个注意力向量 g_h, g_w ;(5)将 g_h, g_w 与输入特征




图3 CA 模块结构

Fig.3 CA module structure

图 X 进行点乘运算,得到最终的输出特征图 Y 。

2 基于Contextual Transformer的自动驾驶单目3D目标检测算法

2.1 CM-RTM3D 模型结构

CM-RTM3D模型结构如图4所示,由数据增强、主干网络、特征金字塔、多尺度空间感知、检测头、透视投影六部分组成。具体功能如下:

数据增强:通过随机缩放、水平翻转以及噪声添加对输入图像进行变换,丰富目标区域的数据。

主干网络:将尺寸为 $3 \times 384 \times 1280$ 的图像输入到包含Contextual Transformer的ResNet-50网络中,构建ResNet-Transformer架构提取特征图。

特征金字塔:对提取到的低分辨率特征图进行3次上采样操作,得到3种不同分辨率的特征图,作为多尺度空间感知模块的输入。

多尺度空间感知:首先通过尺度空间响应操作统一多尺度特征图尺度;然后将CA模块通过坐标信息嵌入和坐标注意力生成两个步骤加入特征图中;最后通过softmax函数输出各尺度软权重,并进行融合得到自注意力学习增强的特征图。

检测头:对于目标的3D边界框,采用关键点热图的方法对9个关键点进行预测,其中包括8个顶点和1个中心点,且不同类别的目标可以共享关键点热图,以优化资源利用。检测头由基础预测和辅助预测两部分组




图4 CM-RTM3D 模型结构

Fig.4 Architecture of CM-RTM3D model

成。其中,基础预测包含中心点、顶点和顶点坐标3个必选信息,这些信息共计提供18个约束条件,用于恢复目标的三维信息;辅助预测包含中心偏移、顶点偏移、维度、方向、距离和2D尺寸6个可选信息,这些信息用于校准目标关键点在原始图像上的位置偏差,辅助完成对目标位置和行驶方向的预测。

透视投影:通过利用透视投影的几何约束对预测的关键点进行优化修正,得到最终的目标检测结果。

2.2 主干网络

CM-RTM3D的主干网络以ResNet-50结构为基础,将其中所有 3×3 卷积替换为CoT模块。CM-RTM3D的主干网络结构如图5所示,左侧为主干网络的整体结构,中间为主干网络各阶段的具体结构,右侧为残差模块Bottleneck的详细结构(C 、 H 、 W 分别表示图像的通道数、高、宽, C' 表示图像经过Bottleneck1后的通道数, S 表示步长)。主干网络由stage0、stage1、stage2、stage3和stage4五部分组成。stage0由 7×7 卷积和最大池化子模块组成,完成下采样操作,其余四个阶段均由 1×1 卷积和CoT模块的堆叠结构而成,分别重复堆叠了3、4、6、3次。

2.3 多尺度空间感知模块

多尺度空间感知模块如图6所示。设多尺度空间

感知模块的输入特征图尺度分别为 f_1 、 f_2 和 f_3 。首先对 f_1 、 f_2 执行上采样操作,将 f_1 、 f_2 的尺度统一到 f_3 尺度上,得到特征图 x_c^u (c 为通道序号; u 为尺度序号, $u = 1, 2, 3$);然后将CA模块嵌入特征图中,具体的实现过程如下:

(1) 坐标信息嵌入

假设输入特征图的尺寸为 $C \times H \times W$,在水平和竖直方向上对输入特征图的每个通道进行编码,得到编码后的特征图 I^u ,计算公式如下:

$$I^u = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c^u(i, j) \quad (1)$$

其中, x_c^u 表示第 c 通道的输入特征图。

对特征图 x_c^u 分别使用大小为 $(H, 1)$ 、 $(1, W)$ 的池化核沿水平、竖直方向并行地实现一维特征编码,得到两个方向上独立的感知特征图 I_h^u 、 I_w^u ,计算公式如下:

$$I_h^u = \frac{1}{W} \sum_{0 \leq i < W} x_c^u(h, i) \quad (2)$$

$$I_w^u = \frac{1}{H} \sum_{0 \leq j < H} x_c^u(j, w) \quad (3)$$

其中, h 表示高度; w 表示宽度; $x_c^u(h, i)$ 表示特征图 x_c^u 在高度 h 处水平方向的特征; $x_c^u(j, w)$ 表示特征图 x_c^u 在宽度 w 处竖直方向的特征。

(2) 坐标注意力生成

将感知特征图 I_h^u 和 I_w^u 融合,进行 1×1 卷积变换 F_1 操

实现正负样本的平衡。计算公式如下:

$$L_{kp} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K \begin{cases} (1 - \hat{Y}_{ij})^\alpha \ln \hat{Y}_{ij}, & \text{若 } Y_{ij} = 1 \\ (1 - Y_{ij})^\beta \hat{Y}_{ij} \ln(1 - \hat{Y}_{ij}), & \text{其他} \end{cases} \quad (10)$$

其中, N 表示图像中目标的数量; K 表示不同类型 heat-map 检测的关键点数量; α 和 β 表示控制正负样本的超参数, $\alpha=2, \beta=4$; Y_{ij} 表示第 i 个目标的第 j 个关键点在输出特征图中的真实值, 当第 j 个关键点位于中心点时, $Y_{ij} = 1$; $\hat{Y}_{ij}$ 表示第 i 个目标中第 j 个关键点的预测值。

(2) L_{off} 损失函数。对输出特征图中涉及目标中心点或关键点的位置进行监督, 采用 Huber 损失函数监督原始图像的修正偏移。计算公式如下:

$$L_{off}^m = \frac{1}{2N} \sum_{i=1}^N \begin{cases} \left| O_i^m - \frac{1}{2} \left(\frac{p_i^m}{S} - \tilde{p}_i^m \right)^2 \right|, & \text{若 } \left| \frac{p_i^m}{S} - \tilde{p}_i^m \right| \leq \delta \\ \left| O_i^m - \delta \right| \left| \frac{p_i^m}{S} - \tilde{p}_i^m \right| - \frac{1}{2} \delta^2, & \text{其他} \end{cases} \quad (11)$$

$$L_{off}^{kp} = \frac{1}{2N} \sum_{i=1}^N \sum_{j=1}^K \begin{cases} \left| O_{ij}^{kp} - \frac{1}{2} \left(\frac{p_{ij}^{kp}}{S} - \tilde{p}_{ij}^{kp} \right)^2 \right|, & \text{若 } \left| \frac{p_{ij}^{kp}}{S} - \tilde{p}_{ij}^{kp} \right| \leq \delta \\ \left| O_{ij}^{kp} - \delta \right| \left| \frac{p_{ij}^{kp}}{S} - \tilde{p}_{ij}^{kp} \right| - \frac{1}{2} \delta^2, & \text{其他} \end{cases} \quad (12)$$

其中, L_{off}^m 表示目标中心点的偏移损失; L_{off}^{kp} 表示投影关键点的偏移损失; p_i^m 表示第 i 个目标的中心点在原图上的坐标; $\tilde{p}_i^m$ 表示第 i 个目标的中心点在输出特征图上的坐标; O_i^m 表示第 i 个目标的原图偏移在特征图 $\tilde{p}_i^m$ 处的输出值; p_{ij}^{kp} 表示第 i 个目标的第 j 个关键点在原图上的坐标; $\tilde{p}_{ij}^{kp}$ 表示第 i 个目标的第 j 个关键点在输出特征图上的坐标; O_{ij}^{kp} 表示第 i 个目标中第 j 个关键点的原图偏移在特征图 $\tilde{p}_{ij}^{kp}$ 处的输出值; δ 表示超参数, $\delta=1$; S 表示下采样倍数, $S=4$ 。

(3) L_{ver} 损失函数。计算公式如下:

$$L_{ver} = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^8 \left| Q_{ij}^{kp} - \left(\frac{p_{ij}^{kp} - p_i^m}{S} \right) \right| \quad (13)$$

其中, 8 表示目标的顶点个数; Q_{ij}^{kp} 表示第 i 个目标的第 j 个关键点与中心点之间的距离残差。

(4) L_{ori} 损失函数。朝向损失函数 L_{ori} 采用 Multi-Bin 方法^[18]对局部角度进行预测。计算公式如下:

$$L_{ori} = L_{soft} - \frac{1}{n_\theta} \sum \cos(\theta - c_b - \Delta\theta_b) \quad (14)$$

其中, L_{soft} 表示 softmax 损失函数; n_θ 表示与地面角度成 θ 的 bin 个数; c_b 表示 bin 的中心角度; $\Delta\theta_b$ 表示 bin 的中心角度变化量。

(5) L_D 损失函数。对目标维度的预测可以转化为对残差的预测, 计算公式如下:

$$L_D = \frac{1}{3N} \sum_{i=1}^N \left(\hat{D}_i - \ln \left(\frac{D_i - \bar{D}}{D_\sigma} \right) \right)^2 \quad (15)$$

其中, D_i 表示第 i 个目标的真实维度; $\hat{D}_i$ 表示第 i 个目标的预测维度; $\bar{D}$ 表示所有目标维度的平均值; D_σ 表示所有目标维度的标准差。

(6) L_z 损失函数。对距离的预测同样转化为对残差的预测, 计算公式如下:

$$L_z = \frac{1}{N} \sum_{i=1}^N \left(\ln \hat{Z}_i - \ln Z_i \right)^2 \quad (16)$$

其中, Z_i 表示第 i 个目标在相机坐标系下的深度; $\hat{Z}_i$ 表示第 i 个目标的预测深度。

3 算法验证与分析

3.1 数据集与评价指标

3.1.1 数据集

KITTI 自动驾驶数据集由德国卡尔斯鲁厄理工学院提供, 该数据集是目前自动驾驶领域中最通用的数据集之一, 包含 7 481 张训练图像和 7 518 张测试图像, 主要涵盖了汽车(car)、行人(pedestrian)和骑行者(cyclist)三个类别, 并对这些目标进行了二维和三维标注。根据目标在图像中的尺寸和遮挡程度, KITTI 数据集将待测目标划分为简单(easy)、中等(moderate)、困难(hard)三个难度等级。从不相交的序列集中将训练集进一步划分为 3 712 个样本进行训练, 3 769 个样本进行验证。Waymo 开放数据集^[19]由 798 个训练序列和 202 个验证序列组成, 主要涵盖了汽车、行人、骑行者和交通标志。由于数据集规模大且帧率高^[1], 实验使用训练集和验证集的子集进行训练(3 000 个样本)和验证(2 716 个样本), 并转换为 KITTI 标注格式进行实验。nuScenes 数据集^[20]包含 1 000 个驾驶场景, 对汽车、行人、骑行者和交通标志等目标进行了精确标注。鉴于数据集规模庞大, 实验使用数据集的子集作为训练集(3 517 个样本)和验证集(2 730 个样本), 并转换为 KITTI 标注格式进行实验。

3.1.2 评价指标

(1) 交并比(intersection-over-union, IoU)

交并比是目标候选框与目标真实框交集面积与并集面积的比值。计算公式如下:

$$IoU = \frac{\text{area}(\text{Pred} \cap \text{Truth})}{\text{area}(\text{Pred} \cup \text{Truth})} \quad (17)$$

其中, Pred 表示目标候选框; Truth 表示目标真实框; $\text{area}(\cdot)$ 表示求解面积函数。

(2) 精确率(precision)与召回率(recall)

精确率表示在所有被预测为正的样本中, 实际为正样本的比例。召回率表示在实际为正的样本中, 被预测为正样本的比例。计算公式如下:

$$\text{precision} = \frac{TP}{TP + FP} \quad (18)$$

$$recall = \frac{TP}{TP + FN} \quad (19)$$

其中, TP 表示预测与实际都为正的样本数; FP 表示预测为正, 但实际为负的样本数; FN 表示预测为负, 但实际为正的样本数。

(3) 平均精度 (average precision, AP)

平均精度基于精确-召回率曲线, 在 40 个召回点集合 $S = \left\{ \frac{1}{40}, \frac{2}{40}, \dots, 1 \right\}$ 下计算最大精确率的平均值。计算公式如下:

$$AP = \frac{1}{40} \sum_{r \in S} \max_{r': r' \geq r} \rho(r') \quad (20)$$

其中, $\rho(r')$ 表示召回率为 r' 时的精确率。

3.2 实验环境与实验方案

3.2.1 实验环境与参数设置

实验环境基于 Pytorch 深度学习框架, 使用 CUDA 与 CuDNN 加速技术。环境配置如表 1 所示。

表 1 实验环境配置

Table 1 Experimental environment configuration

实验环境	配置
操作系统	Ubuntu16.04
GPU 型号	RTX 2080Ti
显存	12 GB
深度学习框架	Pytorch 1.6.0
编程语言	Python 3.8

表 2 汽车类别上的 3D 检测结果

Table 2 3D inspection results on car categories

单位: %

算法	$AP_{3D} (IoU = 0.5)$			$AP_{3D} (IoU = 0.7)$		
	简单	中等	困难	简单	中等	困难
MonoGRNet ^[21]	45.79	33.24	28.72	13.66	10.34	7.76
M3D-RPN ^[22]	48.58	36.61	32.95	17.52	15.18	13.70
FQNet ^[23]	28.16	21.02	19.91	5.98	5.50	4.75
SMOKE ^[12]	—	—	—	13.86	10.03	9.65
MonoDLE ^[9]	49.78	36.04	33.63	16.14	13.70	11.73
RTM3D ^[8]	45.06	32.84	28.68	16.25	13.71	12.05
CM-RTM3D	49.90	36.66	34.04	19.28	15.57	14.60

表 3 汽车类别上的 BEV 检测结果

Table 3 BEV inspection results on car categories

单位: %

算法	$AP_{BEV} (IoU = 0.5)$			$AP_{BEV} (IoU = 0.7)$		
	简单	中等	困难	简单	中等	困难
MonoGRNet ^[21]	51.79	39.90	33.25	22.30	18.28	15.59
M3D-RPN ^[22]	54.75	41.59	34.94	22.95	17.90	15.98
FQNet ^[23]	32.57	24.60	21.25	9.50	8.02	7.71
SMOKE ^[12]	—	—	—	19.37	13.82	13.39
MonoDLE ^[9]	56.03	41.99	36.05	23.40	18.39	17.05
RTM3D ^[8]	51.80	36.27	33.14	19.54	15.45	14.37
CM-RTM3D	56.55	42.53	36.70	24.45	18.46	17.44

参数设置: batch size 设置为 8, 迭代训练 200 次。采用 Adam 优化器对模型进行优化, 初始学习率设置为 1.25×10^{-4} , 在迭代第 90 次和第 120 次时, 学习率降到当前学习率 0.1 倍。

3.2.2 实验方案

方案 1 在 KITTI 数据集上, 根据不同的 IoU 取值, 对比 CM-RTM3D 与 MonoGRNet、M3D-RPN、FQNet、SMOKE、MonoDLE、RTM3D 目前六种主流算法在汽车类别上的 3D 目标检测性能, AP_{3D} 为三维目标检测平均精度, AP_{BEV} 为鸟瞰图视角下目标检测平均精度。

方案 2 (消融实验) 对比 RTM3D、RTM3D+CoT、RTM3D+MSP 以及 RTM3D+CoT+MSP (CM-RTM3D) 在 KITTI 数据集上 3D 目标检测性能, 选择 AP_{3D} 、 AP_{BEV} 作为评价指标。

方案 3 在 KITTI 数据集上, 对比 CM-RTM3D 与 M3D-RPN、MonoDLE、RTM3D 算法在行人、骑行者类别上的 AP_{3D} 检测结果。

方案 4 CM-RTM3D 在 Waymo、nuScenes 数据集上与 RTM3D 算法进行实验比较。

3.3 实验结果与分析

方案 1 在 AP_{3D} 、 AP_{BEV} 指标上的实验结果如表 2、表 3 所示。

从表 2 可知, 在简单级别 ($IoU=0.7$) 下, 相较于 M3D-RPN 和 MonoDLE 算法, CM-RTM3D 在 AP_{3D} 上分别提升了 1.76 个百分点和 3.14 个百分点。在中等难度

($IoU=0.7$)下,相较于 MonoGRNet 和 SMOKE 算法,CM-RTM3D 在 AP_{3D} 上分别提升了 5.23 个百分点和 5.54 个百分点。与基线模型 RTM3D 相比,在 $IoU=0.5$ 和 $IoU=0.7$ 情况下,各难度级别的 AP_{3D} 分别提升了 4.84、3.82、5.36 个百分点和 3.03、1.86、2.55 个百分点。

从表 3 可知,在简单级别($IoU=0.7$)下,相较于 MonoGRNet 和 M3D-RPN 算法,CM-RTM3D 在 AP_{BEV} 上分别提升了 2.15 个百分点和 1.50 个百分点。在困难级别($IoU=0.7$)下,相较于 SMOKE 和 MonoDLE 算法,CM-RTM3D 在 AP_{BEV} 上分别提升了 4.05 个百分点和 0.39 个百分点。当 $IoU=0.5$ 时,相较于 RTM3D,CM-RTM3D 在简单、中等、困难三个难度级别下的 AP_{BEV} 分别提升了 4.75、6.26、3.56 个百分点。当 $IoU=0.7$ 时,相较于 RTM3D 算法,CM-RTM3D 在简单、中等、困难三个难度级别下的 AP_{BEV} 分别提升了 4.91、3.01、3.07 个百分点。

从表 2、表 3 可以看出,在汽车类别的 3D 和 BEV 检测任务中,CM-RTM3D 与其他四种算法相比,在 AP_{3D} 、 AP_{BEV} 指标上的性能最好。

方案 2(消融实验)在 AP_{3D} 、 AP_{BEV} 指标上的实验结果如表 4、表 5 所示。从表 4 可知,加入 CoT 模块后,在 $IoU=0.5$ 和 $IoU=0.7$ 设定下,各难度级别的 AP_{3D} 分别提升了 2.77、1.75、3.29 个百分点和 1.75、1.07、1.79 个百分点。加入 MSP 模块后,各难度级别下的 AP_{3D} 均有显著提升,特别是在 $IoU=0.5$ 的困难设置下, AP_{3D} 提高了 5.14 个百分点。将 CoT 和 MSP 两个模块均加入 RTM3D 后,整体性能提升更为明显,进一步验证了 CM-RTM3D 能够充分挖掘上下文信息,增强网络在每个空间方向上的表达能力。

从表 5 可知,加入 CoT 模块后,在 $IoU=0.5$ 和 $IoU=0.7$ 的设定下,各难度级别的 AP_{BEV} 分别提升了 2.77、4.03、1.68 个百分点和 1.67、3.06、1.89 个百分点。加入 MSP 模块后,各设置下的 AP_{BEV} 分别提升了 2.52、5.02、2.90 个百分点和 3.75、3.00、4.00 个百分点。将 CoT 和 MSP 两个模块同时加入 RTM3D 后,模型性能相较于仅加入其中任意一个模块表现都好,这表明将 CoT 和 MSP 相结合可以有效增强模型对特征图内部自注意力的学习能力,从而在 BEV 视图下提升目标检测性能。

方案 3 在行人、骑行者类别上的实验结果如表 6 所示。从表 6 可知,在简单、中等、困难三个级别($IoU=0.5$)下,相较于 MonoDLE 和 RTM3D 算法,CM-RTM3D 在行人类别的 AP_{3D} 上分别提升了 1.56、1.33、1.59 个百分点和 1.52、1.15、0.82 个百分点;在骑行者类别的 AP_{3D} 上分别提升了 0.64、0.21、0.10 个百分点和 1.23、0.76、0.63 个百分点(注:鉴于这两个类别在数据集中的训练样本较少,性能会出现一定程度的波动)。

方案 4 在 Waymo 开放数据集的实验结果如表 7 所示。从表 7 可知,在简单、中等级别($IoU=0.7$)下,相较于 RTM3D 算法,CM-RTM3D 在 AP_{3D} 上分别提升了 3.21、1.72 个百分点,在 AP_{BEV} 上分别提升了 3.52、2.19 个百分点。

方案 4 在 nuScenes 数据集的实验结果如表 8 所示。从表 8 可知,在简单、中等级别($IoU=0.5:0.95$)下,相较于 RTM3D 算法,CM-RTM3D 在 AP_{3D} 上分别提升了 3.23、2.87 个百分点,在 AP_{BEV} 上分别提升了 2.41、4.49 个百分点。

表 4 消融实验在 AP_{3D} 指标上的实验结果

Table 4 Experimental results of ablation experiment on AP_{3D} 单位: %

算法	$AP_{3D}(IoU = 0.5)$			$AP_{3D}(IoU = 0.7)$		
	简单	中等	困难	简单	中等	困难
RTM3D ^[8]	45.06	32.84	28.68	16.25	12.71	11.05
RTM3D+CoT	47.83	34.59	31.97	18.00	13.78	12.84
RTM3D+MSP	47.82	35.39	33.82	17.99	14.69	14.30
RTM3D+CoT+MSP	49.90	36.66	34.04	19.28	15.57	14.60

表 5 消融实验在 AP_{BEV} 指标上的实验结果

Table 5 Experimental results of ablation experiment on AP_{BEV} 单位: %

算法	$AP_{BEV}(IoU = 0.5)$			$AP_{BEV}(IoU = 0.7)$		
	简单	中等	困难	简单	中等	困难
RTM3D ^[8]	51.80	36.27	33.14	18.54	14.45	13.37
RTM3D+CoT	54.57	40.30	34.82	20.21	17.51	15.26
RTM3D+MSP	54.32	41.29	36.04	22.29	17.45	17.37
RTM3D+CoT+MSP	56.55	42.53	36.70	24.45	18.46	17.44

表6 行人、骑行者类别上的实验结果

Table 6 Experimental results of pedestrians and cyclists categories

算法	Pedestrian AP_{3D} ($IoU = 0.5$)			Cyclist AP_{3D} ($IoU = 0.5$)		
	简单	中等	困难	简单	中等	困难
M3D-RPN ^[22]	4.92	3.48	2.94	0.94	0.65	0.47
MonoDLE ^[9]	9.64	6.55	5.44	4.59	2.66	2.45
RTM3D ^[8]	9.68	6.73	6.21	4.00	2.11	1.92
CM-RTM3D	11.20	7.88	7.03	5.23	2.87	2.55

表7 汽车类别在Waymo开放数据集上的实验结果

Table 7 Experimental results of vehicle categories on Waymo open dataset

算法	AP_{3D} ($IoU = 0.7$)		AP_{BEV} ($IoU = 0.7$)	
	简单	中等	简单	中等
RTM3D ^[8]	59.81	54.77	61.21	56.49
CM-RTM3D	63.02	56.49	64.73	58.68

表8 汽车类别在nuScenes数据集上的实验结果

Table 8 Experimental results of vehicle categories on nuScenes dataset

算法	AP_{3D} ($IoU = 0.5:0.95$)		AP_{BEV} ($IoU = 0.5:0.95$)	
	简单	中等	简单	中等
RTM3D ^[8]	48.33	42.89	62.58	55.27
CM-RTM3D	51.56	45.76	64.99	59.76

3.4 可视化分析

为了更加清晰地评估本文算法的有效性,图7~图10分别展示了截断、多尺度、遮挡以及行人和骑行者密集呈现情况下的可视化结果。


图7(a)为RTM3D的3D检测结果,A、B、C为待检测目标,红线框表示目标的3D边界框,蓝线框表示目标的2D边界框,蓝线框左上角“Car1.0”表示汽车在3D空间下的检测精度为1.0。图7(b)为RTM3D的BEV检测结果,红线条表示目标在BEV视图下的位置,蓝数字表示目标在BEV视图下的检测精度。图7(c)为CM-RTM3D的3D检测结果,图7(d)为CM-RTM3D的BEV检测结果。图7(a)中由于视角范围的限制,左下角被截断的汽车C未能被成功检测到。图7(c)中CM-RTM3D成功检测到被截断的汽车C。对比图7(b)和图7(d),可以发现CM-RTM3D在BEV视角下不仅能够识别出被漏检的汽车C,同时将汽车A和汽车B的检测精度提高了0.03。

图8为多尺度情况下的目标检测结果,A~H为待检测目标。虽然在图8(a)中成功检测到了各个目标,但是图8(c)CM-RTM3D将多辆汽车和右侧自行车的检测精度提升了0.1。对比图8(b)和图8(d),可以看出CM-RTM3D在BEV视图下不仅能够识别出被漏检的汽车F,同时将各个目标的检测精度提高了0.04~0.1。

图9为遮挡和多尺度两种情况下的目标检测结果,A~G为待检测目标。图9(a)中由于周围树木和汽车F




(a) RTM3D的3D检测结果



(b) RTM3D的BEV检测结果



(c) CM-RTM3D的3D检测结果



(d) CM-RTM3D的BEV检测结果

图7 截断情况下的目标检测结果

Fig.7 Detection results in case of truncation




图8 多尺度情况下的目标检测结果
Fig.8 Detection results in multi-scale situations




图9 遮挡、多尺度情况下的目标检测结果
Fig.9 Detection results in obscured, multi-scale situations

的遮挡,汽车G未能被成功检测到。图9(c)中CM-RTM3D成功检测到被遮挡的汽车G,并将多辆汽车的

检测精度提高了0.1~0.2。对比图9(b)和图9(d),CM-RTM3D在BEV视图下成功检测出了汽车G,并将各个




图10 行人、骑行者密集呈现情况下的检测结果

Fig.10 Detection results in case of dense presentation of pedestrians and cyclists

尺度车辆的检测精度提升了0.08~0.23。

图10为行人、骑行者密集呈现情况下的检测结果，A~L为待检测目标。对比图10(a)和图10(c)，在3D空间中CM-RTM3D将行人、骑行者、汽车的检测精度提升了0.1~0.2。对比图10(b)和图10(d)，CM-RTM3D在BEV视图下检测出新增目标M，并将骑行者A的检测精度提高了0.15，行人C的检测精度提高了0.18，汽车E的检测精度提高了0.13。

4 结束语

本文提出了一种基于Contextual Transformer的自动驾驶单目3D目标检测算法。在主干网络中引入Contextual Transformer，通过扩大网络感受野以提取全局特征。同时，设计多尺度空间感知模块，以解决小尺度目标特征丢失的问题，并增强对多尺度特征的学习能力。在回归损失函数中，采用Huber损失函数提高对遮挡等异常情况的敏感度。在KITTI数据集上的实验结果表明：本文算法能够降低漏检率，增强检测多尺度目标时的鲁棒性。研究如何实现轻量化以更好地满足实际应用场景的需求是下一步的研究方向。

参考文献：

- [1] READING C, HARAKEH A, CHAE J, et al. Categorical depth distribution network for monocular 3D object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 8555-8564.
- [2] DING M, HUO Y, YI H, et al. Learning depth-guided convolutions for monocular 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020: 1000-1001.
- [3] LU Y, MA X, YANG L, et al. Geometry uncertainty projection network for monocular 3D object detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 3111-3121.
- [4] KU J, PON A, WASLANDER S. Monocular 3D object detection leveraging accurate proposals and shape reconstruction [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 11867-11876.
- [5] LI B, OUYANG W, SHENG L, et al. GS3D: an efficient 3D object detection framework for autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 1019-1028.
- [6] CHEN Y, TAI L, SUN K, et al. Monopair: monocular 3D object detection using pairwise spatial relationships[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 12093-12102.
- [7] CHABOT F, CHAOUCH M, RABARISOA J, et al. Deep manta: a coarse-to-fine many-task network for joint 2D and 3D vehicle analysis from monocular image[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2040-2049.
- [8] LI P, ZHAO H, LIU P, et al. RTM3D: real-time monocular

- 3D detection from object keypoints for autonomous driving [C]//Proceedings of the European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 644-660.
- [9] MA X, ZHANG Y, XU D, et al. Delving into localization errors for monocular 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 4721-4730.
- [10] ZHOU X, WANG D, KRAHENBUHL P. Objects as points [J]. arxiv:1904.07850, 2019.
- [11] ZHANG Y, LU J, ZHOU J. Objects are different: flexible monocular 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 3289-3298.
- [12] LIU Z, WU Z, TOTH R. Smoke: single-stage monocular 3D object detection via keypoint estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2020: 996-997.
- [13] LI Y, YAO T, PAN Y, et al. Contextual transformer networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(2): 1489-1500.
- [14] HOU Q, ZHOU D, FENG J. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 13713-13722.
- [15] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [16] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the kitti vision benchmark suite[C]//Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012: 3354-3361.
- [17] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 2980-2988.
- [18] MOUSAVIAN A, ANGUELOV D, FLYNN J, et al. 3D bounding box estimation using deep learning and geometry [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 7074-7082.
- [19] SUN P, KRETZSCHMAR H, DOTIWALLA X, et al. Scalability in perception for autonomous driving: Waymo open dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 2446-2454.
- [20] CAESAR H, BANKITI V, LANG A, et al. nuScenes: a multi-modal dataset for autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11621-11631.
- [21] QIN Z, WANG J, LU Y. MonoGRNet: a general framework for monocular 3D object detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(9): 5170-5184.
- [22] BRAZIL G, LIU X. M3D-RPN: monocular 3D region proposal network for object detection[C]//Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2019.
- [23] LIU L, LU J, XU C, et al. Deep fitting degree scoring network for monocular 3D object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 1057-1066.