

基于尺度监督查询优化的Transformer单目3D检测

王鑫威¹, 张友兵^{1,2+}, 周奎¹

1. 湖北汽车工业学院 智能网联汽车学院 Sharing-X 移动服务技术平台联合实验室, 湖北 十堰 442000

2. 荆楚理工学院, 湖北 荆门 448000

+ 通信作者 E-mail: zhangyb@huat.edu.cn

摘要:近年来, 基于Transformer的单目3D目标检测方法取得显著进展, 然而, 其无监督注意力机制受限于感受野不精确, 难以有效感知复杂场景中的关键目标, 易导致低质量查询特征。针对该问题, 提出一种基于深度特征生成尺度监督信号的查询优化机制: 通过预设多尺度掩码, 并引入深度引导的注意力自适应调控策略, 以精细化调节查询感受野。考虑到单目深度预测缺乏显式监督, 仅依赖离散的3D框标签, 易受背景噪声干扰, 进一步设计了基于U-Net的目标区域概率预测分支, 有效增强目标区域深度感知能力。为缓解层级特征图间的语义差异对深度预测的影响, 提出融合空间金字塔结构与矩阵相关性计算的多层次特征融合策略。实验结果证明, 该方法在KITTI数据集上, Easy、Moderate和Hard级别的 AP_{3D} ($IOU=0.7$) 分别提升2.67、2.82和2.55个百分点, 在远距目标(40 m外)检测中尤为有效, 相对提升超过34.38%。

关键词:单目3D目标检测; 多层次注意力; 查询优化; 深度估计; 前景感知

文献标志码:A **中图分类号:**TP391 **doi:**10.3778/j.issn.1002-8331.2505-0003

Transformer-Based Monocular 3D Object Detection with Scale-Supervised Query Refinement

WANG Xinwei¹, ZHANG Youbing^{1,2+}, ZHOU Kui¹

1. Sharing-X Mobile Service Technology Platform Joint Laboratory, School of Intelligent Connected Vehicle, Hubei University of Automotive Technology, Shiyan, Hubei 442000, China

2. Jingchu University of Technology, Jingmen, Hubei 448000, China

Abstract: In recent years, Transformer-based monocular 3D object detection methods have achieved remarkable progress. However, their unsupervised attention mechanisms often suffer from imprecise receptive fields, making it difficult to effectively capture key targets in complex scenes, which leads to low-quality query features. To address this issue, this paper proposes a query refinement mechanism that generates scale supervision signals from depth features. Specifically, this paper designs preset multi-scale masks and introduces a depth-guided adaptive attention modulation strategy to precisely adjust the receptive fields of queries. Given the lack of explicit supervision in monocular depth prediction—typically relying only on sparse 3D box annotations and being easily affected by background noise—this paper further designs a U-Net-based target region probability prediction branch to enhance depth perception in target areas. Moreover, to alleviate the semantic discrepancy among hierarchical feature maps during depth prediction, this paper proposes a multi-level feature fusion strategy that integrates spatial pyramid structures and matrix correlation computation. Experimental results on the KITTI dataset show that this method improves AP_{3D} by 2.67, 2.82, and 2.55 percentage points on the Easy, Moderate, and Hard settings, respectively, with over 34.38% relative improvement in long-range object detection scenarios.

Key words: monocular 3D object detection; multi-level attention; query refinement; depth estimation; foreground awareness

三维目标检测是自动驾驶与机器人感知领域的核心研究方向。相较于激光雷达^[1-2]和双目立体视觉^[3-4]等方案, 单目方法虽因深度信息缺失导致定位精度受限,

但凭借硬件成本低、系统配置简单等显著优势, 近年来持续成为研究热点。

近期, 多项研究仅采用单张图像进行3D目标检测,

基金项目:国家自然科学基金湖北省重大研发计划项目(2020AAA001); 湖北省重点研发计划项目(2021BED004, 2023BAB169)。

作者简介:王鑫威(2000—), 男, 硕士研究生, 研究方向为智能驾驶、环境感知; 张友兵(1972—), 男, 硕士, 教授, 研究方向为智能驾驶; 周奎(1980—), 男, 硕士, 副教授, 研究方向为智能驾驶、环境感知。

收稿日期:2025-05-03 **修回日期:**2025-06-23 **文章编号:**1002-8331(2026)07-0244-12

其主要依赖几何先验知识进行预测。其中Deep3Dbbox^[5]提出了多分支损失以解决姿态估计问题,并利用几何先验约束2D与3D边界框之间的对应关系。MonoFlex^[6]通过引入边缘热力图和边缘融合模块,优化了截断目标检测。MonoCon^[7]在训练阶段学习从三维边界框投影得到的辅助单目上下文信息,并在推理阶段舍弃这些信息以提高效率。MonoDIS^[8]则采用解耦的回归损失,避免了各参数间误差传递的干扰,提高了训练的稳定性。尽管上述方法仅依赖单目图像、结构简单,但由于缺乏明确的深度线索,难以实现精确的目标定位。

为进一步提升检测性能,许多研究提出引入深度信息作为训练辅助,其中Pseudo-LiDAR^[9]、LPCG^[10]是近年来的代表性算法,通过利用预训练的深度估计器和相机标定参数,将图像转换为伪LiDAR表示,再使用现有基于LiDAR的三维检测器进行目标预测。而D4LCN^[11]和DDMP-3D^[12]聚焦于构建图像与估计深度之间的融合机制,通过设计卷积网络进行特征级融合。然而,上述大多数方法依赖预训练的深度估计器,不仅引入了额外的计算开销,还可能因深度信息不准确而导致性能受限。

大多数现有的单目3D方法都是对传统2D目标检测器进行改进^[13],这些方法依赖手工设定参数或几何先验^[14],如图1(a)所示。相较而言,基于Transformer的检测方法(如MonoDETR^[15])可以避免繁琐的参数调整及后处理,通过自注意力机制捕捉全局上下文信息,具备更好的复杂场景下检测效果,其基本结构如图1(b)所示。其中,DETR3D^[16]首次引入了3D目标查询,并为每个查询生成三维参考点特征。该方法通过聚合多视角图像特征,并应用交叉注意力机制,实现三维边界框的

解码。MonoDTR^[17]则借助Transformer融合LiDAR点云提供的辅助深度信息,以增强3D目标检测能力。MonoDGP^[18]提出了一种深度引导的解码器,将解码过程解耦为2D视觉解码器和3D深度引导解码器,从而避免3D检测对2D先验的干扰。MonoATT^[19]根据图像区域的重要性动态分配更精细的token,以替代传统的等大小网格token,从而提升检测精度。MonoDETR^[15]则设计了一种深度引导解码器,通过离散物体深度标签生成前景图,在交叉注意力层中自适应引导目标查询提取深度特征,并提出可变形注意力层来聚合局部视觉特征,以更好地挖掘细节信息。

然而现有基于Transformer的单目3D检测方案通常使用弱监督训练生成查询,缺乏对尺度的显式监督,导致预测点极易漂移至相似物体。同时该方式需更多解码器层进行多次迭代优化,导致模型需要更长的训练时间。且弱监督的查询优化可能导致模型陷入局部最优,尤其是当初始查询与真实目标分布差异较大时。为解决该问题一些方案^[20-21]引入可变形注意力机制,使对象查询能够自适应地关注图像中的关键区域加快模型收敛,然而这种方案带来高额计算且在高遮挡或密集目标场景多个查询可能会聚焦于同一目标,导致检测失败。

针对传统查询优化方法的局限性,本文提出了一种基于尺度监督的查询优化模块(scale-supervised query optimization, SSQM)。利用上层视觉特征生成参考点网格,在查询优化过程中通过轻量级网络预测视觉特征上最匹配查询的Top-M个参考点,根据位置和权重融合为一个查询点。并为每个目标查询点预设多个尺度掩码从视觉图中提取多尺度局部特征,同时基于深度图预测查询点的不同尺度概率分布,通过两者结合从而为查询优化提供尺度信息指导,优化其感受野,同时加快收敛速度。

在单目图像中目标物体与背景的像素特征容易混杂,尤其在遮挡或复杂场景下。同时在特征提取的初期阶段都需直接使用CNN提取的全局特征(如图1),这导致3D检测器难以聚焦于目标区域。且单目深度估计是病态问题,同一2D像素可能对应多个3D位置。传统方法直接回归深度时,背景像素的无效深度会干扰目标物体的深度学习。

为解决此问题本文提出自适应前景感知模块(adaptive foreground perception module, AFPM),基于U-Net结构利用尺度融合特征预测目标区域概率图,以区分前景与背景。通过目标概率图引导3D解码器专注有效区域并约束深度预测仅在前景区域进行,减少背景带来的歧义性。同时由于前景像素通常远少于背景,本文在训练过程中使用Combo Loss,通过结合Dice Loss与BCE Loss,实现有效处理类别不均衡同时保证训练的稳定性。

基于Transformer的单目3D方法依赖深度分支提取输入图片深度特征,以辅助网络学习物体间场景几何




图1 不同单目三维目标检测框架对比

Fig.1 Comparison of different monocular 3D object detection frameworks

结构。为降低标注成本和计算开销多数单目3D深度分支仅依赖三维目标框训练,但由于仅标注前景物体深度,背景区域缺乏监督信号,训练难度提升。其中原始MonoDETR深度估计分支仅使用三个不同尺度特征直接拼接卷积,导致高层语义信息被低层噪声稀释,在复杂背景干扰的场景下识别效果不佳。为解决此问题MonoDETRNext^[22]通过使用改进Lite-Mono^[23]架构,并引入级联扩张卷积和区域-全局交互模块,提高了全局检测精度,但由于使用Transformer深度估计结构,计算复杂度较高,难以满足实时性要求。

针对单目3D目标检测深度估计方面的局限性,本文提出一种基于CNN的多层次注意力融合深度估计方案(multi-level attention fusion depth estimator, MLA-Depth)。以主干网络的4倍下采样特征图与16倍下采样特征图作为输入,构建空洞空间金字塔池化模块,利用不同膨胀率的空洞卷积捕获多尺度上下文信息,通过通道与空间注意力增强特征表达能力。同时,采用矩阵相关性计算跨层特征间的像素级关系,生成权重向量,融合后的低层与高层特征通过线性递增离散化方法生成深度图。通过该模块实现了低成本的多层次语义整合,提高了深度预测精度。

1 本文方法

1.1 模型结构

图2展示了本文提出方法的核心网络结构。该方案以MonoDETR为基准网络,以图像 $I \in \mathbb{R}^{H \times W \times 3}$ 作为

输入,其中 H 和 W 分别表示图像的高度和宽度。

图像通过骨干网络ResNet-50进行初步特征提取,主干网络输出三个不同尺度特征图 f_1 、 f_2 、 f_3 ,分别为4、8和16倍下采样。选择 f_1 作为视觉编码器输入以保证足够语义信息。选择 f_2 、 f_3 两个不同层次特征作为多层次注意力融合深度估计器(MLA-Depth)输入,以保证深度预测兼顾全局与局部关注,其中深度特征输出为 $F_D \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times C}$ 。使用 f_1 、 f_2 、 f_3 作为前景感知模块(AFPM)输入,利用基于U-Net的U形状网络结构,通过上采样和跳跃连接融合浅层和深层特征输出目标区域概率图 F_P ,以指导模型关注前景特征并减少背景干扰。

编码阶段视觉编码器与深度编码器分开,二者独立学习特征,视觉编码器由三个Transformer块组成,每个块包含一个自注意力层和一个前馈神经网络,视觉特征 F_V 通过视觉编码器生成全局视觉嵌入 F_V^e 。深度编码器由一个Transformer块组成,包含一个自注意力层和一个FFN,深度特征 F_D 通过深度编码器生成全局的深度嵌入 F_D^e 。

解码器由对象查询、基于尺度监督的查询优化层、深度交叉注意力层、查询间自注意力层、视觉交叉注意力层和FFN层组成。将初始随机查询输入查询优化层,利用上层特征监督查询优化,输出优化后的多尺度优化查询 $q^{MS} \in \mathbb{R}^{N \times C}$, N 是预定义的最大对象数量。优化后查询 q^{MS} 通过深度交叉注意力层从深度嵌入 F_D^e 中捕获深度特征,输出深度感知查询 q_D ,具体计算过程中增




图2 本文方法整体框架图

Fig.2 Overall framework diagram of proposed method




图3 基于尺度监督的查询优化

Fig.3 Scale-supervised query optimization

强查询 q^{MS} 和 F_D^e 经过线性变换,分别得到查询 Q_D^{MS} 、键 K_D 和值 V_D ,并计算查询与深度特征的注意力分布 A_D ,计算过程如公式(1):

$$A_D = \text{Softmax}\left(\frac{Q_D^{MS} \cdot K_D^T}{\sqrt{C}}\right) \quad (1)$$

其中, C 是通道数,再通过加权求和的方式聚合深度特征得到深度感知查询 q_D 。

深度感知查询通过查询间自注意力层进行对象间的特征交互输出 q_1 。 q_1 通过视觉交叉注意力层从视觉嵌入 F_V^e 中捕获视觉语义信息输出 q_V ,再输入 FFN 层得到 q_F ,最终将 q_F 输入检测头,获得目标物体的对象类别、2D 尺寸、投影的 3D 中心、深度、3D 尺寸和方向属性。

1.2 基于尺度监督的查询优化

为了解决基于 Transformer 的单目 3D 目标检测算法中弱监督查询优化过程缓慢、感受野缺失等问题,本文提出了一种基于尺度监督的查询优化模块。对每个查询首先生成其对应的查询点,并以该点为中心构建多个预设尺度的方形掩码,以提取多尺度局部视觉特征。随后,基于深度特征预测该查询点对各尺度的匹配概率分布,进而对多尺度局部特征进行加权融合。最后将融合特征与原始查询特征相加,得到具备尺度感知能力的优化查询特征。其结构如图 3 所示。

1.2.1 查询点生成

本文提出的基于尺度监督的查询优化模块以 N 个特征查询为输入,记作 $\{q_1, q_2, \dots, q_i, \dots, q_N\}$,其中每个查询 $q_i \in \mathbb{R}^{1 \times C}$ 。为实现每个查询在图像中的空间定位,本设计了空间锚点定位器(spatial anchor locator, SAL),其结构如图 4 所示。SAL 从预定义的图像锚点集合中,为每个查询 q_i 计算其与所有锚点的匹配得分,并选取得分最高的 Top- M 个候选锚点。匹配得分采用查询与锚点特征之间的点积计算,并通过 softmax 函数归一化为权重。这些权重用于加权融合候选锚点的空间

位置,最终生成每个查询对应的唯一空间中心点坐标 (x_i, y_i) 。




图4 空间锚点定位器

Fig.4 Spatial anchor locator

1.2.2 尺度监督

为实现查询特征的尺度监督优化,本文将每个查询特征向量 $q_i \in \mathbb{R}^{1 \times C}$ 与其对应的空间坐标 (x_i, y_i) 进行联合建模,同时输入主干网络提取的视觉特征图 F_V 、深度特征图 F_D ,以及前景区域的概率图 F_P 。首先,通过将前景概率图 F_P 与视觉特征图 F_V 逐元素相乘,得到关注于前景区域的聚焦视觉特征图 $F_{PV} = F_P \odot F_V$ 。随后,以每个查询点 (x_i, y_i) 为中心,预设 K 个不同尺度的方形局部掩码 $M_{(i,j)}$,其中 $M_{(i,j)}$ 表示第 i 个查询对应第 j 个尺度的掩码,其尺寸为 $l_j \times l_j$,尺度集合定义为 $L = \{l_1, l_2, \dots, l_j, \dots, l_K\}$ 。对每个查询 q_i ,使用掩码 $M_{(i,j)}$ 在聚焦特征图 F_{PV} 上提取对应的局部视觉特征 $f_{(i,j)}^V$,计算过程如下:

$$f_{(i,j)}^V = S_V(F_{PV}, M_{(i,j)}) \quad (2)$$

其中, $S_V(\cdot)$ 表示根据掩码从特征图中采样特征的操作,

其本质运算为 $F_{PV} \odot M_{(i,j)}$, 通过点乘运算获取掩码覆盖的特征图区域。为对不同尺度掩码获取的特征进行对齐, 对每个 $f_{(i,j)}^V$ 应用自适应池化和全连接层操作, 将其统一映射到维度为 $R^{1 \times C}$ 的嵌入向量, 记作 $f_{(i,j)}^{V_avg}$ 。最终, 每个查询 q_i 将获得 K 个尺度感知的局部特征嵌入 $\{f_{(i,j)}^{V_avg}\}_{j=1}^K$, 从而有效捕捉其周围区域在不同感受野下的多尺度语义信息, 为后续的尺度选择与特征更新提供基础。

本文方法利用查询点对应的深度特征获取尺度的匹配概率分布。具体实现过程中先利用深度特征采样器 S_V , 根据查询 q_i 的空间坐标 (x_i, y_i) 提取其对应的深度特征向量:

$$f_i^D = S_D(F_D, q_i(x, y)) \quad (3)$$

其中, $f_i^D \in R^{C \times 1}$ 表示第 i 个查询点的深度特征用于表征其对应的空间信息。接下来, 通过两层多层感知机 (MLP) 对 f_i^D 进行非线性变换, 并通过 Softmax 函数将其映射为 K 维的尺度匹配概率分布。

$$\sigma(f_i^D)_K = \left\{ \frac{e^{MLP(f_i^D)_j}}{\sum_{j=1}^K e^{MLP(f_i^D)_j}} \mid k=1, 2, \dots, K \right\} \quad (4)$$

其中, $\sigma(f_i^D)_j$ 表示第 i 个查询点在第 j 个尺度上的匹配概率, 反映了该尺度与当前查询之间的适配程度。Softmax 运算确保各尺度之间形成归一化的竞争关系, 提升尺度分布预测的判别性。

将预测的尺度匹配概率 $\sigma(f_i^D)$ 与对应的多尺度平均视觉特征 $\{f_{(i,j)}^{V_avg}\}_{j=1}^K$ 进行加权求和, 获得融合尺度信息的聚合特征 f_i^{SSD} , 尺寸为 $1 \times R$ 。

$$f_i^{SSD} = \sum_{k=1}^K \sigma(f_i^D)_k \cdot f_{(i,k)}^{V_avg} \quad (5)$$

最后, 将该多尺度聚合特征与原始查询特征 q_i 进行相加, 得到尺度感知优化后的查询特征 q_i^{MS} 。

该模块有效融合了视觉与深度信息, 实现了对查询

的尺度感知增强, 为后续目标预测提供了更精确的语义支撑。

1.3 自适应前景感知模块

基于无额外深度信息的深度预测, 训练过程直接使用 3D 框而不依赖额外深度信息, 模型可能受到背景干扰, 导致特征提取不够精准。基于此, 本方案设计自适应前景感知分支模块 (AFPM), 采用 U-Net 结构预测像素级目标概率, 来增强对前景区域的关注, 结构如图 5 所示。

在具体实现过程中, AFPM 以主干网络提取的 4、8 和 16 倍下采样特征图 f_1 、 f_2 和 f_3 作为输入。

AFPM 将 f_1 作为第一层输入, 先通过一个 3×3 卷积层提取初步特征, 并采用 ReLU 激活函数引入非线性。随后使用最大池化操作进行空间下采样, 得到特征图 f_1' 。接下来, 将下采样特征 f_1' 与主干网络的 8 倍下采样特征图 f_2 相加, 进行多尺度特征融合, 并重复卷积和激活操作, 得到融合特征图 f_2' 。第三层将 f_2' 与 16 倍下采样的特征图 f_3 融合, 并继续执行相同操作, 进一步提取深层语义信息。

在解码阶段, AFPM 通过反卷积逐步恢复空间分辨率, 并利用 U-Net 结构中的跳跃连接, 将编码阶段的浅层特征传递至解码器, 有效提升目标边界的细粒度表达能力。最终, 使用一个 1×1 卷积将通道数从 3 维压缩至 2 维, 随后采用平均池化以对齐与深度预测模块的输出尺寸, 大小为 $\frac{H}{16} \times \frac{W}{16}$ 。最后对二维图像执行 sigmoid 操作, 使概率输出归一化到 $[0, 1]$ 区间。

前景感知模块训练过程, 通过将 3D 边界框投影到图像平面, 在图像上获得目标区域无需深度图或 LiDAR 数据作为监督信号。考虑到前景与背景样本数量严重不平衡, 本文采用 Combo Loss 作为监督损失函数, 该损失由加权的二元交叉熵 (BCE) 与 Dice Loss 组成, 定义如下:

$$L_p = \alpha \cdot L_{BCE} + (1 - \alpha) \cdot L_{Dice} \quad (6)$$

其中, α 是一个超参数, 用于平衡两种损失函数 (BCE 和 Dice) 的权重, 根据文献 [24] 针对前景极少且目标轮廓重要的目标, α 设置为 0.4 可有效提升模型性能。




图5 自适应前景感知模块

Fig.5 Adaptive foreground perception module

1.4 多层次注意力融合深度估计

本文提出的多层次注意力融合深度估计方法不依赖额外的深度信息(如激光点云或深度图),而仅使用离散的3D框标签,其结构如图6所示。

在模型训练过程中,为了引导网络学习精确的深度感知,将三维边界框的中心深度作为监督信号,分配给其对应二维边界框内的像素。对于落入多个边界框的像素点,采用距离相机最近的物体中心深度作为其监督标签,从而确保深度监督的一致性与准确性。

深度估计既依赖于高层特征提供的全局语义上下文(如物体遮挡关系与大尺度深度变化),也需要底层特征中的高分辨率空间信息来保留边缘清晰度和细粒度几何结构。为兼顾这两者,本文选取主干网络中4倍下采样的特征作为低层语义表征,16倍下采样的特征作为高层空间细节,通过融合作用提高深度估计精度。

受空洞空间金字塔池化(ASPP)模块的启发,本方案在高层特征图上应用ASPP模块,为深度预测捕获多尺度上下文信息。同时对ASPP输出运用通道注意力和空间注意力,实现根据不同通道及区域增强对深度估计有用的语义维度,提升估计精度。

在高维低维特征融合过程中,为弥合不同层次特征之间的语义差异,本研究采用矩阵乘法计算低层特征图与高层特征图之间的相关性。具体实施过程中对高层特征 f_{high} 和低层特征 f_{low} 进行二维重塑得到二维矩阵 A 、 B ,尺寸为 $C \times N$,其中 $N=H \times W$ 表示像素数。随后对矩阵 A 和 B 进行矩阵乘法得到相关性矩阵 S ,尺寸为 $N \times N$,并对 S 的每一行应用 Softmax 函数,生成

空间注意力图 S' 。利用该空间注意力图作为加权矩阵与低层特征图相乘获得 A' ,并对结果进行 reshape 操作得到 f'_{low} ,将 f'_{low} 与高层特征图 f_{high} 相加,得到融合不同尺度的特征图 f_D 。

在真实场景中,深度值的分布通常是非线性,即近距离物体的深度值变化较快,而远距离物体的深度值变化较慢。为减少远距离物体的深度估计误差,常用的离散化方法有对数离散化、指数离散化、sigmoid 离散化等,本文采用线性递增离散化(LID)方法来对深度值进行分桶,允许远距离物体的深度值落在更大的区间内,从而降低了对远距离深度值精度的要求。具体实现过程中先对 f_D 进行卷积操作得通道为 m 的特征, m 为深度离散化分区数。

$$m = \lceil -0.5 + 0.5 \sqrt{1 + \frac{8(d - d_{\min})}{\delta}} \rceil \quad (7)$$

其中, $d_{\min}$ 和 $d_{\max}$ 是前景深度的最小值和最大值。 δ 是公差。

$$\delta = \frac{2(d_{\max} - d_{\min})}{m(m+1)} \quad (8)$$

LID的特点是深度分区的长度随着深度增加而线性递增,这样可以有效抑制远距离物体的深度估计误差。对线性递增离散化结果加权求和得到前景深度图 $d_{\text{map}} \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16}}$ 。

深度值本身是低层次的物理量,缺乏位置或空间结构信息可能导致模型难以理解场景的深度分布,本文使用一种深度位置编码如图7所示。

通过将深度值映射到连续的编码空间,以便模型有




图6 多层次注意力引导深度预测器

Fig.6 Multi-level attention-guided depth predictor




图7 深度位置编码器

Fig.7 Depth positional encoder

更好泛化能力。具体实施过程中通过维护一个可学习的嵌入矩阵 $P_D \in \mathbb{R}^{(d_{\text{max}} - d_{\text{min}} + 1) \times C}$ ，每一行表示每米的深度编码，不同深度的像素点可以从该矩阵中获取一个独特的深度编码。对于像素 (x, y) ，其深度估计值 $d_{\text{map}}(x, y)$ 通过置信度加权求和计算得到：

$$d_{\text{map}}(x, y) = \sum_{i=1}^m D_{\text{fig}}(x, y)[i] \cdot d_i^{\text{bin}} \quad (9)$$

其中， $D_{\text{fig}}(x, y)[i]$ 是深度预测的置信度， d_i^{bin} 是该 bin 的深度值。由于 $d_{\text{map}}(x, y)$ 是连续值，而 P_D 只有整数深度的编码，因此通过线性插值获取该深度的编码，计算过程如下：

$$P_D(d_{\text{map}}(x, y)) = w_{\text{low}} \cdot P_D(d_{\text{low}}) + w_{\text{high}} \cdot P_D(d_{\text{high}}) \quad (10)$$

其中， d_{low} 是 $d_{\text{map}}(x, y)$ 的向下取整的最近整数深度， d_{high} 是 $d_{\text{map}}(x, y)$ 的向上取整的最近整数深度。 w_{high} 计算了 $d_{\text{map}}(x, y)$ 在这两个深度值之间的相对位置（即小数部分）。 w_{low} 计算了距离 d_{low} 的归一化权重，保证两个权重相加和为 1。

计算得到的深度位置编码会逐像素加到深度特征图 f_D ，得到增强后的深度特征 F_D ，其既包含了视觉深度特征，又嵌入了 3D 深度位置信息。

1.5 损失计算

由于 Transformer 的查询是无序的，训练时需要将预测查询与真实标签进行匹配。本研究参考文献[15]采用匈牙利算法实现这一过程。具体做法是对每个查询-标签对计算匹配损失，并将六个预测属性划分为两类：2D 属性组 (L_{2D})，包括物体类别、2D 尺寸和投影 3D 中心，主要反映图像中的 2D 外观信息；3D 属性组 (L_{3D})，包括深度、3D 尺寸和方向，用于描述物体的 3D 空间特征。在匹配阶段，仅使用 L_{2D} 作为匹配成本，这是由于相较于 2D 属性，3D 属性在训练初期预测精度较低，直接参与匹配可能引入不稳定因素，影响匹配质量和训练收敛。

完成匹配后，从 N 个查询中筛选出 N_{gt} 个有效匹配对，其中 N_{gt} 表示图像中真实物体的数量。整体损失函数定义为：

$$L_{\text{overall}} = \frac{1}{N_{\text{gt}}} \sum_{n=1}^{N_{\text{gt}}} (L_{2D} + L_{3D}) + L_{\text{dmap}} + L_p \quad (11)$$

2D 属性损失 (L_{2D}) 中类别损失使用 Focal Loss 损失函数，2D 尺寸和投影 3D 中心损失使用 L1 损失函数。3D 属性损失 (L_{3D}) 中深度损失使用离散分类的交叉熵损失函数，如下：

$$L_{\text{depth}} = - \sum_{i=1}^{k+1} y_i \log p_i \quad (12)$$

其中， y_i 为真实深度 bin 的 one-hot 编码， p_i 为预测的深度 bin 概率， $k+1$ 表示深度 bin 总数。3D 属性损失中 3D 尺寸损失使用 L1 损失函数，方向损失遵循基准网络使用多箱分类损失。

前景概率输出损失 L_p 参照 1.3 节使用 Combo Loss 损失。深度图损失 L_{dmap} 使用 Focal Loss，如下公式：

$$L_{\text{dmap}} = -\alpha_t (1 - p_t)^{\gamma} \log p_t \quad (13)$$

其中， p_t 为预测深度 bin 概率，仅对前景区域（有对象覆盖的像素）计算损失，对于落在多个边界框内的像素，选择最近相机的对象的深度标签。

2 实验

2.1 数据集

本文在具有挑战性的 KITTI 数据集上对所提方法进行评估，该数据集包含 7 481 张训练图像和 7 518 张测试图像。由于测试集的真实标注未公开且测试服务器访问受限，本文遵循先前研究，将训练数据划分为训练集（3 712 张图像）和验证集（3 769 张图像），基于该划分进行比对及消融实验。

评估指标方面，KITTI 数据集为自动驾驶场景提供了 3D 检测、鸟瞰图 (BEV) 检测和平均方向相似度 (AOS) 等广泛使用的基准。本文采用 40 个召回位点的平均精度 (AP40) 作为核心指标，在简单、中等和困难三个难度等级下进行多任务评估。实验主要聚焦“汽车”类别（默认 IoU 阈值为 0.7）。

2.2 实验环境与参数设置

测试平台硬件配置，CPU 为 i5-12700，内存为 32 GB，GPU 为 RTX4080 16 GB。软件配置为 Ubuntu20 操作系统，以 Python3.8 编写算法，使用深度学习框架 PyTorch 2.1，CUDA 版本为 12.1，并使用 CuDNN 加速技术。输入图像的分辨率设置为 375×1 245。

训练采用 ResNet50 作为主干网络，并结合 Transformer 进行目标预测。数据增强包括随机翻转、裁剪、缩放和平移，深度估计使用 LID 模式，划分 80 个深度离散区间 (1~60 m)。模型包含 3 层 Transformer 编码器和解码器，使用 Hungarian Matcher 进行目标匹配，并通过多任务损失优化模型。优化器选择 AdamW，初始学习率设置为 0.000 1，采用 Step 学习率衰减，在 125、165 轮衰减至原来的 10%，batch size 设置为 16，训练 250 轮，

每轮保存模型,并在220轮模型进行测试,最终基于Top 50目标进行推理和评估。

在训练阶段,为缓解匈牙利匹配导致的收敛缓慢问题,本研究将50个查询划分为11个组,每组包含4~5个查询,并将每个真实目标分配给同组内多个查询,从而实现一对多匹配。

2.3 对比实验

在KITTI数据集上,对比本文算法与目前主流算法在汽车类别上的3D目标检测性能。结果如表1所示,本文提出的方法在简单、中等、困难这3个级别上 $AP_{3D}(IOU=0.7)$ 精度分别达到了26.32%、18.74%、15.54%,在简单和中等级别上 $AP_{BEV}(IOU=0.7)$ 精度分别达到了34.89%和25.81%,优于目前主流算法。

与基准模型相比在 $AP_{3D}(IOU=0.7)$ 指标的简单、中等、困难级别上提升了2.67、2.82、3.55个百分点,在三个不同难度 $AP_{BEV}(IOU=0.7)$ 指标上领先基准模型2.81、4.37、3.34个百分点。与目前达到SOTA的MonoLSS方法相比,在 $AP_{3D}(IOU=0.7)$ 指标的简单、中等、困难级别上分别领先0.21、0.45个百分点,在BEV指标上与MonoLSS方法相当。

为了系统地对比改进模型与基准模型MonoDETR在KITTI数据集上的检测精度,通过Precision-Recall曲线定量评估模型在简单、中等和困难三个难度等级下的

性能差异。结果如图8所示,实验表明,改进模型(虚线表示)在所有难度等级下均展现出显著的性能提升,其PR曲线具有更大的AUC值,特别是在高召回率区域仍能保持较高的检测精度。




图8 本文模型与基准模型的Precision-Recall曲线对比
Fig.8 Precision-Recall curves:proposed vs. baseline models

单目3D检测模型通常在训练集上表现良好,但因数据分布差异在新场景中性能骤降,且深度估计是最具挑战性的任务。为测试本文模型在跨域泛化性上的表现,设计以下实验。所有模型均在KITTI train上训练,未使用nuScenes数据,对比不同方法在KITTI和nuScenes frontal数据集上近距离(0~20 m)、中距离(20~40 m)和远距离(40~80 m)深度误差。测试结果如表2所示。

由于表2可知,尽管KITTI和nuScenes之间存在数据分布差异,本文方法通过在KITTI数据集上训练的模型在nuScenes frontal Val数据集上仍然取得了最好

表1 KITTI数据集上不同算法的测试结果

Table 1 Test results of different algorithms on KITTI dataset 单位:%

Method	Extra data	$AP_{3D}(IOU=0.7 R_{40})$			$AP_{BEV}(IOU=0.7 R_{40})$		
		Easy	Mod.	Hard	Easy	Mod.	Hard
PatchNet ^[25]	Depth	15.68	11.12	10.17	22.97	16.86	14.97
D4LCN ^[11]	Depth	19.71	12.78	9.80	28.08	17.89	13.44
MonoDTR ^[17]	Lidar	21.99	15.39	12.73	28.59	20.38	17.14
AutoShape ^[26]	CAD	22.47	14.17	11.36	30.66	20.08	15.59
SGM3D ^[27]	Stereo	22.46	14.65	12.97	31.40	21.37	18.43
DID-M3D ^[28]	Depth	24.40	16.29	13.75	32.95	22.76	19.83
CMKD ^[29]	Lidar	25.09	16.98	15.30	33.69	23.10	21.67
MonoPair ^[30]	None	13.07	9.97	8.65	19.28	14.63	12.89
MonoDLE ^[31]	None	17.23	12.26	10.29	24.79	18.89	16.00
MonoDETR ^[15]	None	23.65	15.92	12.99	32.08	21.44	17.85
MonoDDE ^[32]	None	24.93	17.14	15.10	33.58	23.46	20.37
MonoLSS ^[33]	None	26.11	18.29	15.94	34.70	25.36	21.84
Ours	None	26.32	18.74	15.54	34.89	25.81	21.19

表2 跨数据集场景下不同模型的深度估计性能

Table 2 Depth estimation performance of different models in cross-dataset scenarios

Method	KITTI Val				nuScenes frontal Val			
	0~20 m	20~40 m	40~80 m	All	0~20 m	20~40 m	40~80 m	All
MonoRCNN ^[34]	0.46	1.27	2.58	1.13	0.94	2.85	8.72	2.41
MonoDETR ^[15]	0.43	1.13	1.84	0.87	0.78	1.69	6.20	1.41
DEVIANT ^[35]	0.41	1.14	1.87	0.87	0.76	1.60	4.50	1.26
MonoMAE ^[36]	0.36	0.91	1.74	0.86	0.71	1.57	4.95	1.40
Ours	0.35	0.90	1.76	0.84	0.61	2.11	5.38	1.39

的效果,表现出本文方法的高泛化能力。

2.4 消融实验

本文分别引入自适应前景感知模块(AFPM)、多层次注意力融合深度估计(MLA-D)、基于尺度监督的查询优化(SSQ)来提升目标检测精确性,本节通过消融实验分析不同模块对整体效果的影响,选择 $AP_{3D}(IOU = 0.7)$ 作为评价指标。实验结果如表3所示。

表3 KITTI数据集上的消融实验

Table 3 Ablation experiments on KITTI dataset
单位: %

Method	AFPM	MLA-D	SSQ	$AP_{3D}(IOU = 0.7 R_{40})$		
				Easy	Mod.	Hard
a				23.65	15.92	12.99
b	✓			23.87	16.64	13.27
c		✓		24.94	17.22	14.67
d			✓	25.28	17.44	13.16
e	✓	✓		25.76	17.81	14.84
f	✓	✓	✓	26.32	18.74	15.54
g		✓	✓	25.52	17.65	14.91
h	✓		✓	26.41	17.57	14.76

分析表3中数据可得,在基准模型中,单独引入AFPM或MLA-D模块对性能提升有限。单独使用SSQ模块时,在简单和中等难度等级上精度有明显提升,但由于缺乏高质量的深度预测,在困难等级下提升较弱。当AFPM与MLA-D模块联合使用时,模型在深度估计阶段能够更有效地关注前景区域特征,同时抑制背景噪声干扰,进一步提升整体精度。将MLA-D与SSQ模块结合时,在简单和中等难度场景中取得了显著性能提升。

当AFPM、MLA-D、SSQ三个模块联合使用时,模型实现最优性能。其中,尽管AFPM与SSQ模块的组合在简单等级上与三模块联合方案相当,但在中等与困难等级上,深度估计质量不足,导致整体检测效果有所下降。

KITTI数据集中车辆Z轴值的统计分析(图9)表明,目标距离分布呈现显著的长尾特性,表现为近距离样本标注密集而远距离样本稀疏,这种非均匀分布会导致模型在训练过程中对远距离目标的梯度信号不足。

为验证本文方法在跨距离场景下的鲁棒性,在KITTI验证集上对不同深度区间的车辆检测性能进行定量评估,在KITTI验证集上,测试不同深度范围内汽车类别的 $AP_{3D}(IOU = 0.5)$ 和 $AP_{3D}(IOU = 0.7)$ 精度,测试结果如表4。

表4 基线与本文方法在不同距离范围内的 AP_{3D} 性能对比

Table 4 Comparison of AP_{3D} performance across distance ranges for baseline and this methods

Method	$AP_{3D}(IOU = 0.5) / \%$			$AP_{3D}(IOU = 0.7) / \%$		
	5~20 m	20~40 m	40 m~∞	5~20 m	20~40 m	40 m~∞
Baseline	56.16	29.78	15.92	25.49	13.11	6.43
Ours	58.52	32.91	18.27	29.18	16.22	8.65
Improvement/%	+4.19	+10.52	+14.76	+14.48	+23.71	+34.38




图9 KITTI数据集中车辆Z轴值分布

Fig.9 Distribution of car Z-axis values in KITTI dataset

分析表4得,本文提出的方案在不同距离范围内均优于基准模型,在 $IOU = 0.5$ 的评估标准下,该方法在5~20 m(近距离)、20~40 m(中距离)和40 m~∞(远距离)三个距离范围的 AP_{3D} 值分别达到58.52%、32.91%和18.27%。相比 MonoDETR 基线方法提升了4.19%、10.52%和14.76%。在更严格的 $IOU = 0.7$ 评估标准下,性能优势进一步扩大。三个距离段的改进幅度分别达到14.48%、23.71%和34.38%。

本文深度预测器需要将深度值离散化为一组区间(bins),以便模型能够更好地学习和预测深度分布。

为验证不同离散化方法对实验结果的影响,本文设计了三组实验,分别使用Constant离散化方式(所有bin的宽度相同)、sigmoid离散化方式(使用Sigmoid函数调整bin的宽度)、Linear Norm离散化方式(使用线性归一化方法调整bin的宽度),实验结果如表5所示。图10是不同bin离散化方式在距离尺度上的表现。

表5 不同区间离散化方法在车辆类别上的精度对比

Table 5 Comparison of accuracy in car category for different bin discretization methods 单位: %

Method	$AP_{3D}(IOU = 0.7 R_{40})$		
	Easy	Mod.	Hard
Constant	23.16	17.03	14.49
Sigmoid	23.56	17.06	14.55
Linear Norm	26.32	18.74	15.54

由表5可得,使用线性离散化方式,可以更好适应复杂场景中的深度变化,拥有最好的检测精度。

为验证本文提出的查询优化方案中不同部分(前景概率图 F_P 、深度特征 F_D 、视觉特征图 F_V)对整体优化的作用,本文进行了以下实验,分别实验不使用任何优化、仅使用 F_D 、 F_V 进行优化,同时使用 F_P 、 F_D 、 F_V 进



图10 不同bin离散化方式在距离尺度上的表现
Fig.10 Performance of different bin discretization methods across distance scales

行优化。同时三组实验在上层网络中使用 AFPM 和 MLA-Depth 模块,实验结果如表6所示。

表6 SSQM中不同高层语义特征对车辆识别的影响

Table 6 Impact of different high-level semantic features on vehicle recognition in SSQM 单位:%

Method	$AP_{3D}(IOU = 0.7 R_{40})$		
	Easy	Mod.	Hard
NO-SSQM	25.76	17.81	14.84
SSQM; $F_D + F_V$	26.19	18.07	15.22
SSQM; $F_D + F_V + F_P$	26.32	18.74	15.54

根据统计大部分输入查询优化模块的目标像素尺度集中在1到8,为适应这一变化,实验采用不同的尺度组合方案以观察对性能的影响,A方案采用{2,4,6}尺度的掩码;B方案采用{2,4,6,8};C方案采用{1,2,4,6,8};D方案采用{1,2,4,6,8,10}。实验结果如表7所示。

初始采用A方案性能不佳,原因是目标尺度覆盖不足,许多目标未被有效匹配。增加尺度9的掩码后性能显著提升,说明更大尺度能更好匹配部分大目标。针对极小目标进一步引入尺度1,困难目标的检测性能有进一步提高,当继续添加尺度10时,性能下降。推测原

表7 不同尺度设置下的性能变化

Table 7 Performance variations under different scale settings 单位:%

Method	$AP_{3D}(IOU = 0.7 R_{40})$		
	Easy	Mod.	Hard
A	24.81	17.07	14.35
B	26.03	18.46	14.77
C	26.32	18.74	15.54
D	26.05	17.68	14.87

因是这些超大尺度超出多数目标的实际范围,干扰了模型对目标真实尺度的估计。

3 可视化分析

为更直观地对比本文方法与基准模型 MonoDETR 的性能差异,本文在多场景下对相机视角和鸟瞰图(BEV)视角的检测效果进行了可视化分析,如图11所示。图中左侧展示了本文方法的检测结果,右侧则为基准模型的检测效果,其中蓝色边界框标注真实目标,红色边界框表示预测结果。

实验结果表明:在近距离目标检测任务中,本文方法与基准模型的检测性能基本相当;然而在远距离目标检测场景下,本文方法展现出更高的检测精度。特别值得注意的是,如第三个场景所示,本文方法在密集目标检测任务中具有明显优势。但需要指出的是,当前景目标密度较高时,会对远距离目标的检测精度产生显著影响。此外,在近距离目标密集且存在严重遮挡的情况下,本文方法与基准模型对远距离目标的检测性能均表现欠佳。

为展现自适应前景感知模块(AFPM)在深度预测任务中对背景干扰的抑制效果,本文对图2总体网络结构中的深度预测器输出进行单独可视化分析,其输出的深度图分辨率为80×24。



图11 KITTI数据中本文方法与基准模型测试效果对比
Fig.11 Comparison of testing results between proposed method and baseline model on KITTI dataset




图12 KITTI数据中本文方法与基准模型深度预测效果对比

Fig.12 Comparison of depth prediction results between proposed method and baseline model on KITTI dataset

可视化结果如图12所示,其中第三行为本文方法深度预测效果,第四行为基准模型预测效果。结果表明,使用AFPM模块能够有效引导深度预测器聚焦于前景目标,显著降低了无关背景信息对深度预测的干扰,使输出的深度图更符合目标几何分布结构。

4 结语

本文提出的基于尺度监督查询优化的单目3D目标检测方法,通过三个创新模块的系统性设计,在保持纯视觉方案低成本优势的同时,显著提升了检测精度特别是远距离目标的性能。方法在技术实现上巧妙融合了CNN的效率优势和Transformer的全局建模能力,提出的MLA-Depth、AFPM和QSSM模块具有明确的物理意义和工程价值。虽然在某些复杂场景(如高密度遮挡)和理论完备性方面仍存在提升空间,但实验结果表明该方法在主流基准上已达到当前最先进水平,且具有较强的跨域泛化能力。这项工作为不依赖昂贵传感器的3D环境感知提供了实用解决方案,对自动驾驶和机器人导航等应用具有重要价值。未来可通过优化注意力机制、增强小目标检测能力和开发连续深度表示等方法进一步提升性能。

参考文献:

- [1] LANG A H, VORA S, CAESAR H, et al. PointPillars: fast encoders for object detection from point clouds[C]//Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 12689-12697.
- [2] CHEN Y K, LIU J H, ZHANG X Y, et al. VoxelNeXt: fully sparse VoxelNet for 3D object detection and tracking[C]//Proceedings of the 2023 IEEE/CVF Conference on Computer

Vision and Pattern Recognition. Piscataway: IEEE, 2023: 21674-21683.

- [3] SUN H Q, PANG Y W, CAO J L, et al. Transformer-based stereo-aware 3D object detection from binocular images[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(12): 19675-19687.
- [4] CHEN Y L, LIU S, SHEN X Y, et al. DSGN: deep stereo geometry network for 3D object detection[C]//Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 12533-12542.
- [5] GUO E T, CHEN Z F, RAHARDJA S, et al. 3D detection and pose estimation of vehicle in cooperative vehicle infrastructure system[J]. IEEE Sensors Journal, 2021, 21(19): 21759-21771.
- [6] ZHANG Y P, LU J W, ZHOU J. Objects are different: flexible monocular 3D object detection[C]//Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 3288-3297.
- [7] LIU X P, XUE N, WU T F. Learning auxiliary monocular contexts helps monocular 3D object detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022, 36(2): 1810-1818.
- [8] SIMONELLI A, BULO S R, PORZI L, et al. Disentangling monocular 3D object detection[C]//Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2019: 1991-1999.
- [9] MA X Z, LIU S N, XIA Z Y, et al. Rethinking pseudo-LiDAR representation[C]//Proceedings of the 16th European Conference on Computer Vision. Cham: Springer, 2020: 311-327.
- [10] YOU Y R, WANG Y, CHAO W L, et al. Pseudo-LiDAR++: accurate depth for 3D object detection in autonomous driving [EB/OL]. [2025-04-10]. <https://arxiv.org/abs/1906.06310>.
- [11] NG M, HUO Y Q, YI H W, et al. Learning depth-guided convolutions for monocular 3D object detection[C]//Pro-

- ceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2020: 4306-4315.
- [12] WANG L, DU L, YE X Q, et al. Depth-conditioned dynamic message propagation for monocular 3D object detection[C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 454-463.
- [13] QIN Z Y, WANG J L, LU Y. MonoGRNet: a general framework for monocular 3D object detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(9): 5170-5184.
- [14] ZOU Z X, HUANG S S, CAO Y P, et al. GP-recon: online monocular neural 3D reconstruction with geometric prior[J]. IEEE Transactions on Visualization and Computer Graphics, 2025, 31(9): 4790-4804.
- [15] ZHANG R R, QIU H, WANG T, et al. MonoDETR: depth-guided transformer for monocular 3D object detection[C]// Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2024: 9121-9132.
- [16] WANG Y, GUIZILINI V C, ZHANG T Y, et al. DETR3D: 3D object detection from multi-view images via 3D-to-2D queries[C]// Proceedings of the Conference on Robot Learning, 2022: 180-191.
- [17] HUANG K, WU T, SU H, et al. MonoDTR: monocular 3D object detection with depth-aware transformer[C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 4002-4011.
- [18] PU F Q, WANG Y F, DENG J R, et al. MonoDGP: monocular 3D object detection with decoupled-query and geometry-error priors[EB/OL]. [2025-04-10]. <https://arxiv.org/abs/2410.19590>.
- [19] ZHOU Y S, ZHU H Z, LIU Q, et al. MonoATT: online monocular 3D object detection with adaptive token transformer [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 17493-17503.
- [20] WANG Y M, ZHANG X Y, YANG T, et al. Anchor DETR: query design for transformer-based object detection[EB/OL]. [2025-04-10]. <https://arxiv.org/abs/2109.07107>.
- [21] XIA Z F, PAN X R, SONG S J, et al. Vision transformer with deformable attention[C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 4784-4793.
- [22] LIAO P, YANG F, WU D, et al. MonoDETRNext: next-generation accurate and efficient monocular 3D object detector[EB/OL]. [2025-04-10]. <https://arxiv.org/abs/2405.15176>.
- [23] ZHANG N, NEX F, VOSSelman G, et al. Lite-mono: a lightweight CNN and transformer architecture for self-supervised monocular depth estimation[C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 18537-18546.
- [24] TAGHANAKI S A, ZHENG Y F, ZHOU S K, et al. Combo loss: handling input and output imbalance in multi-organ segmentation[J]. Computerized Medical Imaging and Graphics, 2019, 75: 24-33.
- [25] READING C, HARAKEH A, CHAE J L, et al. Categorical depth distribution network for monocular 3D object detection[C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 8551-8560.
- [26] LIU Z D, ZHOU D F, LU F X, et al. AutoShape: real-time shape-aware monocular 3D object detection[C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2022: 15621-15630.
- [27] ZHOU Z Y, DU L, YE X Q, et al. SGM3D: stereo guided monocular 3D object detection[J]. IEEE Robotics and Automation Letters, 2022, 7(4): 10478-10485.
- [28] PENG L, WU X P, YANG Z, et al. DID-M3D: decoupling instance depth for monocular 3D object detection[C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022: 71-88.
- [29] HONG Y, DAI H, DING Y. Cross-modality knowledge distillation network for monocular 3D object detection[C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022: 87-104.
- [30] CHEN Y J, TAI L, SUN K, et al. MonoPair: monocular 3D object detection using pairwise spatial relationships[C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 12090-12099.
- [31] MA X Z, ZHANG Y M, XU D, et al. Delving into localization errors for monocular 3D object detection[C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 4719-4728.
- [32] LI Z L, QU Z, ZHOU Y, et al. Diversity matters: fully exploiting depth clues for reliable monocular 3D object detection [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 2781-2790.
- [33] LI Z J, JIA J R, SHI Y F. MonoLSS: learnable sample selection for monocular 3D detection[C]// Proceedings of the 2024 International Conference on 3D Vision. Piscataway: IEEE, 2024: 1125-1135.
- [34] SHI X P, YE Q, CHEN X Z, et al. Geometry-based distance decomposition for monocular 3D object detection[C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2022: 15152-15161.
- [35] KUMAR A, BRAZIL G, CORONA E, et al. DEVIANT: depth equivariant network for monocular 3D object detection[C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022: 664-683.
- [36] JIANG X Y, JIN S, ZHANG X Q, et al. MonoMAE: enhancing monocular 3D detection through depth-aware masked autoencoders[EB/OL]. [2025-04-15]. <https://arxiv.org/abs/2405.07696>.