

# 基于深度与实例分割融合的单目3D目标检测方法

孙 逊<sup>1</sup>, 冯睿锋<sup>2\*</sup>, 陈彦如<sup>2</sup>

(1. 中铁第四勘察设计院集团有限公司 线路站场设计研究院, 武汉 430063;

2. 西南交通大学 经济管理学院, 成都 610031)

(\* 通信作者电子邮箱 fengruifeng2023@163.com)

**摘要:**针对单目3D目标检测在视角变化引起的物体大小变化以及物体遮挡等情况下效果不佳的问题,提出一种融合深度信息和实例分割掩码的新型单目3D目标检测方法。首先,通过深度-掩码注意力融合(DMAF)模块,将深度信息与实例分割掩码结合,以提供更准确的物体边界;其次,引入动态卷积,并利用DMAF模块得到的融合特征引导动态卷积核的生成,以处理不同尺度的物体;再次,在损失函数中引入2D-3D边界框一致性损失函数,调整预测的3D边界框与对应的2D检测框高度一致,以提高实例分割和3D目标检测任务的效果;最后,通过消融实验验证该方法的有效性,并在KITTI测试集上对该方法进行验证。实验结果表明,与仅使用深度估计图和实例分割掩码的方法相比,在中等难度下对车辆类别检测的平均精度提高了6.36个百分点,且3D目标检测和鸟瞰图目标检测任务的效果均优于D4LCN(Depth-guided Dynamic-Depthwise-Dilated Local Convolutional Network)、M3D-RPN(Monocular 3D Region Proposal Network)等对比方法。

**关键词:**单目3D目标检测;深度学习;动态卷积;实例分割

**中图分类号:**TP391.4 **文献标志码:**A

## Monocular 3D object detection method integrating depth and instance segmentation

SUN Xun<sup>1</sup>, FENG Ruifeng<sup>2\*</sup>, CHEN Yanru<sup>2</sup>

(1. Line Station Design and Research Institute,

China Railway Siyuan Survey and Design Group Company Limited, Wuhan Hubei 430063, China;

2. College of Economics and Management, Southwest Jiaotong University, Chengdu Sichuan 610031, China)

**Abstract:** To address the limitations of monocular 3D object detection, when encountering changing object size due to changing perspective and occlusion, a new monocular 3D object detection method was proposed fusing depth information with instance segmentation masks. Firstly, with the help of the Depth-Mask Attention Fusion (DMAF) module, depth information was combined with instance segmentation masks to provide more accurate object boundaries. Secondly, dynamic convolution was introduced, and the fused features obtained from the DMAF module were used to guide the generation of dynamic convolution kernels for dealing with objects of different scales. Moreover, a 2D-3D bounding box consistency loss function was introduced into loss function, adjusting the predicted 3D bounding box to highly coincide with corresponding 2D detection box, thereby enhancing performance in instance segmentation and 3D object detection tasks. Lastly, the effectiveness of the proposed method was confirmed through ablation studies and validated on the KITTI test set. The results indicate that, compared to methods using only depth estimation maps and instance segmentation masks, the proposed method improves the average accuracy of vehicle detection under medium difficulty by 6.36 percentage points, and it outperforms comparative techniques like D4LCN (Depth-guided Dynamic-Depthwise-Dilated Local Convolutional Network) and M3D-RPN (Monocular 3D Region Proposal Network) in both 3D object detection and aerial view object detection tasks.

**Key words:** monocular 3D object detection; deep learning; dynamic convolution; instance segmentation

## 0 引言

随着自动驾驶和机器人导航技术的发展,三维物体检测已成为机器感知物理环境的关键技术。虽然雷达传感器<sup>[1-3]</sup>和立体相机<sup>[4-5]</sup>可通过获取3D点云信息进行立体深度估计,以提供精确的物体识别和定位,但高成本、稀疏点云和校准等问题限制了它们的广泛应用。相比之下,更具经济性和广

泛应用潜力的单目3D物体检测技术受到了相关行业的持续关注。

大多数基于单目图像的研究依赖先验知识、几何约束和其他辅助信息以提高检测效果。然而,这类方法面临两大主要挑战。首先,由于深度信息的缺失,在特征提取阶段,只能依赖像素强度、纹理等特征进行计算,而无法考虑到物体的

收稿日期:2023-07-21;修回日期:2023-09-26;录用日期:2023-09-28。 基金项目:国家自然科学基金资助项目(62173279)。

**作者简介:**孙逊(1972—)女,湖北武汉人,高级工程师,主要研究方向:场站智能化、物流规划、场站设计; 冯睿锋(1999—),男,四川遂宁人,硕士研究生,主要研究方向:物流系统建模与优化、机器学习; 陈彦如(1974—),女,内蒙古包头人,教授,博士,主要研究方向:物流系统建模与优化、机器学习。

实际距离。这导致在物体和背景没有明显边界或纹理差异的情况下,难以区分物体与背景。例如,在用于汽车识别的二维图像中,如果汽车的部分与背景相似,缺乏深度信息可能会导致滤波器将背景错误识别为汽车。其次,由于透视投影的影响,不同距离的物体在二维图像中会呈现出不同的尺度,而传统的二维卷积核难以同时处理不同尺度的物体,这意味着不同距离的物体可能无法有效地被检测出来。因此,在没有深度信息的帮助下,这类方法的性能往往不能令人满意。

针对这一问题,一些研究已开始探索从预训练的深度估计网络中获取深度图以提高单目3D目标检测的效果。文献[6]中利用深度估计得到的深度图生成伪雷达点云,再利用基于3D点云的方法进行检测。然而,这类方法同样具有局限性:首先,这类方法的检测效果在很大程度上取决于估计的深度图的精度,从单目图像提取的深度图通常比较粗糙,导致三维预测不准确;其次,虽然伪雷达点云捕获了空间信息,但却牺牲了RGB图像的重要语义信息,容易产生误报。尽管文献[6-8]中采用不同的融合策略将深度信息与二维图像信息结合用于单目3D目标检测,但仍然需要依赖高精度的深度估计网络。

基于已有研究的局限性,本文提出了一种新的单目3D目标检测方法。首先,由于二维图像缺少深度信息,因此难以准确判断物体的大小和距离,并且物体的遮挡和重叠可能会导致检测困难。本文设计DMAF(Depth-Mask Attention Fusion)特征融合模块,通过深度估计得到的深度图与实例分割掩码相结合,能够提供更准确的物体边界,有助于确定物体的位置和形状;此外,在二维图像中,物体的形状和尺寸会随着视角的改变而改变,而传统的二维卷积核难以处理不同尺度物体的问题,本文引入了动态卷积,并使用DMAF模块融合深度图与实例分割掩码特征,利用融合特征引导动态卷积核的生成,从而利用深度信息处理不同尺度的物体;为进一步提高性能,本文采用数据增强手段,将输入通道RGB中的红、绿色通道互换,并在损失函数中引入了2D-3D边界框一致性损失,确保实例分割网络和3D目标检测网络的同步训练;最后,本文通过在KITTI数据集的单目3D目标检测任务和鸟瞰图任务上评估了所提出的模块和方法,验证了方法的有效性。

## 1 相关工作

### 1.1 仅使用图像的单目3D目标检测

仅使用图像的单目3D目标检测旨在从单张RGB图像中推导出物体的3D位置和方向。例如,Deep3DBox(3D bounding Box estimation using Deep learning and geometry)<sup>[9]</sup>基于2D检测框拟合3D检测框,通过设计角度回归和尺寸回归损失函数以获取相对稳定的3D属性,并将3D属性与2D检测框的几何约束相结合以生成3D检测框。MonoGRNet(Geometric Reasoning Network for Monocular 3D object localization)<sup>[10]</sup>引入了一个物体方向和尺寸估计的网络,用于预测3D边界框,然后利用生成的3D边界框和2D检测结果进行约束,以进一步优化预测结果。由于以前的研究中的2D检测、语义分割等操作都严重依赖于外部子网络,为了更好地理解3D检测框和对象之间的关系,M3D-RPN

(Monocular 3D Region Proposal Network)<sup>[11]</sup>提出了一种完全独立的端到端的方法,可以同时得到2D检测框和3D检测框,并提出利用深度感知卷积改善3D参数估计。然而,由于缺少深度信息,以上方法检测效果不佳。为此,本文引入深度信息和实例分割掩码的融合,进一步增强检测准确性。

### 1.2 基于深度信息辅助的单目3D目标检测

深度估计在单目3D目标检测中有关键作用,为了获得更准确的单目检测结果,许多论文采取预训练的深度估计网络对单目3D目标检测进行辅助。首先将单目图像通过预训练的深度估计网络(例如MonoDepth(Monocular Depth estimation)<sup>[12]</sup>、DORN(Deep Ordinal Regression Network)<sup>[13]</sup>等)进行处理,生成深度图像。随后,针对深度图像和单目图像的处理,主要存在两类方法。

基于伪雷达点云的方法将深度图像转换为伪雷达点云,然后可以使用基于点云的目标检测网络对点云数据进行处理,以预测3D物体的信息。文献[5]中提出了伪雷达点云的概念,即利用深度估计将单目相机的图像转化为3D点云形式,但网络结构和整体性能都有待改进;MV3D(Multi-View 3D object detection network)<sup>[14]</sup>融合了RGB图像和伪点云数据作为模型的输入,利用这些融合的特征预测物体的类别并返回3D检测框,但是计算过程比较繁琐;AM3D(Accurate Monocular 3D object detection)<sup>[15]</sup>首先获得深度信息和2D物体目标位置的先验信息,然后将二维深度信息映射到三维空间,并以点云数据的形式进行后续处理。

与严重依赖深度估计准确性的基于伪雷达点云的方法不同,基于深度图像的方法使用专门的神经网络融合图像和深度图,生成具有深度感知的特征,以提高检测性能。基于深度图像融合的方法大多利用两个主干网络分别处理RGB图像和深度图像,然后利用特征融合模块将两个主干网络的信息融合,从而获得具有深度感知的图像特征。通过该特征,可以进一步得到比较准确的3D检测框。例如,D4LCN(Depth-guided Dynamic-Depthwise-Dilated Local Convolutional Network)<sup>[8]</sup>提出一种局部卷积网络,使用深度图作为引导,学习图像的局部动态深度分布,以融合图像和深度特征;CaDDN(Categorical Depth Distribution Network)<sup>[16]</sup>学习每个像素的分类深度分布以构建鸟瞰图表示,并从鸟瞰图投影中恢复边界框。然而,上述方法不能完全捕获透视投影和遮挡条件下的物体,且没有机制解决不准确的深度估计所带来的影响。

## 2 本文方法

本文方法的总体框架由3个部分组成:特征提取模块、深度图与实例分割掩码融合模块和动态卷积层,如图1所示。为了充分利用RGB图像的信息、深度图信息以及语义信息,本文将网络主干表示为两个分支网络:第一个分支是RGB图像的特征提取网络,它基于预训练的ResNet-50模型<sup>[17]</sup>的Layer1至Layer4,并进行了调整,以增强其特征提取能力;另一个分支是滤波器生成网络,用于生成动态卷积层的卷积核。这两个分支网络分别以RGB图像、深度图和实例分割掩码融合特征作为输入,然后将特征提取网络的特征图作为2D和3D检测头的输入,以获取检测对象的位置信息,最后采用非极大值抑制(Non-Maximum Suppression,

NMS)和数据转换进行可视化。

## 2.1 网络主干

### 2.1.1 特征提取网络

本文提出的RGB图像特征提取网络在ResNet-50模型的网络结构基础上进行了设计。其中,Layer1至Layer3是直接继承自预训练的Resnet-50模型,而Layer4虽然也是继承自该模型;调整了“conv2”卷积层的膨胀率和填充,以扩大其感受野,更好地捕获上下文信息。

本文方法移除了ResNet-50最后的全连接层和池化层以保留更多的空间位置信息和上下文信息;其次,考虑到感受野对于目标检测的重要性,将网络的步长设置为16,以获得更大的感受野;最后,由于距离不同的物体在二维图像中的尺度会发生较大变化,而传统的二维卷积核难以同时处理不同尺度的物体,在特征提取网络中加入了动态卷积层以缓解这种问题,动态卷积层位于Layer3之后。




图1 基于深度与实例分割融合的单目3D目标检测方法

Fig. 1 Monocular 3D object detection method by fusing depth and instance segmentation

### 2.1.2 深度图生成网络

为了获取输入图像的深度信息,本文直接使用深度估计网络DORN<sup>[13]</sup>作为子网络,这是一种用于单目深度估计任务的深度学习网络。它采用编码器-解码器结构,以从单张RGB图像中推测场景的深度信息。为减轻训练过程的计算负担,本文使用预训练的权重初始化DORN,并且该权重在训练过程中不会被更新,因此,它可以看作是一个离线模块,专门用于提供深度估计。

### 2.1.3 实例分割掩码生成网络

精确实例分割掩码和计算效率对于目标检测任务是至关重要的,考虑到这两点,本文选择Mask R-CNN(Mask Region Convolutional Neural Network)<sup>[18]</sup>作为实例分割掩码生成网络,它在保持计算效率的同时,能够生成较高质量的实例分割掩码。Mask R-CNN是在Faster R-CNN(Faster Region Convolutional Neural Network)<sup>[19]</sup>的基础上发展而来,它增加了一个额外的分支,用于预测图像中每个物体实例的像素级掩码。它的主要组成包括特征提取、区域提议网络(Region Proposal Network, RPN)、感兴趣区域对齐(Region of Interest Align, RoI Align),以及并行的分类、边界框回归和掩码预测分支。

虽然Mask R-CNN的实例分割效果显著,但它依赖大量的带有像素级注释的训练图像,而KITTI数据集<sup>[20]</sup>的实例分割基准只提供了200张这样的图像,远不足以从头训练一个实例分割掩码生成网络。因此,本文采用了一种两阶段的训练策略。首先,在Cityscapes数据集<sup>[21]</sup>上使用3475张训练图像对Mask R-CNN进行预训练,然后再将预训练好的实例分

割模块嵌入本文所提出的单目3D目标检测网络中,一同使用KITTI数据集进行训练,通过这种方式可以让Mask R-CNN更好地适应KITTI数据集的特征,得到更好的实例分割效果。这种策略充分利用了有限的训练数据,也避免了过拟合问题。

## 2.2 深度-掩码注意力融合模块

二维图像在深度信息方面的缺失导致难以准确地判断物体的大小和距离,一种有效的策略是通过深度估计等方法得到预测的深度信息并用于辅助单目3D目标检测。然而,当物体之间存在遮挡或者重叠时,检测难度会进一步增加。同时,一些较小或较远的物体可能会被映射到很小的像素区域或者深度值很大的区域,这可能会导致模型对这些物体的检测性能较差,表现为长尾效应。而实例分割掩码可以在像素级别上区分不同的物体实例,从而提供更准确的物体边界信息,因此,如图2所示,本文采用了一种实例分割掩码与深度图相结合的策略,设计了DMAF特征融合模块,旨在充分利用深度信息和实例分割掩码的优势,不仅可以提供更准确的物体边界,而且可以有助于确定物体的位置和形状。该模块的计算步骤如下:

1)预处理阶段:首先,将实例分割掩码和深度图分别经过一个 $1 \times 1$ 卷积层,在不显著增加计算负担的情况下提取并压缩实例分割掩码和深度图的关键信息;卷积层的输出分别通过整流线性单元(Rectified Linear Unit, ReLU)激活函数,实现非线性变换。




图2 DMAF模块结构

Fig. 2 DMAF module structure

2)融合阶段:经过处理的实例分割掩码和深度图在通道维度上进行拼接,以便在后续步骤中共享特征和信息;随后,通过一个卷积层进行融合,使两种信息能够相互补充,提高特征的丰富性。

3)注意力计算阶段:在完成融合之后,本文使用了卷积块注意力模块(Convolutional Block Attention Module, CBAM)<sup>[22]</sup>计算融合特征的通道和空间注意力。CBAM是一种有效的注意力模块,它可以捕获空间和通道之间的复杂依赖关系,有助于强化重要的特征以及抑制不重要的特征。



CBAM由通道注意力模块和空间注意力模块组成:通道注意力模块用于挖掘通道之间的关系并重新标定通道的重要性;空间注意力模块则挖掘像素之间的关系并对每个位置的重要性进行标定。DMAF特征融合模块通过使用CBAM,可以更聚焦于重要的特征,从而提高特征的代表能力。

4)权重生成和空间降维阶段:在注意力计算之后,首先利用一个 $1 \times 1$ 卷积层配合ReLU激活函数以进一步精炼特征并降维,从而得到多个经过优化的特征图。这一步骤在保持计算效率的同时,可实现更好的非线性表征。其次,使用另一个 $1 \times 1$ 卷积层和Sigmoid激活函数生成每个像素位置的权重。最后,通过空间平均池化减小特征的空间维度,在保持特征精确度的同时降低模型的计算复杂度。

5)全局权重计算和最终特征生成阶段:通过一个全连接层和softmax操作计算全局权重,这些全局权重与之前计算的像素级权重相乘,然后沿通道维度进行加权求和,生成最终的融合特征。

### 2.3 基于深度-掩码融合的动态卷积核

由于单目图像不能直接提供深度信息,在预测3D物体的位置和大小时会面临一些困难,而传统的二维卷积核并不能完全捕捉透视投影和遮挡条件下的对象的上下文信息,在处理视角变化或者对象被遮挡的情况时表现不佳。如图3所示,传统二维卷积核并不会因为输入的图像变化而改变,而是使用同一个固定的卷积核。基于此,本文引入动态卷积<sup>[23]</sup>的概念,利用深度图和实例分割掩码的融合特征生成动态卷积核,能够为不同像素分配特定的卷积核,并为不同通道赋予自适应的感受野。而动态卷积核根据输入图像变化而改变,如图4所示,不同的图片所使用的卷积核也不同,与之前的方法相比,这种方式能够增强对物体尺寸和局部结构的感知能力,提高对透视投影和遮挡条件下的对象上下文信息的处理效果。由于本文使用融合特征引导动态卷积核的生成,因而采用一种简单的方法调整该融合特征体的尺寸大小:首先将该融合特征的尺寸大小转换为 $h_n \cdot w_n$ ;然后将该特征图输入滤波器生成网络中,生成对应每个局部区域的卷积核;最后将该卷积核输入动态卷积层,其中 $h_n$ 和 $w_n$ 为第 $n$ 层特征图的高度和宽度。



图3 传统二维卷积核( $K=n$ )

Fig. 3 Traditional 2D convolution kernel ( $K=n$ )



图4 动态卷积核

Fig. 4 Dynamic convolution kernel

如图5所示,滤波器生成网络的主干网络同样使用了ResNet-50的前三层进行计算,这与特征提取网络的前三层相同,并且每个块的通道数也相同,通过这种结构的重用,有效地降低了计算成本;然后,将滤波器生成网络得到的动态卷积核输入动态卷积层中,使特征提取网络的前三层得到的特征图与动态卷积层处理得到的特征图进行逐元素乘积的操作;最后,将结果作为特征提取网络最后一层Layer4的

输入。




图5 滤波器生成网络

Fig. 5 Filter generation network

### 2.4 三维边界框预测

本文采用基于先验信息的2D-3D锚框的单阶段检测器<sup>[24]</sup>作为基础目标检测器,用于定义目标在图像中的位置和尺度;然后将特征提取网络输出的特征图作为目标检测器的输入以预测2D和3D框的坐标值,输出2D-3D边界框的锚点变换;最后通过非极大值抑制NMS和数据转换完成2D和3D边界框的回归过程。具体细节如下:

#### 2.4.1 输入设置

按照惯例,本文使用经过校准的设置,假设在训练和测试时都可以获取每张图片的相机内参 $\delta \in \mathbf{R}^{3 \times 4}$ ,则三维到二维的投影可以用式(1)表示:

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix}_p \cdot z_{3D} = \delta \cdot \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}_{3D} \quad (1)$$

其中: $[x, y, z]_{3D}$ 表示相机坐标系中的3D中心点的水平位置、高度和深度; $[x, y]_p$ 表示该3D中心点在2D图像坐标系中的投影位置; $z_{3D}$ 表示其真实标签的深度。

#### 2.4.2 真实标签设置

本文使用以下参数定义真实标签框: $[x, y, w, h]_{2D}$ 表示2D边界框,其中, $(x, y)$ 表示2D边界框的中心点, $w$ 和 $h$ 分别表示2D边界框的宽度和高度; $[x, y, z]_{3D}$ 表示相机坐标系中的3D中心点的位置; $[w, h, l]_{3D}$ 表示3D物体的宽度、高度和长度; $\theta_{3D} \in [-\pi, \pi]$ 表示3D空间中的不同中心姿态,即物体在3D空间中的观察角度。同时,本文将投影的3D边界框的最小包围矩形作为真实标签的2D边界框,如图6所示。



图6 真实标签的2D边界框表示

Fig. 6 2D bounding box representation of ground truth labels

#### 2.4.3 输出设置

本文假设锚点的数量为 $n_a$ ,类别的数量为 $n_c$ 。对于输入的每个位置,每个锚盒的输出包含 $35 + n_c$ 个参数: $\{[t_x, t_y, t_w, t_h]_{2D}, [t_x, t_y]_p, [t_z, t_w, t_h, t_l, t_\alpha]_{3D}, T_{corner}^{(m)}, s\}$ ,其中, $[t_x, t_y, t_w, t_h]_{2D}$ 表示预测的2D边界框; $[t_x, t_y]_p$ 表示在2D平面上投影的3D中心点的位置; $[t_z, t_w, t_h, t_l, t_\alpha]_{3D}$ 分别表示预测的深度、3D边界框的形状以及旋转角度; $T_{corner}^{(m)}$ 表示3D边界框的8个角点, $T_{corner}^{(m)} = \{[t_x^{(m)}, t_y^{(m)}]_p, [t_z^{(m)}]_{3D}\}$ ,其中, $m = \{1, 2, \dots, 8\}$ ;s表示每个列表的分类得分。输出的尺寸为 $[h_4, w_4, n_a, 35 + n_c]$ ,其中, $[h_4, w_4]$ 是输入图像的大小。

#### 2.4.4 2D-3D锚点设置

基于以上锚点参数设置,本文使用类似于文献[23]中提出的方法,首先在2D空间中定义了2D-3D锚点,然后利用训

练集中的相应先验知识计算了这些锚点在3D空间中的部分。本文使用两个空间参数定义模板锚点:  $[A_x, A_y, A_w, A_h]_{2D}$ 、 $[A_z, A_w, A_h, A_l, A_\alpha]_{3D}$ , 其中,  $[A_x, A_y, A_w, A_h]_{2D}$  表示2D锚点, 对于每个2D锚点, 均使用与真实标签匹配的3D边界框的统计数据作为其对应的3D锚点  $[A_z, A_w, A_h, A_l, A_\alpha]_{3D}$ 。此外, 在处理  $[t_x, t_y]_{2D}$  与  $[t_x, t_y]_p$  的回归时, 也使用同样的锚盒参数  $[A_x, A_y]_{2D}$ 。使用基于锚点的方法能够学习真实标签的相对值(残差), 大幅降低学习的难度。为了完成整个流程, 本文进一步将网络输出与预定义的锚点相结合, 以获得估计的3D边界框。具体组合方式如下:

$$[x', y']_{2D} = [A_x, A_y]_{2D} + [t_x, t_y]_{2D} * [A_w, A_h]_{2D} \quad (2)$$

$$[x', y']_p = [A_x, A_y]_{2D} + [t_x, t_y]_p * [A_w, A_h]_{2D} \quad (3)$$

$$[x^{(m)}, y^{(m)}]_{2D} = [A_x, A_y]_{2D} + [t_x^{(m)}, t_y^{(m)}]_p * [A_w, A_h]_{2D} \quad (4)$$

$$[w', h']_{2D} = [A_w, A_h]_{2D} * \exp([t_w, t_h]_{2D}) \quad (5)$$

$$[w', h', l']_{3D} = [A_w, A_h, A_l]_{3D} * \exp([t_w, t_h, t_l]_{3D}) \quad (6)$$

$$[z', z^{(m)}, \alpha']_p = [A_z, A_z, A_\alpha] + [t^z, t^z, t_\alpha]_{3D} \quad (7)$$

其中:  $[x', y']_p$  表示预测的3D中心点在2D空间上的投影坐标;  $[z', z^{(m)}, \alpha']_p$  表示预测的3D中心点及其8个角点的深度值和旋转角度。

## 2.5 损失函数的定义

在目标检测任务中, 前景目标点与背景点的数量比例严重不平衡, 并且存在大量与目标无关的背景点。传统的损失函数无法充分挖掘前景目标的重要性。为了解决这个问题, 本文采用了 Focal Loss<sup>[25]</sup> 作为总体损失函数。Focal Loss 能够有效降低训练过程中许多背景点的权重, 使训练更专注于目标物体。总体损失函数由目标分类损失、2D回归损失、3D回归损失、2D-3D角点损失和边框一致性损失组成, 如式(8)所示:

$$L = (1 - s_c)^\gamma (L_{\text{class}} + L_{2D} + L_{3D} + L_{\text{corner}} + L_{\text{bbc}}) \quad (8)$$

其中:  $L_{\text{class}}$ 、 $L_{2D}$ 、 $L_{3D}$ 、 $L_{\text{corner}}$ 、 $L_{\text{bbc}}$  分别代表目标分类损失、2D回归损失、3D回归损失、2D-3D角点损失和边框一致性损失;  $s_c$  ( $c=1, 2, \dots$ ) 是目标的分类得分;  $\gamma$  是调节因子。为了确定最佳的调节因子, 本文分别将  $\gamma$  设置为 0.5、1 和 2, 进行了大量的实验对比。实验结果表明, 当  $\gamma=2$  时, 实验效果最佳, 因此, 本文的调节因子  $\gamma$  被设置为 2, 这有助于调节样本权重下降的速率, 解决目标检测中的类别不平衡问题, 并提升模型对难以分类样本的关注程度。

目标分类使用标准交叉熵损失, 如式(9):

$$L_{\text{class}} = -\log(s_c) \quad (9)$$

对于2D和3D回归, 本文选择简单的 SmoothL1 回归损失函数, 并且为每个特定的损失函数定义式(10)~(12):

$$L_{2D} = \text{SmoothL1}([x', y', w', h']_{2D}, [x, y, w, h]_{2D}) \quad (10)$$

$$L_{3D} = \text{SmoothL1}([w', h', l', z', \alpha']_{3D}, [w, h, l, z, \alpha]_{3D}) + \text{SmoothL1}([x', y']_p, [x, y]_p) \quad (11)$$

$$L_{\text{corner}} = \frac{1}{8} \sum \text{SmoothL1}([x'^{(m)}, y'^{(m)}]_p, [x^{(m)}, y^{(m)}]_p) + \text{SmoothL1}([z'^{(m)}]_{3D}, [z]_{3D}) \quad (12)$$

其中:  $[x^{(m)}, y^{(m)}]_p$  表示3D边界框的8个顶点;  $[z]_{3D}$  是对应的深度。

由于本文使用 Mask R-CNN 生成实例分割掩码, 并依赖

于这些掩码与深度信息的融合进行3D预测。为了使本文模型生成的3D预测边界框能与这些实例分割掩码在2D平面上有更好的一致性, 本文引入边界框一致性损失函数 (Boundary Box Consistency Loss, BBCL)。这实际上建立了一个从 Mask R-CNN 生成的实例分割掩码到最终3D预测的显式约束, 鼓励实例分割掩码能够在2D空间上更好地对应3D预测, 如式(13):

$$L_{\text{bbc}} = \sum_{i \in \{x, y, w, h\}} \text{SmoothL1}(t_i^e - t_i^p) \quad (13)$$

其中:  $t_i^e$  表示的是将3D边界框转换为8个角点表示后, 通过相机投影矩阵将8个角点投影到2D图像平面上, 投影后的8个角点形成一个不规则的2D多边形, 最后计算得到的最小边界矩形的中心点坐标以及宽高; 同理,  $t_i^p$  表示实例分割掩码的最小边界矩形的相关参数。

## 3 实验与结果分析

### 3.1 KITTI数据集

本文选用了公开的 KITTI 数据集进行实验。KITTI 数据集是专为自动驾驶研究设计的大规模数据集, 覆盖了包括2D/3D目标检测、光流计算、路面分割等在内的多种任务, 本文在此基础上重点利用了其中的3D目标检测部分。该数据集提供了7481张训练图像和7518张测试图像。然而, 鉴于测试集标签的缺失, 本文参照 Split1 划分协议<sup>[26]</sup>, 将原有的训练数据集重新划分为3712张图像的训练集和3769张图像的验证集。

### 3.2 实验细节和参数设置

本文方法在 PyTorch 1.11.0 上实现。首先, 将输入图像缩放到 512 像素  $\times$  1760 像素, 并将输入通道 RGB 中的红、绿色通道互换以进行数据增强, 得到处理后的图像分别用于特征提取、深度图生成以及实例分割掩码生成。其中, 特征提取网络的 Layer4 的卷积层的膨胀率和填充调整为 2, 并将步长设置为 1, 下采样层的步长也被设置为 1。生成的深度图和实例分割掩码通过 DMAF 特征提取模块融合后, 输入自适应滤波器获得动态卷积。然后, 特征提取网络的前三层生成的特征图与动态卷积层生成的特征图相应元素相乘, 得到的结果作为特征提取网络最后一层的输入, 并最终输出目标的2D和3D检测框坐标。经过交并比 (Intersection over Union, IoU) 阈值为 0.4 的非极大值抑制后, 输出最终的可视化结果。选择初始学习率设置为 0.01, 随着训练的进行逐渐衰减, 指数参数设置为 0.9。使用随机梯度下降 (Stochastic Gradient Descent, SGD) 优化器, 动量设置为 0.9, 权重衰减设置为 0.0005。将 batch\_size 设置为 8, 训练迭代次数设置为 40000。实验环境如表1所示。

表1 实验配置

Tab. 1 Experimental configuration

| 项目   | 配置或版本                |
|------|----------------------|
| CPU  | Intel Xeon Gold 5320 |
| 内存   | 120 GB               |
| GPU  | A30 $\times$ 2       |
| 系统   | Ubuntu 20.04         |
| CUDA | 11.4                 |

### 3.3 模型训练分析

在进行模型优化的过程中, 损失函数曲线的分析具有重要意义。基于3.2节的实验环境和参数, 本文进行了模型训



练。为了验证添加边框一致性损失函数的效果,分别对添加边框一致性损失函数前后的训练过程中的各项损失函数变化进行了对比,如图7所示。结果表明,随着迭代次数的增加,两者的损失函数均呈现出下降趋势,这意味着模型在逐渐学习从输入数据到输出标签的映射关系。但是,如

图7(b)所示,在加入边框一致性损失函数后,模型的损失函数曲线相对更平稳,并且收敛速度更快。相比之下,没有加入边框一致性损失函数在损失函数曲线上出现了更多的波动,如图7(a)所示。这进一步证明了边框一致性损失函数在提高模型稳定性和减少损失波动方面起到了积极作用。





图7 损失函数变化曲线

Fig. 7 Loss function evolution curves

### 3.4 实验结果分析

在性能评估方面,本文遵循了3种不同难度级别(简单、中等、困难)下的平均精度(Average Precision, AP)作为主要的评价指标,并在评价过程中考虑了最多40个召回位置(Recall Positions, RP)。针对3D目标检测和鸟瞰视图检测的性能评估,本文将IoU阈值设置为0.7,并进行了实验。这两个阈值用于衡量检测结果与真实标签之间的重叠程度。此外,与当前主流研究论文保持一致,本文的关注重点是模型在汽车类别上的检测性能。根据以上设置和评估方法,本文在KITTI数据集上对模型进行了性能测试,给出了相应的实验结果并与Mono3D (Monocular 3D object detection)<sup>[27]</sup>、MF3D (Multi-level Fusion based 3D object detection)<sup>[28]</sup>、MoNoGRNet<sup>[10]</sup>、M3D-RPN<sup>[11]</sup>、SMOKE (Single-stage Monocular 3D Object detection via Keypoint Estimation)<sup>[29]</sup>、MonoDistill (Distillation based Monocular 3D detector)<sup>[30]</sup>、D4LCN<sup>[8]</sup>共7种方法进行对比实验,实验结果如表2所示。

表2 不同方法基于鸟瞰图和3D边界框的

性能比较(IoU $\geq$ 0.7)

单位: %

Tab. 2 Performance comparison of different methods based on aerial view and 3D bounding box (IoU $\geq$ 0.7) unit: %

| 方法                          | AP <sup>3D</sup> |       |       | AP <sup>BEV</sup> |       |       |
|-----------------------------|------------------|-------|-------|-------------------|-------|-------|
|                             | Easy             | Mod   | Hard  | Easy              | Mod   | Hard  |
| Mono3D <sup>[27]</sup>      | 2.53             | 2.31  | 2.31  | 5.22              | 5.19  | 4.13  |
| MF3D <sup>[28]</sup>        | 10.53            | 5.69  | 5.39  | 22.03             | 13.63 | 11.60 |
| MoNoGRNet <sup>[10]</sup>   | 13.88            | 10.19 | 7.62  | 24.97             | 19.44 | 16.30 |
| M3D-RPN <sup>[11]</sup>     | 20.27            | 17.06 | 15.21 | 25.94             | 21.18 | 17.90 |
| D4LCN <sup>[8]</sup>        | 22.32            | 16.20 | 12.30 | 31.53             | 22.58 | 17.87 |
| SMOKE <sup>[29]</sup>       | 14.76            | 12.85 | 11.50 | 19.99             | 15.61 | 15.28 |
| MonoDistill <sup>[30]</sup> | 18.05            | 14.98 | 13.42 | 24.26             | 18.43 | 16.95 |
| 本文方法                        | 24.91            | 21.03 | 17.28 | 33.40             | 25.03 | 19.80 |

由表2可知,本文方法在严格条件下(IoU $\geq$ 0.7),3D目标检测的评价指标AP<sup>3D</sup>及鸟瞰图检测评价指标AP<sup>BEV</sup>在简单(Easy)、中等(Mod)、困难(Hard)3个难度下均超越了M3D-

RPN、D4LCN、SMOKE等方法。与表2中的次优方法作比较,在3D目标检测任务和鸟瞰图检测任务的简单、中等、困难设置下AP<sup>3D</sup>和AP<sup>BEV</sup>分别提升2.59、3.97、2.07个百分点和1.87、2.45、1.90个百分点。同时,从“简单”到“困难”难度级别,尽管所有方法的性能都出现下降,但本文方法的性能下降幅度相对较小。实验结果表明,本文方法在单目3D目标检测任务上取得了较好的检测性能,不仅在不同的难度级别下保持了高精度,而且相较于其他先进方法显示出明显的优势。

### 3.5 消融实验

为了验证本文方法各个部分对模型性能的贡献,在KITTI数据集的Split1验证集中对模型进行了消融实验。基线方法为仅使用深度估计图和实例分割掩码的方法,即未使用本文所提出的动态卷积、DMAF模块和边框一致性损失函数。在最基本的设置中,深度估计图由DORN生成,实例分割掩码使用Mask R-CNN的框架训练生成。

消融实验的结果如表3所示,通过添加由深度图引导生成的动态卷积层、DMAF模块以及边框一致性损失函数,模型的性能得到了明显的提升。在加入边框一致性损失函数后,性能得到了提升,说明引入边框一致性损失不仅能够使训练模型更稳定和收敛速度更快,且能够部分提高模型性能。与此同时,如果仅将深度信息和实例分割掩码简单融合以引导动态卷积生成,对模型的性能影响较小,甚至可能造成性能下降。这很可能是因为简单的融合方式未能充分利用深度信息和实例分割掩码之间的交互关系。相比之下,利用本文提出的DMAF模块,将深度信息和实例分割掩码进行更充分的融合后,模型的性能得到了显著提升。这一结果验证了DMAF模块在整合深度信息和实例分割掩码方面的优越性。最终,通过使用DMAF模块将深度信息和实例分割掩码融合,以引导动态卷积核的生成,并在损失函数中添加边框一致性损失函数,从深度和空间两个维度同时增强了网络的表达能力,从而进一步提升了模型性能。实验结果表明,在3D目标检测任务的简单、中等、困难场景下,本文方法的

平均精度相比基线方法分别提升 6.63、6.36 和 3.90 个百分点。这一结果验证了本文方法的有效性,并展现了它在复杂的 3D 物体检测任务中的潜力。

表 3 消融实验结果(IoU≥0.7) 单位:%  
Tab. 3 Ablation study results (IoU≥0.7) unit:%

| 方法       | AP <sup>3D</sup> |       |       | AP <sup>BEV</sup> |       |       |
|----------|------------------|-------|-------|-------------------|-------|-------|
|          | Easy             | Mod   | Hard  | Easy              | Mod   | Hard  |
| 基线       | 18.28            | 14.67 | 13.38 | 26.38             | 19.88 | 16.27 |
| +①       | 19.41            | 16.49 | 14.41 | 28.12             | 21.30 | 17.54 |
| +①+④     | 22.18            | 16.63 | 15.57 | 28.96             | 23.07 | 17.87 |
| +①+②     | 20.89            | 14.92 | 14.12 | 27.42             | 21.81 | 16.82 |
| +①+②+③   | 22.39            | 17.64 | 15.77 | 29.16             | 23.22 | 18.73 |
| +①+②+③+④ | 24.91            | 21.03 | 17.28 | 33.40             | 25.03 | 19.80 |

注:①表示深度引导生成的动态卷积;②表示实例分割掩码;③表示 DMAF 模块;④表示边框一致性损失函数。



图 8 KITTI数据集可视化结果

Fig. 8 Visualization results on KITTI dataset

## 4 结语

在众多利用深度信息进行 3D 目标检测的方法中,仅仅依靠深度估计常常无法有效识别被遮挡的物体;同样,传统二维卷积也难以有效处理透视投影、视角变化等问题。因此,本文采用了一种融合实例分割掩码与深度信息的策略,使它引导动态卷积核的生成,从而提出了一种新的单目 3D 目标检测方法。实验结果显示,与 7 种单目 3D 检测方法相比,本文方法性能优越。

然而,当前的研究面临的一个主要挑战是 3D 目标检测的数据集难以获取,限制了研究的深入发展。虽然目前的工作主要集中在自动驾驶和机器人导航领域,但在未来的工作中,期望能够积极探索弱监督学习和自监督学习的策略,以减少对标注数据的依赖。这可以通过利用弱标签、无标签数据、自动生成的注释或者自监督的视觉任务信号等方式实现,以提高模型的泛化能力和适应性,从而推动单目 3D 目标检测的进一步发展,使单目 3D 目标检测在更多领域得到应用。

## 参考文献 (References)

[1] MATURANA D, SCHERER S. VoxNet: a 3D convolutional neural

## 3.6 可视化结果分析

为了更全面地评估本文方法的有效性,本文在图 8 中对 KITTI 数据集的某些检测结果进行了可视化,将本文方法的 3D 预测框与基线方法的 3D 预测框绘制在原始的 RGB 图像中,并在不同检测难度的场景中进行了比较。

通过对比图像中的检测结果可以发现,对于距离相对较近且没有遮挡的物体,3 种方法都能够给出相对准确的 3D 边界框。然而,在复杂场景下,特别是当物体的大部分被遮挡或者目标距离较远时,如图 8(c)箭头所指物体,对比方法 M3D-RPN 将它与遮挡物混为一体,影响前一车辆 3D 边界框的准确性,而基线方法甚至未能准确识别出该物体;本文方法能够准确地识别出该物体,并给出较为准确的 3D 边界框。这从侧面验证了本文所提出的 DMAF 模块和动态卷积的有效性,尤其是在处理物体遮挡和深度信息缺失的问题上。

network for real-time object recognition [C]// Proceedings of the 2015 IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway: IEEE, 2015: 922-928.

- [2] QI C R, LIU W, WU C, et al. Frustum PointNets for 3D object detection from RGB-D data [C]// Proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2018: 918-927.
- [3] 周静,胡怡宇,胡成玉,等. 基于点云补全和多分辨Transformer的弱感知目标检测方法[J]. 计算机应用, 2023, 43(7): 2155-2165. (ZHOU J, HU Y Y, HU C Y, et al. Weakly perceived object detection method based on point cloud completion and multi-resolution Transformer [J]. Journal of Computer Applications, 2023, 43(7): 2155-2165.)
- [4] WANG Y, CHAO W-L, GARG D, et al. Pseudo-LiDAR from visual depth estimation: bridging the gap in 3D object detection for autonomous driving [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 8445-8453.
- [5] LI P, CHEN X, SHEN S. Stereo R-CNN based 3D object detection for autonomous driving [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition.

- Piscataway: IEEE, 2019: 7636-7644.
- [6] WENG X, KITANI K. Monocular 3D object detection with pseudo-lidar point cloud [C]// Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision Workshop. Piscataway: IEEE, 2019: 857-866.
  - [7] 王凤随,熊磊,钱亚萍. 联合实例深度的多尺度单目3D目标检测算法[J]. 激光与光电子学进展, 2023, 60(16): 1612002. (WANG F S, XIONG L, QIAN Y P. Multiscale monocular three-dimensional object detection algorithm incorporating instance depth [J]. Laser & Optoelectronics Progress, 2023, 60(16): 1612002.)
  - [8] DING M, HUO Y, YI H, et al. Learning depth-guided convolutions for monocular 3D object detection [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 11669-11678.
  - [9] MOUSAVIAN A, ANGUELOV D, FLYNN J, et al. 3D bounding box estimation using deep learning and geometry [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 5632-5640.
  - [10] QIN Z, WANG J, LU Y. MonoGRNet: a geometric reasoning network for monocular 3D object localization [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 8851-8858.
  - [11] BRAZIL G, LIU X. M3D-RPN: monocular 3D region proposal network for object detection [C]// Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2019: 9286-9295.
  - [12] GODARD C, AODHA O M, FIRMAN M, et al. Digging into self-supervised monocular depth estimation [C]// Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2019: 3827-3837.
  - [13] FU H, GONG M, WANG C, et al. Deep ordinal regression network for monocular depth estimation [C]// Proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2018: 2002-2011.
  - [14] CHEN X, MA H, WAN J, et al. Multi-view 3D object detection network for autonomous driving [C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 6526-6534.
  - [15] SHIRMOHAMMADI Z, NIKOOFARD A, ERSHADI G. AM3D: an accurate crosstalk probability modeling to predict channel delay in 3D ICs [J]. Microelectronics Reliability, 2019, 102: 113379.
  - [16] READING C, HARAKEH A, CHAE J, et al. Categorical depth distribution network for monocular 3D object detection [C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 8551-8560.
  - [17] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.
  - [18] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN [C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2980-2988.
  - [19] GIRSHICK R. Fast R-CNN [C]// Proceedings of the 2015 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015: 1440-1448.
  - [20] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the KITTI vision benchmark suite [C]// Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2012: 3354-3361.
  - [21] CORDTS M, OMRAN M, RAMOS S, et al. The Cityscapes dataset for semantic urban scene understanding [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 3213-3223.
  - [22] WOO S, PARK J, LEE J-Y, et al. CBAM: convolutional block attention module [C]// Proceedings of the 15th European Conference on Computer Vision. Cham: Springer, 2018: 3-19.
  - [23] DE BRABANDERE B, JIA X, TUYTELAARS T, et al. Dynamic filter networks [C]// Proceedings of the 30th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2016: 667-675.
  - [24] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector [C]// Proceedings of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 21-37.
  - [25] LIN T-Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2999-3007.
  - [26] CHEN X, KUNDU K, ZHU Y, et al. 3D object proposals for accurate object class detection [C]// Proceedings of the 28th International Conference on Neural Information Processing Systems. Cambridge: MIT Press, 2015: 424-432.
  - [27] CHEN X, KUNDU K, ZHANG Z, et al. Monocular 3D object detection for autonomous driving [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 2147-2156.
  - [28] XU B, CHEN Z. Multi-level fusion based 3D object detection from monocular images [C]// Proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2018: 2345-2353.
  - [29] LIU Z, WU Z, TÓTH R. Smoke: single-stage monocular 3D object detection via keypoint estimation [C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Piscataway: IEEE, 2020: 4289-4298.
  - [30] CHONG Z, MA X, ZHANG H, et al. MonoDistill: learning spatial features for monocular 3D object detection [EB/OL]. (2022-01-26) [2023-08-29]. <https://arxiv.org/pdf/2201.10830.pdf>.

This work is partially supported by National Natural Science Foundation of China (62173279).

**SUN Xun**, born in 1972, senior engineer. Her research interests include station intelligence, logistics planning, station design.

**FENG Ruifeng**, born in 1999, M. S. candidate. His research interests include logistics system modeling and optimization, machine learning.

**CHEN Yanru**, born in 1974, Ph. D., professor. Her research interests include logistics system modeling and optimization, machine learning.