



南京信息工程大学学报

Journal of Nanjing University of Information Science & Technology

ISSN 1674-7070, CN 32-1801/N

《南京信息工程大学学报》网络首发论文

题目: 时序特征与几何约束辅助的三维目标检测技术及应用
作者: 许德刚, 刘栋梁, 李滨, 李宝森
DOI: 10.13878/j.cnki.jnuist.20250314001
收稿日期: 2025-03-14
网络首发日期: 2025-06-25
引用格式: 许德刚, 刘栋梁, 李滨, 李宝森. 时序特征与几何约束辅助的三维目标检测技术及应用[J/OL]. 南京信息工程大学学报.
<https://doi.org/10.13878/j.cnki.jnuist.20250314001>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

时序特征与几何约束辅助的三维目标检测技术及应用

许德刚^{1,2}, 刘栋梁^{1,2,3}, 李滨^{1,2,3}, 李宝森^{1,2,3}

1 河南工业大学 粮食信息处理与控制教育部重点实验室, 郑州 450001

2 河南工业大学 河南省粮食仓储信息智能感知与决策重点实验室, 郑州 450001

3 河南工业大学 信息科学与工程学院, 郑州 450001

摘要：当前主流的单目 3D 目标检测网络采用关键点检测，在时序特征建模、几何约束与深度估计方面存在局限性，限制了 3D 检测器的性能发挥。本文提出一种改进的单目 3D 目标检测算法 MonoTGD(Monocular Temporal Geometric Deep)，引入时序特征交互模块，利用多帧序列的长短期时序信息增强特征表达的一致性和动态建模能力；几何结构增强模块通过扩展关键点集合并引入几何一致性约束提升关键点预测的准确性；伪深度生成与监督模块在不引入激光雷达数据的同时生成的伪深度图为深度估计提供有效的监督信号。上述模块仅在训练阶段使用，推理阶段不引入额外的计算成本。在 KITTI3D 数据集上的实验结果表明，相比基线方法 MonoCon，MonoTGD 在验证集上的 3D 检测平均精度指标中，在简单类别上提高了 4.25 个百分点，而在测试集上，中等难度类别提高了 4.82 个百分点。特别是测试集上中等难度类别的性能提升，充分验证了本方法在实际应用场景中的有效性。

关键词：3D 目标检测；时序特征建模；多关键点约束；深度估计；几何一致性

中图分类号：TP391.4

DOI:10.13878/j.cnki.jnuist.20250314001

收稿日期：2025-03-14

基金项目：河南省重大科技专项(241100210100)；河南工业大学粮食信息处理中心科研平台开放课题(KFJJ2023003)

作者简介：许德刚，男，博士，教授，研究方向为系统工程理论与优化、群智能优化、计算机视觉.degangxu@163.com

李滨（通信作者），男，博士，副教授，研究方向为空间数据库、智能 GIS、GIS 知识工程.lbgis@haut.edu.cn

3D object detection with temporal features and geometric constraints

XU Degang^{1,2} LIU Dongliang^{1,2,3} LI Bin^{1,2,3} LI Baosen^{1,2,3}

1 Key Laboratory of Grain Information Processing and Control, Ministry of Education, Henan University of Technology, Zhengzhou 450001, China

2 Henan Key Laboratory of Grain Storage Information Intelligent Perception and Decision Making, Henan University of Technology, Zhengzhou 450001, China

3 School of Information Science & Engineering, Henan University of Technology, Zhengzhou 450001, China

Abstract: The current mainstream monocular 3D object detection network uses key point detection, which has limitations in temporal feature modeling, geometric constraints and depth estimation, limiting the performance of 3D detectors. This paper proposes an improved monocular 3D object detection algorithm MonoTGD(Monocular Temporal Geometric Deep), which introduces a temporal feature interaction module and uses the long-term and short-term temporal information of multi-frame sequences to enhance the consistency of feature expression and dynamic modeling capabilities; the geometric structure enhancement module improves the accuracy of key point prediction by expanding the key point set and introducing geometric consistency constraints; the pseudo-depth generation and supervision module generates a pseudo-depth map without introducing lidar data, providing an effective supervision signal for depth estimation. All these modules are only used in the training phase, and no additional computational cost is introduced in the inference phase. Experimental results on the KITTI3D dataset show that MonoTGD improves the average precision of 3D detection on the validation set by 4.25 percentage points in the easy category, and by 4.82 percentage points in the moderate difficulty category on the test set. In particular, the performance improvement of the moderate difficulty category on the test set fully verifies the effectiveness of this method in practical application scenarios.

Key words: 3D object detection; temporal feature modeling; multi-keypoint constraints; depth estimation; geometric consistency

0 引言

伴随自动驾驶领域对 3D 目标检测技术需求的增加,相较于双目相机,单目相机作为低成本、结构简单且易于标定的传感器,逐步成为 3D 目标检测任务中的重要部分。单目相机能够通过图像提取物体的中心点坐标、尺寸、朝向等关键信息^[1],在深度学习技术的推动下,单目 3D 目标检测算法得到了广泛关注^[2]。

现有主流的单目 3D 目标检测方法,如 MonoCon^[3]、CenterNet^[4]、MonoDLE^[5]等,普遍采用关键点检测进行目标定位,通过预测关键点的坐标来推导物体的几何属性与空间位置。MonoCon 通过图像特征的提取与建模有效预测目标的三维信息,在精度与效率上优于传统的 Anchor-based 方法。然而, MonoCon 的检测精度仍受到时序特征利用不足、几何结构建模简化及深度估计精度有限等因素的制约,尤其在目标结构几何表征和深度预测方面不够稳定和准确。因此,本文提出一种基于 MonoCon 改进的单目 3D 目标检测算法——MonoTGD。MonoTGD 在 MonoCon 的基础上做了三个主要改进:

- 1) 引入时序特征建模模块,通过多帧图像序列建模增强时序信息的表达能力,提高目标特征一致性与稳定性;
- 2) 提出几何结构增强关键点模块,通过扩展关键点集合并结合几何一致性约束,提升三维结构建模精度和稳定性;
- 3) 设计基于几何规则的伪深度生成与增强监督模块,通过生成伪深度图为深度估计提供稠密的监督信号,提升单目深度估计在数据缺失场景下的鲁棒性。

1 相关工作

1.1 单目 3D 目标检测网络基本框架及问题分析

基于关键点检测范式的单目 3D 目标检测网络通过特征提取、特征融合及多个独立检测分支的层级处理,输出目标位置 (x,y,z) 、尺寸 (w,h,l) 和偏航角 (θ) 的三维检测框。采用 Hourglass^[6]或 DLA^[7]等骨干网络从图像中提取多尺度特征,通过 Neck 层的上采样与聚合机制实现特征融合,并依托多个专用检测分支执行关键点定位、3D 偏移量估计、尺寸预测和偏航角判定等关键任务。

MonoCon 作为该范式的代表性网络,虽能在静态场景中实现目标三维信息预测,但仍面临三个核心挑战:复杂环境和稀疏目标情况下 3D 关键点的定位精度不足,基于中心点的单点表示策略难以全面捕捉目标几何特征;受限于单帧图像固有的深度信息稀疏性及缺乏有效的深度监督与几何约束,深度预测准确性显著受损;尽管引入多检测分支架构,但在处理多尺度目标时的适应性仍有局限。这些问题表明, MonoCon 虽为单目 3D 目标检测奠定了基础,但在关键点定位和深度可靠估计方面存在亟待解决的技术瓶颈。

1.2 单目 3D 目标检测中的时序信息建模

基于单目相机的 3D 目标检测方法虽在 KITTI 数据集上取得了一定成绩,但与基于激光雷达的检测器相比仍存在明显性能差距。这一差距主要源于现有方法过度依赖单帧图像建模范式,未能有效利用图像序列中丰富的时序关联性,导致目标定位和深度估计出现系统性误差,制约了检测精度的进一步提升。

针对这一问题, MonoTGD 在 MonoCon 基础上构建了时序信息建模框架,通过特征交互学习模块整合多帧图像的时序特征,增强目标的空间表达能力并提高跨帧特征一致性。该方法巧妙地引入长短期记忆网络,对多帧图像序列进行时序建模,有效捕捉目标再连续帧间的变化与一致性,确保预测结果具有时序平滑性。同时,设计时序一致性监督信号,对深度、关键点位置和目标方向施加约束,抑制时序特征波动,提升检测精度。多帧图像序列中蕴含的丰富时序信息为目标空间定位和深度估计提供关键依据。因此,如何有效融合多帧图像的时序特征并提升模型性能是一个关键问题。

1.3 单目 3D 目标检测中的关键点几何约束

在单目 3D 目标检测中,关键点几何约束是提升检测精度的关键因素之一。传统基于关键点的检测方法依赖二维图像平面标定来预测目标的三维检测框。通过中心点和关键点的联合优化来表征物体的立体结构。然而,单纯依赖中心投影点进行训练可能导致定位精度不足,影响检测准确率。

MonoCon 通过引入 8 个额外角点作为辅助训练点提高了关键点定位精度,但其角点独立优化机制无法保证整体框架的几何一致性,在某些情形下性能不足。对于几何约束问题, Liu 等^[8]指出,现有检测器未能充分挖掘目标的形状信息,并提出了自动生成包含形状特征的多点标注方法——AutoShape,其检测性能得到提升,但计算复杂度也相应增加。MonoCD^[9]通过融合全局与局部特征,利用关键点间的几何关系进行深度估计补偿,克服了单一关键点特征易受相似性干扰的固有缺陷。3D 目标的几何结构蕴含着丰富的空间信息,单靠 3D 检测框的中心投影点难以全面表征物体的立体形态,而增加关键点数量并结合形状先验能够显著提升定位精度。因此,如何平衡计算效率与表征能力,合理选择关键点的数量和分布并有效建模其几何关联,仍是当前研究的核心问题。

1.4 单目 3D 目标检测中的深度估计

单目 3D 目标检测由于缺少激光雷达或深度传感器数据，导致深度估计精度不足。传统方法依赖激光雷达或深度补全算法获取外部深度信息，但会增加硬件成本和计算复杂度，导致应用场景限制。

为解决这一问题，研究者提出了多种深度估计方法。MonoRCNN^[10]通过几何分解方法优化了中距离物体的深度估计精度，但在远距离物体上仍存在系统性误差；GUPNet^[11]引入几何先验和建模深度估计的不确定性，但未能完全解决距离预测问题；DID-M3D^[12]采用深度解耦策略提升了估计精度；MonoFlex^[13]运用几何投影模型构建深度先验进一步提高精度，但计算开销较大；MonoRCNN++^[14]则通过不确定性感知回归损失替代传统 L1 损失，优化了物体位置、尺寸与投影中心预测，进而提升了深度估计的准确性。此外，MonoDETR^[15]和 MonoDTR^[16]基于 DETR 框架整合深度编码器与特征增强模块提升深度估计能力。BEVDepth^[17]提出的深度细化模块通过结合深度监督信号，缓解了特征与位置不匹配问题；NeRF-Det^[18]借助共享 MLP 和专用深度损失的 NeRF 模型优化了深度估计性能。尽管这些方法在特定场景下取得了进展，但在远距离物体和复杂场景适应性中，深度估计仍是关键难题，未来研究应聚焦于如何通过纯几何推导生成更精确的深度估计，减少对外部数据的依赖，提升整体检测性能。

2 本文方法

本文提出一种基于 MonoCon 改进的单目三维目标检测算法——MonoTGD。MonoTGD 在设计中引入特征交互学习模块、几何结构增强关键点模块和伪深度生成与增强监督模块，从时序特征的动态建模、三维几何信息的完整性和深度估计的监督信号三方面提升网络性能。

2.1 MonoTGD 网络总体框架

MonoCon 作为一种高效的单目 3D 目标检测网络，其性能已在多种场景中得到验证。本文在其基础上提出了 MonoTGD 网络框架。通过引入时序特征建模、几何信息优化与深度伪监督三大核心模块提升检测性能。图 1 展示了 MonoTGD 的总体框架。网络以 KITTI 数据集单目图像作为输入，经由 DLA34 骨干网络提取四层多尺度特征图，随后通过特征金字塔网络融合生成统一特征表示。

融合特征图输入到多个独立检测头中，这些独立检测头按照功能被划分到 3D 检测分支、2D 检测分支、特征交互分支、几何结构增强分支、深度辅助估计分支。前两个分支为 MonoCon 现有分支，后三个分支为 MonoTGD 新增分支。

特征交互分支引入时序信息增强目标特征表达能力后，基于融合后的特征图开展预测，这一模块中的检测头与 2D 检测分支和 3D 检测分支的检测头完全相同，均采用“卷积-ReLU-卷积”的设计方式；几何结构增强分支通过扩展关键点和几何一致性约束优化三维结构建模；深度辅助估计分支中，设计了表面深度估计头和偏移深度估计头来预测目标的表面深度和中心点偏移值。这些估计头采用“卷积-ReLU-卷积”的设计，通过 ROI-Align 对检测框中的目标区域特征进行对齐。伪深度图作为深度估计的真值，通过 LiDAR-Free 解耦深度估计算法生成。伪深度生成与增强监督生成伪深度图，为深度估计提供监督信号。




图 1 基于单目图像的 3D 目标检测网络 MonoTGD

Fig.1 MonoTGD, a 3D object detection network based on monocular images

在训练阶段，图 1 中所有独立检测头均参与训练，而在测试推理阶段，特征交互分支、几何结构增强分支、深度辅助估计分支对应的特征交互学习模块、几何结构增强关键点模块、几何辅助深度模块并不需要参与，因此，在推理阶段能够保持高效推理性能，充分利用训练阶段的增强特征和监督信号。

2.2 特征交互学习模块

主流的 3D 目标检测器将检测框的预测任务分解为关键点预测、尺寸估计和方向推断。传统方法基于单帧特征进行建模，忽略了目标在多帧输入下的特征一致性和信息关联性。本文提出特征交互学习模块，其整体架构如图 2 所示。该模块通过整合时序特征与多帧图像序列中的空间特征，提升目标特征的表达能力和检测精度。通过利用多帧图像序列输入，引入长短期记忆网络(LSTM)对序列化的多帧特征进行建模，捕获特征在时间维度上的一致性与时序变化。为了充分约束特征的时序一致性，本文设计了时序一致性监督信号。在训练过程中对多帧特征的深度、关键点位置和方向估计进行约束，确保预测结果在时间维度上的平滑性与一致性。




图 2 特征交互学习模块架构示意

Fig.2 Schematic diagram of the feature interaction learning module architecture

2.2.1 多帧特征提取与时序建模框架

多帧特征提取与时序建模框架是强化目标时序特征表达能力的核心模块。与传统单帧输入特征提取不同，本文结合 DLA 网络作为主干网络提取单帧特征，并通过 LSTM 网络对多帧特征进行序列化建模，捕获多帧之间的特征关联，提高模型目标外观和空间位置的表达能力，从而提高检测精度。

输入的多帧图像序列 $\{I_{t-n}, \dots, I_{t-1}, I_t\}$ 通过 DLA-34 网络提取多尺度空间特征，生成特征金字塔 $\{F_{t-n}, \dots, F_{t-1}, F_t\}$ ， F_t 代表当前帧的特征，这些特征序列随后输入到时序建模模块，并利用轻量化的 LSTM 网络对帧间的特征关联性进行建模。LSTM 的隐状态通过特征间动态变化和历史信息进行更新，从而学习到目标在时间维度上的轨迹特性^[19]。LSTM 网络的建模过程可描述为

$$h_t = \sigma(W_h F_t + U_h h_{t-1} + b_h). \quad (1)$$

其中： h_t 为当前时刻的隐状态； σ 为激活函数； W_h 和 U_h 分别为输入特征和前一时刻隐状态的权重矩阵。为进一步提升模型的时序特征捕获能力，框架引入基于注意力机制的动态加权策略^[20]，计算帧间特征相似性和全局重要性得分，动态调整每帧的特征权重。最终的特征表示是加权后的多帧特征融合结果：

$$F_{\text{final}} = \sum_{t=1}^n \alpha_t \cdot h_t. \quad (2)$$

其中： α_t 是注意力模块分配的帧重要性权重，其计算过程为：

$$\alpha_t = \text{soft max}(e_t) = \frac{\exp(e_t)}{\sum_{j=1}^T \exp(e_j)}, e_t = \mathbf{v}^T \tanh(W_1 h_t + W_2 h_T). \quad (3)$$

其中： $\mathbf{v} \in \mathbf{R}^d$ 和 $W_1, W_2 \in \mathbf{R}^{d \times d}$ 为可学习参数； h_t 表示第 t 帧经过 LSTM 网络处理后的隐状态特征。通过整合空间与时间特征，该框架显著提升了特征表达质量，为后续的 3D 检测任务提供了精准的特征表示。

2.2.2 时序特征一致性约束的监督设计

除了对特征序列进行建模与预测，本文还引入时序特征一致性约束作为辅助监督机制^[21]。该机制通过对连续帧之间的特征变化进行动态约束，缓解时间维度上的误差传播问题。这种约束为各预测分支的训练提供额外的监督信号，在促进多任务学习的协同效果的同时还能增强时序特征的稳定性和准确性，提高模型整体表现和预测可靠性。

针对相邻帧间的关键点位置 (x_t, y_t, z_t) 和 $(x_{t+1}, y_{t+1}, z_{t+1})$ ，定义平滑性损失函数，用以限制相邻帧关键点位置变化的剧烈程度：

$$L_{\text{smooth}} = \frac{1}{N} \sum_{i=1}^N \left\| (x_{t+1}^i - x_t^i)^2 + (y_{t+1}^i - y_t^i)^2 + (z_{t+1}^i - z_t^i)^2 \right\|. \quad (4)$$

其中: (x_t, y_t, z_t) 和 $(x_{t+1}, y_{t+1}, z_{t+1})$ 表示相邻帧间的关键点三维坐标。此外, 为了抑制深度预测结果的不连续性, 本文引入深度差分约束, 来限制相邻帧深度预测值的波动:

$$L_{\text{depth}} = \frac{1}{N} \sum_{i=1}^N (d_{t+1}^i - d_t^i)^2. \quad (5)$$

其中: $d_t \in \mathbf{R}^{H \times W}$ 表示第 t 帧的深度预测值。在目标方向预测方面, 本文设计了方向连续性约束, 通过限制相邻帧方向估计的变化范围, 优化目标方向预测的稳定性。

模型通过时序特征一致性约束的监督机制, 在多帧场景下的特征学习能力得到提升, 减少了预测结果的不稳定性, 为 3D 目标检测任务提供了可靠的支持。

2.3 几何结构增强关键点建模模块

传统单目 3D 目标检测方法通常通过预测目标的中心点、三维尺寸和朝向来完成检测任务^[22], 但在实际场景中, 受二维图像平面与三维空间特性映射关系影响, 预测结果不稳定且一致性较差。本文提出的几何结构增强关键点模块通过扩展关键点描述范围、引入几何一致性关系约束, 并结合基于高斯热力图的监督机制来强化关键点预测的精度, 提升模型在三维目标检测任务中的几何结构表达能力。

2.3.1 关键点扩展与几何描述

在传统单目 3D 目标检测任务中, 关键点的选择通常仅限于 3D 检测框的 8 个角点, 无法全面描述目标的几何形状。结合图 3 可以看到, 本文通过在原有 8 个角点的基础上, 引入 3D 检测框上下表面的中心点, 此外, 还引入上下表面边的中心点, 扩展关键点的几何表达能力。这些新增关键点的几何位置可以通过已有角点的计算关系推导。上下表面的中心点是通过分别计算顶面和底面 4 个角点的中心坐标得到, 其公式如下:

$$P_{\text{center_top}} = \frac{1}{4} \sum_{i=1}^4 P_i, P_{\text{center_bottom}} = \frac{1}{4} \sum_{i=5}^8 P_i. \quad (6)$$

其中: P_i 表示每个角点的三维坐标。而上下表面边的中心点则可以通过相邻角点的中点计算得到, 其表达式为

$$P_{\text{edge_center}} = \frac{1}{2} (P_i + P_j). \quad (7)$$

其中: P_i 和 P_j 为相邻的 2 个交点的三维坐标。这些新增关键点的引入通过与原有角点的几何关系, 加强了 3D 检测框的空间约束。如图 3 所示, 这些关键点的扩展使得模型在学习目标几何结构时具有更全面的描述能力。




图 3 3D 检测框关键点扩展

Fig.3 3D detection box key point expansion

此外, 本文利用这些新增关键点在二维图像平面上的投影点, 作为辅助监督信号, 与传统角点的投影点共同作用于关键点预测分支, 帮助模型更好地学习到 3D 目标的几何结构及其在图像平面上的映射。

2.3.2 几何一致性关系约束与优化

为了进一步提升模型对目标几何结构的理解能力, 本文在关键点扩展的基础上, 提出了几何一致性关系约束与优化机制。通过几何一致性关系约束, 使关键点的预测结果更符合目标的实际空间结构。这些约束包括相邻角点之间的距离、上下表面中心点与角点的对称性, 以及上下表面边中心点的中点一致性约束。这些约束通过构造基于欧几里得距离^[23]的损失函数进行优化, 相邻关键点 P_i 和 P_j 的几何一致性约束可以表示为:

$$L_{\text{distance}} = \frac{1}{N} \sum_{i=1}^N \|P_m - P_n^*\|^2. \quad (8)$$

其中： P_m 和 P_n 分别为模型预测的关键点位置和几何约束的理想位置。针对上下表面中心点和边中心点的对称性，引入对称性损失函数确保新增关键点的位置符合几何结构的对称性原则，在引入几何一致性约束后，模型在复杂场景中的 3D 检测框形状更加精确，预测结果的几何结构表达能力和稳定性也得到了提升。

2.3.3 基于高斯热力图的关键点监督

在进一步提升关键点预测精度和稳定性的需求下，引入基于高斯热力图的监督机制，实现对关键点投影点更精确的指导。将关键点的预测与特定的高斯分布联系起来，强化关键点的区域响应，提升关键点定位的精度。具体来说，在关键点投影点处生成高斯热力图作为监督信号，其生成过程通过如下公式实现：

$$G(x, y) = \exp\left(-\frac{(x - x_b)^2 + (y - y_b)^2}{2\sigma_b^2}\right). \quad (9)$$

其中： (x_b, y_b) 为关键点在特征图上的坐标； σ_b 表示与目标大小相关的自适应标准差。高斯热力图为关键点预测任务提供了平滑且连续的目标区域指导，减少了预测过程中对单一像素点的依赖。图 4 可视化了热力图与 RGB 图像叠加的结果。




图 4 10 个关键点热力图

Fig.4 Heatmap of 10 key points

若多个热力图之间存在重叠，则在重叠区域内取最大值以确保预测结果的唯一性。在对关键点投影点的热力图进行预处理后，采用 Gaussian Focal Loss 进行优化，其具体计算公式如下：

$$L_{\text{focal}}(H, H^*) = \begin{cases} -\frac{1}{N} \sum (1 - H_{xy})^\gamma \lg(H_{xy}), & H_{xy}^* = 1; \\ -\frac{1}{N} \sum (1 - H_{xy}^*)^\beta H_{xy}^\gamma \lg(1 - H_{xy}), & \text{otherwise.} \end{cases} \quad (10)$$

其中： H 与 H^* 分别表示模型预测的热力图以及真实的热力图； N 表示真实物体的个数； γ 与 β 则是超参，通常分别设置为 2.0 和 4.0。该损失函数通过对关键点预测的正负样本进行加权，可以缓解正负样本比例失衡对训练造成的影响，并增强模型对关键点定位的关注。结合高斯热力图和 Gaussian Focal Loss 的关键点监督机制^[24]，提升了关键点投影点的精确性。与几何一致性约束机制共同作用后，模型在关键点预测的精度和整体几何表达能力上有所提升，为复杂场景下的单目三维目标检测提供了更为可靠的技术支撑。

2.4 伪深度生成与增强监督模块

在单目 3D 目标检测任务中，深度信息的缺失与不完整会影响检测性能。现有方法依赖于激光雷达数据或深度补全算法生成深度图^[25]，但这种依赖会增加硬件与计算的复杂性，限制模型的适用范围。本文提出一种伪深度生成与增强监督模块，通过结合几何规则推导与深度联合监督策略，在不依赖外部深度数据的情况下生成伪深度图，为模型提供丰富的监督信号，提升模型的深度估计能力和整体检测性能。

2.4.1 几何规则约束下的伪深度图生成方法

本文设计了一种基于几何规则的伪深度图生成方法，通过目标 3D 检测框标注信息推导生成目标的表面深度和偏移深度，如图 5 所示。。首先，基于已知的 3D 检测框标注信息，计算其上表面或下表面 4 个顶点的三维坐标，移除高度信息后投影到二维 BEV 平面构建空间几何关系。接着，结合相机成像的视场约束，确定目标在可视范围内的边界角点。




图 5 伪深度图生成示例

Fig.5 Example of pseudo-depth map generation

具体而言，可视区域左右两端角点坐标由相机成像边界确定，其余可视顶点则通过线性几何关系推导得到，其表面深度的计算公式为

$$z = \frac{(z_2 - z_1)x + (z_2x_1 - z_1x_2)}{x_2 - x_1} \quad (11)$$

其中：\$(x_1, z_1)\$和\$(x_2, z_2)\$为相邻顶点的二维坐标；\$z\$ 为计算得到的表面深度。在获得所有可视点的深度后，根据采样密度沿物体表面均匀生成三维点并计算其深度值。最终，将这些三维点投影到二维图像平面内，生成目标伪深度图。

2.4.2 表面深度与偏移深度联合监督策略

为了优化伪深度图的精度和监督效果，本文提出表面深度与偏移深度的联合监督策略，如图 6 所示。伪深度图生成阶段提供了训练监督信号，还通过深度估计分支反馈到整体网络。表面深度通过几何规则直接推导，描述了目标在当前可视范围内的深度分布；偏移深度反映了目标 3D 检测框中心点与表面深度之间的距离。




图 6 表面深度和偏移深度的联合监督策略

Fig.6 Joint supervision strategy for surface depth and offset depth

表面深度的监督通过伪深度图进行优化，而偏移深度的监督通过中心点与表面深度差值的约束进行建模，两者的联合损失表达为

$$L_{\text{depth}} = \lambda_1 L_{\text{surface}} + \lambda_2 L_{\text{offset}} \quad (12)$$

其中：\$L_{\text{surface}}\$ 表示表面深度的预测误差；\$L_{\text{offset}}\$ 表示偏移深度的预测误差；\$\lambda_1\$ 和 \$\lambda_2\$ 为权重参数。联合监督策略的引入使得模型在学习目标深度信息时，能够全面地捕捉目标的几何特性，提升深度预测的稳定性和准确性。

3 实验分析比较

3.1 数据集及实验设置

本文实验使用了 KITTI3D 数据集，该数据集包含 14999 张 3D 目标检测双目图像，针对单目 3D 目标检测任务，仅

使用左图作为模型的输入。训练数据包含 7481 张带标注的图像，测试集包含 7518 张未公开标注的图像。为了保证实验结果的公平性，将 7481 张训练数据分割为 3712 张训练集和 3769 张验证集。

在实验过程中,所有消融实验采用相同的超参数设置。选择 Nadam 优化器^[26],学习率初始值设置为 0.001,衰减系数 β_1 和 β_2 分别设置为 0.9 和 0.999,防止除零错误的小常数为 1×10^{-8} 。在训练过程中,学习率会随着训练轮次的变化逐步调整:前 50 轮使用学习率 0.001,第 51 至 150 轮使用 0.0001,第 151 至 200 轮使用 0.00001。训练批量大小设置为 16,总共训练 200 轮。在每 10 轮保存一次模型,并展示所有中间模型的最佳性能结果。数据增强方面^[27],所有输入图像统一缩放到 1280×384 的分辨率,同时应用随机翻转和随机裁剪作为训练过程中使用的增强策略。

KITTI3D 数据集的 3D 检测任务根据目标遮挡程度以及最大 box 重叠比例分为 Easy（简单目标）、Mod（一般目标）、Hard（困难目标）三类，评价指标包括 3D AP、BEV AP 以及 AOS，分别表示 3D 检测框的识别准确率、BEV 视图下的检测框准确率和目标旋转角度的准确率。所有指标均以数值越高表示性能越好。

实验环境配置如下：CPU 为 Intel Xeon Gold 6248，主频为 2.50 GHz；GPU 为 NVIDIA A6000，内存为 512 GB；操作系统为 Ubuntu 18.04；训练框架为 Pytorch 2.4.0+cu117。

3.2 MonoTGD 与基线模型的性能对比

基于 KITTI3D 验证集开展 MonoTGD 与基线模型 MonoCon 的性能对比实验，表 1 结果展示出了 MonoTGD 在目标检测精度与计算效率上的优势。实验结果表明，MonoTGD 相较于 MonoCon 在 3D AP 和 BEV AP 上分别提升了 4.25、2.63、2.18 个百分点和 3.92、1.98、1.75 个百分点，展现其在精度方面的显著提升。此结果验证了 MonoTGD 在多帧时序信息建模、几何结构优化以及伪深度生成等方面的设计创新，在处理复杂目标检测任务时能够提供更准确的定位和深度估计。

在推理时间方面，MonoTGD 为 24ms，优于 MonoCon。尽管 MonoTGD 参数量略高于 MonoCon，但其性能优势明显超过了额外参数带来的计算成本。具体来说，MonoTGD 结合了时序特征建模与几何结构增强等模块，在保证检测精度的同时，避免了计算资源的过度消耗，使其在需要快速响应的实时任务中表现得更加高效。

表 1 结果表明, MonoTGD 在精度和效率方面取得了平衡, 既提升了目标检测精度, 又保持了合理的推理速度, 能够满足实时检测应用的需求。这一优化使 MonoTGD 在各类实际应用场景中展现出竞争力。

表 1 MonoTGD 与基线模型的性能对比

Module (IoU@0.7)	3D AP↑			BEV AP↑			AOS↑			推理时 间/ms	参 数 量/10 ⁶
	Easy	Mod	Hard	Easy	Mod	Hard	Easy	Mod	Hard		
MonoCon	22.46	16.24	13.14	30.94	21.32	21.54	91.63	81.04	70.84	26	19.64
MonoTGD	26.71	18.87	15.32	34.86	23.30	23.29	93.92	83.90	73.14	24	20.74

3.3 3D 检测框关键点辅助学习模块实验

本文首先基于 KITTI3D 验证集开展了消融实验，验证了上下表面边的中心点和上下表面中心点辅助学习模块的有效性。实验结果表 2 所示，本文设计的关键点辅助学习模块稳定提升了 MonoTGD 单目 3D 检测器的性能。引入中心投影点后，3D AP 指标的 3 类目标相较于复现数据分别提升 2.64、1.56、1.96 个百分点，证明了关键点预测任务的有效性。

但仅仅引入中心投影点性能提升有限。实验发现其原因在于该训练分支的损失较大，导致该模块难以收敛。实际上，性能提升主要来源于上下表面关键点的精确预测，尤其是上下表面中心点的加入，提供了丰富的几何信息，可以提升 3D 框的稳定性和定位精度。为了验证模块是否学习充分，将这两个分支与特征融合模块和伪深度生成与增强监督模块联合训练。表 2 中显示联合训练这两个子任务后的 MonoTGD 性能进一步提升。此外，引入上下表面中心点后，优化了预测框的几何结构，使得模型更适应立方体目标，相较于联合训练后的 MonoTGD，3D AP 指标在各难度下均有提升。表 2 结果表明，通过引入更多的几何约束，使得 MonoTGD 能够在更全面的关键点指导下提升 3D 目标检测的精度。同时，MonoTGD 在引入额外功能模块的情况下仍保持良好的计算效率。尽管参数量略有增加，但推理时间实际有所减少，验证了本文优化设计的有效性。这一结果表明 MonoTGD 模型能够在提升检测精度的同时满足应用需求，实现了精度与效率的良好平衡。

表 2 关键点辅助学习模块在 KITTI3D 验证集上的结果

Module (IoU@0.7)	3D AP↑	BEV AP↑	AOS↑	推理	参数量
------------------	--------	---------	------	----	-----

	Easy	Mod	Hard	Easy	Mod	Hard	Easy	Mod	Hard	时间 /ms	/10 ⁶
MonoCon 论文数据	22.50	16.46	13.95	31.12	22.10	19.00					
MonoCon 复现数据	22.14	17.11	13.97	30.40	22.16	19.08	91.63	81.04	70.84	26	19.78
MonoCon+中心投影点	24.78	18.67	15.93	30.14	24.41	18.88	92.57	82.67	71.65	26	20.56
MonoCon+上下表面边的 中心点和中心投影点	25.91	18.93	16.51	30.53	26.19	19.27	92.96	83.14	72.58	26	20.68
MonoCon+上下表面边的 中心点和中心投影点+上 下表面中心点(本文方法)	26.34	19.65	16.66	33.24	25.26	20.90	93.92	83.90	73.14	24	20.74

3.4 深度估计策略对性能的影响

为了验证本文提出的伪深度生成与增强监督模块的有效性，选择一个具备一定的目标检测能力但未集成深度估计功能的基础模型做对比。通过在 KITTI3D 验证集上的对比实验详细分析其性能变化。

常见的图像特征深度估计方法在复杂场景中准确性受影响，导致 3D 目标检测性能提升有限，训练时偏差大。基于单目深度估计模型调整的方案能够提高一些简单场景的指标，但在复杂场景中误差仍较大。而几何模型的深度估计方法虽提升了部分指标，但对复杂形状和不规则目标的适应性有限。

本文提出的伪深度生成与增强监督模块通过几何规则约束生成目标的表面深度和偏移深度，无需依赖外部深度数据。该模块采用联合监督策略全面捕捉目标的几何特性，在目标几何形状还原和定位精度方面显著提升了 3D 检测器性能。引入联合监督策略后，模型在 3D AP 指标上取得更优表现，深度估计的准确性和稳定性在复杂场景中得到显著提升。与依赖激光点云数据的方法相比，本文的 LiDAR-Free 方案在不增加硬件成本和计算复杂度的情况下表现优越。

由表 3 可知，集成伪深度生成与增强监督模块的模型相比基线模型在 3D AP Hard 的 Mod 指标上提升了 1.06 个百分点，同时保持了与基线基本一致推理时间且未增加额外参数量。

表 3 深度估计的单目 3D 目标检测方法在 KITTI3D 验证集上的结果对比

Table 3 Comparison of monocular 3D object detection methods with depth estimation on KITTI3D validation set

Module (IoU@0.7)	3D AP↑			BEV AP↑			推理时间 /ms	参数/ 10 ⁶
	Easy	Mod	Hard	Easy	Mod	Hard		
MonoGRNet*(AAAI19) ^[28]	13.88	10.19	7.62	24.97	19.44	16.30	60	27.87
MonoPSR†(CVPR19) ^[29]	13.94	12.24	10.77	21.52	18.90	14.94	200	30.21
DID-M3D ^[12]	24.40	16.29	13.75	32.95	22.76	19.83	40	21.76
MonoCon+角点投影点预测+中心投影点与 角点投影点偏移量(基线模型)	22.82	15.76	13.06	30.72	21.39	17.57	26	21.36
MonoCon+LiDAR-Free 深度图(本文方法)	23.88	16.07	14.48	31.38	22.65	19.37	24	20.74

注：KITTI3D 的验证集有 split1、split2 两种划分方式，本表根据原文献标注了各结果采用的划分方式。*：KITTI validation split1；†：KITTI validation split2；本文实验采用 split2。

由表 3 还可以看出，本文方法明显优于除 DID-M3D 之外的所有方法。尽管 DID-M3D 在一些指标上优于本文方法，但其依赖复杂的深度估计和大量计算资源，本文方法的推理时间仅为 DID-M3D 的 60%，显示出本文伪深度生成与增强监督模块的高效性。

事实上，单目 3D 目标检测的难点之一是准确深度估计。本文通过创新的几何规则推导和联合监督策略，在不依赖外部深度数据和复杂计算的情况下，实现了高效准确的深度估计，有力地支持了单目 3D 目标检测性能的提升。

3.5 与其他方法对比

在 KITTI 官方测试集上，本文提出的 MonoTGD 与过去几年的优秀的单目 3D 目标检测算法进行比较。其中，MonoCon 被选为本文的基线方法，同时，MonoDLE、MonoFlex、GUPNet、MonoRCNN、DID-M3D、MonoDETR、MonoCD 等多个标准单目 3D 目标检测器仅使用 KITTI3D 数据集的标注信息，与本文方法类似，并未引入额外的数据源（如 LiDAR、CAD 模型、外部私有数据）。在这些方法中，MonoRCNN++和 MonoRCNN 提出了创新的深度估计方法，而 MonoDETR 和 MonoCD 则是利用几何特征的方法。

表 4 MonoTGD 与其他优秀方法在 KITTI3D 测试集上的结果对比

Table4 Comparison of MonoTGD and other excellent methods on the KITTI3D test set

Module (IoU@0.7)	3D AP↑			BEV AP↑			推理时间 /ms	参数量/ 10 ⁶	是否使用额 外数据
	Easy	Mod	Hard	Easy	Mod	Hard			
MonoDLE(CVPR21) ^[5]	17.23	12.26	10.29	24.79	18.89	16.00	40	20.32	否
GrooMeD-NMS(CVPR21) ^[30]	18.36	12.65	10.03	25.48	18.11	14.10	120	12.09	否
CaDDN(CVPR21) ^[31]	19.17	13.41	11.46	27.94	18.91	17.19	630	20.82	是, LiDAR
MonoRCNN(ICCV21) ^[10]	18.36	12.65	10.03	25.48	18.11	14.10	70		否
MonoFLex(CVPR21) ^[13]	19.94	12.89	12.07	28.23	19.75	16.89	30	20.84	否
GUPNet(ICCV21) ^[11]	22.26	15.02	13.12	30.29	21.19	18.20	34	20.89	否
AutoShape(ICCV21) ^[8]	22.47	14.17	11.36	30.66	20.08	15.95	40	21.35	是, CAD
MonoDTR(CVPR22) ^[16]	21.99	15.39	12.73	28.59	20.38	17.14	37	69.79	是, LiDAR
MonoCon(AAAI22) ^[3]	22.50	16.46	13.95	31.12	22.10	19.00	26	19.64	否
MonoDistill(ICLR22) ^[32]	22.97	16.03	13.60	31.87	22.59	19.72	40	37.68	是, LiDAR
MonoRCNN++(WACV23) ^[14]	20.08	13.72	11.34					67.67	否
MonoDETR(ICCV23) ^[15]	25.00	16.37	13.58	33.60	22.11	18.60	38	21.47	否
MonoAux ^[33]	23.87	16.90	14.09	32.30	23.00	19.84	40	20.76	否
DID-M3D ^[12]	24.40	16.29	13.75	32.95	22.76	19.83	40	21.76	否
MonoCD(CVPR24) ^[9]	25.53	16.59	14.53	33.41	22.81	19.57	36	54.25	否
MonoTGD(本文方法)	26.42	21.28	14.46	31.38	23.31	19.86	24	20.74	否

由表 4 可知, MonoTGD 相比于基线方法 MonoCon, 在 3D AP 的 Mod 指标上提高了 4.82 个百分点。此外, 在与其他方法的比较中, 本文方法也具有较大的优势, 尤其在不依赖外部数据的情况下, 明显优于 MonoDLE、MonoFlex、GUPNet 和 MonoCon 等方法。即便与采用外部数据的算法 (如 CaDDN、AutoShape、MonoDTR) 对比, MonoTGD 仍表现优异。与最新方法 MonoCD (CVPR24) 的比较中也具有一定优势。在这些比较方法中, MonoTGD 在 3D 目标检测最关注的 Mod 类别上精度最优, 在 6 个检测精度指标中有 4 个指标第 1, 推理时间和计算复杂度也满足实时检测的要求, 具有一定的优势。

3.6 3D 目标检测结果可视化比较

为直观展示本文提出的算法的有效性, 图 7a—d 分别展示了基线模型 MonoCon、MonoDLE、DID-M3D 与本文提出的 MonoTGD 在 KITTI3D 验证集上的 3D 目标检测结果对比。图中, 绿色 3D 检测框表示 KITTI 数据集标注结果, 红色框表示检测器的预测结果。通过对比可视化结果, 可以发现 MonoTGD 在多个场景中展现出更高的检测精度, 预测的红色框与实际标注的绿色框更为相近。图 8 为三维 BEV 可视图对比, 图中绿色框和蓝色框分别代表预测结果和标注结果, 从 BEV 视角观察, 检测到的目标距离为 48.78m。



a.MonoCon



b.MonoDLE




c.DID-M3D




d.MonoTGD (本文方法)

图 7 MonoTGD 与 Monocon、MonoDLE、DID-M3D 检测结果对比


Fig.7 Comparison of the detection results of MonoTGD, Monocon, MonoDLE, and DID-M3D



a.MonoCon



b.MonoDLE



c.DID-M3D



d.MonoTGD

图 8 MonoTGD 与 Monocon、MonoDLE、DID-M3D 的三维 BEV 可视化对比

Fig.8 Comparison of 3D BEV visualization between MonoTGD, Monocon, MonoDLE, and DID-M3D

虽然在原始图像上叠加的 3D 检测框和 BEV 视图视觉差异不够明显，但通过对样例的定量分析可以发现实际三维空间中存在明显性能差距，如表 5 所示。

表 5 MonoTGD 与不同方法在远距离目标检测样例中的性能对比

Table 5 Performance comparison of MonoTGD and different methods in long-distance target detection examples				
方法	3D 框 IoU 值↑	BEV 框 IoU 值↑	深度绝对误差/m↓	横向偏移量/m ↓
MonoCon(AAAI22) ^[3]	0.61	0.65	1.07	0.68
MonoDLE(CVPR21) ^[5]	0.58	0.60	1.32	0.85
DID-M3D ^[12]	0.65	0.68	0.84	0.53
MonoTGD(本文)	0.72	0.75	0.52	0.36

由表 5 可知，MonoTGD 在关键指标上都优于对比方法，特别是在深度误差和横向位置误差方面较为明显。根据时序信息建模与几何结构优化，本文方法在较为复杂的场景中有效消除了漏检和误检现象，特别是在远距离目标的检测中，预测框与实际目标的重合度高于其他方法。MonoTGD 能够准确地捕捉远距离目标的位置，实现了更加精准的目标检测。

4 总结

本文提出了一种基于时序特征、几何优化与深度估计的单目 3D 目标检测算法 MonoTGD，提升现有 3D 检测器在深度估计与特征建模方面的性能。设计了三种创新的辅助学习模块，包括特征交互学习模块、几何结构增强模块和伪深度生成模块。分别从时序信息、几何约束优化与深度估计辅助方面提升模型的检测精度。特征交互学习模块通过跨帧特征建模引入时序信息增强目标特征的一致性。几何结构增强模块通过扩展关键点集合并引入几何一致性约束，优化目标三维结构的建模能力。伪深度生成模块则利用几何规则生成的伪深度图，为深度估计任务提供稠密的监督信号，进而提升了深度估计精度。

实验结果验证了 MonoTGD 在图像序列的时序信息和深度估计任务中的有效性。在 KITTI3D 目标检测的关键评价指标上，相比于基线方法 MonoCon，MonoTGD 在验证集的 3D AP Easy 难度类别上提高了 4.25 个百分点，在测试集的 3D AP Mod 上提高了 4.82 个百分点。与近年来会议提出的 MonoRCNN、MonoFlex、GUPNet、DID-M3D 等方法相比，本文方法也展现了显著的性能优势，在不引入激光雷达或外部深度信息的情况下也有不错的性能表现。

尽管如此，本文方法在某些方面仍有待改进。例如：当前采用的 LSTM 时序建模机制在处理长序列数据时存在长期依赖问题，在复杂交通场景中，随着序列长度增加，LSTM 对早期信息的记忆能力减弱，影响其对长时间运动目标的识别精度；伪深度生成模块在光照变化剧烈、遮挡严重等复杂场景下的稳定性仍有提升空间。未来研究将探索基于 Transformer 的时序建模架构，利用其全局自注意力机制和并行计算能力来增强对长序列时序信息的捕获能力；探索半监督和自监督学习策略，减少对标注数据的依赖，提升模型在开放场景的泛化能力；结合多模态特征融合技术，在保持低成本单目识别优势的同时，增强模型对复杂环境的适应能力。

参考文献

References

[1] Li P X, Jin J Y. Time3D: end-to-end joint monocular 3D object detection and tracking for autonomous driving[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 18-24, 2022, New Orleans, LA, USA. IEEE, 2022: 3875-3884

[2] Jiang J J, Li Z Y, Liu X M. Deep learning based monocular depth estimation: a survey[J]. Chinese Journal of Computers, 2022, 45(6): 1276-1307

[3] Gloudemans D, Lu X X, Xia S, et al. Polygon intersection-over-union loss for viewpoint-agnostic monocular 3D vehicle detection[J]. arXiv e-Print, 2023, arXiv:2309.07104

[4] Zhou X Y, Wang D Q, Krähenbühl P. Objects as points[J]. arXiv e-Print, 2019, arXiv:1904.07850

[5] Ma X Z, Zhang Y M, Xu D, et al. Delving into localization errors for monocular 3D object detection[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 20-25, 2021. Nashville, TN, USA. IEEE, 2021: 4719-4728

- [6] Newell A, Yang K Y, Deng J. Stacked hourglass networks for human pose estimation[C]//Computer Vision – ECCV 2016. Cham: Springer, 2016: 483-499
- [7] Yu F, Wang D Q, Shelhamer E, et al. Deep layer aggregation[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. June 18-23, 2018, Salt Lake City, UT, USA. IEEE, 2018: 2403-2412
- [8] Liu Z D, Zhou D F, Lu F X, et al. AutoShape: real-time shape-aware monocular 3D object detection[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). October 10-17, 2021, Montreal, QC, Canada. IEEE, 2021: 15621-15630
- [9] Yan L F, Yan P, Xiong S Z, et al. MonoCD: monocular 3D object detection with complementary depths[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 16-22, 2024, Seattle, WA, USA. IEEE, 2024: 10248-10257
- [10] Shi X P, Ye Q, Chen X Z, et al. Geometry-based distance decomposition for monocular 3D object detection[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). October 10-17, 2021, Montreal, QC, Canada. IEEE, 2021: 15152-15161
- [11] Silberstein M, Kim S, Huh S, et al. GPUUnet[J]. ACM Transactions on Computer Systems, 2016, 34(3): 1-31
- [12] Peng L, Wu X P, Yang Z, et al. DID-M3D: decoupling instance depth for Monocular 3D object detection[C]//Computer Vision – ECCV 2022. Cham: Springer, 2022: 71-88
- [13] Zhang Y P, Lu J W, Zhou J. Objects are different: flexible monocular 3D object detection[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 20-25, 2021, Nashville, TN, USA. IEEE, 2021: 3288-3297
- [14] Shi X P, Chen Z X, Kim T K. Multivariate probabilistic monocular 3D object detection[C]//2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). January 2-7, 2023, Waikoloa, HI, USA. IEEE, 2023: 4270-4279
- [15] Zhang R R, Qiu H, Wang T, et al. MonoDETR: depth-guided transformer for monocular 3D object detection[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). October 1-6, 2023, Paris, France. IEEE, 2023: 9121-9132
- [16] Huang K, Wu T, Su H, et al. MonoDTR: monocular 3D object detection with depth-aware transformer[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 18-24, 2022, New Orleans, LA, USA. IEEE, 2022: 4002-4011
- [17] Li Y H, Ge Z, Yu G Y, et al. BEVDepth: acquisition of reliable depth for multi-view 3D object detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(2): 1477-1485
- [18] Xu C F, Wu B C, Hou J, et al. NeRF-det: learning geometry-aware volumetric representation for multi-view 3D object detection[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). October 1-6, 2023, Paris, France. IEEE, 2023: 23263-23273
- [19] 符广, 刘彦隆, 刘建霞. 基于时序信息的轻量级视频车辆目标检测方法[J]. 电子设计工程, 2024, 32(1): 175-180, 186
FU Guang, LIU Yanlong, LIU Jianxia. The lightweight video vehicle object detection method based on temporal information[J]. Electronic Design Engineering, 2024, 32(1): 175-180, 186
- [20] Wan C X, Si W J, Deng Z A. Research on modulation recognition method of multi-component radar signals based on deep convolution neural network[J]. IET Radar, Sonar & Navigation, 2023, 17(9): 1313-1326
- [21] 岑旭铭. 基于时序信息融合的联合式多目标跟踪算法研究[D]. 沈阳: 沈阳建筑大学, 2024
CEN Xuming. Research on joint multi-target tracking algorithm based on time series information fusion[D]. Shenyang: Shenyang Jianzhu University, 2024
- [22] 张志刚, 游安清. 基于 CPN 网络的车辆关键点检测[J]. 计算机与现代化, 2021(10): 75-80
ZHANG Zhigang, YOU Anqing. Vehicle key point detection based on CPN network[J]. Computer and Modernization, 2021(10): 75-80
- [23] Yuan X R, Huang W, Absil P A, et al. Computing the matrix geometric mean: Riemannian versus euclidean conditioning, implementation techniques, and a Riemannian BFGS method[J]. Numerical Linear Algebra with Applications, 2020, 27(5): e2321
- [24] Nguyen D A, Hoang K N, Nguyen N T, et al. Enhancing indoor robot pedestrian detection using improved PIXOR backbone and Gaussian heatmap regression in 3D LiDAR point clouds[J]. IEEE Access, 2024, 12: 9162-9176
- [25] Sboui N, Hadded M, Ghazzai H, et al. Anomaly detection in autonomous vehicle's lidar sensor data using variational autoencoders[C]//2024 IEEE 100th Vehicular Technology Conference (VTC2024-Fall). October 7-10, 2024, Washington, DC, USA. IEEE, 2024: 1-5

- [26] Alasmari N, Alohal M A, Khalid M, et al. Improved metaheuristics with deep learning based object detector for intelligent control in autonomous vehicles[J]. Computers and Electrical Engineering, 2023, 108: 108718
- [27] 刘镇, 孙振, 孙哲, 等. 非结构化环境下基于占据预测的可通行性分析[J/OL]. 南京信息工程大学学报, 2024: 1–12. (2024–10–23). LIU Zhen, SUN Zhen, SUN Zhe, et al. WildOcc: traversability analysis based on occupancy prediction in unstructured environment[J/OL]. Journal of Nanjing University of Information Science & Technology, 2024: 1–12. (2024–10–23). <https://link.cnki.net/doi/10.13878/j.cnki.jnuist.20240709002>
- [28] Qin Z Y, Wang J L, Lu Y. MonoGRNet: a geometric reasoning network for monocular 3D object localization[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 8851–8858
- [29] Ku J, Pon A D, Waslander S L. Monocular 3D object detection leveraging accurate proposals and shape reconstruction[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 15–20, 2019, Long Beach, CA, USA. IEEE, 2019: 11859–11868
- [30] Kumar A, Brazil G, Liu X M. GrooMeD-NMS: grouped mathematically differentiable NMS for monocular 3D object detection[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 20–25, 2021. Nashville, TN, USA. IEEE, 2021: 8969–8979
- [31] Reading C, Harakeh A, Chae J L, et al. Categorical depth distribution network for monocular 3D object detection[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 20–25, 2021. Nashville, TN, USA. IEEE, 2021: 8551–8560
- [32] Chong Z Y, Ma X Z, Zhang H, et al. MonoDistill: learning spatial features for monocular 3D object detection[J]. arXiv e-Print, 2022, arXiv:2201.10830
- [33] 郑锦, 王森, 李航, 等. 多关键点约束与深度估计辅助的单目 3D 目标检测算法[J]. 计算机学报, 2024, 47(12): 2803–2818
ZHENG Jin, WANG Sen, LI Hang, et al. A monocular 3D object detection algorithm with multi-keypoint constraints and depth estimation assistance[J]. Chinese Journal of Computers, 2024, 47(12): 2803–2818