



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：面向单目三维目标检测的跨尺度特征引导与深度建模
作者：杨帅兵，王雨萌，豆文君，马宗方
网络首发日期：2026-03-20
引用格式：杨帅兵，王雨萌，豆文君，马宗方. 面向单目三维目标检测的跨尺度特征引导与深度建模[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260319.1849.020>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向单目三维目标检测的跨尺度特征引导与深度建模

杨帅兵, 王雨萌⁺, 豆文君, 马宗方

西安建筑科技大学 信息与控制工程学院, 西安 710311

+ 通信作者 E-mail: wangyumeng@xauat.edu.cn

摘要: 单目三维物体检测旨在从单张图像中预测物体在三维空间中的位置、姿态和尺寸,是自动驾驶等视觉任务中的关键挑战。现有基于 Transformer 的端到端方法凭借强大的全局建模能力在目标检测领域取得了显著成果。然而,受骨干网络像素级特征融合策略简单的限制,高层语义特征与低层细节特征难以有效整合,导致对遮挡目标和远距离小目标的检测性能仍不理想。针对这一问题,提出了一种基于改进 MonoDETR 的单目三维目标检测算法。通过引入一种特征聚合金字塔模块,结合双重注意力机制并通过高层引导低层的跨尺度注意力实现多尺度特征的自适应融合,增强了对遮挡目标和远距离小目标的感知能力。此外,引入自适应深度预测模块,采用深度头对多尺度特征进行精炼化处理,并结合增强的三维位置编码嵌入,实现模型更准确的深度信息估计,改进了原模型在深度估计方面的不足。在 KITTI 测试集上的实验结果表明,所提模型在车辆、s 行人和骑行者三类目标的不同难度等级上均取得了优秀性能。以车辆类别为例,在简单、中等和困难难度下分别较基线模型提升了 1.69%、1.77%和 2.56%。

关键词: 单目三维目标检测;多尺度特征融合;深度估计

文献标志码:A 中图分类号:TP391.41 doi: 10.3778/j.issn.1002-8331.2509-0168

Cross-Scale Feature Guidance and Depth Modeling for Monocular 3D Object Detection

YANG Shuaibing, WANG Yumeng⁺, DOU Wenjun, MA Zongfang

College of Information and Control Engineering, Xi'an University of Architecture and Technology, Xian 710311

Abstract: Monocular 3D object detection aims to predict the position, orientation, and size of objects in 3D space from a single image, and is a key challenge in visual tasks such as autonomous driving. Existing Transformer-based end-to-end methods have achieved significant results in object detection due to their powerful global modeling capabilities. However, limited by the simple pixel-level feature fusion strategy of the backbone network, it is difficult to effectively integrate high-level semantic features with low-level detailed features, resulting in unsatisfactory detection performance for occluded objects and small objects at long distances. To address this problem, we propose a monocular 3D object detection algorithm based on an improved MonoDETR. By introducing a feature aggregation pyramid module that combines a dual attention mechanism, we achieve adaptive fusion of multi-scale features through high-level guided low-level cross-scale attention, thereby enhancing the perception ability for occluded objects and small objects at long distances. In addition, an adaptive depth prediction module is introduced, utilizing a depth head to refine the multi-scale features and combining enhanced 3D positional encoding embedding to achieve more accurate

基金项目: 国家自然科学基金青年科学基金项目(62302379); 陕西省重点研发计划(2025SF-YBXM-548)。

作者简介: 杨帅兵(1999—), 男, 硕士研究生, 主要研究方向为单目三维目标检测; 王雨萌(1990—), 女, 博士, 讲师, 硕士生导师, 主要研究方向为计算机视觉、人工智能; 豆文君(2000—), 女, 硕士研究生, 主要研究方向为人体姿态估计; 马宗方(1980—), 男, 博士, 教授, 博士生导师 主要研究方向为信息融合、智慧城市。

depth information estimation, thereby improving the shortcomings of the original model in depth estimation. Experimental results on the KITTI test set demonstrate that the proposed model achieves excellent performance across various difficulty levels for three target categories: vehicles, pedestrians, and cyclists. Taking the vehicle category as an example, the performance improved by 1.69%, 1.77%, and 2.56% compared to the baseline model under simple, moderate, and difficult conditions, respectively.

Key words: Monocular 3D Object Detection; Multi-scale Feature Fusion; Depth Estimation

单目三维目标检测是计算机视觉领域的一项关键任务,旨在利用单张图像恢复目标的三维位置、尺寸及姿态,在自动驾驶、机器人导航、智能监控及增强现实等领域具有重要应用价值。相比依赖激光雷达(LiDAR)^{[1][2][3]}和立体视觉^{[4][5]}的方法,单目视觉方法在成本与部署灵活性方面具有显著优势。然而,由于单目图像缺乏真实深度信息,且场景中目标存在尺度变化剧烈遮挡严重等问题,单目三维检测仍然面临特征表达不足和深度预测不稳定等挑战。

早期主流的单目三维目标检测技术大多遵循二维检测范式,通过中心点预测^{[6][7]}、几何先验推断^{[8][9]}或多分支深度分类^{[10][11]}实现三维属性的间接恢复。这类方法通常依赖局部卷积特征,在处理遮挡严重或目标密集的场景时容易出现定位偏移与深度估计不稳定的问题^[12]。为缓解局部特征导致的建模能力不足问题,近年来,基于 Transformer 的端到端方法^{[13][14][15]}受到广泛关注。得益于自注意力机制的全局建模能力,此类方法能够建立目标与上下文的长距离关联,并通过深度引导的解码器实现跨区域特征匹配,从而在多个基准数据集上取得了性能提升。

尽管 Transformer 架构有效增强了全局建模能力,但其在单目三维目标检测任务中的性能仍然受多尺度特征融合策略的影响。现有方法多采用逐像素相加、加权求和与线性融合等方式整合不同层级的特征图。然而,深层特征往往具有更强的语义判别能力但空间分辨率较低,而浅层特征则包含更丰富的几何细节却语义表达能力弱。在缺乏约束的情况下,无差别的线性融合方式容易引入语义信息与几何信息间的冲突,导致特征表示的不一致性。进而 Transformer 解码器在建

立查询与图像区域关联时,缺乏稳定的语义几何对齐基础,最终影响遮挡目标和远距离小目标的定位精度。

针对上述挑战,本文提出一种空间通道注意力特征聚合金字塔(Spatial-Channel Attention Feature Pyramid Network, SCA-FPN)模块。该模块以高层语义特征的全局稳定性为引导,通过空间注意力与通道注意力对浅层几何特征进行自适应选择与调制,从而显式建模跨尺度特征之间的语义几何对齐关系。通过这种方式,SCA-FPN 能够在抑制无关背景干扰的同时,强化与目标几何结构一致的关键信息,为 Transformer 解码器提供有力的多尺度特征表示。

特征融合的优化虽缓解了语义几何对齐问题,但单目三维检测的核心痛点(深度预测不稳定)仍然存在。作为三维定位的关键因素,深度误差在相机投影过程中会被放大,从而影响三维属性的整体精度。如图 1 所示, MonoDETR^[14] 采用多桶深度分类与浅层 Transformer 编码对深度进行建模。其深度特征主要依赖浅层编码结果,局部结构表达能力有限,难以有效捕获远距离场景中的长距离上下文关系、弱纹理区域的细节关联以及遮挡区域的互补信息,导致深度响应在空间上出现不连续现象。

为此,本文在其基础上提出一种改进的自适应深度预测模块(Adaptive Depth Prediction Module, ADPM),进一步提升深度建模的稳定性与几何一致性。该模块通过强化深度特征的结构化表达,并引入三维位置嵌入,对深度信息进行多尺度精炼与约束,从而构建空间连续的深度表征,使深度响应更加聚焦于目标

本体及其几何一致的邻域。




图1 深度响应可视化对比

Fig.1 Depth Response Visualization Comparison

1 相关工作

1.1 基于中心点方法

现有单目三维目标检测方法中,一类代表性工作是基于增强的二维中心点检测范式,通过在图像平面上预测目标中心并回归对应的三维属性。SMOKE^[6]采用单阶段设计,在无需候选框生成的情况下直接回归三维位置与朝向,从而简化整体检测流程。MonoPair^[8]通过构建物体之间的成对关系图,引入目标间的空间约束来辅助深度推断。MonoDLE^[12]对单目三维检测中的定位误差来源进行了系统分析,并提出针对性的缓解策略以提升检测鲁棒性。MonoFlex^[10]针对截断目标与完整目标分别建模质心偏移,并结合几何深度关键点实现高效检测。GUPNet^[9]通过几何不确定性投影模块显式建模深度不确定性,有效缓解深度误差放大的问题;在此基础上,DEVIANT^[16]进一步引入组不变卷积,增强了几何感知能力。MonoCD^[11]结合多深度分支结构与几何约束关系,实现多深度线索之间的互补融合。尽管上述方法在几何建模与深度估计方面取得了一定进展,但它们大多依赖局部卷积特征或显式几何先验进行三维属性回归,难以在复杂场景中充分建模

远距离目标和严重遮挡目标的全局上下文关系。

1.2 基于 Transformer 方法

在二维目标检测领域,DETR^[17]首次提出基于Transformer的端到端检测框架,消除了对人工候选区域和非极大值抑制(NMS)的依赖。随后,Deformable DETR^[18]通过可变形注意力与稀疏采样机制显著提升了小目标的建模能力,而RT-DETR^[19]则通过优化解码器结构实现了实时性能。

近年来,Transformer架构逐渐被引入单目三维目标检测任务。MonoDTR^[15]利用LiDAR点云作为辅助监督信号,引导Transformer学习更具判别性的深度特征。DST3D^[20]将Swin Transformer与深度层聚合相结合,在无需额外传感器数据的情况下实现三维检测。MonoPGC^[21]通过引入深度空间感知Transformer与梯度位置编码,有效融合三维空间位置信息与深度感知特征。MonoDETR^[14]提出深度引导解码器,利用深度交叉注意力机制提取全局深度线索,并结合可变形注意力聚合局部视觉特征。随后,MonoATT^[13]和SSD-MonoDETR^[22]进一步通过自适应令牌与尺度感知注意力机制提升检测性能。然而,现有基于Transformer的

单目三维检测方法普遍依赖主干网络输出的逐像素或简单加权的多尺度特征作为编码输入,缺乏对不同尺度特征之间语义强度与几何细节差异的显式建模。在复杂场景中,这种无选择的特征融合方式容易引入语义几何冲突,从而导致解码阶段查询与特征区域的匹配不稳定,尤其影响遮挡目标和远距离小目标的定位精度。

1.3 特征金字塔策略

多尺度特征表示在目标检测任务中具有重要作用。早期 FPN^[23]通过自底向上特征提取与自顶向下特征传播,实现了跨尺度信息融合。后续工作如 PaFPN^[24]、NAS-FPN^[25]和 BiFPN^[26]通过引入双向信息流、路径增强或可学习权重机制,进一步提升了多尺度融合的效率与性能。此外, FaPN^[27]关注特征对齐问题,而 HS-FPN^[28]则通过调制高层特征权重提升对小目标的检测

能力。

尽管上述特征金字塔结构在二维检测任务中取得了显著成功,但其设计目标主要聚焦于二维语义判别,未考虑三维目标检测中特有的几何约束与成像条件。如图 2 所示,在远距离目标分辨率受限、弱纹理区域信息不足以及遮挡频繁的场景下,现有 FPN 变体(如 BiFPN、PaFPN)采用同尺度或相邻尺度的加权融合策略,缺乏对高层语义信息向低层空间特征引导关系的显式建模,容易引入背景干扰,导致目标响应不足。

为此,本文提出一种空间通道注意力特征聚合金字塔(SCA-FPN)。该模块从单目三维目标检测的任务特性出发,在传统自顶向下特征传播框架中引入高层语义引导低层空间注意力的跨尺度建模机制,使高语义层在特征传播过程中自适应调制低层特征中的关键区域响应,从而获得更加聚焦且有判别力的多尺度特征表示。




图 2 不同 FPN 变体的特征响应对比

Fig.2 Feature Response Comparison of Different FPN Variants

2 研究方法

2.1 方法框架

本文模型的整体结构如图 3 所示。对单张 RGB 图像采用 ResNet-50 主干网络提取多尺度特征表示

$F_i \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times C}$, $i=1,2,3$, 其分别对应 ResNet-50 的 $\{C_3, C_4, C_5\}$ 的输出。随后, F_i 经由空间通道注意力特

征聚合金字塔模块(SCA-FPN)进行跨尺度融合与语义增强,生成增强后的特征集合 $F_v = \{S_0, S_1, S_2, S_3\}$ 。在此基础上, F_v 被输入自适应深度预测模块(ADPM),以预测稠密深度分布及其连续深度图,并进一步生成深度感知特征 F_{dep} 。同时,结合预测深度信息与图像坐标,构建三维位置嵌入,从而在特征层面显式建模图像空间与三维几何空间之间的映射关系,为后续目标检测

提供几何一致性约束。随后,多尺度视觉特征 F_v 与深度感知特征 F_{dep} 分别送入视觉编码器与深度编码器进行联合建模,学习具有全局上下文感知能力和几何一

致性的联合特征表示。最后,解码器以目标查询为引导,在深度约束条件下对候选目标进行逐层精炼,最终输出三维目标检测结果,包括类别概率、二维与三维边界框、深度、投影中心及方向角度等信息。




图3 网络框架图

Fig.3 Network Architecture

2.2 特征金字塔模块

在目标检测任务的特征表示中,深层特征具有较强的类别区分能力和全局上下文信息,但其空间分辨率较低,难以精确刻画目标的几何结构;另一方面,浅层特征保留了丰富的边缘与纹理细节,却缺乏稳定的语义约束,易受背景噪声干扰。这一矛盾在三维检测任务中表现更加明显。在缺乏有效约束的情况下,直接采用逐像素相加或加权求和等线性融合方式,容易引入语义信息与几何信息之间的冲突,从而削弱特征表示的一致性与判别性。

为解决该问题,本文提出空间通道注意力特征聚合金字塔 (Spatial-Channel Attention Feature Pyramid Network, SCA-FPN)。其核心思想在于以高层语义特征的稳定性作为引导,通过空间与通道注意力机制^[29],对低层特征中的几何信息进行自适应选择与增强,从而在跨尺度融合过程中构建语义几何对齐关系,为后续深度建模与 Transformer 解码提供更加一致稳定的特征表示。SCA-FPN 整体结构如图 4 所示,分为特征选择与特征融合两个阶段。

2.2.1 特征选择

不同层级特征在语义强度、空间分辨率及噪声分

布上差异显著,直接跨尺度融合易导致语义冲突或目标响应稀释。因此,在特征融合之前,有必要对各尺度特征进行筛选与增强,以突出对三维建模的通道与空间区域。具体过程如下:

首先选取主干网络输出的多尺度特征图

$F_i \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times C}$, $i=1,2,3$ 作为输入,其中 F_3 作为高层特征具有更强的语义判别能力。为消除不同尺度特征在通道维度上的差异,在进入 SCA-FPN 之前,通过 1×1 卷积将各尺度特征统一映射至 256 维隐藏空间,得

到投影特征 $P_i \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times 256}$, $i=1,2,3$ 。进一步地,为扩展特征金字塔的尺度层级并增强全局上下文建模能力,对高层特征 P_3 施加步长为 2 的卷积下采样操作,构造额外的尺度扩展层 $P_4 \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times 256}$, $i=4$ 。该过程在不引入新的语义来源的前提下,扩大了特征的有效感受野,有助于捕获更大范围的信息。

在完成尺度对齐后,SCA-FPN 首先对各尺度投影特征 P_i 施加通道注意力机制。通道注意力模块通过并行的全局平均与最大池化操作,对不同通道的响应强度进

行建模,并用共享多层感知器生成通道权重,从而实现对关键语义通道的选择性增强。该过程能够有效抑制冗余或噪声通道,突出对目标类别判别和几何推断更为重要的特征维度。由于通道注意力主要作用于特征的重加权而非表示空间本身,本文进一步地引入 1×1 卷积对通道增强后的特征进行重映射,以提升特征表示在跨尺度融合过程中的稳定性。该过程可表示为:

$$P_i^{CA} = \text{Conv}_{1 \times 1}(\text{CA}(P_i)), i = 1, 2, 3, 4 \quad (1)$$

其中, $\text{CA}(\cdot)$ 表示通道注意力算子。

在空间维度上,考虑到高层特征具有更加稳定的语义响应,其空间激活区域能够较好地指示目标的整体位置分布,因此选择在最高层级特征 P_4^{SA} 施加空间注意力机制,并将其作为跨尺度融合的语义引导源。相比之下,在低层特征上直接施加空间注意力容易受到局部噪声干扰,反而削弱几何一致性。具体来说,空间注

意力通过在通道维度上计算平均值与最大值并进行拼接,使用 7×7 卷积生成空间权重,经 Sigmoid 激活后与输入特征逐元素相乘,得到空间增强特征。该过程可以表示为:

$$P_4^{SA} = \text{SA}(P_4^{CA}) \otimes P_4^{CA} \quad (2)$$

其中 $\text{SA}(\cdot)$ 表示空间注意力算子,而表示 $\otimes$ 逐元素级乘法。

随后,将空间注意力增强后的高层特征 P_4^{SA} 作为起始输入,通过长为 2、卷积核大小为 3×3 的转置卷积操逐级进行上采样以实现自顶向下传播。上采样后的

特征可以表示为: $U_i \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times 256}$, $i = 1, 2, 3, 4$ 。这些上采样后的特征将与对应尺度的投影特征进行跨尺度融合,为后续的深度预测与目标检测到提供增强后的多尺度特征表示。




图4 空间通道注意力特征聚合特征金字塔模块

Fig.4 Spatial-Channel Attention Feature Aggregation Pyramid Network Module

2.2.2 特征融合

经过特征选择后,各尺度特征仍存在语义强度与空间分辨率差异,直接逐元素相加难以实现最优信息流动。SCA-FPN 进一步设计了一种高层语义引导的跨尺度注意力融合策略,在保留低层几何细节的同时,实现对关键区域的自适应增强。

具体而言,对 $U_i \in \mathbb{R}^{\frac{H}{2^{i+2}} \times \frac{W}{2^{i+2}} \times 256}$, $i = 1, 2, 3$ 施加空

间注意力以获得显著性增强特征,随后将其送入通道注意力模块生成通道权重,并将其作用于低层特征 P_i^{CA} ,实现对低层几何信息的选择性增强。随后,将增强后的低层特征与使用了空间注意力后的上采样特征进行融合,得到融合特征,融合过程可以表示为:

$$P_i^{fus} = (\text{CA}(\text{SA}(U_i)) \otimes P_i^{CA}) + \text{SA}(U_i), i = 1, 2, 3 \quad (3)$$

该融合方式使高层语义信息能够通过空间注意力定位关键区域,并通过通道注意力精确调制低层特征中的有效

几何细节,从而避免逐像素融合所带来的特征干扰。

进一步地对融合特征 P_i^{fus} 施加由 3×3 卷积、组归一化和 ReLU 激活函数构成的横向卷积,以提升特征表达稳定性。由于最高层特征已具备最强的全局语义,其输出无需参与跨尺度融合。最终,各尺度特征表示为:

$$\begin{cases} S_0 = U_4 \\ S_i = \text{Conv}_{lat}(P_i^{fus}), i=1,2,3 \end{cases} \quad (4)$$

其中 Conv_{lat} 表示由 3×3 卷积、组归一化及 ReLU 激活函数组成的横向卷积模块。

最终,SCA-FPN 输出一组增强的多尺度特征表示 $F_v = \{S_0, S_1, S_2, S_3\}$,该特征集将被送入自适应深度预测模块及编码器-解码器结构。得益于在自顶向下融合路径中联合建模空间与通道维度的跨尺度注意力关系,SCA-FPN 能够有效提升多尺度特征的语义几何一致性,在远距离小尺度及部分遮挡目标场景中获得更加稳健的特征表示。

2.3 自适应深度预测模块

现有基于 Transformer 的方法多依赖浅层特征建模深度,在远距离、弱纹理及遮挡场景中易失效,导致深度特征空间不连续或局部偏移,削弱其引导作用。与现有方法不同,本文提出的自适应深度预测模(ADPM),通过多尺度残差式深度精炼与三维位置编码嵌入,构建跨尺度一致、空间连续的深度表征,为后续三维检测任务提供可靠深度引导。整体结构如图 5 所示,具体过程如下:

ADPM 以 SCA-FPN 输出的多尺度特征增强集 $\{S_1, S_2, S_3\}$ 输入。为保持较高空间分辨率的同时有效整合不同尺度的特征图,将各尺度特征在空间维度上统一对齐至中等分辨率特征 S_2 。相比于直接采用最高或最低分辨率特征,该选择在低层细节表达与高层语义稳定性之间取得了更合理的平衡。对齐后的特征经双线性插值后进行逐元素平均,得到基准深度特征

$f_d \in \mathbb{R}^{256 \times \frac{H}{16} \times \frac{W}{16}}$ 。该基准特征在一定程度上缓解了单一尺度特征在深度建模中的偏置问题,为后续深度精炼提供统一的特征基础。然而,仅依赖多尺度特征融合仍难以保证深度响应在空间维度上的连续性,尤其在远距离和遮挡区域,深度特征仍容易受到局部噪声干扰。进一步地,ADPM 引入结构化的残差式深度精炼机制。具体而言,将基准深度特征 f_d 输入至由两个串联残差深度块组成的深度头进行逐级建模,其计算过程可表示为:

$$\begin{cases} f_d^{(1)} = f_d + G_{\delta 1}(f_d) \\ F_d = f_d^{(1)} + G_{\delta 2}(f_d^{(1)}) \end{cases} \quad (5)$$

其中 $G_{\delta l}(\cdot)$ 表示扩张率为 δl 的卷积算子, $\delta 1=1, \delta 2=2$ 。

其中,第一个残差块采用标准 3×3 卷积,以强化局部几何结构与边界信息的建模;第二个残差块通过扩张卷积扩大有效感受野,从而捕获更大范围内的深度依赖关系。通过局部与非局部建模的协同作用,该残差式精炼过程能够在保持空间分辨率的同时,有效抑制深度响应中的离散噪声,提升深度特征在空间维度上的连续性与稳定性。

在获得结构稳定的深度感知特征 F_d 后,ADPM 采用深度离散分桶策略对像素级深度进行分类预测。具体而言,通过 1×1 卷积生成对应于预定义深度分桶的概率分布,并基于该分布进行加权求和,得到连续形式的深度估计 $\hat{z}$ 。

为显式引入三维几何先验,ADPM 在深度预测结果的基础上构建三维位置编码嵌入。具体而言,将二维像素坐标 (x, y) 与对应的深度估计 $\hat{z}$ 共同映射至统一的高维嵌入空间。其中,像素坐标沿图像宽高方向进行归一化处理,而深度采用对数映射形式以增强远距离区域的深度分辨能力。深度处理过程可以表示为:

$$\bar{z} = \frac{\log(1 + \hat{z})}{\log(1 + z_{\max})} \quad (6)$$

随后,分别对 $\bar{x}, \bar{y}, \bar{z}$ 施加正余弦位置编码,并在通道维度上进行拼接,组成三维位置嵌入 $E_{3D}(x, y, \bar{z})$ 。在此基础上,ADPM 将残差精炼后的深度特征 F_d 输入至轻量级 Transformer 编码器进行上下文建模,并将深度插值位置编码与三维正弦位置编码一同注入特征空间,得到最终的深度感知表示:

$$F_{dep} = \text{Enc}(F_d) + E_{3D}(x, y, \bar{z}) \quad (7)$$

该表示同时编码了局部几何结构、跨尺度深度一致性以及显式三维空间位置信息,使深度特征能够以更加连续、稳定且几何一致的形式参与后续 Transformer 解码过程,从而提升模型在远距离、小目标及遮挡场景下的三维检测性能。




图 5 自适应深度预测模块

Fig.5 Adaptive Depth Prediction Module

3 实验及结果分析

3.1 KITTI 数据集

为了评估所提模型的性能,本文在 KITTI 基准数据集上进行了实验。该数据集^[30]包含 7,481 张训练图像和 7,518 张测试图像,涵盖三类目标:车辆(Car)、行人(Pedestrian)和骑行者(Cyclist)。根据目标尺寸、遮挡程度和截断情况,检测难度分为简单(easy)、中等(moderate)和困难(hard)三个等级。依据过去研究的设定^[31],统一将训练数据划分为 3,712 张训练图像和 3,769 张验证图像以进行性能对比。主要评估指标采用中等难度下的三维边界框平均精度(AP_{3D})和鸟瞰图二维边界框平均精度(AP_{BEV}),其中车辆检测的 IoU 阈值为 0.7,行人和骑行者检测的 IoU 阈值为 0.5,并以 40 个召回点作为核心评估标准。

3.2 实验设置

本文模型采用 ResNet-50 作为主干网络,在单张 RTX 3090 GPU 上进行了 250 轮训练,批次大小设置为 12,使用 AdamW 优化器。初始学习率为 2×10^{-4} 权重衰减率为 1×10^{-4} ,并在第 85、125、165 和 205 轮训练时以 0.5 的系数进行学习率衰减。为增强模型泛化能力,额外应用了 Mixup3D^[32] 数据增强方法。在 Transformer 架构中,设置 8 个自注意力头,编码器与解码器均配置为 3 层,以实现表达能力与训练效率的平衡。

3.3 对比实验

为了保证对比结果的公平性,本文方法在 KITTI 数据集上独立测试五次,并取平均值作为最终性能指标。值得注意的是,表中有其余方法的数据均引用其在 KITTI 官方评测公布的测试集成绩。本文的测试集结果同样如此。

为验证 SCA-FPN 的有效性,本文将其与多种代表性特征金字塔变体进行对比,实验结果如表 1 所示。在相同设置下,SCA-FPN 在 Easy、Moderate 和 Hard 三个难度级别上均取得了最优性能,相较基线模型, AP_{3D} 分别提升 2.62、2.14 和 1.97 个百分点。尤其在 Hard 难度下,模型仍能保持稳定的性能增益。这表明 SCA-FPN 在遮挡严重和远距离小目标场景中具有更强的性能。进一步地,与 PaFPN^[24]和 HS-FPN^[28]相比,SCA-FPN 在参数量和 FLOPs 相近前提下取得了更优的检测性能,表明该金字塔结构在性能提升与计算开销之间的良好平衡,进一步说明所提出的 SCA-FPN 能够在复杂场景下稳定增强多尺度特征表示,具备良好的实用价值。

表 1 不同特征金字塔变体性能比较

Table 1 Performance of Feature Pyramid Variants

方法	Val, $AP_{3D}(\%)$			Params (M)	FLOPs (G)
	Easy	Mod.	Hard		
Baseline	26.19	19.41	16.29	35.93	59.72
FPN ^[23]	26.80	19.18	16.09	35.14	60.33
BiFPN ^[26]	27.24	19.71	17.08	37.50	66.35
PaFPN ^[24]	28.81	20.57	17.69	39.86	72.36
HS-FPN ^[28]	28.73	20.91	17.57	39.53	72.29
本文(SCA-FPN)	28.81	21.55	18.26	39.57	72.31

注: 粗体表示最优值。

表 2 评估了在行人(Pedestrian)和骑行者(Cyclist)两个弱势类别上的检测性能。实验结果表明,本文方法在行人类别上取得了最优性能,在 Easy、Moderate 和 Hard 三个难度级别上的 AP_{3D} 分别提升了 2.08、1.39 和 0.84 个百分点。行人目标通常尺度较小、外观变化大且易受遮挡影响,对多尺度特征的语义几何一致性要求更高,该结果表明 SCA-FPN 与 ADPM 能够有效增强对细粒度目标的特征表达能力。对于骑行者类别,模型在 Hard 难度下取得了 0.34 个百分点的提升,而在 Easy 和 Moderate 难度下与最优方法存在较小差距。该现象主要源于数据集中骑行者样本数量相对稀缺,且该类别普遍存在剧烈姿态变化和严重遮挡,导致评测指标波动较大。尽管如此,在骑行者类别中仍保持了具有竞争力的性能,尤其在 Hard 难度下表现更出色。

表 2 KITTI 测试集行人和骑行者对比

Table 2 Performance Comparison of Pedestrian and Cyclist on KITTI Test Set

方法	<i>Test, AP_{3D}(%)</i>					
	Pedestrian			Cyclist		
	Easy	Mod.	Hard	Easy	Mod.	Hard
MonoDLE ^[12]	9.64	6.55	5.44	4.59	2.66	2.45
MonoPair ^[8]	10.02	6.68	5.53	3.79	2.12	1.83
PDR ^[33]	11.61	7.72	6.40	2.72	1.57	1.50
MonoDETR ^[14]	12.54	7.89	6.65	7.33	4.18	2.92
DEVIANT ^[16]	13.43	8.65	7.69	5.05	3.13	2.59
本文	15.51	10.04	8.53	6.05	3.43	3.26

注. 粗体表示最优值.

为进一步验证所提方法的有效性,本文在 KITTI

表 3 KITTI 测试集下“汽车”类别不同方法性能对比

Table 3 Performance Comparison of Different Methods for the “Car” on the KITTI Test Set

方法	有无额外数据	<i>Test, AP_{3D}(%)</i>			<i>Test, AP_{BEV}(%)</i>		
		Easy	Mod.	Hard	Easy	Mod.	Hard
MonoPGC ^[21]	深度信息	24.68	17.17	14.14	32.50	23.14	20.30
OPA-3D ^[34]	深度信息	24.60	17.05	14.25	33.54	22.53	19.22
CaDDN ^[35]	激光雷达数据	19.17	13.41	11.46	27.94	18.91	17.19
MonoDTR ^[15]	激光雷达数据	21.99	15.39	12.73	28.59	20.38	17.14
OccupancyM3D ^[36]	激光雷达数据	25.55	17.02	14.79	35.38	24.18	21.37
本文	无	26.69	18.24	16.14	35.29	24.93	21.70
MonoFlex ^[10]	无	19.94	13.89	12.07	28.23	19.75	16.89
DEVIANT ^[16]	无	21.88	14.46	11.89	29.65	20.44	17.43
DVDET ^[37]	无	23.19	15.44	13.07	32.05	22.15	19.32
MonoDETR ^[14]	无	25.00	16.47	13.58	33.60	22.11	18.30
MonoUNI ^[38]	无	24.75	16.73	13.49	33.28	23.05	19.39
MonoCD ^[11]	无	25.53	16.59	14.53	33.41	22.81	19.57
FD3D ^[39]	无	25.38	17.12	14.50	34.20	23.72	20.76
本文	无	26.69	18.24	16.14	35.29	24.93	21.70

注. 粗体表示最优值.

本文进一步评估了车辆深度估计的平均绝对误差 (Mean Absolute Error, MAE), 结果如表 4 所示。结果表明, 本文方法在整体深度估计精度上优于现有主流方法, 在 0–20m、20–40m 及整体平均误差上均取得最优结果, 验证了所引入自适应深度估计模块的有效性。对于 40m 以外的远距离目标, 尽管仍优于基线方法但深度估计误差整体仍然偏高。这主要源于单目成像条件下, 远距离目标在图像中分辨率低、纹理信息稀缺, 深度估计本身具有较强的不适定性, 而非单一模型结构所能完全解决的问题。为进一步分析该问题, 本文尝试通过增加深度精炼部分的容量以提升远距离深度估计能力, 但提升的性能有限, 相反, 增加了的计算开销。

表 4 深度估计均方误差 MAE(m)

Table 4 Depth Estimation Mean Absolute Error(m)

方法	0-20 米	20-40 米	40 米外	平均
MonoRCNN ^[40]	0.46	1.27	2.59	1.14
GUPNet ^[9]	0.45	1.10	1.85	0.89
DEVIANT ^[16]	0.40	1.09	1.80	0.87
MonoDETR ^[14]	0.40	1.15	1.98	0.93
MonoDGP ^[41]	0.37	1.10	2.15	0.90
本文	0.35	1.09	1.89	0.86

注. 粗体表示最优值.

测试集上针对车辆(Car)类别进行了实验, 结果如表 3 所示。与当前最先进的单目方法相比, 本文方法取得了有竞争力的性能。值得注意的是, 在无额外数据使用情况下, 其性能仍超越一些依赖额外数据的方法。在无额外数据辅助情况下, 与次优方法相比, 在简单、中等和困难难度下的 AP_{3D} 与 AP_{BEV} 指标分别提升: 1.16、1.12、1.61、1.09、1.21 和 0.94 个百分点。实验结果验证了所提方法在车辆类别上的有效性与稳定性, 说明跨尺度特征引导与自适应深度建模能够协同提升车辆目标的三维定位精度。

表 5 对本文模型的数量 (Params)、计算复杂度 (FLOPs) 以及运行时间 (Runtime) 进行了对比分析。实验结果表明, 尽管在基线模型的基础上引入了特征聚合金字塔模块 (SCA-FPN) 和自适应深度预测模块 (ADPM), 使模型的参数规模与计算复杂度相较基线略有增加, 但这一额外开销换来了显著的三维检测性能提升。进一步地, 与同样基于 MonoDETR^[14]改进的 SSD-MonoDETR^[22]和 MonoDGP^[41]等方法相比, 本文模型 AP_{3D} 指标上取得了更优的检测精度, 同时并未引入明显的推理时间延迟, 其运行时间保持在 39ms。

表 5 计算开销

Table 5 Computational cost

方法	<i>Val, AP_{3D}(%)</i>	Params	FLOPs	Runtime
	Mod.	(M)	(G)	(ms)
Baseline	19.41	35.93	59.72	35
SSD-MonoDETR ^[35]	21.96	35.08	59.68	36
MonoDGP ^[41]	22.34	38.90	68.99	42
本文	22.60	41.34	75.71	39

注. 粗体表示最优值.

3.4 消融实验

为评估本文方法中各模块设计的有效性,在 KITTI 验证集上针对车辆(Car)类别的 AP_{3D} 进行消融实验,结果如表 6 所示。模型整体框架由三个组件组成: Mixup3D 数据增强、特征聚合金字塔模块(SCA-FPN)和自适应深度估计模块(ADPM)本文将 MonoDETR 作为基线模型,为缓解 KITTI 数据集规模较小导致的过拟合问题,本文引入了 Mixup3D^[28]以缓解这一问题,并提升模型的泛化能力。

在此基础上,引入 SCA-FPN 模块对多尺度特征进行进一步建模。该模块统一采用高层语义特征引导低层特征融合的方式。实验结果表明,单独引入通道注意力即可带来一定性能提升,说明对不同语义通道重要性的自适应建模有助于增强特征判别能力;进一步引入空间注意力后,模型性能取得更为显著的提升,相较于仅使用 Mixup3D 时,在 Easy、Moderate 和 Hard 难度

下的 AP_{3D} 分别提高了 1.08、1.61 和 1.53 个百分点。该结果表明,空间注意力与通道注意力在多尺度特征融合过程中具有良好的互补性,能够通过显式建模多尺度特征之间的语义与几何对齐关系,有效增强对遮挡目标及远距离小尺度目标的表征能力。

最后,在特征聚合基础上进一步引入自适应深度预测模块,构成完整检测框架。实验结果表明,在保持 ADPM 其余结构不变的情况下,移除三维位置编码会导致模型性能出现一定程度下降,说明引入三维空间位置信息对于稳定深度建模具有重要作用。当引入完整的 ADPM 结构后,模型在 Easy、Moderate 和 Hard 难度下的 AP_{3D} 分别提升至 30.86%、22.60%和 19.56%,相较基线模型整体提升了 4.67、3.19 和 3.27 个百分点,可以看出,各模块在整体框架中均发挥了互补作用,验证了本文方法在特征融合与深度估计两个关键环节上设计的合理性。

表 6 消融实验

Table 6 Ablation experiment

Mixup3D	SCA-FPN (CA)	SCA-FPN (SA)	ADPM	ADPM (3D Pos)	$Val, AP_{3D}(\%)$			Params(M)
					Easy	Mod.	Hard	
-	-	-	-	-	26.19	19.41	16.29	35.93
✓	-	-	-	-	28.45	20.07	16.90	35.93
✓	✓	-	-	-	28.92	20.94	17.56	37.68
✓	✓	✓	-	-	29.53	21.68	18.43	39.57
✓	✓	✓	✓	-	30.21	22.03	18.97	40.82
✓	✓	✓	✓	✓	30.86	22.60	19.56	41.34

注: 粗体表示最优

3.5 可视化分析

图 6 展示了 KITTI 验证集中车辆类别在鸟瞰视角 (Bird's-eye view, BEV) 下的检测结果。与基线模型相比,引入 SCA-FPN 与 ADPM 模块后,模型在车辆空间定位方面表现出更为稳定和一致的预测结果。基线模型的预测框(红色)在部分样本中与真实标注框(绿色)

存在偏移,并有一定程度的漏检;而本文模型在整体上与真实框具有更高的重叠度,空间位置偏差显著减小。得益于 SCA-FPN 对多尺度特征的有效增强与融合,以及 ADPM 对深度相关局部结构与全局上下文信息的联合建模,模型在鸟瞰视角下能够更准确地恢复车辆的平面位置,从而呈现更加准确的检测结果。



图 6 鸟瞰图可视化

Fig.6 Bird's-eye view visualization

图 7 更直观地展示了 KITTI 验证集上一些具有挑战性的典型样本,重点关注遮挡目标和远距离小尺度目标的检测表现。得益于 SCA-FPN 所引入的跨尺度语义引导机制,即使在目标严重遮挡或视觉特征微弱

的情况下,模型仍能够有效聚合多尺度特征中的信息,在图像中捕获到关键视觉线索,从而在这些困难场景下表现出更稳定的目标识别与定位能力。




图 7 三维投影框可视化结果

Fig.7 Visualization of 3D projection boxes on image

4 结语

本文提出了一种基于 MonoDETR 改进的单目三维目标检测方法。该模型通过联合使用特征聚合金字塔与自适应深度估计模块,缓解了复杂场景下遮挡目标及远距离小目标的检测困难。在特征聚合金字塔模块,采用双重注意力机制与高层引导低层的跨尺度注意力融合策略,增强特征表示,从而提升检测能力。自适应深度估计模块通过深度头对特征进行精细化处理,

参考文献:

并引入三维位置编码函数,实现了更加精准的深度估计,为三维检测提供了可靠的几何先验信息。实验结果表明,模型在 KITTI 数据集上优于现有的单目三维目标检测方法,验证了特征聚合金字塔和自适应深度估计的关键作用。

未来的研究工作将进一步探索更高效的特征金字塔设计方法,以进一步提升模型对极端遮挡和远距离小目标的检测能力。

- [1] SHI S, GUO C, JIANG L, et al. Pv-rcnn: Point-voxel feature set abstraction for 3d object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10529-10538.

- [2] ZHOU Y, TUZEL O. Voxelnet: End-to-end learning for point cloud based 3D object detection [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4490-4499.
- [3] LANG A H, VORA S, CAESAR H, et al. Pointpillars: Fast encoders for object detection from point clouds [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 12697-12705.
- [4] CHEN X, KUNDU K, ZHU Y, et al. 3D object proposals using stereo imagery for accurate object class detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40 (5): 1259-1272.
- [5] LI P, CHEN X, SHEN S. Stereo R-CNN based 3D object detection for autonomous driving [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7644-7652.
- [6] LIU Z, WU Z, TÓTH R. SMOKE: Single-stage monocular 3D object detection via keypoint estimation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 996-997.
- [7] Wang T, Zhu X, Pang J, et al. FCOS3D: Fully Convolutional One-Stage Monocular 3D Object Detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 913-922.
- [8] CHEN Y, TAI L, SUN K, et al. MonoPair: Monocular 3D object detection using pairwise spatial relationships [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 12093-12102.
- [9] LU Y, MA X, YANG L, et al. Geometry uncertainty projection network for monocular 3D object detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3111-3121.
- [10] ZHANG Y, LU J, ZHOU J. Objects are different: Flexible monocular 3D object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3289-3298.
- [11] YAN L, YAN P, XIONG S, et al. MonoCD: Monocular 3D object detection with complementary depths [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 10248-10257.
- [12] Ma X, Zhang Y, Xu D, et al. Delving into localization errors for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 4721-4730.
- [13] ZHOU Y, ZHU H, LIU Q, et al. MonoATT: Online monocular 3D object detection with adaptive token transformer [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 17493-17503.
- [14] ZHANG R, QIU H, WANG T, et al. MonoDETR: Depth-guided transformer for monocular 3D object detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 9155-9166.
- [15] HUANG K C, WU T H, SU H T, et al. MonoDTR: Monocular 3D object detection with depth-aware transformer [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 4012-4021.
- [16] KUMAR A, BRAZIL G, CORONA E, et al. Deviant: Depth equivariant network for monocular 3D object detection [C]//Proceedings of the European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 664-683.
- [17] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers [C]//Proceedings of the European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 213-229.
- [18] ZHU X, SU W, LU L, et al. Deformable DETR: Deformable transformers for end-to-end object detection [EB/OL]. [2025-09-14]. <https://arxiv.org/abs/2010.04159>.
- [19] ZHAO Y, LV W, XU S, et al. DETRs beat YOLOs on real-time object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 16965-16974.
- [20] WU Z, JIANG X, XU R, et al. DST3D: DLA-Swin transformer for single-stage monocular 3D object detection [C]//Proceedings of the 2022 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2022: 411-418.
- [21] U Z, GAN Y, WANG L, et al. MonoPGC: Monocular 3D object detection with pixel geometry contexts [EB/OL] [2025-09-14]. <https://arxiv.org/abs/2302.10549>.
- [22] HE X, YANG F, YANG K, et al. SSD-MonoDETR: Supervised scale-aware deformable transformer for monocular 3D object detection[J]. IEEE Transactions on Intelligent Vehicles, 2023, 9 (1): 555-567.

- [23] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.
- [24] LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8759-8768.
- [25] GHIASI G, LIN T Y, LE Q V. NAS-FPN: Learning scalable feature pyramid architecture for object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7036-7045.
- [26] TAN M, PANG R, LE Q V. EfficientDet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10781-10790.
- [27] HUANG S, LU Z, CHENG R, et al. FaPN: Feature-aligned pyramid network for dense image prediction [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 864-873.
- [28] CHEN Y, ZHANG C, CHEN B, et al. Accurate leukocyte detection based on deformable-DETR and multi-level feature fusion for aiding diagnosis of blood diseases[J]. *Computers in Biology and Medicine*, 2024, 170: 107917.
- [29] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 3-19.
- [30] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the KITTI vision benchmark suite[C]//Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2012: 3354-3361.
- [31] CHEN X, KUNDU K, ZHU Y, et al. 3D object proposals for accurate object class detection[J]. *Advances in Neural Information Processing Systems*, 2015, 28.
- [32] LI Z, JIA J, SHI Y. MonoLSS: Learnable sample selection for monocular 3D detection[C]//Proceedings of the 2024 International Conference on 3D Vision (3DV). IEEE, 2024: 1125-1135.
- [33] SHENG H, CAI S, ZHAO N, et al. PDR: Progressive depth regularization for monocular 3D object detection[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2023, 33 (12): 7591-7603.
- [34] SU Y, DI Y, ZHAI G, et al. OPA-3D: Occlusion-aware pixel-wise aggregation for monocular 3D object detection[J]. *IEEE Robotics and Automation Letters*, 2023, 8 (3): 1327-1334.
- [35] READING C, HARAKEH A, CHAE J, et al. Categorical depth distribution network for monocular 3d object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 8555-8564.
- [36] PENG L, XU J, CHENG H, et al. Learning occupancy for monocular 3D object detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 10281-10292.
- [37] HU Y, FANG S, XIE W, et al. Aerial monocular 3D object detection [J]. *IEEE Robotics and Automation Letters*, 2023, 8 (4): 1959-1966.
- [38] JINRANG J, LI Z, SHI Y. MonoUNI: A unified vehicle and infrastructure-side monocular 3D object detection network with sufficient depth clues [J]. *Advances in Neural Information Processing Systems*, 2023, 36: 11703-11715.
- [39] WU Z, GAN Y, WU Y, et al. FD3D: Exploiting foreground depth map for feature-supervised monocular 3D object detection [C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38 (6): 6189-6197.
- [40] HI X, YE Q, CHEN X, et al. Geometry-based distance decomposition for monocular 3D object detection [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 15172-15181.
- [41] PU F, WANG Y, DENG J, et al. MonoDGP: Monocular 3D object detection with decoupled-query and geometry-error priors [C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 6520-6530.