

分 类 号: TP391
学 号: 210401115

单位代码: 11726
密 级: 公 开



長春大學

专业硕士学位论文

自动驾驶场景中基于单目视觉的三维目标检测算法研究

**Research on 3D Object Detection Algorithm Based on Monocular
Vision in Automatic Driving Scene**

作 者 姓 名: 李铖硕

专 业 领 域 名 称: 电子信息

校内指导教师及职称: 于存江（教授）

企业指导教师及职称: 刘杰（工程师）

培 养 单 位: 电子信息工程学院

2024 年 6 月

分 类 号: TP391
学 号: 210401115

单位代码: 11726
密 级: 公 开

自动驾驶场景中基于单目视觉的三维目标检测算法研究

**Research on 3D Object Detection Algorithm Based on
Monocular Vision in Automatic Driving Scene**

作 者 姓 名: 李铖硕
专 业 领 域 名 称: 电子信息
校内指导教师及职称: 于存江（教授）
企业指导教师及职称: 刘杰（工程师）
培 养 单 位: 电子信息工程学院

2024 年 6 月

摘要

三维目标检测是自动驾驶感知技术的一个重要组成部分，其目的在于检测目标在三维空间中的深度、位置坐标和尺度大小等信息。基于单目视觉的三维目标检测技术因其摄像头成本较低且易于部署受到了广泛关注。但单目相机本身深度感知能力较弱，导致相关算法与基于激光雷达的算法在三维检测效果上仍有差距。因此，进行单目场景下的三维目标检测算法研究具有重要学术意义和实用性。

在众多单目三维目标检测算法中，基于 DETR (Detection Transformer) 结构的 MonoDETR 算法性能表现优秀。该算法重新设计了传统 DETR 的解码器，实现以深度特征为引导的解码模块进行三维目标检测。本文针对 MonoDETR 在三维目标检测中的不足做进一步研究与改进，本文具体研究内容如下：

针对 MonoDETR 算法对全局特征信息利用较少并且收敛速度较慢的问题，本文提出基于空间调制的共同注意力三维目标检测算法。该算法通过在编码模块中对全局特征进行编码，提高模型对全局信息的获取能力；在解码部分的共同注意力机制中融合待检测目标的高斯分布权重图，将每个目标的查询向量搜索范围调节至目标边界框周围，使解码器能够更快地在全局特征中较快定位待检测目标的特征，有效提高模型对全局特征的捕获能力和收敛速度。改进后的算法与基准算法相比，训练轮次减少了 51 轮，平均检测精度提升了 1.32%。

针对图像中存在不同尺度目标以及目标间遮挡严重导致难以检测的问题，本文提出了基于多尺度特征融合三维目标检测算法。首先对深度特征提取模块进行改进，将卷积与注意力机制结合，提高模型的深度特征提取能力。再通过将不同尺度特征图在编码器中交替进行层内和层间的自注意力编码，实现不同尺度间信息的交换，有效提高模型从不同尺度的特征图上获得目标信息的能力。改进后的算法实现了提升对不同尺度目标的三维检测精度，同时改善了目标间遮挡导致的问题。经过实验验证，改进算法的检测精度与基准模型相比提升了 2.25%。

综上所述，本文将基于空间调制的共同注意力三维目标检测算法与多尺度特征融合机制结合，提出了改善在多尺度目标场景下检测精度的 DSC-MonoDETR 三维目标检测算法。在公开 KITTI 数据集上通过消融实验验证了各改进部分的有效性，证实了本文所提出的算法可以提升自动驾驶场景中三维目标检测的精度。

关键词：三维目标检测； 空间调制的共同注意力； 多尺度特征融合； DETR

Abstract

Three-dimensional object detection is an important part of automatic driving perception technology. Its purpose is to detect the depth, position coordinate and scale of the object in three-dimensional space. 3D object detection based on monocular vision has received extensive attention because of its low camera cost and easy deployment. However, the depth perception ability of monocular camera is weak, which leads to the gap between correlation algorithm and LiDAR based algorithm in 3D detection effect. Therefore, the research of 3D object detection algorithm in monocular scene has important academic significance and practicability.

Among many monomer 3D object Detection algorithms, the MonoDETR algorithm based on DETR (Detection Transformer) has excellent performance. In this algorithm, the decoder of traditional DETR is redesigned to realize 3D target detection by decoding module guided by depth feature. In this paper, the shortcomings of MonoDETR in 3D target detection are further studied and improved. The specific research contents of this paper are as follows:

To solve the problem that MonoDETR algorithm uses less global feature information and converges slowly, this paper proposes a common attention three-dimensional object detection algorithm based on spatial modulation. By encoding global features in the coding module, the algorithm improves the ability of the model to obtain global information. The Gaussian distribution weight graph of the target to be detected is fused into the common attention mechanism of the decoding part, and the search range of the query vector of each target is adjusted around the boundary box of the target, so that the decoder can locate the feature of the target to be detected faster in the global feature, and effectively improve the model's capturing ability and convergence speed of the global feature. Compared with the benchmark algorithm, the training rounds of the improved algorithm are reduced by 51 rounds, and the average detection accuracy is increased by 1.32%.

Aiming at the problem that there are objects of different scales in the image and the occlusion between the objects makes it difficult to detect, this paper proposes a three-dimensional object detection algorithm based on multi-scale feature fusion. Firstly, the depth feature extraction module is improved, and the convolution and attention

mechanism are combined to improve the depth feature extraction ability of the model. Then, the information exchange between different scales is realized by interlayer and intra-layer self-attention coding of different scale feature maps in the encoder, and the ability of obtaining target information from different scale feature maps is effectively improved. The improved algorithm can improve the 3D detection accuracy of different scale targets and improve the problem caused by the occlusion between targets. The experimental results show that the accuracy of the improved algorithm is 2.25% higher than that of the benchmark model.

In this paper, a DSC-MonoDETR 3D target detection algorithm based on spatial modulation and multi-scale feature fusion is proposed to improve the detection accuracy in multi-scale target scenes. The effectiveness of the improved parts is verified by ablation experiments on the open KITTI data set, which proves that the proposed algorithm can improve the accuracy of 3D target detection in the automatic driving scene.

Key Words: three-dimensional object detection; Common attention for spatial modulation; Multi-scale feature fusion; DETR

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 引入额外监督项的单目三维目标检测算法研究现状	3
1.2.2 基于 RGB 图像的单目三维目标检测算法研究现状	4
1.3 本文的主要工作.....	5
1.4 本文的章节安排.....	6
第 2 章 三维目标检测算法基础理论	8
2.1 单目三维目标检测基础理论	8
2.1.1 基本概念	8
2.1.2 相机传感器.....	9
2.2 基于视觉 Transformer 的目标检测算法	12
2.2.1 视觉 Transformer 实现原理.....	12
2.2.2 DETR 算法	14
2.3 三维目标检测数据集与评价指标	15
2.3.1 KITTI 数据集	15
2.3.2 评价指标.....	16
2.4 本章小结.....	17
第 3 章 基于空间调制共同注意力的三维目标检测算法	18
3.1 注意力机制设计.....	19
3.1.1 动态空间权重图.....	20
3.1.2 空间调制共同注意力机制.....	21
3.2 基于空间调制共同注意力的检测模型结构	23
3.2.1 特征提取网络.....	23
3.2.2 特征编码与解码模块.....	24
3.3 实验与分析.....	26
3.3.1 实验设置.....	26
3.3.2 实验结果分析.....	28
3.4 本章小结.....	33
第 4 章 基于多尺度特征融合三维目标检测算法	34
4.1 算法整体框架.....	34
4.2 深度特征提取模块的改进	36
4.2.1 深度特征提取模块结构.....	36
4.2.2 融合 ACmix 的深度特征提取模块.....	37

4.3 基于多尺度特征融合三维目标检测模型结构	39
4.3.1 多尺度特征编码模块.....	39
4.3.2 深度特征引导的解码模块.....	40
4.4 实验与分析.....	42
4.4.1 实验设置.....	42
4.4.2 实验结果分析.....	43
4.5 本章小结.....	49
第5章 总结与展望	50
5.1 本文研究总结.....	50
5.2 未来展望.....	51
参考文献.....	52

第1章 绪论

1.1 研究背景及意义

随着人工智能和深度学习等技术的飞速进步，基于深度学习的目标检测算法在精确度和效率上均取得了显著成效。目标检测技术是计算机视觉与图像处理领域的重要组成部分，其核心任务是识别并定位数字图像或视频流中的多个目标对象。这一技术不仅是计算机视觉基础任务的重要组成，还为更高级的任务如实例分割与目标分割任务提供了重要技术支撑。近年来，目标检测技术在多个应用场景中得到了广泛应用，如卫星图像识别、文档识别、安防警戒系统以及自动驾驶等领域，展现出了其强大的应用潜力和广阔的市场前景，在极大提高人类劳动生产力的同时，也为人们日常生活提供了便捷的服务。

在自动驾驶^[1]的感知系统和机器人视觉系统中，深度学习技术扮演着至关重要的角色。这类感知和视觉系统通常将视觉传感器捕捉到的图像或视频流数据抽象为模型能理解的高级语义信息，通过解析语义信息实现对周围环境的精准感知，为整个辅助驾驶系统提供准确的环境信息。其中，自动驾驶感知系统的一个核心功能就是三维目标检测，它要求能够获取目标或障碍物的深度以及其他三维尺度信息，以便对行驶过程中的周围环境进行全面感知，辅助系统进行判断和路径规划。然而，尽管现有的基于深度学习的二维目标检测技术^[3]已经取得了令人瞩目的成果，其精度甚至超越了人眼的辨识能力，但这些技术仍然存在局限性，无法满足自动驾驶领域的需求。自动驾驶相关感知任务需要目标在三维空间中的位置和结构信息，而二维目标检测技术仅能提供目标二维图像平面上的位置信息。目标的三维尺度信息对于自动驾驶等任务至关重要，如路线规划、避让等决策都需要准确的三维信息作为依据。相比之下，通过3D目标检测技术不仅可以感知目标的存在，还可以获取其详细的空间结构和位置信息，如物体在三维空间中的坐标位置、三维尺度大小以及朝向角等信息。因此，3D目标检测技术能够为系统提供更加全面和准确的感知数据，其在自动驾驶等辅助系统中的应用价值更为显著，能有效提高系统的安全性和可靠性。

近年来,三维目标检测已成为目标检测领域的研究热点,众多创新技术应运而生。目前,主流的三维目标检测方法主要依靠激光雷达采集的点云信息,或是利用多模态技术将点云信息与图像特征进行融合^[6]。然而,激光雷达传感器作为点云信息的主要来源,其较高的部署与维护成本限制了其广泛应用,并且对远距离小尺度目标的检测能力存在不足。相比之下,基于单目视觉的三维目标检测,即仅利用单目相机传感器的输入数据完成三维目标检测任务,成为了一种具有性价比、且便于实施部署的解决方案。由于单目相机传感器无法直接感知物体在三维空间中的深度,因此模型无法直接获得目标在三维空间中的位置以及尺寸信息。这一问题的存在对通过单目视觉进行三维目标检测任务提出了挑战,即如何在二维图像中获取三维信息,但这也激发了研究者们对该领域的持续研究和探索。由于缺乏直接有效的三维空间信息,因此在单目视觉场景中大多数算法沿用二维目标检测算法的思想,先进行二维目标检测确定目标中心点,随后这些算法会通过传统卷积网络、几何关系约束或三维体素化匹配^[6]等不同方法对目标的三维边界框进行预测。因此,目前许多单目三维目标检测的算法都是在二维目标检测算法的结果上预测的中心点位置,进一步展开预测其他三维参考点,最后预测完整的三维边界框。这种基于二维检测的拓展方法,不仅充分利用了二维图像中的丰富信息,还通过引入三维信息,提高了检测的准确性和可靠性。

自动驾驶场景要求感知模块能够检测到目标的三维空间信息,使用激光雷达等设备虽然能较为准确的捕捉目标在三维空间中的结构信息,但其成本较高不易于维护部署。然而以二维图像目标检测技术为基础的算法在获取目标的三维空间位置和结构方面却有所不足。为解决这一局限性,基于单目视觉的三维目标检测技术受到了关注,虽然其成本相对较低,却面临着多重挑战。首先,由于摄像头拍摄所得图像中目标的姿态和规模多样,不同的车辆比如在颜色、大小以及与相机的距离和运动方向等方面都存在差异,在图像中表现为不同的尺度大小。因此,本文目标式开发出能够适应这些变量的检测算法,以准确评估目标的三维定位和尺寸。其次,在繁忙的道路上,车辆和行人通常彼此靠得很近并经常发生遮挡,这可能导致图像中缺乏目标的细节信息,使得二维和三维预测面临信息不完整的问题。检测算法必须能够针对这些被遮挡的目标进行准确的预测。最后,算法的处理速度也是一个不容忽视的挑战,很多应用场景对于目标检测模型的响应时间要求苛刻,旨在实时支持后续的决策制定。然而,

目前很多高精度的检测算法往往伴随着高运算量和繁琐的结构设计，难以在实际中广泛部署。因此，如何在保证运行速度的同时提高模型检测精度便是需要解决的实际问题。

为了解决上述问题，本文对自动驾驶场景中基于单目视觉的三维目标检测方法进行分析研究，对现有算法的不足进行改进优化。

1.2 国内外研究现状

1.2.1 引入额外监督项的单目三维目标检测算法研究现状

相对于使用高线束激光雷达传感器采集点云信息进行三维目标检测^[19]的算法，采用单目摄像机设备进行三维目标检测更加方便且成本更低。目前基于深度学习的目标检测已经成为 2D 目标检测领域的主流算法^[7-11]，大多数三维目标检测的工作也逐渐采用深度学习作为研究方法。近年来，国内外专家学者提出了许多优秀的基于单目视觉的三维目标检测算法，这些算法充分验证了该领域研究前景的可行性。其中一些算法仅通过 RGB 图像完成检测，而其他方法则需要依赖于额外的辅助数据或者其他独立网络模型输出的深度信息、伪雷达点云信息^[12]结果作为先验知识完成检测。

首先是基于额外数据辅助的方法：2016 年 Chen 等人提出了 Mono3D^[13]算法，通过利用深度图像在类似的框架中生成区域提议。通过在 3D 空间上进行穷举搜索生成区域提议，并使用非极大值抑制方法（Non-Maxima Suppression, NMS）进行过滤，最后通过回归 3D 边界框的 Fast R-CNN 模型进一步完善结果；Mono3D 研究者在 2017 年又提出了 3DOP^[14]，并增加了对候选框进行评分所需的三维点云特征信息；2017 年 Chabot 等人提出 DeepMANTA^[15]并将 CAD 模型作为辅助数据；2019 年 He 等人提出 Mono3D++^[16]，使用可变形线框模型^[17]估计车辆的三维状态和姿态，并优化所生成假设与相应伪度量之间投影一致性损失。2019 年 Brazil 等人提出 M3D-RPN^[18]算法，该算法通过将单目三维目标检测问题建模为一个独立的三维区域建议网络，通过深度感知卷积层提取特定位置的特征，以解决复杂的三维参数估计问题。此外，算法还利用后优化算法中的 3D 到 2D 投影一致性损失来优化方向估计，提高检测精度。

另一种主流方法是基于深度信息或伪 Lidar 点云：通过深度估计算法生成深度图像或从图像中自动生成伪 Lidar 点云信息，利用生成的先验信息在后续

推理中帮助模型提高检测精度。Psuedo-Lidar^[20] 首先利用深度估计技术从单目图像中获取目标的深度信息。然后, 根据这些深度信息, 将图像中的像素映射到 3D 空间中, 生成伪点云数据。这些伪点云数据在结构上与激光雷达生成的点云数据相似, 因此可以直接应用基于激光雷达的 3D 目标检测算法来进行目标检测。MonoPSR^[21] 主要思路是结合边界框提议算法与形状重构, 在场景中为每个目标生成具有高准确率的建议框从而有效降低回归难度; AM3D^[22] 通过将二维图像与深度图结合转换为三维点云图像, 并通过点云网络进行三维尺度估计; MonnFlex 算法^[23] 在 2021 年由 Zhang 等人提出, 该算法通过结合截断的中心点选取差异、深度估计中的几何深度与直接回归深度的加权结合, 以及边缘特征提取和融合等关键技术, 显著提升了目标检测的精度和效率。

1.2.2 基于 RGB 图像的单目三维目标检测算法研究现状

在单目三维目标检测领域中, Barabanau 等人于 2019 年提出了一种采用两阶段的架构进行单目视觉三维检测 MonoDIS^[24]。MonoDIS 算法采用了两阶段架构, 这一设计包含一个单级 2D 检测器作为第一阶段, 以及一个额外的 3D 探测头作为第二阶段。特别的是, 这个 3D 探测头是在第一阶段检测到的 2D 包围盒所提取的特征基础上构建的。除此之外, MonoDIS 还引入了一种创新的损失解纠缠和参数隔离策略。这种方法有效地解决了不同参数之间可能存在的依赖性问题, 从而进一步提升了三维检测的精确度。Brazil 等人提出的 M3D-RPN^[25] 算法通过设计独立的三维区域候选网络, 成功解决了复杂的三维参数估计问题。该算法引入深度感知卷积层, 学习空间感知特征, 提升了对 3D 场景的理解能力。此外, M3D-RPN 利用 3D 到 2D 的投影一致性损失优化方向估计, 提高了检测精度。Qin 等人提出了 MonoGRNet^[26], 该算法结合了多尺度特征融合和几何关系约束, 有效提升了检测精度和鲁棒性。MonoGRNet 通过引入几何推理模块, 对目标的三维位置、尺寸和姿态进行准确估计。此外, 它还利用深度特征提取网络, 从单目图像中捕捉丰富的上下文信息, 进一步提高了检测性能。Liu 等人在 2020 年提出的 SMOKE^[27] 算法是一种端到端的检测模型, 该算法通过直接学习目标相关特征点, 并结合模型输出的特征点进行约束, 生成对应的 3D 框, 从而实现对目标在三维空间中的精确定位。与传统的单目 3D 目标检测算法相比, SMOKE 摒弃了复杂的几何估算过程, 直接通过深度学习模型学习出 3D 视觉的障碍物信息。这使得 SMOKE 在检测速度和精度上都有了显著提升,

同时也降低了算法实现的复杂度。RTM3D^[28]则通过预测目标三维边界框在图像上的9个投影点，并利用二维平面和三维空间的透视关系来回归预测目标在三维空间中的尺寸、位置和方向。2022年Zhang等人提出了MonoDETR算法该算法通过引入深度编码器对输入的单目图像进行深度特征的编码，以提取图像中的深度信息。采用深度引导解码器，使物体能够在深度信息的引导下自适应地提取2D和深度特征，从而提高3D检测的准确性，实现了端到端的3D单目视觉三维目标检测。

1.3 本文的主要工作

基于单目视觉的三维检测算法 MonoDETR 是当前该领域中取得优秀成绩的一种算法。该算法设计了一个轻量化的深度信息预测结构，通过对原始的 Transformer 网络进行改造，加入了以深度为引导的 Transformer 解码器。本文针对 MonoDETR 模型在三维目标检测中存在的不足做进一步的优化改进工作，提出一种基于空间调制共同注意力的三维检测算法，然后在此基础上改进深度特征预测模块并与多尺度特征融合机制相结合，提出了单目三维目标检测算法 DSC-MonoDETR，具体工作内容如下：

（1）针对单目三维目标检测算法在训练过程中收敛缓慢，训练周期较长的问题，提出基于空间调制的共同注意力三维目标检测算法。重新设计了基准模型的深度感知解码模块，将每个物体的查询向量在共同注意力机制中的搜索范围调整到目标位置的周围，在一定程度上解决传统 DETR 解码模块的查询向量与大量无关背景进行信息交互从而带了计算量上升的问题。经过对比实验有效性实验，所提出的 SC-MonoDETR 可以进一步加快模型的收敛速度、减少计算量，同时在大尺度目标的检测效果上明显提高。

（2）针对图像中存在目标尺度多样以及目标间遮挡严重的问题，提出深度引导的多尺度融合共同注意力三维目标检测算法。通过将不同尺度特征图在编码器中交替进行层内和层间的自注意力机制实现尺度信息的交换，从而让模型能够从不同尺度的特征图上获得目标特征信息。同时，改进的深度特征提取模块将注意力模块与卷积层整合，提高深度特征提取能力，实现了提升对不同尺度目标的三维检测精度的同时，仍保持算法高效运行，对目标遮挡和截断的问题进行了有效优化。经过实验，验证了深度引导的多尺度特征融合算法可以提

高对不同尺度目标的检测精度，相比于原始基准模型，本文所提出的 DSC-MonoDETR 在三维目标检测精度上提高了 2.25%。

将基于空间调制的共同注意力三维目标检测算法与深度引导的多尺度特征融合机制结合，提出改善在多尺度目标场景下检测精度的 DSC-MonoDETR 三维目标检测算法。在 KITTI 数据集上通过消融实验验证了各改进部分的有效性，证实了本文所提出算法具有比基准模型更快的收敛速度，并且可以提升自动驾驶场景中三维目标检测的精度。

1.4 本文的章节安排

本文主要分为五个章节，其中第二章对本文研究用到的基础理论进行了阐述；第三章和第四章介绍了本文主要的创新改进工作以及每项工作的实验论证；第五章对本文做出总结和展望，论文的核心结构如图 1-1 所示。




图 1-1 本文核心结构安排

第二章，单目视觉三维目标检测算法基础理论。首先在第一节中对单目场景下进行三维目标检测的基础原理、相机传感器原理、实验所用 KITTI 数据集以及评价指标作了介绍阐述；第二节重点介绍了本文后续工作所依托的视觉 Transformer 模型架构以及编码解码原理。

第三章，基于空间调制共同注意力的三维目标检测算法（SC-MonoDETR）。首先介绍了传统 DETR 模型收敛速度、计算量以及精度方面存在的问题；紧接

着在第一节中介绍了空间调制的共同注意力核心思想和实现原理，同时介绍了动态空间权重图的实现过程；第二节介绍基于空间调制共同注意力机制的三维目标检测模型的特征提取网络以及模型结构的实现细节；最后在第三节中给出实验结果与分析，并在图像上展示算法的检测效果。

第四章，深度引导的多尺度融合三维目标检测算法（DSC-MonoDETR）。首先分析现有算法在多尺度和遮挡目标检测上精度不足的原因；接着介绍了对基准模型的深度特征提取和引导机制做出的改进，同时介绍了这些改进的实现细节；第二节介绍了多尺度特征融合的空间调制共同注意力机制的实现方法和解码模块；最后第三节给出实验过程和实验结果分析，并在图像上展示算法的检测结果。

第2章 三维目标检测算法基础理论

2.1 单目三维目标检测基础理论

2.1.1 基本概念

三维目标检测作为人工智能领域中的一个重要分支，近年来得到了广泛的关注。它起源于自动驾驶技术和二维目标检测算法^[30-34]，并在此基础上不断发展和完善。这一任务的核心目标是根据单目图像或附加的额外知识，精确地定位出一个三维边界框^[36]，从而为后续的图像理解和处理提供关键的依据。

在实际应用中，由于传感器和输入数据类型的差异，三维目标检测技术可以分为两大类。第一类是利用激光、深度相机以及单目相机、双目相机等硬件设备获取图像和点云数据。这种方法的优势在于可以获取较为精确的深度信息，从而提高目标检测的准确性。第二类则是基于单目相机进行目标检测，它通过单目相机拍摄的二维图像来推断物体的三维位置和形状。尽管这种方法的准确度相对较低，但其成本低廉、易于部署，因此在工业界得到了广泛的应用。




图 2-1 三维目标检测任务方法分类

在单目 3D 目标检测领域，又可细分为三类方法。直接法（Direct Methods），所谓直接法就是直接从二维平面图像中直接预测出三维检测框，省略预测中间的三维场景表示的步骤。更进一步的说就是，直接法可以借助二维平面图像和三维空间之间的几何关系来帮助模型预测。例如，可以在图像平面上估计出某对象的关键点^[37]，以帮助使用已知几何结构构建 3D box。M3D-RPN 引入深度感知卷积，它按行划分输入并学习每个区域的 no-shared kernels，以学习 3D 空间中位于相关区域的特定特征。

基于其他辅助数据的方法可以对场景中的物体进行形状估计，从而理解三维物体的几何形状。形状估计可以从三维 CAD 模型^[35]的标记顶点中被监督，或从 LiDAR 扫描，或直接从输入数据以自我监督的方式。直接法的缺点是三维检测框直接从二维平面图像中生成，而二维平面图像中没有明确的深度信息，相对于引入先验知识的方法，对目标在三维空间的位置预测能力较差。

基于深度估计的方法（Depth-Based Methods），该方法先利用深度估计模型获得像素级的场景深度图，再将模型估计的深度图与原始图像结合输入模型从而完成三维目标检测任务。深度图可以转换成 3D 点云，这种方法被称为伪激光雷达（Pseudo-LiDAR），或者直接使用，或者结合图像信息来生成 3D 目标检测结果。基于深度的方法在训练阶段将深度估计从三维目标检测任务中分离，导致还需要学习用于三维检测任务的次佳的深度地图。对于兴趣区域内的目标的像素，模型应该优先获取其精确的深度信息，而背景像素的深度特征不需要模型预测，如果深度估计和目标检测是独立训练的，则无法捕捉到这一属性。

基于网格的方法（Grid-Based Methods），基于网格的方法通过预测 BEV 网格表示（BEV grid representation），来避免估计用做 3D 检测框架输入的原始深度值。如 OFT^[38]首先将 3D 空间划分为等大的体素，并将每个体素内的点云数据进行聚合，形成体素特征。然后，利用特征变换器对体素特征进行编码和变换，以捕捉 3D 目标的形状、姿态和位置信息。通过多层次的特征提取和融合，OFT 网络能够生成高质量的 3D 候选框，并实现精确的目标分类和定位。

2.1.2 相机传感器

相机模型是单目视觉目标检测领域中的一个重要传感器，涉及到相机坐标系(camera)、世界坐标系(world)、理坐标系(image)以及像素坐标系(pixel)。这四种不同坐标系的详细定义如下。

相机坐标系 (Camera Coordinate System) (x_c, y_c, z_c) :

相机坐标系是固定在相机上的三维坐标系, 也称为观察坐标系。它的原点通常设定在相机的光心位置, x 轴和 y 轴与图像平面的 X 和 Y 轴平行, 而 z 轴与相机的光轴重合, 垂直于图像平面。相机坐标系用于描述物体在相机视角下的三维空间位置, 是连接现实世界与图像平面的桥梁。

世界坐标系 (World Coordinate System) (x_w, y_w, z_w) :

世界坐标系是一个绝对坐标系, 用于描述物体在真实世界中的位置。它没有固定的原点, 但通常会在场景中选择一个方便的点作为原点, 并定义三个互相垂直的轴 (x_w, y_w, z_w) 来构成坐标系。世界坐标系是物体空间位置的基准, 用于将不同视角下的物体位置统一到同一个坐标体系下, 便于进行空间几何变换和目标定位。

图像物理坐标系 (Image Coordinate System) (x', y') :

图像坐标系是一个二维坐标系, 建立在图像平面上。它的原点通常设定在图像平面的左上角或中心位置, x 轴和 y 轴分别平行于图像平面的水平和垂直方向。图像坐标系用于描述物体在图像平面上的投影位置, 是连接相机坐标系与像素坐标系的中间环节。

像素坐标系 (Pixel Coordinate System) (u, v) :

像素坐标系也是一个二维坐标系, 但它的单位是以像素为单位的。在数字图像处理中, 图像的每个像素都可以用一个坐标值来表示, 这个坐标系就是像素坐标系。像素坐标系主要用于数字图像的存储和读取, 方便计算机对图像进行处理和分析。在单目视觉目标检测中, 通过将图像坐标系转换为像素坐标系, 可以方便地对图像中的目标进行定位和识别。

根据三角形相似性原理, 现实世界的空间点 P 与成像平面的成像点 P' 之间存在一种特定的空间关系。

$$\frac{z}{f} = \frac{X}{X'} = -\frac{Y}{Y'} \quad (2-1)$$

式 (2-1) 描述了现实世界的空间点 P 和成像平面的成像点 P' 的空间关系, 但是在实际应用中, 我们并不能直接获得成像点 P' 的连续坐标值, 因为相机捕捉到的是一个离散个像素。真实的相机投影过程一般需要经过三个步骤, 由世界坐标转化为相机坐标, 再归一化为图像上的坐标, 其成像原理如图 2-2 所示。




图 2-2 相机成像原理

为了将这些连续的图像信息转化为离散的像素数据，相机需要对成像平面上的对象进行采样和量化。经过这一步骤后，我们最终得到的是成像点 P' 的像素坐标 $[u, v]^T$ ，这些坐标值直接对应于数字图像中的像素位置。

可以知道，像素平面与成像平面之间相差了一个缩放倍数和一个原点偏置量。假设像素坐标在 u 轴上缩放 α 倍，在 v 轴上缩放 β 倍，并且原点平移了 $[c_x, c_y]^T$ 。那么成像点 P' 与像素坐标 $[u, v]^T$ 的关系为：

$$\begin{cases} u = \alpha X' + c_x \\ v = \beta Y' + c_y \end{cases} \quad (2-2)$$

代入式 (2-1) 并把 αf 合并成 f_x ，把 βf 合并成 f_y ，得：

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases} \quad (2-3)$$

将式(2-3)表示为矩阵形式，再把 Z 移到左侧可得到：

$$Z \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \quad (2-4)$$

经过上述推导，可以得到从相机坐标到像素坐标的转换公式（式 2-4）。在这个公式中，涉及到一个关键矩阵，该矩阵被称之为相机的内参矩阵，它由多个中间量组成。这些内参在相机的封装调试阶段就已确定，并且通常不会发生变化。

在转换过程中，一个值得注意的现象是深度信息的丢失。具体来说，参数 Z 代表了点 P 的深度，也就是点 P 到相机光心 O 的垂直距离。然而，由于投影原理，在 P 到 P' 这条线段上的任意一点都可能投影到像素平面上的同一点 P' 。这种不确定性导致了深度信息的难以获取。因此，在单目三维目标检测领域，如何准确地估计物体的深度信息成为了一个核心挑战和关键问题。

2.2 基于视觉 Transformer 的目标检测算法

计算机视觉技术广泛用于图像和视频的检测与评估，涵盖了图像分类、目标检测、跟踪以及语义分割等多个细分领域。在计算机视觉领域，基于深度学习的卷积神经网络（CNN）是一种典型应用。然而，卷积神经网络在处理图像时往往难以捕捉全局信息，特别是在建立长距离特征关系方面存在局限，因此模型不能有效利用全局上下文信息。为了解决这个问题，研究人员借鉴了自然语言处理领域中的 Transformer 模型^[39]，并成功将其应用于目标检测任务中。相比传统的卷积神经网络，Transformer 模型^[40]中的多头注意力机制可以有效避免陷入局部信息相互作用的范围，它同步计算的机制能够有效对长距离特征的依赖关系建模。这种机制使得 Transformer 能够根据不同的任务目标学习最适宜的回归修正，并在各种目标检测、分类、分割等任务中展现出优越的性能。

实践表明，在大规模数据集中对视觉 Transformer 模型进行预训练，然后再将其迁移到数据规模更小的检测任务中，往往能够获得比卷积神经网络模型更高的准确度。这种方法不仅提升了模型的泛化能力，还使得计算机视觉任务的处理更加高效和精准。

2.2.1 视觉 Transformer 实现原理

Vision Transformer 可以看成是 Transformer 的视觉领域模型，在尽可能少的改造下将标准的 Transformer 模型直接迁移至图像领域变成视觉 Transformer 模型。为了将 Transformer 模型适用于图像，将原始输入图像切分成很多子块并将这些子块组成线性嵌入序列^[41]，然后将这些线性嵌入序列作为 Transformer 的输

入以模拟在自然语言处理领域中词组序列输入。在传统卷积神经网络结构中，通常直接用连续的卷积层直接对原始图像进行处理，不需要额外的预处理步骤，而在视觉 Transformer 结构的算法^[43]中，需要对图像进行区域划分和编码，其结构如图 2-3 所示。




图 2-3 Vision Transformer 结构原理图

首先将一个 $H \times W \times C$ 的图像划分为多个大小为 $P \times P \times C$ 的 Patches，具体个数为 $N = H \times W / P^2$ 个 Patches。然后将每个 Patches 进行展平，相应的维度表示为 $N \times (P^2 \times C)$ ， $x \in N \times (P^2 \times C)$ 的二维块序列。每个二维块序列中包含 $H \times W / P^2$ 个展平的二维块（维度是 $P^2 \times C$ ）。视觉 Transformer 模型要求的输入是尺寸大小为 (N, D) 的张量，因此进一步对二维块序列进行 Patch Embedding。Patch Embedding 操作是将每个向量单独做一次线性变换（即作全连接），即将二维块序列的维度压缩成 D 维。

$$Z_0 = [x_{\text{class}}; x_p^1 E; \dots x_p^N E] + E_{\text{pos}}^{\leftarrow} \quad (2-5)$$

其中 E 为全连接层，输入通道为 $P^2 \times C$ ，输出通道为 N 。 x_{class} 为手动添加的一个可学习的类别编码，是为后续的分类任务预留一个可学习的嵌入向量。多添加一个分类编码可以避免最后选择从 N 个展平二维嵌入向量中做选择，直

接使用单独的嵌入向量做分类预测。接下来，为了补充图像序列中的位置信息，视觉 Transformer 引入了位置编码 E_{pos} ，并附加了一个可学习的位置编码参数。这种位置编码通过计算相似性来编码图像中不同区域之间的距离，使得相邻的图像块（patch）拥有更相似的位置嵌入。同时，这种编码方式还呈现出行列结构的特点，即位于同一行或同一列的 patch 往往具有相似的嵌入特征。图 2-3 详细展示了视觉 Transformer 的编码流程，主要包括以下四个关键步骤：首先，对输入图像进行分块处理，将其划分为多个小块；接着，对每个图像块进行嵌入操作，将其转换为适合 Transformer 处理的嵌入向量；然后，通过加入位置编码来补充位置信息；随后，利用 Transformer 编码器对嵌入向量进行进一步的处理和转换；最后，通过多层感知机（MLP）进行分类或其他相关任务的处理。这一过程充分体现了视觉 Transformer 在图像处理中的高效性和灵活性。

2.2.2 DETR 算法

DETR 架构的相关算法^[42-45]将目标检测任务视为图像到集合的问题，需要预测一张图像中所有目标的无序集合，并给出每个目标的类别和边界框。为了进行端到端训练，DETR 使用集合损失函数作为监督信号，并利用匈牙利匹配算法将预测目标与真实目标匹配起来。这种方法简化了训练过程，避免了复杂处理如 anchor 和 NMS。

传统计算机视觉模型通常使用复杂且手动操作的 pipeline 来定位图像中的目标并提取特征，而 DETR 则提供了一个端到端深度学习解决方案，如图 2-4 所示。




图 2-4 DETR 编码与解码过程

DETR 采用卷积神经网络（CNN）提取局部信息，将输入图像嵌入成一个二维表征向量，然后将二维表征转换成一维表征并结合位置编码信息一起送入编码模块。而解码模块将少量固定数量的已学习的目标查询向量和编码模块的

输出作为输入。最后将解码模块得到的每个输出向量传递到一个共享的前馈网络(FFN)，该网络可以预测一个检测结果(包括类和边框)或“没有目标”的类。

DETR 框架包含基于集合的全局损失函数以及 Transformer 编码器-解码器架构，在给定固定目标查询向量时对目标和背景关系进行推理，并直接输出最终预测集。之前有研究者尝试使用循环神经网络等按序列做预测的架构进行目标检测，但由于速度慢且有效性低效果不好。

2.3 三维目标检测数据集与评价指标

2.3.1 KITTI 数据集

KITTI 数据集^[46-47]创立于 2012 年，是由德国卡尔斯鲁厄理工学院（Karlsruhe Institute of Technology, KIT）和美国丰田技术研究院芝加哥分院（Toyota Technological Institute at Chicago, TTI-C）共同发起的项目，它被广泛认为是自动驾驶领域中用于评估基于深度学习计算机视觉算法^[48]的国际领先数据集之一。这一数据集旨在测试包括立体成像、光流技术、视觉测距、三维物体检测和三维跟踪等多个计算机视觉功能在内的技术在实际车辆环境中的表现。它涵盖了从市中心到乡村以及高速公路的各种真实场景，图像数据中可能包含多达 15 辆车辆和 30 名行人，并显示了不同程度的遮挡和截断情况。针对三维物体检测任务，KITTI 数据集提供了 14899 张含有点云的图像，这些图像被分为用于训练的 7481 组和用于测试的 7518 组，它们标注了汽车、行人和自行车三种物体，总共有 80256 个标记项。




图 2-3 KITTI 数据集采集平台

KITTI 数据集还提供了进行三维检测的标准测试基准。该基准根据目标在图像中的像素占比进行分类筛选，剔除了远距离的目标，从而确保评测的准确性和有效性。根据图像中目标的像素高度和截断情况，将其所有图像划分为为三种不同难度的场景，分别为：

简单场景，仅对图像中二维边界框高度超过 40 像素、无遮挡且截断比例不超过 15%的目标进行评测，此时检测难度相对较低。

中等场景则涵盖了存在小面积遮挡和部分截断的目标，要求目标高度至少为 25 像素，截断比例不超过 30%，且最大遮挡级别为部分遮挡，增加了检测的挑战性。

而在困难场景下，目标可能因大面积遮挡和大比例截断而在图像中难以辨识，此时评测包括了存在大面积遮挡的目标，且最大截断比例可达 50%，同时忽略了高度小于 25 像素的目标，进一步提升了检测的难度。这些不同难度的场景设置，有助于更全面地评估三维目标检测算法的性能。

2.3.2 评价指标

参考三维目标检测领域中的通用评价指标，本文采用 AP_{3D} 指标在 KITTI 数据集上进行算法有效性验证。平均准确率（Average Precision, AP）是 KITTI 数据集通用的一种评价指标，用来对模型的三维目标检测性能评估。该评判标准将预测框与真实框的交并比（Intersection over Union, IoU）大于一定阈值的预测框判断为正确，反之判别为错误。在三维目标检测任务中，IoU 的定义为真实三维框与预测三维框相交体积与两框体积并集的比值。检测汽车类别的 IoU 阈值设置为 0.7，而行人与自行车由于目标尺度较小，将 IoU 阈值设置为 0.5。在计算 AP 时，通过计算准确率与召回率得到，计算方式如下：

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} \\ Recall &= \frac{TP}{TP + FN} \end{aligned} \quad (2-6)$$

其中， TP 代表真阳，即预测值为真且真实值也为真； FP 代表假阳，即预测值为真但真实值为假； FN 代表假阴，即预测值为假但真实值为真。值得注意的是，KITTI 官方测试网站在 2019 年 10 月之后采用 40 点召回计算的 AP_{40} ， AP 值越高代表检测性能越好。

2.4 本章小结

本章将所涉及到的理论知识和实验数据集分为三个部分进行阐述。在第一节中阐述了单目场景进行三维目标检测的基本原理，包含三维目标检测基本概念、单目相机传感器原理；第二节对视觉 Transformer 和 DETR 模型的原理进行阐述；第三小节介绍了实验所用 KITTI 数据集介绍以及算法的评价指标，本文所用的 KITTI 数据集是自动驾驶领域的经典通用数据集，对车辆和行人等目标进行了高质量标注。本文第三章和第四章所提出算法均在基于 DETR 模型结构的单目三维目标检测算法上做进一步的改进工作。

第3章 基于空间调制共同注意力的三维目标检测算法

当前主流的单目三维目标检测算法，通常遵循传统的二维目标检测流程。首先通过检测图像上的投影中心来定位对象，然后聚合相邻的视觉特征以进行三维属性预测，如图 3-1（a）所示。尽管这种中心引导的方法在概念上很简单，但受限于没有长长上下文的局部外观，并且无法从平面图像中捕获隐含的几何线索，例如深度引导，这对在三维空间中检测目标至关重要。本章算法所用基准模型 MonoDETR^[52]提出了一种新的深度引导的三维目标检测算法，取得了优秀的性能，如表 3-1 所示。与二维目标检测中的 DETR 模型相比，MonoDETR 中的注意力解码模块配备了深度引导模块，以更好地捕捉上下文深度线索，是第一个用于单目三维目标检测的 DETR 模型，如图 3-1（b）所示。该算法由两个用于视觉和深度表示学习的并行编码器和一个用于自适应深度引导检测的解码器组成。




图 3-1 传统 DETR 目标检测与 MonoDETR 的区别

在 DETR 中，Transformer 通过不同位置和对象查询之间的特征交换来对目标特征增强，但这种结构在解码时查询向量会与大量的无关背景进行信息交互，导致模型收敛缓慢，计算量较大。而 MonoDETR 所采用的可变形注意力机制通

过探索局部信息获得了比原始的 DETR 有更快的收敛速度，但代价是算法检测精度下降。本章提出一种基于空间调制共同注意注意力的三维目标检测算法，通过将注意力权重与手工设计的空间查询先验结合，将参与查询交互的特征约束在目标周围，实现了提高算法检测精度的同时保证模型的收敛速度加快。

表 3-1 当前主要单目视觉三维目标检测算法性能对比

Method	先验知识	Car, AP _{3D} (IOU=0.7)		
		Easy	Mod.	Hard
PatchNet	Depth	14.72	12.31	9.32
DDMP-3D		20.01	12.43	9.98
CaDDN	LiDar	19.76	12.89	10.21
SMOKE	None	14.12	9.87	8.03
RTM3D		13.86	10.08	8.17
MonoRCNN		18.26	13.45	10.12
MonoFlex		19.83	13.87	12.08
MonoDTR		20.01	14.82	12.03
MonoDETR		23.72	16.07	12.19

3.1 注意力机制设计

在目标检测领域中，DETR 模型收敛速度较慢的原因之一，来自于其中的共同注意力（Co-Attention）机制。DETR 不同于传统卷积神经网络捕捉局部特征的目标检测算法，它引入了物体查询向量（Object Queries）的概念^[51]。这些查询向量能够与图像的全局特征进行交互，通过共同注意力机制自适应地从图像的各个位置提取物体特征。这一方法使得 DETR 能够预测物体的边界框坐标及其类别。需要注意的是，与每个物体查询向量进行交互的特征区域可能并不局限于目标物体本身，而是可能包含了大范围的背景或其他不相关的物体。因此，在应用 DETR 进行目标检测时，需要仔细处理这些潜在的干扰因素，需要更长的训练时间来使物体查询向量能较为准确地定位物体。

3.1.1 动态空间权重图

原始的 DETR 模型中的共同注意力没有对目标的边界框尺度进行预测, 因此需要多次迭代来学习如何为每个对象查询生成适当的注意力图。空间调制共同注意力机制将可学习的共同注意力图与手工制作的查询空间先验相结合, 将参与查询的特征约束在待测目标的初始估计周围, 从而查询过程与最终预测更相关。

首先网络模型对输入图像正常使用 CNN 卷积网络提取特征, 视觉编码模块对特征提取网络提取的特征进行视觉编码, 进一步获得高级的语义特征; 在网络的解码部分, 将可学习的共同注意力权重与预先设定的物体查询向量的空间先验相结合, 将特征聚合的范围限制在查询向量估计的物体位置周围。对于每一个给定的物体查询向量, 首先对其中心位置以及尺度进行预测高斯分布模型, 将每个物体查询向量在共同注意力机制的查询区域调整到物体中心和边界框的一定距离内, 从而加速模型的收敛。

每个对象查询首先动态预测其负责对象的中心和尺度, 然后用于生成一个二维类高斯空间权重图。类高斯分布的中心在 $[0, 1] \times [0, 1]$ 的规范化坐标中进行参数化。对象查询 O_q 的类高斯分布的归一化中心 c_h^{norm}, c_w^{norm} 和规模 s_h, s_w 的初始预测表示为:

$$\begin{aligned} c_h^{norm}, c_w^{norm} &= \text{sigmoid}(\text{MLP}(O_q)) \\ s_h, s_w &= \text{FC}(O_q) \end{aligned} \quad (3-1)$$

其中对象查询 O_q 被投影为在二维 c_h^{norm}, c_w^{norm} 中获得规范化预测中心, 具有 2 层 MLP 和 sigmoid 激活函数。然后对预测的中心进行非归一化, 以获得原始图像中的中心坐标 c_h, c_w 。 O_q 还将动态估计对象缩放 s_h, s_w 沿两个维度创建 2D 类高斯权重图, 然后用于重新加权共同注意力图, 以强调预测对象位置周围的特征。自然图像中的物体显示出不同的尺度和高/宽比率。设计预测宽度和高度无关 s_h, s_w 可以更好地解决现实世界中复杂的物体长宽比。对于大目标或小目标, 空间调制共同注意力动态生成不同值的 s_h, s_w , 使空间权重图 G 调制的共同注意力图可以聚合大目标所有部分的足够信息或抑制小目标的背景杂波。在预测目标中心 c_w, c_h 和尺度 s_w, s_h 后, 生成类高斯权重图:

$$G_{(i,j)} = \exp\left(-\frac{(i-c_w)^2}{\beta s_w^2} - \frac{(j-c_h)^2}{\beta s_h^2}\right) \quad (3-2)$$

其中 $(i, j) \in [0, W] \times [0, H]$ 是权重图 G 的空间索引， β 是调节类高斯分布带宽的超参数。权重图 G 通常将靠近中心的位置赋予较高的重要性，而将远离中心的位置赋予较低的重要性。 β 可以用手工设计的方案进行手动调整，以确保 G 在开始时覆盖足够的空间范围，以便网络可以接收更多的信息梯度。

3.1.2 空间调制共同注意力机制

MonoDETR 算法在编码模块与解码模块中，使用局部可变形注意力机制代替了传统 DETR 算法中原有的自注意力机制，使算法在编码与解码过程中，在目标参考点附近进行查询向量与局部特征向量的交互。传统 DETR 算法使用的自注意力机制虽然能对物体的全局特征进行编码与解码，但这种方式在提取图像不同位置物体的特征时，需要与每一个物体查询向量进行交互，进而预测物体的类别和边界框。然而，这一过程中涵盖了过多的背景信息以及与目标物体无关的其他物体信息，导致解码器在定位物体位置时耗费大量时间。自注意力模型如图 3-2 所示。




图 3-2 自注意力机制

MonoDETR 使用的局部可变形注意力与传统 DETR 算法相比，探索局部信息的方式虽然可以在一定程度上加快模型的收敛速度，但其代价是算法的检测精度下降。局部可变形注意力需要预测 8 个采样点进行可变形注意，而空间调制的共同注意力机制仅需要一个采样点。针对这一问题，本文将对 MonoDETR 算法的解码模块的自注意力机制进行改进本文学习借鉴了空间查询先验的思想，

在 MonoDETR 中实现空间调制的共同注意力机制，构建能够在保证检测精度的同时更快收敛的单目三维目标检测算法。空间调制的共同注意力机制如图 3-3 所示。




图 3-3 空间调制的共同注意力机制

对于每一个给定的物体查询向量，空间共同注意力首先对物体的中心位置以及尺度进行预测,并使用预测值生成物体的二维高斯分布。其中，式（3-2）用以调节高斯分布的带宽。用动态生成的空间先验 G 调制对象查询 Oq 和自注意力编码特征 E 之间的共同注意力图 C_i 。对于用点积注意力生成的每个共同注意力图 C_i ，利用空间权重图 G 调制共同注意力图 C_i ，其中 G 为空间调制共同注意力中的所有共同注意力共享头。将物体的二维高斯分布与共同注意力模型中的注意力矩阵结合，得到空间调制的多头注意力矩阵：

$$C_i = \text{softmax} \left(\frac{K_i^T Q_i}{\sqrt{d}} + \log G_i \right) V_i \quad (3-3)$$

空间调制的共同注意力机制中，多头注意力模型的每一个分支都使用了不同的空间位置估计，使其分别聚焦于物体的不同位置，从而更全面的提取物体特征。在空间地图的对数 G 和点积联合注意力 $K_i^T Q_i / \sqrt{d}$ 之间行元素相加，然后

对所有空间位置通过 Softmax 激活函数进行归一化。通过这种方式，解码器共同注意力将在预测的边界框位置周围施加更多的权重，这限制了共同注意力的空间模式的搜索空间，从而提高了收敛速度。如图 3-3 所示，通过空间查询先验约束共同注意力，使其更多地关注预测边界框位置周围的区域，从而显著提高了收敛速度。

3.2 基于空间调制共同注意力的检测模型结构

3.2.1 特征提取网络

基准模型 MonoDETR 所使用的特征提取网络是 ResNet50 残差网络^[63]。当我们训练深度神经网络时，网络的层数越多，模型的复杂度和表达能力就越强。然而，更深层的网络也会带来一些问题，比如梯度消失和梯度爆炸。梯度消失是指在反向传播过程中，梯度（导数）逐渐缩小并接近于零，导致浅层网络的权重更新速度非常慢，难以进行有效的训练。而梯度爆炸则是传播过程中偏导系数变得非常大，导致网络不稳定，持续发散。

为了解决这些问题，ResNet 网络引入了残差连接，将输入数据直接添加到后续层的输出中，从而使后续层的输出更丰富、更容易学习。这种连接方式允许信息在网络中直接跳过一个或多个层，使得梯度可以更快地传播。ResNet50 采用的特殊的残差块结构，其中包含了多个卷积层，并使用批量归一化和激活函数（通常是 ReLU 激活函数）进行非线性变换。每个残差块的内部有多个卷积层，以提取不同尺度的特征，并通过残差连接将输入数据与输出数据相加。




图 3-4 残差块结构图

此外, ResNet50 还引入了 1×1 的卷积层, 用来调整通道数, 以减少模型参数量和计算复杂度。在训练过程中, ResNet50 使用反向传播算法来对预测输出与真实标签之间的损失函数最小化, 以优化网络的权重参数。ResNet50 通过残差连接和深层网络结构, 有效地解决了梯度消失和梯度爆炸等问题, 使得更深层的网络可以更好地学习和表示图像特征, 从而在特征提取方面获得更优秀的能力。特征提取网络结构如表 3-2 所示。

表 3-2 ResNet50 网络结构

模块名称	输出特征图大小	模块结构
Conv1	112×112	$7 \times 7, 64, \text{stride } 2$
		$3 \times 3, \text{max pool, stride } 2$
Conv2_x	56×56	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
Conv3_x	28×28	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$
Conv4_x	14×14	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$
Conv5_x	7×7	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
全连接层	1×1	Average pool, 1000-d fc, softmax

3.2.2 特征编码与解码模块

本文采用一种基于 DETR 框架的用于单目检测的网络 MonoDETR 作为基准模型, 并针对其存在的问题进行优化改进研究工作。通过对原始的 DETR 编码与解码模块进行改造, 加快模型的收敛速度, 提高模型的检测精度。

MonoDETR 在使用视觉编码器去提取图像的特征外, 还引入了一种深度特征编码器去预测前景深度地图, 后续将其转化为深度编码信息。之后就和传统的 DETR 或者 BevFormer 一致, 使用 3D 查询向量去与前述生成的视觉编码和

深度编码分别做自注意力和交叉注意力，通过解码模块得到最终的 2D 以及 3D 结果。但是 MonoDETR 所采用的解码方式是可变形注意力机制，这种聚焦局部信息的编解码方式比原始的自注意力编解码方式具有更快的收敛速度，但其代价是算法检测性能下降。

改进后的算法结构主要由特征提取模块、视觉编码模块、深度编码模块以及解码模块组成，如图 3-5 所示。




图 3-5 SC-MonoDETR 网络结构

特征提取网络：为了便于与基准模型对比，本章算法的特征提取网络沿用残差网络 ResNet50。

编码模块：改进后的编码模块与基准模型所采用的编码方式不同，基准模型使用的可变形注意力更聚焦于对局部信息进行编码，改进后的编码模块采用多头自注意力对全局特征进行编码。每个编码模块层包含了使用位置编码的多头自注意力、前向反馈网络和归一化层。

解码模块：改进后的解码模块在原有共同注意力机制的基础上融合了空间查询先验，通过构建了空间自注意力机制，使得改进后的模型在训练时收敛更

快。同时，因为改进后的解码模块在带有全局信息的编码特征中进行解码，使模型提高了对全局特征的学习能力，从而提高模型对大尺度目标的检测精度。

查询向量（Object Queries）：查询向量表示检测器的输出。其中每个向量对应于一个目标，这些向量经由改进后解码器输出的解码向量与编码器的特征图相乘表示为待测目标的特征。

3.3 实验与分析

3.3.1 实验设置

（1）环境配置

本文实验的系统环境运行于 Windows 平台，使用的操作系统是 Windows11，本实验的算法模型全部基于 Pytorch 1.8 深度学习框架实现，使用 CUDA 11.8 与 CuDNN 进行加速训练。本节实验中所涉及到的算法均采用 Python 和 C++作为实现语言，在一张 12G 内存的 NVIDIA Geforce 3060 上进行训练和测试，具体相关配置如表 3-3 所示。

表 3-3 实验环境配置

配置名称	配置信息
操作系统	Windows11
内存	16G
CPU	Intel(R) Core(TM) i5-10600K CPU @ 4.10GHz
GPU	NVIDIA Geforce 3060 12G
GPU 加速	Cuda11.8
编译软件	PyCharm
编程语言	Python 3.9

（2）参数设置

本章实验的数据集划分方式采用三维目标检测领域相关工作通用划分方式，首先从 KITTI 包含标签的数据样本中划分出 3412 个样本，组成训练集合用于模型的学习训练。其次，在剩余的样本当中抽取 3769 个样本组成测试集合用于检验训练后模型的实际检测效果，同时在这个集合上与其它算法进行评测对

比。最后。将剩余 300 个样本组成验证集合，用于模型训练过程中的效果验证。训练过程的相关参数设置为：图像输入尺寸为 1280×387 ，Batch Size 设置为 16，采用 Adam 优化器进行模型参数的优化，Momentum 动量参数设置为 0.9，初始学习率设为 0.00125。


如图 3-6 所示，Easy、Mod.和 Hard 分别代表 KITTI 数据集中简单、中等和困难三种检测难度级别的场景，难度级别越高表示场景中存在更多的小尺寸目标，并且目标遮挡现象与截断现象更为严重。本实验将列出在这三种不同难度场景下的相关评价指标。



(a) 简单难度场景



(b) 中等难度场景



(c) 困难难度场景

图 3-6 三种难度场景图像

3.3.2 实验结果分析

本章对所提出 SC-MonoDETR 算法的检测精度通过对比实验进行算法性能验证,同时将所提出的算法与基于相同 DETR 结构的算法进行横向对比验证其性能和收敛速度。在三维目标检测领域,大多数相关工作在对其所提出的算法在 KITTI 数据集上进行对比评测时,都对车辆目标进行评测。参考三维目标检测领域通用的评测方法,本实验也将车辆目标在不同场景下的 AP_{3D} 得分作为主要的评价指标,其中 IOU 阈值设置为 0.7。

(1) 相关算法性能对比

本节实验首先将本章提出的 SC-MonoDETR 与基准网络 MonoDETR 进行对比,两者均采用 ResNet-50 作为特征提取网络。同时,将本章提出的 SC-MonoDETR 与其他基于单目视觉但采用不同先验知识的三维目标检测算法进行对比,比如依赖于先验深度信息的 DDMP-3D 和 D4LNCN;基于伪雷达点云信息的 CaDDN 和 MonoDTR 算法;还有不引入任何先验知识的 SMOKE、RTM3D、MonoFlex、MonoRCNN 以及 GUPNet 算法。

在上述算法中,大多数算法的通用评价方法是仅对车辆目标使用 AP_{3D} 指标进行评测,因此在此处遵循通用的评价方法,对车辆目标进行测试。本节实验在三种不同难度的场景下进行评测,IOU 阈值设置为 0.7,在测试集上推理预测并分别统计每种算法在不同难度级别场景下的 AP_{3D} 得分,相关实验结果如表 3-4 所示。

表 3-4 SC-MonoDETR 与相关算法在车辆检测上 AP_{3D} 指标对比

Method	Extra Data	Time	Car, AP_{3D} (IOU=0.7)		
			Easy	Mod.	Hard
DDMP-3D	Depth	0.18s	19.71	12.78	13.44
D4LNCN		0.20s	16.64	11.72	9.51
CaDDN	LiDAR	0.63s	19.17	13.41	11.46
MonoDTR		0.037s	21.69	15.41	12.73

续表 3-4 SC-MonoDETR 与相关算法在车辆检测上 AP_{3D} 指标对比

Method	Extra Data	Time	Car, AP_{3D} (IOU=0.7)		
			Easy	Mod.	Hard
SMOKE	None	0.34s	14.03	9.76	7.84
RTM3D		0.055s	14.41	10.34	8.77
MonoRCNN		0.07s	18.36	12.65	10.04
MonoFlex		0.036s	19.94	13.89	12.07
GUPNet		0.034s	22.26	15.02	13.12
MonoDETR		0.038s	25.00	16.38	13.58
SC-					
MonoDETR		0.037s	26.32	16.24	13.25
(ours)					

通过表 3-4 可以看出, 在使用相同特征提取网络 ResNet-50 的前提下, 本文改进后的 SC-MonoDETR 模型与其他不引入任何先验知识的模型以及预先引入深度信息与雷达信息的模型相比, 在简单、中等和困难三种场景中的精度指标有着明显优势。在 IOU 设置为 0.7 的情况下, SC-MonoDETR 与原始基准模型相比, 在模型运行时有所提升的同时也提升了模型的检测精度, 精度提升了 1.32%。证实了 SC-MonoDETR 在结合空间共同注意力的情况下, 通过在共同注意力机制中引入物体的高斯分布模型, 将每个物体查询向量在共同注意力机制中的查询区域限制在物体中心和预测边界框的附近区域, 在一定程度上缩短了模型的运行时间。此处从引入不同先验知识和不引入任何先验知识的算法中分别选出精度较高的算法与本章算法进行检测效果对比, 结果如图 3-7 所示。



(a) 真实标注



(b) DDMP-3D 算法检测结果



(c) MonoDTR 算法检测结果



(d) MonoDETR 检测结果



(e) SC-MonoDETR 检测结果（本章算法）

图 3-7 不同算法检测结果可视化

通过观察图 3-7 可以发现，基准算法与本章算法没有发生误检现象，并且检测出的目标数量高于其他算法。本章算法与基准算法相比，在检测距离镜头较近、像素占比较多的目标时表现更优。

(2) 模块有效性实验验证

为了验证空间共同注意力机制的有效性，此处实验采用相同特征提取网络 ResNet-50 作为骨干网络，以 MonoDETR 作为基准模型。将使用空间共同注意力的 SC-MonoDETR 与采用多头自注意力机制的基准模型以及引入可变形注意力机制的基准模型进行比对，以充分验证改进带来的效果提升，并且另外在批量大小设置为 1 的 RTX4090 上测试运行时间以及，其结果如表 3-5 所示。

表 1-1 空间共同注意力有效性验证

Method	MonoDETR (多头自注意力)	MonoDETR (可变形注意力)	MonoDETR (空间共同注意力)
Time	0.036s	0.038s	0.037s
GFlops	68.32	62.12	60.74
Epochs	230	193	142
AP _{3D} Mod.	15.98	16.38	16.24
AP _{3D} Easy	25.16	25.00	26.32

通过表 3-5 可以看出，在使用相同骨干网络 ResNet-50 并且只处理 1\16 和 1\32 下采样比率特征图的前提下，与原始基准模型以及改进可变形注意力机制的基准模型相比，引入空间共同注意力机制的 SC-MonoDETR 能够在不明显降

低小尺度目标检测精度的前提下，极大的提高收敛速度。与使用可变形注意力机制的基准模型相比，在一定程度上缩短了模型的运行时间，运行时间为 0.037s，同时在大尺度目标较多的简单场景中，检测精度的提升了 1.67%。由上表的实验结果可以分析出空间调制的共同注意力机制是有效的，通过在共同注意力机制中引入物体的高斯分布模型，将每个物体查询向量在共同注意力机制中的查询区域限制在物体中心和预测边界框的附近区域，加速 DETR 模型收敛。

（3） 算法性能比较

为了验证本章所提出的 SC-MonoDETR 算法性能，此处将 SC-MonoDETR 与表 3-6 中的现有算法进行对比实验。实验在批量大小设置为 1 的 RTX4090 上进行，实验中所对比的相关指标为算法在简单场景与中等难度场景中的运行时间与计算量，实验结果如表 3-6 所示。

表 1-4 SC-MonoDETR 算法效率对比

Method	GUPNet	MonoDLE	MonoDTR	SC-MonoDETR
Time	0.034s	0.040s	0.037s	0.037s
GFlops	62.32	79.12	120.48	60.74
AP _{3D} Mod.	15.02	12.26	15.39	16.24
AP _{3D} Easy	22.26	17.23	21.99	26.32

由表 3-6 可知，本章提出的算法与其他三维目标检测算法相比，在运行时间方面要比 GUPNet 慢 0.003s，但是在计算量和检测精度方面仍然具有显著优势，可以在不消耗太多计算资源的情况下取得更好的检测性能。这是因为 SC-MonoDETR 只处理 1\16 和 1\32 下采样比率的特征图，减少了运行时间和计算量，而其它方法采用 1\4 和 1\8 下采样比率的特征图。

同时，SC-MonoDETR 算法在进行特征编码时对全局信息进行编码，而在解码时通过引入空间查询先验权重让模型能够较快从全局特征编码信息中定位对检测目标有效的特征信息。在检测精度方面，由于空间共同注意力机制对全局进行编码，使得模型能够有效利用全局特征信息，对大尺度目标的检测能力显著提升。

3.4 本章小结

本章提出一种基于空间调制的共同注意力三维目标检测算法 SC-MonoDETR，该算法结构分为特征提取网络、注意力编码模块和注意力解码模块三个部分。通过在编码模块中对全局特征进行编码，在解码模块的共同注意力权重中融合待检测目标的高斯分布权重图，构建出空间调制的共同注意力，将每个目标的查询向量搜索范围调节至目标边界框周围，让模型能够快速从带有全局特征的编码向量中快速定位目标特征，有效提高了模型的三维目标检测精度与收敛速度。为了验证本章算法的性能，在 KITTI 数据集上将本章算法与其它单目三维目标检测模型进行对比评测，同时与基准模型进行对比评价。为了进一步说明改进的有效性，将 SC-MonoDETR 算法与同样使用 DETR 结构的算法进行横向对比。实验表明，相比于其它算法，本章提出的算法在精度方面表现优异，与基准算法相比训练轮次减少了 51 轮，同时检测精度提升了 1.32%，证实了本章算法的有效性。

第4章 基于多尺度特征融合三维目标检测算法

单目 3D 目标检测一直是自动驾驶领域的一项挑战性任务。现有的三维属性预测方法大多遵循传统的二维检测器，首先定位目标中心，然后通过邻域特征预测目标的三维属性。然而，仅利用局部视觉特征不足以理解场景级的 3D 空间结构，忽略了长程物体间的深度关系，并且由于道路状况的复杂性，在单目相机拍摄的 RGB 图像中目标会呈现出不同尺度和目标被遮挡的情况。

由于卷积神经网络中的每个卷积层的感受野大小固定的特性，导致在使用卷积神经网络在目标尺度多样的场景中进行检测时效果往往不理想。常规卷积层的卷积核大小是固定不变，每次只能在一定区域内提取特征，因此常规卷积层很难适应不同尺度和朝向的目标，并且无法有效在全局上下信息中建立联系。一旦训练过程中某个尺度的样本数量较多，则模型会逐渐偏向于学习该类目标特征，而忽略其他尺度目标。同时，由于缺乏深度信息，全局场景特征有助于预测目标三维属性。

为了解决上述对深度特征提取不足以及目标尺度多样性的问题，本章在第三章所提算法 SC-MonoDETR 的基础上做进一步改进优化工作。首先对深度特征提取模块进行改进，将卷积与注意力机制结合，增强了模型对深度特征的提取能力。此外，还设计了一种基于深度引导的多尺度特征融合三维目标检测算法。该算法利用编码器中交替进行层内和层间自注意力机制来实现不同尺度信息的交换，并使得模型能够从不同尺度的特征图中获取目标特征信息。这在一定程度上改善了传统算法在处理多尺度目标和遮挡目标时精确性不足的问题。本章将所提出的算法模型为 DSC-MonoDETR，通过对比试验和消融实验来验证各个改进部分的有效性。

4.1 算法整体框架

本章算法在编码器中引入了对多尺度特征的编码，通过层内和层间自注意力机制以及尺度选择注意力机制，空间调制的共同注意力可以高效地编码图像的多尺度信息，并在解码器中自适应地从来自不同尺度特征图的特征中选择合适尺度的特征信息，从而提高对多尺度目标的检测精度。

目标检测任务中, 由于不同目标的大小各异, 所以使用多尺度特征尤为重要。给定一幅图像, CNN 能够抽取不同尺度的特征, 如下采样 8, 16, 32 倍等。在进行多尺度特征编码时, 自注意力机制在不同尺度的所有特征像素之间传播和聚合信息。然而, 所有尺度的特征像素数量都非常大, 因此多尺度自注意力操作的计算成本很高。为解决该问题, 引入尺度内自注意力编码作为辅助算子来辅助多尺度自注意力编码。

首先从主干特征提取网络中获得下采样 8 倍、16 倍和 32 倍的三个不同尺度的特征图作为编码器的输入。然后在编码器中交替使用层内和层间的自注意力机制对不同尺度的特征分别进行编码, 对多层特征统一进行编码。在这一过程中尺度内注意力仅用于在每个尺度内的特征像素之间传播和聚合特征, 多尺度注意力的权重在不同尺度上共享, 增强了尺度内自注意力编码的泛化能力。在第三节的对比实验中, 本章所采用的多尺度融合共同注意力机制, 通过多尺度空间共同注意力与改进的深度特征提取模块结合, 有效提高了本章算法在目标遮挡和多尺度目标场景中的检测能力。本章算法的结构如图 4-4 所示。




图 4-4 多尺度特征融合的三维目标检测算法框架

4.2 深度特征提取模块的改进

4.2.1 深度特征提取模块结构

为了更好地学习深度信息，基准模型引入了一个轻量化的深度预测模块，这个模块并不需要引入额外的深度估计的监督，仅仅采用目标真实框的深度值作为目标的真实深度值。

对于输入的单张 2D 图片，首先从主干网络中提取到该图像对应的多尺度视觉特征，并将它们统一分辨率后进行逐元素的相加合并，基于此多尺度的视觉特征，使用两个 3×3 卷积层，来得到该图像的深度特征。通过监督前景深度图的生成，使得模型不依赖于额外的深度标注，仅仅使用物体级别的深度标签，来监督前景深度图的预测，并且可以将有效的深度信息嵌入图像对应的深度特征，使网络更关注于前景物体的几何深度关系。对于图像坐标系而言，由于三维真实框和二维真实框是一一对应的，并且三维真实框的 Z 值就是所要求得深度值。二维真实框在某一张图像具体的位置，在一张背景像素值均设为 0 的图像上对应得位置填充深度值 (Z) 就获得了目标深度监督值，不需要引入额外的深度估计的监督，例如由 LiDAR 点云投影得到的逐像素的深度。深度特征提取模块的结构如图 4-1 所示。




图 4-1 深度特征提取模块

为了将有效的深度信息纳入深度特征中，本章算法仍通过 1×1 卷积层对深度特征图顶部的前景深度图进行预测，并且只通过离散的对象深度标签来监督深度图，而不需要额外的密集深度标注。同一个 2D 边界框内的像素被赋予

对应对象的相同深度标签，对于多个框内的像素，选择距离相机最近的物体的深度标签，以符合图像的视觉外观。在这里，将深度离散化为 $k + 1$ bins 其中第一个有序的 k bins 表示前景深度，最后一个表示背景。采用线性递增离散化，因为更远的物体的较大深度估计误差可以用更大的分类间隔来抑制。将前景深度值限制在 $[d_{min}, d_{max}]$ 内，并将第一个间隔长度和线性递增离散化的共同差异设置为 δ 。然后，将 ground-truth 深度标签 d 划分到线性增长的 bin 中。

$$k = \left\lfloor -0.5 + 0.5 \sqrt{1 + \frac{8(d - d_{min})}{\delta}} \right\rfloor, \quad (4-1)$$

其中 $\delta = 2(d_{max} - d_{min}) \setminus k(k+1)$ 。通过关注对象深度值，该网络可以更好地捕捉前景空间结构和对象间深度关系，为后续的深度引导的注意力解码器产生信息量大的深度特征。

4.2.2 融合 ACmix 的深度特征提取模块

基准模型设计了轻量化的深度提取模块来完成对深度信息的监督和学习，但在提取深度特征时仅采用两个 3×3 的卷积块与 ResNet-50 网络结合完成，对深度特征的提取能力不足。本节采用将自注意力与卷积模块整合的 ACmix 模块与 ResNet-50 相结合，形成改进的深度特征提取模块，再缩小计算量的同时更好的提取深度信息。

在拆解开自注意力和卷积模块后，可以从不同层面深入探讨两个模块的更深层次的关联。首先，这两个模块在功能上表现出一定的相似性并它们都具有一个特征学习阶段，即第一阶段。在这一阶段中，两种方法均通过 1×1 卷积模块提升特征的维度，从而实现将特征进行更丰富的表达。其次，它们又都具有一个特征融合阶段，即第二阶段。尽管在这一阶段，自注意力和卷积模块的学习范式有所不同，但它们的目标都是对特征进行整合与提炼。

从计算量上看，这两个模块在第一阶段的 1×1 卷积操作中，都涉及到理论上的浮点运算次数 (FLOPs) 以及与通道大小 C 相关的参数的二次复杂度。这意味着在特征学习的初级阶段，两者在计算量上具有一定的相似性。然而进入第二阶段，这两个模块的计算负担则呈现出明显的差异。自注意力模块和卷积模块在第二阶段都表现得相对轻量级，几乎不增加的计算开销。轻量级自注意力与卷积结合的 Acmix 模块结构如图 4-2 所示。




图 4-2 卷积与自注意力操作融合模块

上述分析表明：卷积和自注意力在通过 1×1 卷积投影输入特征图时实际上共享相同的操作，这也是两个模块的计算开销；第二阶段的聚合操作虽然对捕获语义特征至关重要，但其操作是轻量级的，不会获得额外的学习参数。

第一阶段，对输入特征图进行 3 组 1×1 卷积投影。第二阶段，中间特征分别使用以下两种范式。将两种路径的特征进行融合作为最终输出，每个操作块的计算复杂度在上角标出。

上述观察自然会导致卷积和自注意力的优雅整合。由于两个模块共享相同的 1×1 卷积操作，因此我们只执行一次投影，并分别为不同的聚合操作复用这些中间特征图。卷积与自注意力操作整合模块包括两个阶段：第一阶段，卷积层路径，输入特征图分别输入 3 条支路，每条支路由一个 1×1 卷积构成，被分别映射为 N 块，得到一个包含 $3 \times N$ 个特征图的特征集合；第二阶段，自注意力路径，所有来自一阶段 1×1 的卷积块的中间特征集合被聚集成 N 组，每组包含 3 个特征图。按照传统的多头自注意力方式，将对应的 3 个特征图分别作为查询向量、键向量和值向量。

在第二阶段的卷积路径中，由一个轻量级的全连接层生成特征，一共 N 组，每组包含 k^2 个特征图，其中 k 为卷积核大小。这一设计使得模型能够平移和聚合这些生成的特征，以类似卷积的方式更加高效地处理输入特征。卷积路径能够像常规方法一样更加关注局部感受野内的特征，从中收集局部关键信息。通

过这种方式，不仅能够保持模型的计算效率，还能够确保对局部细节的准确捕捉，从而进一步提升模型的性能。最后，将来自两条不同路径的特征进行融合相加，每条路径的权重大小由一个可学习的参数控制：

$$F_{out} = \alpha F_{att} + \beta F_{conv} \quad (4-2)$$

改进后的深度特征提取模块结构如图 4-3 所示。




图 4-3 改进深度图预测模块

通过以上改进，避免了使用连续的 3×3 卷积学习深度特征而导致深度特征提取模块只能聚焦与局部的特征信息。改进后的深度特征提取模块能够更好的从融合特征图中获取深度信息，通过融合卷积与自注意力整合的机制，可以在保证模型计算开销不明显增加的同时，从信息更丰富的全局特征中学习所需要的深度特征。

4.3 基于多尺度特征融合三维目标检测模型结构

4.3.1 多尺度特征编码模块

在编码器中，多尺度的自注意力编码把不同尺度的所有位置的特征同等对待，导致计算很复杂、计算量大。为了解决这个问题，对多尺度的特征首先进行尺度内自注意力，也就是仅仅在单个尺度特征图内进行注意力操作，注意力编码模块共享这些权重，在第三节实验中也证实了这种编码机制有效减少了计算量，提高了模型各项性能。

给定编码后的多尺度特征 E_8 , E_{16} , E_{32} 的下采样率为 8, 16, 32，解码器执行共同注意的一种简单解决方案是首先重新缩放并连接多尺度特征以形成单尺度特征图，然后在对象查询和结果特征图之间进行共同注意。然而，在实际应

用中，一些查询向量可能只需要来自特定尺度的信息，并不总是来自所有尺度。例如，在低分辨率特征图 E_{32} 中，小尺度目标的信息是缺失的，因此负责小目标的对象查询应该更有效地从高分辨率特征图中获取信息。另一方面，传统方法，如特征金字塔网络，将每个边界框明确分配给特定尺度的特征图。与特征金字塔网络不同，本章算法对于编码器输出的三种不同尺度的特征，首先根据物体查询向量预测尺度选择的权重：

$$\alpha_8, \alpha_{16}, \alpha_{32} = \text{Softmax}(\text{FC}(O_q)) \quad (4-3)$$

其中 $\alpha_8, \alpha_{16}, \alpha_{32}$ 表示选择三种不同尺度特征图的重要性。进行共同关注对象查询和多尺度视觉特征 E_8, E_{16}, E_{32} ，首先得到多尺度键和值的特征 $K_{i,8}, K_{i,16}, K_{i,32}$ 和注意力头 i 的 $V_{i,8}, V_{i,16}, V_{i,32}$ ，分别由 E_8, E_{16}, E_{32} 进行单独的线性投影。空间调制的共同注意(4-5)采用尺度选择权值 $\alpha_8, \alpha_{16}, \alpha_{32}$ 进行自适应的加权和聚合：

$$C_{i,j} = \text{softmax} \left(\frac{K_{i,j}^T Q_i}{\sqrt{d}} + \log G_i \right) V_{i,j} \odot \alpha_j \quad (4-4)$$

$$C_i = \sum_{allj} C_{i,j} \quad \text{for } j \in \{8, 16, 32\} \quad (4-5)$$

其中 $C_{i,j}$ 表示的查询和视觉特征之间的第 i 个共同注意力头和第 j 个尺度特征的共同注意特征。 $C_{i,j}$ 按在公式(4-4)中获得的缩放注意力权重 α_j 尺度选择注意力机制，与尺度最相关的每个对象查询都通过 Softmax 进行选择。

4.3.2 深度特征引导的解码模块

对于目标的深度信息处理，本章算法对落在一个物体二维标注区域内的所有像素，均使其预测该同一物体的深度值。为了更好的编码深度信息，基准模型参考 CaDDN 的方法，对连续的深度值进行量化，并采用 LID 的方法，将深度值划分为线性增长的分类区间进行预测。

在得到输入图像的二维特征和深度特征后，基准算法设计了并行的两个编码器结构，视觉编码器和深度编码器，分别对两种特征进行全局编码。在编码器中，我们采用了基于自注意力的编码结构，来交互两种特征内的远距离语义信息。对于视觉编码器，算法堆叠了 3 层编码块来解析更加丰富的 RGB 表征信息，而对于深度编码器，只使用一层编码块来理解单通道的深度信息。通过并

行的设置，两种编码器可以互不干扰、各司其职，即分别专注于编码图像的二维表征视觉信息，以及三维的深度几何信息。在第三小节中，本章算法通过多尺度特征融合的思想对编码器结构进行了改进，使用层内注意力、跨尺度注意力交叉的方式对特征进行编码。

在经过二维视觉和深度特征的全局编码后，本章算法参考 DETR 将物体检测的候选定义为一组查询向量，并设计了深度引导的解码模块来引导每一个物体自适应的提取二维和深度的特征。编码器采用了 3 个注意力解码块结构，在每一个解码块中，本章算法使物体的查询向量依次经过深度交互注意力、查询向量间的自注意力、二维交互注意力。它们三者分别是为了交互物体与深度特征、物体间特征、物体与二维特征。通过将物体与深度特征的交互放在第一位，使得物体查询向量可以优先的整合全局的深度特征，并将该深度信息作为引导，帮助后续的特征提取。




图 4-4 多尺度空间调制的解码模块

对于非局部深度特征和视觉特征，利用一组可学习的对象查询 $q \in R^N \times C$ 通过深度引导的解码器来检测对象的三维信息，其中 N 表示输入图像中预定义的最大对象数量。每个解码器块依次包含一个深度交叉注意力层、一个查询间自注意力层、一个视觉交叉注意力层和一个前向传播。具体来说，查询首先通

过深度交叉注意力层从深度特征图捕获信息量丰富的深度特征，其中我们将对象查询和深度嵌入线性转换为查询、键和值：

$$Q_a = \text{Linear}(q), \quad K_D, V_D = \text{Linear}(f_D^e) \quad (4-6)$$

其中 $Q_a \in R^{N \times C}$ 和 $K_D, V_D \in R^{\frac{HW}{16^2} \times C}$ 。然后，计算查询深度注意力图 $A_D \in R^{\frac{HW}{16^2} \times C}$ ，并聚合由 A_D 加权的信息深度特征以产生深度感知查询 q' ，表示为：

$$A_D = \text{Softmax}(Q_a K_D^T / \sqrt{C}) \quad (4-7)$$

$$q' = \text{Linear}(A_D V_D) \quad (4-8)$$

这种机制使每个对象查询能够自适应地从图像上的深度引导区域捕获空间线索，从而实现对目标场景有更好的空间理解。然后，将深度感知的查询输入到查询间自注意力层以实现对象之间的特征交互，并输入到视觉交叉注意力层以视觉编码特征中收集视觉语义，堆叠三个解码器块，将场景中的深度线索完全融合到对象查询中。

4.4 实验与分析

4.4.1 实验设置

(1) 环境配置

本文实验的系统环境运行于 Windows 平台，使用的操作系统是 Windows11，本实验的算法模型全部基于 Pytorch1.8 深度学习框架实现，使用 CUDA11.8 与 CuDNN 进行加速训练。本章算法以及实验中所涉及算法的实现编程语言均为 Python 和 C++，具体相关配置如表 4-1 所示。

表 4-1 实验环境配置

配置名称	配置信息
操作系统	Windows11
内存	16G
CPU	Intel(R) Core(TM) i5-10600K CPU @ 4.10GHz
GPU	NVIDIA Geforce 4090 24G
GPU 加速	Cuda11.8
编译软件	PyCharm
编程语言	Python 3.9

(2) 参数设置

本章实验的数据集划分方式采用三维目标检测领域相关工作通用划分方式，首先从 KITTI 包含标签的数据样本中划分出 3412 个样本，组成训练集合用于模型的学习训练。其次，在剩余的样本当中抽取 3769 个样本组成测试集合用于检验训练后模型的实际检测效果，同时在这个集合上与其它算法进行评测对比。最后，使用 300 个样本组成验证集合对模型训练过程中的效果进行定期验证。训练过程的相关参数设置为：图像输入尺寸为 1280×387 ，Batch Size 设置为 16，采用 Adam 优化器进行模型参数的优化，Momentum 动量参数设置为 0.9，初始学习率设为 0.00125。

4.4.2 实验结果分析

(1) 相关方法对比

同上一章的工作相比，本章工作在 KITTI 标准集合的测试集上，对加入深度引导与多尺度特征融合的 DSC-MonoDETR 和其他单目视觉场景下的三维目标检测算法进行对比验证。对比的相关算法中，包括上一章提出的基于空间调制共同注意力的 SC-MonoDETR 模型、原始基准模型 MonoDETR、引入先验知识的模型以及未加入任何先验知识的单目三维目标检测算法。本节实验在多个场景下进行评测，IOU 阈值设置为 0.7，在测试集上推理预测并分别统计每种算法在不同难度级别场景下的 AP_{3D} 得分。遵循本领域大多数工作采用的测试方法，对车辆目标的三维目标检测性能进行对比评估，结果如表 4-2 所示。

表 4-2 SC-MonoDETR 与相关算法在车辆检测上 AP_{3D} 指标对比结果

Method	Extra	Time	Car, AP_{3D} (IOU=0.7)		
	Data		Easy	Mod.	Hard
DDMP-3D	Depth	0.18s	19.71	12.78	13.44
D4LNCN		0.20s	16.64	11.72	9.51
CaDDN	LiDAR	0.63s	19.17	13.41	11.46
MonoDTR		0.037s	21.69	15.41	12.73
SMOKE	None	0.34s	14.03	9.76	7.84

续表 4-2 SC-MonoDETR 与相关算法在车辆检测上 AP_{3D} 指标对比结果

Method	Extra	Time	Car, AP_{3D} (IOU=0.7)		
	Data		Easy	Mod.	Hard
RTM3D		0.055s	14.41	10.34	8.77
MonoRCNN		0.07s	18.36	12.65	10.04
MonoFlex		0.036s	19.94	13.89	12.07
GUPNet	None	0.034s	22.26	15.02	13.12
MonoDETR		0.038s	25.00	16.38	13.58
SC-MonoDETR		0.037s	26.32	16.24	13.25
DSC-MonoDETR		0.039s	27.25	17.32	13.86

通过表 4-2 中的数据可以看出, 改进了深度特征提取模块和多尺度特征融合的 DSC-MonoDETR 算法在多个指标上较 SC-MonoDETR 以及原始基准模型均有不同程度的提升, 比如在 IOU 阈值设置为 0.7 的中等难度级别场景 AP_{3D} 指标上, 相对于 MonoDETR 提升了 2.25%, 相比于 SC-MonoDETR 提升了 0.93%。并且, 改进深度特征提取模块并进行多尺度特征融合的 DSC-MonoDETR 算法与其他引入先验知识和不引入先验知识的单目三维目标检测算法相比, 在保证算法运行时间的基础上多个指标上均保持领先优势。

分析表 4-2 结果可得, 通过改进的深度特征提取模块、深度信息融合与多尺度特征融合方法, 提高了模型的深度特征提取能力、增强了模型从不同尺度特征图上获取所需特征的能力, 可以使得模型在目标查询时自适应的探索全局深度以及空间引导区域的目标线索, 并通过注意力机制进行物体间、物体与场景间的深度信息交互, 从而提高算法在复杂场景中进行三维检测的能力。

本章同时对比基准算法 MonoDETR、改进算法 SC-MonoDETR 与 DSC-MonoDETR 在行人目标上的三维检测效果以更好地说明本文所提出算法的有效性。本实验采用将 IOU 设置为 0.25 的 AP_{3D} 指标进行算法性能对比, 对比结果如图 4-5 所示。




图 4-5 DSC-DETR 在行人上的检测效果提升对比

分析图 4-5 的结果可以得出，在大尺度目标较多的简单场景上，通过融合空间调制的共同注意力机制可以提高算法的三位检测精度。随着进一步改进深度特征提取模块、融合多尺度特征融合机制，模型的深度特征提取能力与从不同尺度特征图获取所需特征的能力明显增加。算法能够在目标查询时自适应的探索全局深度和空间引导区域的目标线索，并通过注意力机制进行物体间、物体与场景间的深度信息交互，从而提高算法对不同尺度目标的三维检测能力。

(2) 改进的深度特征提取模块量化分析验证

改进的深度特征提取模块将融合卷积与自注意力的 ACmix 模块与 ResNet-50 网络结合，代替原有深度特征提取结构。为了验证深度特征提取模块的有效性，在保持第三章所提出的 SC-MonoDETR 算法其他结构不变的基础上，对其深度特征提取模块中分别融合自注意力层与 ACmix 层，与原始深度特征提取模块中连续两个卷积层结构进行对比试验。分别验证不同组合对检测结果的影响，结果如表 4-3 所示。

表 4-3 卷积与自注意力整合模块性能分析

Method	卷积层	自注意力	卷积与自注意力 整合模块
Time	0.037s	0.038s	0.038s
GFlops	62.12	72.32	62.48
AP _{3D} Mod.	16.24	16.62	16.63
AP _{3D} Easy	26.32	26.77	26.83

通过表 4-3 对比实验结果可以看出，加入自注意力机制可以有效增加模型的检测精度，但同时计算量也会显著增加。而卷积层与轻量级自注意力整合的 ACmix 模块，通过将卷积和自注意力在一阶段 1×1 卷积投影输入特征图时共享相同操作；第二阶段通过轻量级的全连接层进行特征聚合，减少了额外的学习参数。与使用完整的自注意力机制相比，改进后的特征提取模块在提高检测精度的同时极大压缩了计算量；同基准模型所采用的连续两个卷积层相比，计算量略微增加，运行时间增加 0.001s，但是在尺度目标较多和小尺度目标较多的场景中精度均获得提升。分析可得，将卷积与自注意力整合的方式有效提高了模型的检测精度与运行性能。

(3) 多尺度特征融合有效性验证

为了验证多尺度特征融合机制对提升三维目标检测效果的有效性，本实验将所涉及算法的主干特征提取网络设置为 ResNet-50，以单目视觉三维目标检测算法 SC-MonoDETR 作为基准模型，对比其在单一尺度与多尺度机制下的检测精度。将 Batch Size 数值设置为 8，IOU 阈值设置为 0.7，结果如表 4-4 所示。

表 4-4 多尺度特征融合有效性验证实验

实验 编号	Method	Times	GFlops	Car, AP _{3D} (IOU=0.7)		
				Easy	Mod.	Hard
1	MonoDETR	0.038s	62.12	25.00	16.38	13.58
2	SC-MonoDETR +单一尺度	0.037s	60.74	26.32	16.24	13.25
3	SC-MonoDETR +多尺度特征融合	0.038s	63.77	26.82	16.79	13.50

由于自然图像中的物体具有不同的尺寸，因此可以通过多尺度特征融合机制使模型进行尺度预测，自适应地从不同尺度的特征图上学习不同尺寸物体的特征。从表 4-4 中可以看出，结合了多尺度特征融合机制后的模型比基准模型 MonoDETR 在简单、中等中的检测精度均有所提升，分别提升了 1.82%、0.41%，在困难场景中的检测精度降低了 0.08%。与采用单一尺度的 SC-MonoDETR 相比，在三种不同难度场景中的检测精度均有提升。说明多尺度特征融合机制可以为单目视觉的三维目标检测任务带来增益。

(4) 算法有效性验证的消融实验

为了验证改进的深度特征提取模块和多尺度特征融合对三维目标检测的提升效果，在保证主干特征提取网络均使用 ResNet-50 的前提下，以单目视觉三维目标检测算法 SC-MonoDETR 作为基准模型。本实验验证不同改进模块组合的情况下对检测结果的影响，将 Batch Size 数值设置为 8，IOU 阈值设置为 0.7，结果如表 4-5 所示。


表 2-4 算法有效性验证的消融实验

实验 编号	Method	Times	GFlops	Car, AP _{3D} (IOU=0.7)		
				Easy	Mod.	Hard
1	基准模型	0.037s	60.74	26.32	16.24	13.25
2	+改进深度特征提取模块	0.038s	62.48	26.83	16.68	13.28
3	+多尺度特征融合	0.038s	63.77	26.82	16.79	13.50
4	+改进深度特征提取 +多尺度特征融合	0.039s	64.52	27.25	17.32	13.86


表 4-5 的消融实验结果展示了本章算法在 KITTI 数据集三维目标检测基准的查准率结果。在单目三维目标检测基准下，本章算法在轿车检测的三种难度场景的检测精度均达到最高值。在单独加入深度特征提取模块或多尺度特征融合机制时，对检测精度均有不同程度地提升；当同时加入深度特征提取模块和多尺度特征融合机制后，本章算法具有更高的全局深度信息提取和多尺度信息建模能力，在注意力编码与解码过程中更好的融合来在不同尺度的信息，显著提高了中等和困难场景下的检测精度。

(5) 检测结果可视化分析


此处对消融实验的结果进行可视化。对第三章所提算法 SC-MonoDETR 依次添加改进部分进行检测结果可视化，并将所有改进部分融合后的检测结果同样进行可视化，最后将每个实验的可视化检测结果与数据集的真实标注框进行对比，实验结果如图 4-6 所示。




(a) 真实标注结果




(b) 消融实验 1 检测结果 (SC-MonoDETR 算法)



(c) 消融实验 2 检测结果 (SC-MonoDETR+ 改进深度特征提取模块)



(d) 消融实验 3 检测结果 (+多尺度特征融合)



(e) 消融实验 4 检测结果 (DSC-MonoDETR 算法)

图 4-6 算法检测效果对比图

图 4-6 展示了本章算法的消融实验检测结果。由图 4-6 分析可知，加入空调调制的共同注意力机制后，网络模型能够检测到右边的车辆。在加入卷积与自注意力融合的深度特征提取模块后，模型能够检测到图像左侧的遮挡轿车；继续加入多尺度特征融合机制后，模型检测到了距离较远的小尺度表，模型检测能力显著增强。

4.5 本章小结

本章针对图像中存在不同尺度目标以及目标间遮挡严重导致难以检测的问题，在第三章提出的 SC-MonoDETR 算法基础上做进一步优化改进，提出了基于多尺度融合三维目标检测算法 DSC-MonoDETR。首先对深度特征提取模块进行改进，将注意力模块与卷积模块融合，提高模型对深度特征的提取能力，从而提高模型的精度；其次，对编码模块与解码模块进行改进，通过将不同尺度特征图在编码器中交替进行层内和层间的自注意力机制实现尺度信息的交换，从而让模型能够从不同尺度的特征图上获得目标特征信息，在一定程度上改善传统算法在对多尺度目标和遮挡目标进行三维检测精度不足的情况。最后，本章算法在通用的 KITTI 数据集作为测试数据，在测试集上对本章算法进行验证，将 DSC-MonoDETR 与其它三维目标检测算法进行对比评测，同时对改进点进行了消融实验，验证了深度引导的多尺度特征融合算法对于被遮挡目标和多尺度目标检测方面的有效性提升。实验结果表明，提出的 DSC-MonoDETR 在基准模型的基础上进一步提高了三维检测精度，与基准模型相比改进算法的检测精度提升了 2.25%。

第5章 总结与展望

5.1 本文研究总结

在自动驾驶等前沿领域，三维目标检测技术的重要性不言而喻。该技术能够凭借三维检测结果，实现对周围环境的精准感知，为路径规划和避障提供强有力的支持。相比基于激光雷达的检测算法，以成本更低更易于部署维护的单目摄像头进行三维检测面临的挑战则更为严峻。由于缺乏直接提取深度信息的能力，进行三维目标检测的难度和复杂性均显著增加。这一挑战也为相关研究领域提供了广阔的探索空间，促使我们不断寻求新的方法和技术，以进一步提升三维目标检测的性能和准确性。本文以单目三维目标检测算法 MonoDETR 为基础，对相关算法展开了深入的研究。具体的研究内容和成果如下：

（1）本文提出了基于空间调制的共同注意力三维目标检测算法 SC-MonoDETR，用以解决 MonoDETR 算法对全局特征学习能力较为不足并且收敛速度较慢的问题。通过在编码模块中对全局特征进行编码，在解码模块的共同注意力权重中融合待检测目标的高斯分布权重图，构建出空间调制的共同注意力，将每个目标的查询向量搜索范围调节至目标边界框周围，让模型在解码时能够快速从带有全局特征的编码向量中快速定位目标特征，减少与大量无关背景进行交互提高模型的三维目标检测精度与收敛速度。本章以自动驾驶领域通用的 KITTI 数据集作为测试数据，IOU 阈值设置为 0.7，将本章提出的 SC-MonoDETR 与其它单目三维目标检测模型进行对比评测，同时与基准模型进行对比评价。实验表明，相比与其它算法本章提出的算法在精度方面表现优异，与基准算法相比达到相同水平精度时训练轮次减少 51 轮，同时在大尺度目标的检测精度上提升了 1.32%。

（2）本文在第三章提出的 SC-MonoDETR 算法的基础上进一步优化改进。第一，通过卷积与注意力机制结合的思想重新设计了深度特征提取模块，提高模型对深度特征的提取能力，从而提高模型的精度；第二，结合多尺度特征融合，通过将不同尺度特征图在编码器中交替进行层内和层间的自注意力机制实现尺度信息的交换，从而让模型能够从不同尺度的特征图上获得目标特征信息，在一定程度上改善传统算法在对多尺度目标和遮挡目标进行三维检测精度不足

的情况。以通用的 KITTI 数据集作为测试数据，将改进后的算法与其它三维目标检测算法进行对比，验证了深度引导的多尺度特征融合算法对于遮挡和多尺度检测方面的有效性提升。实验结果表明，提出的 DSC-MonoDETR 与基准模型相比，在简单、中等和困难三种难度场景下的检测精度分别提高了 2.25%、1.08%和 0.58%。从检测效果可视化图像中可以看出，本文提出的算法有效检测出了距离较远的小尺度目标与遮挡目标，在一定程度上对遮挡和截断问题进行了改善。

5.2 未来展望

展望未来，本领域仍具有研究空间，如何进一步提升模型从二维图像中获取深度信息的能力以及如何构建以较低计算量实现高检测精度的模型仍是该研究方向的重点问题。基于本文和本领域最新的研究成果展望下一步工作，可以进一步研究轻量化的深度特征提取方法和深度信息编解码模块，将深度信息更好的与成熟的视觉信息结合，从而更有效利地用深度信息，进一步提高检测精度。

参考文献

- [1] 张新钰, 高洪波, 赵建辉, 周沫. 基于深度学习的自动驾驶技术综述[J]. 清华大学学报(自然科学版), 2018, 58(04): 438-444.
- [2] Zou Z, Shi Z, Guo Y, et al. Object detection in 20 years: A survey[J]. arXiv preprint arXiv:1905.05055, 2019.
- [3] Huang Y, Chen Y. Survey of State-of-Art Autonomous Driving Technologies with Deep Learning[C]. 2020 IEEE 20th International Conference on Software Quality, Reliability and Security Companion (QRS-C). IEEE, 2020.
- [4] Olson F, Huttenlocher D P. Automatic object recognition by matching oriented edge pixels[J]. IEEE Transactions on Image Processing, 1997, 6(1): 103-113.
- [5] Shi W, Ragunathan, Rajkumar. Point-GNN: Graph Neural Network for 3D Object Detection in a Point Cloud[J]. IEEE, 2020.
- [6] Yang B, Luo W, Urtasun R. PIXOR: Real-time 3D Object Detection from Point Clouds[J]. IEEE, 2019.
- [7] Krizhevsky A, Sutskever I, Hinton G. ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in Neural Information Processing Systems, 2012, 25: 1097-1105.
- [8] Girshick R. Fast r-cnn[C]. Proceedings of the IEEE International Conference on Computer Vision. 2015: 1440-1448.
- [9] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[C]. Advances in Neural Information Processing Systems. 2015: 91-99.
- [10] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [11] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]. Proceedings of the IEEE Conference.
- [12] Zhou X, Wang D, Krahenbuhl P. Object as points[J]. arXiv preprint arXiv: 1904.07850, 2019.

- [13] Chen X, Kundu K, Zhu Y, et al. 3d object proposals using stereo imagery for accurate object class detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(5): 1259-1272.
- [14] Chen X, Kundu K, Zhu Y, et al. 3d object proposals using stereo imagery for accurate object class detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(5): 1259-1272.
- [15] Chabot F, Chaouch M, Rabarisoa J, et al. Deep manta: A coarse-to-fine many-task network for joint 2d and 3d vehicle analysis from monocular image[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2040-2049.
- [16] He T, Soatto S. Mono3d++: Monocular 3d vehicle detection with two-scale 3d hypotheses and task priors[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 8409-8416.
- [17] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]. Proceedings of the IEEE International Conference on Computer Vision. 2017: 764-773.
- [18] Brazil G, Liu X. M3D-RPN: Monocular 3D Region Proposal Network for Object Detection[J]. IEEE, 2019.
- [19] Qi C, Su H, Mo K, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 652-660.
- [20] Wang Y, Chao W L, Garg D, et al. Pseudo-lidar from visual depth estimation: Bridging the gap in 3d object detection for autonomous driving[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 8445-8453.
- [21] Ku J, Pon A D, Waslander S L. Monocular 3d object detection leveraging accurate proposals and shape reconstruction[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 11867-11876.
- [22] Ma X, Wang Z, Li H, et al. Accurate monocular 3d object detection via color-embedded 3d reconstruction for autonomous driving[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6851-6860.
- [23] Zhang Y, Lu J, Zhou J. Objects are Different: Flexible Monocular 3D Object Detection

- ction[J]. 2021.
- [24] Barabanau I, Artemov A, Burnaev E, et al. Monocular 3d object detection via geometric reasoning on keypoints[J]. arXiv preprint arXiv:1905.05618, 2019.
- [25] Brazil G, Liu X. M3d-rpn: Monocular 3d region proposal network for object detection[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9287-9296.
- [26] Qin Z, Wang J, Lu Y. MonoGRNet: A Geometric Reasoning Network for Monocular 3D Object Localization[C]. 2019: 8851-8858.
- [27] Liu Z, Wu Z, Tóth R. Smoke: single-stage monocular 3d object detection via key point estimation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020: 996-997.
- [28] Li P, Zhao H, Liu P, et al. RTM3D: Real-time monocular 3D detection from object keypoints for autonomous driving[J]. arXiv preprint arXiv:2001.03343, 2020, 2.
- [29] Mousavian A, Anguelov D, Flynn J, et al. 3d bounding box estimation using deep learning and geometry[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 7074-7082.
- [30] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Computer Vision & Pattern Recognition. IEEE, 2016.
- [31] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.
- [32] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[J]. arXiv e-prints, 2018.
- [33] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. arXiv e-prints. arXiv, 2022.
- [34] Zhu X, Su W, Lu L, et al. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C]. International Conference on Learning Representations. 2021.
- [35] Abhijit Kundu. 3D-RCNN: Instance-Level 3D Object Reconstruction via Render-and-Compare[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition.IEEE, 2018.

- [36] Arsalan Mousavian, Dragomir Anguelov, John Flynn, and Jana Kosecka. 3d bounding box estimation using deep learning and geometry. In IEEE Conference on Computer Vision and Pattern Recognition, 2017.
- [37] Lowe D G. Distinctive Image Features from Scale-Invariant Key points[J]. International Journal of Computer Vision, 2004, 60(2):91-110.
- [38] Roddick T, Kendall A, Cipolla R. Orthographic Feature Transform for Monocular 3D Object Detection[J]. 2018.
- [39] Lewis M, Liu Y, Goyal N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]. Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2020.
- [40] Xia Z, Pan X, Song S, et al. Vision Transformer with Deformable Attention[J]. 2022.
- [41] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. 2020.
- [42] Meng D, Chen X, Fan Z, et al. Conditional DETR for Fast Training Convergence [J]. 2021.
- [43] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. 2021.
- [44] Liu S, Li F, Zhang H, et al. DAB-DETR: Dynamic Anchor Boxes are Better Queries for DETR[J]. 2022.
- [45] Yao Z, Ai J, Li B, et al. Efficient DETR: Improving End-to-End Object Detector with Dense Prior[J]. 2021.
- [46] Geiger A, Lenz P, Urtasun R. Are we ready for autonomous driving? The KITTI vision benchmark suite[C]. IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2012.
- [47] Geiger A, Lenz P, Stiller C, et al. Vision meets robotics: The KITTI dataset[J]. International Journal of Robotics Research, 2013, 32(11): 1231-1237.
- [48] Huang Y, Chen Y. Autonomous driving with deep learning: a survey of State-of-Art technologies[J]. arXiv preprint arXiv: 2006.06091, 2020.
- [49] Dalal N. Histograms of oriented gradients for human detection[J]. Proc of Cvpr, 2005.

- [50] Uijlings R, Van De Sande A, Gevers T, et al. Selective search for object recognition[J]. International Journal of Computer Vision, 2013, 104(2): 154-171.
- [51] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. arXiv preprint arXiv: 1706.03762, 2017.
- [52] Zhang R, Qiu H, Wang T, et al. MonoDETR: Depth-aware Transformer for Monocular 3D Object Detection[J]. 2022.
- [53] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. IEEE Conference on Computer Vision and Pattern Recognition.IEEE, 2016.